



ARISTOTLE
UNIVERSITY
OF THESSALONIKI

Department of Electrical
and Computer Engineering

Τμήμα Ηλεκτρολόγων Μηχανικών
και Μηχανικών Υπολογιστών

Thesis - Διπλωματική Εργασία

“Talking Heads”: Phoneme Prediction from Muted Video

“Talking Heads”: Πρόβλεψη Φωνημάτων από Βουβό Βίντεο

Όνομα	Βαπόρης Δημήτριος
A.E.M.	10625
Email	dvaporis@ece.auth.gr
Επιβλέπων Καθηγητής	Ντελόπουλος Αναστάσιος

Καλοκαίρι 2026

Περιεχόμενα

Περιεχόμενα	1
1 Περιλήψεις	2
1.1 Summary in English	2
1.2 Περίληψη στα Ελληνικά	2
2 Εισαγωγή	3
2.1 Ορισμός του Προβλήματος	3
2.2 Διαθέσιμες Μέθοδοι	3
2.3 Περιγραφή της Συγκεκριμένης Εργασίας	3
2.4 Δομή της Συγκεκριμένης Αναφοράς	3
3 Τεχνικό Υπόβαθρο	4
3.1 Φωνήματα και Visemes	4
3.2 Έννοιες Μηχανικής Μάθησης	5
3.3 Άλλες Χρήσιμες Έννοιες	7
4 State of the Art	10
5 Μεθοδολογία	11
5.1 Προεπεξεργασία Δεδομένων	11
5.1.1 Εξαγωγή της περιοχής των χειλιών	11
5.1.2 Εξαγωγή φωνημάτων για κάθε frame	13
5.1.3 Data Augmentation	14
5.2 Δομή του προτεινόμενου μοντέλου	15
5.3 Βήματα Post-Processing	20
5.3.1 Αλγοριθμική Πρόβλεψη Λέξεων	20
6 Αξιολόγηση της Μεθοδολογίας	23
6.1 Datasets	23
6.2 Κριτήρια Αξιολόγησης	23
6.3 Πειράματα	24
6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον	24
6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον	32
6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων	32
7 Συμπεράσματα και Μελλοντικές Επεκτάσεις	41
8 Αναφορές	42

1 Περιλήψεις

1.1 Summary in English

Summary in English.

1.2 Περίληψη στα Ελληνικά

Περίληψη στα Ελληνικά.

2 Εισαγωγή

2.1 Ορισμός του Προβλήματος

What is the problem this work aims to solve? Why is it important? What may be some applications?

2.2 Διαθέσιμες Μέθοδοι

Briefly describe the methods that have been shown to (partially) solve this problem (or subproblems that may exist). Mention Section 3 (State of the Art) for more info.

2.3 Περιγραφή της Συγκεκριμένης Εργασίας

What did I do for this thesis? How did I attempt to solve the problem? About one page.

2.4 Δομή της Συγκεκριμένης Αναφοράς

Describe the structure of this report in about half a page.

3 Τεχνικό Υπόβαθρο

Στο κεφάλαιο αυτό, θα χτιστεί το τεχνικό υπόβαθρο που χρειάζεται για την κατανόηση της εργασίας. Συμπεριλαμβάνονται λεπτομέρειες τόσο για έννοιες μηχανικής μάθησης όσο και για βασικές ιδέες της γλωσσολογίας.

3.1 Φωνήματα και Visemes

Τα φωνήματα αποτελούν το βασικό αντικείμενο μελέτης της συγκεκριμένης εργασίας. Ένα φώνημα ορίζεται ως ένα σύνολο παρόμοιων ήχων ομιλίας το οποίο γίνεται αντιληπτό από ομιλητές μίας γλώσσας ως ένας βασικός ήχος, πρόκειται δηλαδή για τη μικρότερη πιθανή μονάδα φωνής. Συμβολίζονται συνήθως ως ένας χαρακτήρας εντός δύο forward slash. Για παράδειγμα, το φώνημα /b/ εκπροσωπεί τον ήχο στην αρχή της αγγλικής λέξης bat. Κάθε ομιλούμενη γλώσσα αξιοποιεί τα φωνήματα σε διαφορετικό βαθμό, ενώ ίδια γράμματα ή φθόγγοι μπορεί σε διαφορετικές γλώσσες να προφέρονται τελείως διαφορετικά. Τα προβλήματα αυτά προσπαθεί να λύσει το International Phonetic Alphabet (IPA), το οποίο είναι ένα “αλφάβητο” από φωνήματα βασισμένο κυρίως στους λατινικούς χαρακτήρες και ομοιόμορφο για κάθε γλώσσα. Να σημειωθεί ότι το πλήρες IPA είναι υπερβολικά περίπλοκο για την ανάλυση που ακολουθεί, καθώς αρκετά φωνήματα συναντώνται πολύ σπάνια (ή καθόλου) στην αγγλική γλώσσα που μελετάται καθ’ όλη τη διάρκεια της εργασίας.

Όντας η ελάχιστη μονάδα ομιλίας, τα φωνήματα έχουν αποτελέσει το αντικείμενο ποικίλων γλωσσολογικών μελετών, πολλές από τις οποίες αφορούν το “διάβασμα χειλιών” (lip reading) ή, αλλιώς, την κατανόηση ομιλίας χρησιμοποιώντας αποκλειστικά οπτικά (και όχι ακουστικά) μέσα. Από τις μελέτες αυτές έχει δημιουργηθεί το πρόβλημα των “visemes”, τα οποία αποτελούν το σύνολο ήχων ομιλίας με πανομοιότυπη όψη στα χείλια (ή γενικότερα στο πρόσωπο). Να σημειωθεί ότι τα σύνολα αυτά δεν περιορίζονται σε μοναδικά φωνήματα: για παράδειγμα, οι φράσεις “elephant juice” και “i love you” αποτελούν ένα χιουμοριστικό αλλά έγκυρο παράδειγμα viseme. Στα πλαίσια της συγκεκριμένης μελέτης, στο εξής ως visemes θα αναφέρονται τα φωνήματα κατά την έκφραση των οποίων η όψη του ομιλητή είναι όμοια. Για παράδειγμα, τα φωνήματα /m/, /b/ και /p/ αποτελούν ένα παράδειγμα viseme. Τα visemes προσφέρουν πληροφορία για την τοποθεσία του στόματος στην οποία παράγεται ο ήχος, αλλά όχι για τον τρόπο με τον οποίο παράγεται ο ήχος, το οποίο απαιτεί ακουστικά στοιχεία.

Πέραν της ομαδοποίησης τους μέσω των visemes, τα φωνήματα μπορούν να ομαδοποιηθούν και με βάση 3 ακόμα χαρακτηριστικά: τον τόπο, τον τρόπο εκφοράς τους και το αν είναι έμφωνα ή όχι. Για να παρουσιαστούν με μεγαλύτερη ακρίβεια τα παραπάνω, συμπεριλαμβάνεται το επίσης chart φωνημάτων του IPA. Αγνοώντας τις υπερβολικές λεπτομέρειες στο Σχήμα 1 και εστιάζοντας την προσοχή στον πρώτο πίνακα με τίτλο CONSONANTS (PULMONIC) και στον αμέσως κάτω δεξιά χάρτη με τίτλο VOWELS, μπορούν να εξαχθούν τα παρακάτω συμπεράσματα.

Παρατηρούμε ότι τα σύμφωνα χωρίζονται σε 11 κατηγορίες όσον αφορά τον τόπο εκφοράς τους: τα δειχικά (bilabial, παράγονται χρησιμοποιώντας τα 2 χείλη), τα χειλοδοντικά (labiodental, παράγονται με τη συμμετοχή χειλιών και δοντιών), τα οδοντικά (dental, με τα δόντια), τα φατνιακά (alveolar, παράγονται με τη γλώσσα να ακουμπά ή να πλησιάζει τη φατνιακή ακρολοφία), τα μεταφατνιακά (postalveolar, παράγονται με τη γλώσσα να τοποθετείται πίσω από τη φατνιακή ακρολοφία), τα ανακεκαμμένα (retroflex, παράγονται από την άκρη της γλώσσας όταν κάμπτεται προς τα πίσω προς τον ουρανίσκο), τα ουρανικά (palatals, παράγονται υψώνοντας το κυρίως τμήμα της γλώσσας στον σκληρό ουρανίσκο), τα υπερωικά (velar, όταν το πίσω μέρος της γλώσσας αγγίζει ή πλησιάζει τον μαλακό ουρανίσκο), τα σταφυλικά (uvular, με το πίσω μέρος της γλώσσας να αγγίζει ή να πλησιάζει τη σταφυλή), τα φαρυγγικά (pharyngeal, παράγονται περιορίζοντας τον φάρυγγα) και τέλος τα γλωττιδικά (glottal, χρησιμοποιώντας τη γλωττίδα). Το χαρακτηριστικό αυτό είναι που επηρεάζει κατά κύριο λόγο τα visemes, καθώς ο τρόπος με τον οποίον παράγεται ένα φώνημα και το αν είναι έμφωνο ή όχι πολλές φορές γίνεται κρυφό λόγω της μορφολογίας των χειλιών, που επηρεάζεται προφανώς από τον τόπο εκφοράς του φωνήματος.

Πέραν του τόπου εκφοράς, τα σύμφωνα διαχωρίζονται στον πίνακα με βάση τον τρόπο εκφοράς τους ως εξής: τα έκκροτα/κλειστά σύμφωνα (plosive, παράγονται όταν διακόπτεται τελείως η ροή του αέρα

και απελευθερώνεται ξαφνικά), τα ρινικά (nasal, επιτρέπουν στον αέρα να διαφύγει μέσω της ρινικής κοιλότητας και όχι του στόματος), τα μέσω τρίλιας (trill, παράγονται μέσω γρήγορης δόνησης λόγω της ροής αέρα), τα παλμού/κτύπου (tap/flip, όταν η γλώσσα ακουμπάει στιγμιαία ένα σημείο του στόματος), τα τριβόμενα (fricative, όταν ο αέρας περνάει από στενή δίοδο δημιουργώντας τριβή), τα πλευρικά τριβόμενα (lateral fricative, όπου ο αέρας παράγει τριβή καθώς περνάει από τα πλάγια της γλώσσας), τα προσεγγιστικά (approximant, όπου δύο αρθρωτές πλησιάζουν χωρίς να παράγουν τυρβώδη ροή αέρα ή ολικό κλείσιμο), και τα πλευρικά προσεγγιστικά (lateral approximant, μπλοκάροντας το κέντρο της στοματικής κοιλότητας στην περιοχή του αρθρωτή και επιτρέποντας τη ροή του αέρα από τα πλάγια). Πειραματιζόμενοι με τα παραπάνω μπορούμε να συνειδητοποιήσουμε πώς παράγονται τα φωνήματα που χρησιμοποιούμε, όπως και να αρθρώσουμε φωνήματα που ίσως δεν έχουμε συνηθίσει (π.χ. στα ελληνικά δεν υπάρχει πλευρικό τριβόμενο φώνημα, αλλά σε γλώσσες όπως τα σουαλικά υπάρχει).

Τέλος, ο χαρακτηρισμός έμφωνο ή άφωνο φαίνεται από τη θέση των συμφώνων στο εκάστοτε κελί. Αυτά που είναι τοποθετημένα προς τα δεξιά είναι έμφωνα, ενώ αυτά προς τα αριστερά είναι άφωνα. Τα φωνήεντα, από την άλλη είναι όλα έμφωνα και διαχωρίζονται με βάση το ύψος της γλώσσας (στον κατακόρυφο άξονα), την προώθησή της (στον οριζόντιο άξονα) και το αν τα χείλη είναι στρογγυλεμένα (rounded) ή όχι. Όσον αφορά το ύψος, οι κατηγορίες είναι close, close-mid, open-mid και open, ενώ στον οριζόντιο άξονα οι πιθανές επιλογές είναι front, central και back. Όπου στον χάρτη εμφανίζονται δύο φωνήματα, το δεξιότερο παράγεται με στρογγυλεμένα χείλη.

Με γνώση των παραπάνων και αντίστοιχη προσαρμογή στις ανάγκες της εκάστοτε γλώσσας ή, στην περίπτωση περιορισμένου περιβάλλοντος, στις ιδιαιτερότητες του λεξιλογίου, τα φωνήματα μπορούν να ομαδοποιηθούν με τους παραπάνω κανόνες. Έτσι, σε πλαίσια lip reading, είναι δυνατόν να χτιστούν μέθοδοι εφαρμογής διαφορετικής ποιικής με βάση την ομοιότητα των φωνημάτων (είτε σε επίπεδο visemes είτε σε επίπεδο χαρακτηριστικών, όπως παρουσιάστηκε) ή και μέθοδοι πρόβλεψης λέξεων που να συνυπολογίζουν την ομοιότητα φωνημάτων κατά την αντικατάστασή τους (για περισσότερα βλ. παράγραφο 5.1.2).

3.2 Έννοιες Μηχανικής Μάθησης

Στην ενότητα αυτή ορίζονται οι διάφορες έννοιες της μηχανικής μάθησης και της βαθιάς μάθησης που χρησιμοποιούνται παρακάτω. Ταυτόχρονα, αναπτύσσεται ο συμβολισμός που τηρείται στο υπόλοιπο μέρος της εργασίας.

Positional Encoding Στη βαθιά μάθηση, η σειρά των tokens έχει σημαντική επίδραση στην κατανόηση του συνολικού περιεχομένου. Το κλασικό παράδειγμα “Allen walks dog” και “dog walks Allen” αποδεικνύει τον παραπάνω ισχυρισμό: οι δύο φράσεις έχουν πολύ διαφορετική σημασία, παρά το γεγονός ότι παράγονται από τις ίδιες λέξεις (τα tokens σε αυτήν την περίπτωση). Μοντέλα όπως τα επαναλαμβανόμενα νευρωνικά δίκτυα (RNNs) ή τα μοντέλα μακροπρόθεσμης και βραχυπρόθεσμης μνήμης (long-short term memory, LSTM) διαθέτουν μηχανισμούς που αντιλαμβάνονται και αξιοποιούν τη σειρά των tokens. Αντιθέτως, αρχιτεκτονικές που βασίζονται στους transformers επεξεργάζονται τα tokens εν παραλλήλω και άρα δε διατηρούν πληροφορία για τη σειρά των tokens.

Ο τρόπος με τον οποίον επιλύεται το πρόβλημα αυτό είναι χρησιμοποιώντας Positional Encoding που προσθέτει πληροφορία για την σειρά των tokens στο embedding τους, συγκεκριμένα μέσω Sinusoidal Encoding. Στην εργασία αυτή χρησιμοποιείται το sinusoidal encoding όπως παρουσιάζεται στο [5], που υπολογίζεται ως εξής:

$$PE_{pos,2i} = \sin(pos/n^{2i/d_{model}})$$

$$PE_{pos,2i+1} = \cos(pos/n^{2i/d_{model}})$$

όπου PE είναι η συνάρτηση positional encoding, pos είναι η θέση του token, i είναι η συγκεκριμένη διάσταση, n ένας μεγάλος επιλεγμένος αριθμός (τυπικά 10000) και d_{model} η διάσταση του μοντέλου. Προσθέτοντας (ή σε κάποιες περιπτώσεις συνενώνοντας) τους όρους που παράγονται με αυτόν τον

κανόνα με τα embeddings των tokens, δίνεται στο μοντέλο η έξτρα πληροφορία της τοποθεσίας του κάθε token.

Συνάρτηση Κόστους Cross-Entropy Η συνάρτηση κόστους cross-entropy αποτελεί το τυπικό objective εκπαίδευσης, όταν είναι επιθυμητό ένας ταξινομητής να προσεγγίζει μία στοχευμένη κατανομή. Στη θεωρία πληροφορίας, η cross-entropy μεταξύ δύο κατανομών πιθανότητας p και q , στο ίδιο set γεγονότων, αποτυπώνει τον αριθμό των bits που χρειάζονται για να κατηγοριοποιήσουν ένα γεγονός επιλεγμένο από το set όταν η κωδικοποίηση είναι βέλτιστη για την εκτιμώμενη κατανομή πιθανότητας q και όχι την πραγματική p . Υπολογίζεται από τον τύπο:

$$H(p, q) = - \sum_i p_i \cdot \log(q_i)$$

όπου p_i και q_i είναι οι πιθανότητες που αποδίδονται από τις δύο κατανομές για το i -οστό γεγονός. Σε περίπτωση που η πραγματική κατανομή p έχει τιμή 1 για μία κλάση και τιμή 0 σε οποιαδήποτε άλλη περίπτωση (αντίστοιχα, σε περίπτωση που τα targets σε ένα πρόβλημα ταξινόμησης ακολουθούν τη σύμβαση one-hot encoding), τότε ο τύπος γίνεται $H(p, q) = -\log(q_i)$, δηλαδή η γνωστή αρνητική λογαριθμική πιθανοφάνεια (negative log-likelihood). Στο πρόβλημα του lip reading, για λόγους που γίνονται κατανοητοί παρακάτω, κρίνεται χρήσιμο οι στόχοι να μην είναι απόλυτοι (hard), δηλαδή με πιθανότητα 1 στη σωστή κλάση και 0 αλλού, αλλά εξομαλυσμένοι (soft).

Η πρακτική αυτή, κατά την οποία ένα ποσοστό της μάζας πιθανότητας αναδιανέμεται σε άλλες κλάσεις πέραν της σωστής, ονομάζεται label smoothing (εξομάλυνση ετικετών) και έχει ως στόχο να αποτρέψει την υπερβολική αυτοπεποίθηση του μοντέλου και άρα να βελτιώσει τη γενίκευση αυτού. Στη μελέτη αυτή, όπως φαίνεται στην παράγραφο 5.1.2, η εξομάλυνση αυτή δεν είναι ομοιόμορφη για όλες τις λανθασμένες κλάσεις αλλά βασίζεται στην ομοιότητα που παρουσιάζουν τα φωνήματα, τόσο οπτικά μέσω των visemes όσο και από το τελικό ηχητικό τους αποτέλεσμα (μέσω των τρόπων, τόπων παραγωγής τους και το αν είναι έμφωνα ή όχι).

Η εφαρμογή της cross-entropy loss στη μελέτη αυτή επιφέρει την ανάγκη δημιουργίας ορθών targets για κάθε frame ενός δεδομένου βίντεο. Επομένως, τα δεδομένα πρέπει να προεπεξεργαστούν καταλλήλως ώστε να αντιστοιχισθεί κάθε frame με το φώνημα που εκφέρεται (ή τη σιγή). Πρόκειται για την παλαιότερη και πιο άμεση πρακτική για την εξαγωγή ετικετών της αλληλουχίας, η οποία χρησιμοποιείται από το [3] και επιτρέπει την επιβλεπόμενη μάθηση σε επίπεδο frame.

Συνάρτηση κόστους CTC Για να μην απαιτείται η παραπάνω δημιουργία targets σε επίπεδο frames, εισήχθη από το [2] η συνάρτηση κόστους CTC (Connectionist Temporal Classification). Η συνάρτηση αυτή δεν απαιτεί label για κάθε frame, αλλά απλά μία αλληλουχία φωνημάτων χωρίς segmentation, εκπαιδεύοντας το μοντέλο να αναθέτει υψηλή πιθανότητα στην αλληλουχία αυτή υπό ενός κανόνα “κατάρρευσης” (collapsing rule). Προστίθεται το σύμβολο του κενού και κάθε αλληλουχία σε επίπεδο frame που

- μετά την αφαίρεση των κενών συμβόλων και
- μετά την κατάρρευση διαδοχικών ίδιων συμβόλων σε ένα

οδηγεί στην αρχική αλληλουχία, θεωρείται σωστή. Έτσι, πολλές διαφορετικές αλληλουχίες φωνημάτων τελικά θεωρούνται σωστές, με αποτέλεσμα η ακριβής πρόβλεψη του χρονισμού του κάθε φωνήματος να απαιτεί πολλά περισσότερα δεδομένα (όπως φαίνεται από την επίδοση του V4 στο 6.3.1).

Πιο συγκεκριμένα, έστω μία πιθανή ακολουθία με μήκος T που προβλέπει το μοντέλο $\pi = (\pi_1, \pi_2, \dots, \pi_T)$, που ονομάζεται μονοπάτι (path). Η συνάρτηση κατάρρευσης $B(\pi)$ εκτελεί τη λειτουργία που αναφέρθηκε παραπάνω και υπολογίζει από το αρχικό μονοπάτι το collapsed sequence. Υποθέτοντας ανεξαρτησία μεταξύ των χρονικών βημάτων, η πιθανότητα ενός path δεδομένης της ακολουθίας εισόδου X υπολογίζεται ως $P(\pi|X) = \prod_{t=1}^T y_t^{\pi_t}$, όπου $y_t^{\pi_t}$ είναι η πιθανότητα που έδωσε το δίκτυο για το σύμβολο π_t στο frame t .

Όπως αναφέρθηκε προηγουμένως, η ίδια τελική ακολουθία μπορεί να παραχθεί από πολλά διαφορετικά αρχικά alignments. Άρα, η πιθανότητα της τελικής ακολουθίας Y ορίζεται ως

$$P(Y|X) = \sum_{\pi \in B^{-1}(Y)} P(\pi|X)$$

και η αντικειμενική συνάρτηση υπολογίζεται ως

$$L_{CTC} = -\log(P(Y|X)) = -\log\left(\sum_{\pi \in B^{-1}(Y)} P(\pi|X)\right)$$

Στην πράξη, καθώς το πλήθος των πιθανών paths αυξάνεται εκθετικά με το μήκος της ακολουθίας, δεν είναι εφικτό να απαριθμίσουν όλα από τα παραπάνω μονοπάτια. Αντ’ αυτού, χρησιμοποιείται ο αλγόριθμος Forward-Backward, μία μορφή δυναμικού προγραμματισμού, ο οποίος υπολογίζει την πιθανότητα της επιθυμητής αλληλουχίας σε χρόνο $O(TU)$, όπου T είναι το μήκος της εισόδου και U είναι το μήκος της targeted ακολουθίας. Ο αλγόριθμος αυτός ορίζει forward και backward μεταβλητές που αντιστοιχούν στις πιθανότητες να έχει παραχθεί ένα συγκεκριμένο πρόθεμα ή επίθεμα της ακολουθίας στόχου μέχρι μία χρονική στιγμή. Συνδυάζοντας τις πιθανότητες αυτές υπολογίζεται το συνολικό άθροισμα όλων των έγκυρων αλληλουχιών, χωρίς να εξετάζεται κάθε πιθανό path ξεχωριστά.

Τα πλεονεκτήματα της εκπαίδευσης με την παραπάνω αντικειμενική συνάρτηση είναι η εξάλειψη της απαίτησης ετικετών σε επίπεδο frame, η ικανότητα χρήσης διαφορετικών μηκών εισόδου και εξόδου, η αυτόματη μάθηση της χρονικής ευθυγράμμισης (temporal alignment) των φωνημάτων και ότι επιτρέπει την εκπαίδευση end-to-end. Αποτελεί μειονέκτημα, ωστόσο, η υπόθεση ότι οι προβλέψεις σε διαδοχικά χρονικά βήματα είναι ανεξάρτητες δεδομένης της εισόδου, γεγονός που περιορίζει τη μοντελοποίηση ισχυρών εξαρτήσεων μεταξύ των συμβόλων εξόδου. Άλλα ελαττώματα της χρήσης της συνάρτησης αυτής είναι ότι δεν ενσωματώνεται γλωσσικό μοντέλο κατά την εκπαίδευση, με τη γλωσσική πληροφορία να προστίθεται μόνο κατά την αποκωδικοποίηση, όπως επίσης ότι παρουσιάζονται δυσκολίες κατά την επεξεργασία μεγάλων ακολουθιών ή ακολουθιών με πολλά επαναλαμβανόμενα σύμβολα.

3.3 Άλλες Χρήσιμες Έννοιες

Απόσταση Levenshtein Στη θεωρία πληροφορίας, η απόσταση Levenshtein (ή αλλιώς edit distance) είναι μία μετρική που αφορά την απόσταση δύο αλληλουχιών χαρακτήρων (strings). Αφορά τον ελάχιστο αριθμό αλλαγών μοναδικού χαρακτήρα (αφαιρέσεων, προσθέσεων ή μετατροπών) ώστε ένα string να μετατραπεί σε κάποιο άλλο. Συγκεκριμένα, έστω a και b δύο συμβολοσειρές με μήκη $|a|$ και $|b|$ αντίστοιχα. Η απόσταση Levenshtein των δύο αυτών συμβολοσειρών υπολογίζεται με τον παρακάτω αναδρομικό τύπο ως:

$$lev(a, b) = \begin{cases} |a| & \text{if } |b| = 0 \\ |b| & \text{if } |a| = 0 \\ lev(tail(a), tail(b)) & \text{if } head(a) = head(b) \\ 1 + \min \begin{cases} lev(tail(a), b) \\ lev(a, tail(b)) \\ lev(tail(a), tail(b)) \end{cases} & \text{otherwise} \end{cases}$$

όπου $tail(x)$ μίας συμβολοσειράς x είναι η συμβολοσειρά όλων των χαρακτήρων της x δίχως τον πρώτο και $head(x)$, αντίστοιχα, είναι μόνο ο πρώτος χαρακτήρας της x .

Στην πράξη, για να αποφευχθεί η χρήση του παραπάνω αναδρομικού ορισμού, η οποία αυξάνει το υπολογιστικό κόστος εκθετικά με το μήκος των συμβολοσειρών, χρησιμοποιούνται τεχνικές δυναμικού προγραμματισμού για τον υπολογισμό της απόστασης Levenshtein μεταξύ δύο συμβολοσειρών. Παρακάτω δίνεται ένα παράδειγμα υπολογισμού της απόστασης Levenshtein των συμβολοσειρών “kitten” και “sitting”.

Παρατηρούμε ότι ο ελάχιστος αριθμός αλλαγών σε χαρακτήρες που πρέπει να γίνουν για να ταυτιστούν οι δύο συμβολοσειρές είναι 3, και συγκεκριμένα:

- kitten → sitten (μετατροπή του "k" σε "s")
- sitten → sittin (μετατροπή του "e" σε "i")
- sittin → sitting (προσθήκη του "g")

Η μετατροπή δεν μπορεί να γίνει με λιγότερες κινήσεις και άρα η Levenshtein απόσταση των συμβολοσειρών "kitten" και "sitting" είναι 3.

THE INTERNATIONAL PHONETIC ALPHABET (revised to 2020)

CONSONANTS (PULMONIC)

© 2020 IPA

	Bilabial	Labiodental	Dental	Alveolar	Postalveolar	Retroflex	Palatal	Velar	Uvular	Pharyngeal	Glottal
Plosive	p b			t d		ʈ ɖ	c ɟ	k ɡ	q ɢ		ʔ
Nasal	m	ɱ		n		ɳ	ɲ	ŋ	ɴ		
Trill	ʙ			r					ʀ		
Tap or Flap		ⱱ		ɾ		ɽ					
Fricative	ɸ β	f v	θ ð	s z	ʃ ʒ	ʂ ʐ	ç ʝ	x ɣ	χ ʁ	ħ ʕ	h ɦ
Lateral fricative				ɬ ɮ							
Approximant		ʋ		ɹ		ɻ	j	ɰ			
Lateral approximant				l		ɭ	ʎ	ʟ			

Symbols to the right in a cell are voiced, to the left are voiceless. Shaded areas denote articulations judged impossible.

CONSONANTS (NON-PULMONIC)

Clicks	Voiced implosives	Ejectives
◌ Bilabial	ɓ Bilabial	ʼ Examples:
◌ Dental	ɗ Dental/alveolar	pʼ Bilabial
◌ (Post)alveolar	ɟ Palatal	tʼ Dental/alveolar
◌ Palatoalveolar	ɡ Velar	kʼ Velar
◌ Alveolar lateral	ɠ Uvular	sʼ Alveolar fricative

OTHER SYMBOLS

ɱ Voiceless labial-velar fricative	ɕ ʑ Alveolo-palatal fricatives
ʋ Voiced labial-velar approximant	ɭ Voiced alveolar lateral flap
ɥ Voiced labial-palatal approximant	ɥ Simultaneous ʃ and x
ħ Voiceless epiglottal fricative	
ʕ Voiced epiglottal fricative	Affricates and double articulations can be represented by two symbols joined by a tie bar if necessary.
ʡ Epiglottal plosive	


DIACRITICS

◌ Voiceless	◌ Breathy voiced	◌ Dental
◌ Voiced	◌ Creaky voiced	◌ Apical
◌ Aspirated	◌ Linguolabial	◌ Laminal
◌ More rounded	◌ Labialized	◌ Nasalized
◌ Less rounded	◌ Palatalized	◌ Nasal release
◌ Advanced	◌ Velarized	◌ Lateral release
◌ Retracted	◌ Pharyngealized	◌ No audible release
◌ Centralized	◌ Velarized or pharyngealized	
◌ Mid-centralized	◌ Raised	
◌ Syllabic	◌ Lowered	
◌ Non-syllabic	◌ Advanced Tongue Root	
◌ Rhoticity	◌ Retracted Tongue Root	

Some diacritics may be placed above a symbol with a descender, e.g. ɲ̥

Typefaces: Doulos SIL (metatext); unipa (symbols)

VOWELS



Where symbols appear in pairs, the one to the right represents a rounded vowel.

SUPRASEGMENTALS

ˈ Primary stress	ˈfounəˈtʃən
ˌ Secondary stress	
ː Long	eː
ˑ Half-long	eˑ
◌ Extra-short	ẽ
◌ Minor (foot) group	
◌ Major (intonation) group	
◌ Syllable break	.i.ækt
◌ Linking (absence of a break)	

TONES AND WORD ACCENTS

LEVEL	CONTOUR
é or ˥ Extra high	ě or ˨ Rising
é High	ê or ˩ Falling
ē Mid	ē High rising
è Low	è Low rising
ě Extra low	ě Rising-falling
↓ Downstep	↗ Global rise
↑ Upstep	↘ Global fall

Σχήμα 1: Επίσημο chart φωνημάτων του IPA, έκδοση 2020

4 State of the Art

A more detailed description of the state of the art I alluded to in the Introduction chapter.

5 Μεθοδολογία

Στο κεφάλαιο αυτό παρουσιάζεται αναλυτικά η μεθοδολογία που χρησιμοποιήθηκε κατά τη διεξαγωγή των πειραμάτων. Συμπεριλαμβάνονται επακριβείς πληροφορίες για την προεπεξεργασία των δεδομένων, τη δομή του μοντέλου και για το post-processing που εφαρμόζεται.


5.1 Προεπεξεργασία Δεδομένων

Η προεπεξεργασία των δεδομένων αποτελεί βασικό τμήμα κάθε μελέτης στη Βαθιά Μάθηση. Αποτελεί τη διαδικασία κατά την οποία τα δεδομένα, τα οποία αρχικά βρίσκονται σε μορφή που δεν μπορούν να υποστηρίξουν μάθηση (στην περίπτωση μας, τα αρχικά βίντεο των ομιλητών με τον ήχο και πριν την απόδοση φωνημάτων σε κάθε frame), αποκτούν τη μορφή που τους επιτρέπει να εισαχθούν στο μοντέλο. Αξιοποιώντας τις γνώσεις πάνω στο αντικείμενο, είναι δυνατόν να μειωθεί ο χρόνος εκπαίδευσης μέσω της μείωσης των διαστάσεων των πληροφοριών που εισάγονται στο νευρωνικό δίκτυο και, γενικότερα, να βελτιωθούν τα τελικά αποτελέσματα. Παρακάτω αναλύονται οι εκάστοτε τεχνικές pre-processing που εφαρμόζονται ώστε να λάβουν τα δεδομένα την επιθυμητή μορφή.


5.1.1 Εξαγωγή της περιοχής των χειλιών

Έστω ένα βίντεο ομιλητή $T \times C \times H \times W$ με T τη χρονική διάσταση (τον αριθμό των frames), C τον αριθμό των καναλιών (για RGB βίντεο είναι 3) και H ύψος και W πλάτος σε pixel. Για να περιοριστεί το μέγεθος των δεδομένων και να παραλειφθούν περιττές πληροφορίες του παρασκήνιου αλλά και του προσώπου του ομιλητή, αναπτύχθηκε ένα pre-processing script εντοπισμού της περιοχής των χειλιών. Η περιοχή αυτή είναι που αφορά το αντικείμενο, καθώς εκεί βρίσκεται η πληροφορία των visemes (άλλωστε, για αυτό αποκαλείται lip reading). Χρησιμοποιώντας το διαθέσιμο προεκπαιδευμένο MediaPipe Face Landmarker της Google, εντοπίζονται τα διάφορα “τοπόσημα προσώπου” (facial landmarks) του ομιλητή για κάθε frame του αρχικού βίντεο. Οι δείκτες των τοποσήμων των χειλιών εξαγονται για κάθε frame ξεχωριστά και παράγουν μία νέα εικόνα της περιοχής αυτής (συμπεριλαμβανομένου ενός επιπρόσθετου padding γύρω από τα χείλη για ασφάλεια) με διαστάσεις $H' \times W' \times 3$ και $H' < H, W' < W$.


Από τα εκάστοτε frames παράγεται το νέο βίντεο της περιοχής των χειλιών, το οποίο μετασχηματίζεται by default στην τελική διάσταση $224 \times 224 \times 3 \times T$. Κατά τη διάρκεια των πειραμάτων, βρέθηκε ότι ακόμα λιγότερα pixels είναι ικανά να αποδόσουν το περιεχόμενο των visemes, με αποτέλεσμα πριν την εκπαίδευση να εφαρμόζεται ένας ακόμα μετασχηματισμός στα 96 pixels. Κατά τον εντοπισμό των τοποσήμων χρησιμοποιείται και ένας μηχανισμός fallback, σε περίπτωση που το Face Landmarker αδυνατεί να βρει τους ζητούμενους δείκτες. Συγκεκριμένα, εάν δεν εντοπιστούν για ένα δεδομένο frame τα τοπόσημα, τότε επαναχρησιμοποιούνται αυτά του προηγούμενου frame, ενώ αν δεν υπάρχουν ούτε αυτά εκτιμάται η τοποθεσία των χειλιών ως η κάτω περιοχή του προσώπου (50% του πλάτους και 35% του ύψους, με κατακόρυφο offset 42%). Τα δεδομένα κωδικοποιούνται σε μορφή βίντεο .mp4 διατηρώντας το framerate του αρχικού βίντεο, ενώ παράγονται και μερικά παραδείγματα frames από το βίντεο bbaf2n.mp4 του dataset GRID (βλ. παράγραφο 6.1), τα οποία παρουσιάζονται παρακάτω.




Σχήμα 2: Εξαγωγή χειλιών για το frame 0



Σχήμα 3: Εξαγωγή χειλιών για το frame 24



Σχήμα 4: Εξαγωγή χειλιών για το frame 49



Σχήμα 5: Εξαγωγή χειλιών για το frame 74

5.1.2 Εξαγωγή φωνημάτων για κάθε frame

Για να έχει νόημα η εφαρμογή του όρου cross entropy, είναι απαραίτητο να δημιουργηθούν labels για κάθε frame των βίντεο. Αυτό επιτυγχάνεται με συνδυασμό της γνώσης του περιορισμένου περιβάλλοντος και μεθόδων αναγνώρισης φωνημάτων από ηχητικά σήματα ομιλίας. Να σημειωθεί ότι η παρακάτω διαδικασία μπορεί κάλλιστα να εφαρμοστεί και σε μη πεπερασμένο περιβάλλον, αλλά οι περαιτέρω περιορισμοί που προκύπτουν από τέτοια περιβάλλοντα επιτρέπουν απλοποιήσεις και διορθώσεις σε περίπτωση λανθασμένης προφοράς από τον ομιλητή.

Θεωρώντας γνωστό το φραστικό περιεχόμενο κάθε βίντεο (π.χ. στο GRID dataset γίνεται γνωστή η φράση που εκφέρεται από τον ομιλητή μέσω του τίτλου του αρχείου), μπορεί να μετατραπεί η φράση σε αλληλουχία φωνημάτων μέσω του eSpeak-NG, δίχως ακόμα να υπάρχει ωστόσο γνώση για τον χρονισμό του κάθε φωνήματος. Χρησιμοποιείται ελαφριά κανονικοποίηση στα φωνήματα που εξάγονται ώστε το “αλφάβητο” των τελικών αλληλουχιών να ταυτίζεται με αυτό του μοντέλου wav2vec2, που χρησιμοποιείται για την εξαγωγή φωνημάτων από το ηχητικό περιεχόμενο. Το CTC μοντέλο του wav2vec2 εξάγει πιθανότητες κάθε φωνήματος για κάθε frame και, συγκρίνοντας με την αλληλουχία φωνημάτων που γνωρίζουμε ότι αναμένεται, παράγει μία τελική πρόβλεψη για την αρχή και το τέλος του κάθε φωνήματος. Μέσω αυτών των πληροφοριών, είναι δυνατόν να ολοκληρωθεί το labelling κάθε frame με το αντίστοιχο φώνημα ή το blank token, εφόσον το frame αντιστοιχεί σε χρονική στιγμή εκτός των φωνημάτων. Έτσι, πέραν της εξαγωγής των απαιτούμενων labels, αποφεύγονται τυχόντα προβλήματα από αστοχία κατά την προφορά της κάθε φράσης.

Η επεξεργασία των φωνημάτων δεν ολοκληρώνεται εκεί. Συγκεκριμένα, δημιουργείται ένα viseme grouping (ομαδοποίηση, δηλαδή, των όμοιων οπτικά φωνημάτων) με βάση τα χαρακτηριστικά των φωνημάτων. Για αναλυτικότερες πληροφορίες ως προς την ομαδοποίηση των φωνημάτων, ανατρέξτε στην ενότητα 3.1. Από τα hard targets που υπάρχουν ήδη για κάθε frame των βίντεο, δημιουργούνται soft targets με βάση τις παραπάνω ομάδες. Συγκεκριμένα, το 85% αποδίδεται στο πραγματικό φώνημα, ενώ το υπόλοιπο 15% μοιράζεται στα όμοια φωνήματα του πραγματικού με βάρη που ανταποκρίνονται στην ομοιότητα των φωνημάτων. Για ίδιο viseme, χρησιμοποιείται βάρος 0.95, ενώ για διαφορετικό υπολογίζεται similarity score ως εξής: κάθε φώνημα έχει τον τόπο, τον τρόπο άρθρωσης και το αν είναι έμφωνο ή όχι. Με βάση το πόσα κοινά features άρθρωσης έχουν δύο φωνήματα που δεν ανήκουν στο ίδιο viseme, αποδίδεται μεγαλύτερο βάρος σε αυτά με περισσότερες ομοιότητες και μικρότερο σε αυτά με τις λιγότερες. Έτσι, υπολογίζεται το articulatory_similarity ως εξής: $sim = 1 - \text{diffs}/3$, όπου diffs είναι ο αριθμός διαφορετικών features. Το τελικό similarity matrix χτίζεται με τον ακόλουθο κανόνα:

$$mat[i, j] = \begin{cases} 1 & i = j \\ 0 & \text{είτε το } i \text{ είτε το } j \text{ είναι blank token και } i \neq j \\ 0.95 & \text{ίδια ομάδα viseme} \\ sim(a, b) \cdot 0.4 & \text{σε άλλη περίπτωση} \end{cases}$$

Τελικά τα soft targets χτίζονται με το 85% στο πραγματικό φώνημα και το υπόλοιπο 15% μοιρασμένο στα όμοια φωνήματα σε αναλογία με το similarity score των φωνημάτων, εκτός από την περίπτωση του


blank token, κατά την οποία διατηρούνται τα hard targets. Αυτό συμβαίνει ώστε να ενισχυθεί η ικανότητα του μοντέλου να προβλέπει ακριβώς πότε λέγεται ένα φώνημα και πότε όχι, με αποτέλεσμα οι χρονισμοί των προβλέψεων να είναι ορθοί.

5.1.3 Data Augmentation

Για να εμπλουτιστεί ιδιαίτερα κάποιο περιορισμένο σε μέγεθος dataset, κρίνεται αναγκαίο να εφαρμοστούν μέθοδοι data augmentation, δηλαδή επαύξεσης δεδομένων. Αυτές οι μέθοδοι, εκμεταλλευόμενες τη γνώση μας στο αντικείμενο, παράγουν νέα δεδομένα από τα υπάρχοντα και εμπλουτίζουν τη μάθηση του μοντέλου. Είναι σημαντικό να τονιστεί ότι οι τεχνικές data augmentation που εφαρμόζονται πρέπει να συμβαδίζουν με τους στόχους μάθησης του μοντέλου. Για παράδειγμα, μία πιθανή μέθοδος data augmentation στην περίπτωση που τα δεδομένα βρίσκονται σε μορφή βίντεο είναι η αναστροφή της αλληλουχίας των frames. Ωστόσο, όταν το μοντέλο πρόκειται να μάθει σε κάποιο παρακείμενο στο οποίο έχει σημασία η σωστή χρονική αλληλουχία (όπως για παράδειγμα στο lip reading, όπου οι κινήσεις των χειλιών για την παραγωγή ενός φωνήματος είναι ευαίσθητες στη σωστή χρονική σειρά), δε θα μπορούσε να εφαρμοστεί η παραπάνω μέθοδος.


Οι τεχνικές data augmentation που τελικά εφαρμόζονται, λόγω της ορθότητάς τους για τον τελικό στόχο και λόγω της ταχείας εφαρμογής τους σε πολλαπλά δεδομένα, είναι ο καθρεπτισμός γύρω από τον κατακόρυφο άξονα (horizontal flip), η χρωματική αλλαγή (color jitter) και η αφαίρεση/επικάλυψη (cutout/occlusion). Σε κάθε περίπτωση οι μετασχηματισμοί αυτοί εφαρμόζονται σε ολόκληρο το βίντεο και όχι σε μεμονωμένα frames, ώστε να αποφευχθούν ανεπιθύμητα φαινόμενα αστάθειας. Ο καθρεπτισμός εφαρμόζεται με πιθανότητα $p = 0.5$, ενώ η χρωματική αλλαγή πραγματοποιείται μέσω των παραγόντων της φωτεινότητας (brightness) με συντελεστή από 0.8 έως 1.2, της αντίθεσης (contrast) με παράγοντα 0.8-1.2 και του κορεσμού (saturation) με παράγοντα 0.9-1.1 και με πιθανότητα $p = 0.4$. Τέλος, με τη μέθοδο της επικάλυψης, με πιθανότητα $p = 0.25$ επιλέγεται τυχαία μία ορθογώνια περιοχή (8-20% του ύψους και του πλάτους του frame) και αποκρύπτεται για όλα τα frame του δεδομένου βίντεο, προσομοιώνοντας την ύπαρξη ενός αντικειμένου που εμποδίζει τη θέαση συγκεκριμένης περιοχής. Αυτό έχει ως αποτέλεσμα η εκπαίδευση να γίνεται πιο εύρωστη. Να σημειωθεί ότι η διαδικασία του data augmentation εφαρμόζεται αποκλειστικά στο training split και όχι σε αυτά του validation και του test. Παρακάτω παρουσιάζονται μερικά παραδείγματα των παραπάνω μεθόδων επαύξεσης δεδομένων.

Data Augmentation: Horizontal flip




Σχήμα 6: Παρουσίαση του καθρεπτισμού (horizontal flip) για μερικά frames

Data Augmentation: Brightness / contrast / saturation



Σχήμα 7: Παρουσίαση της αλλαγής χρώματος (color jitter) για μερικά frames

Data Augmentation: Random cutout



Σχήμα 8: Παρουσίαση της αφαίρεσης/επικάλυψης (cutout/occlusion) για μερικά frames

5.2 Δομή του προτεινόμενου μοντέλου

Στην ενότητα αυτή περιγράφεται αναλυτικά η αρχιτεκτονική του προτεινόμενου μοντέλου. Στο σχήμα 9 παρουσιάζεται μία απεικόνιση των βασικών σχεδιαστικών επιλογών του μοντέλου.

Μορφή των δεδομένων εισόδου Όπως παρουσιάστηκε και στην ενότητα 5.1.2, κάθε αντικείμενο του training (κάθε βίντεο) συμπληρώνεται από μία προβλεπόμενη αλληλουχία φωνημάτων σε επίπεδο frame. Για κάθε frame υπάρχει η πρόβλεψη του φωνήματος (κενό αν δεν εκφέρεται φώνημα), ενώ συμπληρωματικά υπάρχει και η συμπυκνωμένη (collapsed) ακολουθία, στην οποία συνεχόμενα επαναλαμβάνονται φωνήματα και κενά παραλείπονται και η οποία απαιτείται για τον όρο CTC της αντικειμεντικής συνάρτησης. Τέλος, συμπεριλαμβάνεται στις γνωστές πληροφορίες και ένα log-probability confidence score για κάθε πρόβλεψη, που έχει παραχθεί κατά τη δημιουργία των προβλεπόμενων αλληλουχιών. Τα log-probabilities περιορίζονται στο σύνολο $[-10, 0]$ και έπειτα μεταφέρονται γραμμικά στο σύνολο $[0.5, 1.5]$, με frames που δεν καλύπτονται από το span κάποιου φωνήματος (κενά frames) να παίρνουν

το default βάρος 1. Τα βάρη αυτά επηρεάζουν, έπειτα, τη συνεισφορά του κάθε λάθους σε επίπεδο frame στον όρο cross entropy, ώστε το μοντέλο να τιμωρείται λιγότερο στις περιπτώσεις που η ίδια η πρόβλεψη του target είναι αβέβαιη.

Όσον αφορά τα ίδια τα βίντεο, θεωρούμε ότι σε αυτά έχει εφαρμοστεί η πρόβλεψη χειλιών όπως παρουσιάζεται στην παράγραφο 5.1.1. Θεωρούμε, επίσης, batch size B , αριθμό frames T , αριθμό καναλιών C , ύψος H και πλάτος W σε pixels, με την τελική μορφή των δεδομένων εισόδου, όπως φαίνεται και στο σχήμα 9, να είναι $B \times T \times C \times H \times W$.

Εξαγωγή των Visual Features: Conv3D Frontend Η βασική σχεδιαστική επιλογή του συγκεκριμένου μοντέλου είναι η χρήση 3D συνελικτικού νευρωνικού δικτύου ως το πρώτο στάδιο του μοντέλου και όχι διδιάστατου νευρωνικού εφαρμοσμένου σε κάθε frame του βίντεο χωριστά. Η επιλογή αυτή συμβαίνει συνειδητά λόγω της φύσης του προβλήματος του διαβάσματος των χειλιών, το οποίο είναι τόσο πρόβλημα αναγνώρισης της εμφάνισης των χειλιών όσο είναι και πρόβλημα αναγνώρισης των κινήσεών τους. Η διαφοροποίηση μεταξύ πολλών φωνημάτων δεν έγκειται συχνά στην εικόνα απομονωμένων frames όσο στη σχέση μεταξύ διαδοχικών frames, η οποία φανερώνει, για παράδειγμα, την ταχύτητα με την οποία κλείνουν τα χείλη. Η πληροφορία αυτή, αν δεν μαθαίνεται ήδη από τα αρχικά στάδια του μοντέλου, πρέπει να μαθευτεί αποκλειστικά από το επόμενο στάδιο του μοντέλου (τον sequence encoder), ο οποίος σε αυτήν την περίπτωση έχει πρόσβαση μόνο σε στατική περιγραφή κάθε frame ξεχωριστά. Ωστόσο, σε εκείνο το στάδιο υπάρχει και η μακροπρόθεσμη παρακείμενη πληροφορία (πληροφορία που έχει να κάνει με ποια φωνήματα προηγούνται και ποια έπονται), οπότε κρίθηκε χρήσιμο η πληροφορία της κίνησης των χειλιών σε γειτονικά frames να εξάγεται ήδη από τον feature extractor.

Για κάθε ένα από τα 3 blocks συνελικτικού δικτύου 3 διαστάσεων, δεν εφαρμόζεται η τυπική συνέλιξη 3D, αλλά αυτή χωρίζεται σε 2 στάδια: το depthwise stage, κατά το οποίο μία συνέλιξη με kernel $(3, 3, 3)$ εφαρμόζεται ανεξάρτητα σε κάθε κανάλι της εισόδου, και το pointwise stage, που αποτελείται από μία pointwise $(1 \times 1 \times 1)$ συνέλιξη η οποία αναμειγνύει τις προηγούμενες εξόδους. Πρόκειται για μία συνήθη παραγοντοποίηση της συνέλιξης σε 3 διαστάσεις και ονομάζεται depthwise separable convolution (συνέλιξη διαχωρίσιμη ως προς το βάθος). Χρησιμοποιείται λόγω της μείωσης του αριθμού των παραμέτρων που προσφέρει. Συγκεκριμένα, έστω μία τυπική 3D συνέλιξη με πυρήνα $(3, 3, 3)$, η οποία οδηγεί C_{in} κανάλια εισόδου σε C_{out} κανάλια εξόδου. Το δίκτυο αυτό υπολογίζει το κάθε κανάλι εξόδου ως ένα σταθμισμένο άθροισμα όλων των καναλιών εισόδου και όλων των 27 πιθανών “χρωροχρονικών” τοποθετήσεων του πυρήνα, χρειάζεται δηλαδή $27 \cdot C_{in} \cdot C_{out}$ παραμέτρους και άλλους τόσους πολλαπλασιασμούς και προσθέσεις. Από την άλλη, κατά το depthwise βήμα του depthwise separable convolution, κάθε κανάλι γίνεται αντικείμενο συνέλιξης με τον δικό του πυρήνα $(3, 3, 3)$ χωρίς να αναμειγνύεται με άλλα κανάλια, χρειάζονται δηλαδή $27 \cdot C_{in}$ παράμετροι. Η μίξη μεταξύ των καναλιών συμβαίνει στο pointwise stage, το οποίο δεν προσφέρει παρακείμενο (context) ούτε στη χρονική ούτε στις χωρικές διαστάσεις και άρα χρειάζεται $C_{in} \cdot C_{out}$ παραμέτρους, ίδιες με την περίπτωση fully connected layer μεταξύ των δύο καναλιών. Τελικά, χρησιμοποιώντας τη μέθοδο της depthwise separable convolution, οι απαιτούμενες παράμετροι και πράξεις μειώνονται από $27 \cdot C_{in} \cdot C_{out}$ σε $27 \cdot C_{in} + C_{in} \cdot C_{out}$, ελαττώνοντας αισθητά το υπολογιστικό κόστος του μοντέλου.

Πιο συγκεκριμένα, για τα 3 συνελικτικά μπλοκ που χρησιμοποιούνται στο μοντέλο, παρατηρούνται οι εξής μειώσεις σε παραμέτρους: για το πρώτο μπλοκ, ενώ με τυπική 3D συνέλιξη θα υπήρχαν $27 \cdot 3 \cdot 32 = 2592$ παράμετροι, ενώ με τη μέθοδο της depthwise separable convolution υπάρχουν $27 \cdot 3 + 3 \cdot 32 = 177$, μείωση δηλαδή κατά πάνω από 93%. Αντίστοιχα, για το δεύτερο μπλοκ η μείωση είναι από $27 \cdot 32 \cdot 64 = 55296$ σε $27 \cdot 32 + 32 \cdot 64 = 2912$, δηλαδή σχεδόν 19 φορές, ενώ στο τρίτο μπλοκ οι παράμετροι ελαττώνονται από $27 \cdot 64 \cdot 128 = 221184$ σε $27 \cdot 64 + 64 \cdot 128 = 9920$, άρα πάνω από 22 φορές λιγότερες. Παρατηρούμε ότι, όσο αυξάνεται το μέγεθος των καναλιών (συγκεκριμένα του καναλιού εξόδου), τόσο μεγαλύτερο γίνεται και το κέρδος χρήσης της μεθόδου αυτής, κάτι που γίνεται προφανές αν συγκριθούν οι όροι $C_{in} \cdot (27 + C_{out})$ και $C_{in} \cdot 27 \cdot C_{out}$: ο συντελεστής του C_{in} στον έναν όρο αυξάνει προσθετικά ενώ στον άλλον πολλαπλασιαστικά με το C_{out} .

Το trade-off της συγκεκριμένης μεθόδου είναι η ενίσχυση του inductive bias (επαγωγική μεροληψία) του μοντέλου: η φύση της depthwise separable convolution υποθέτει ότι τα διάφορα μοτίβα σε χώρο

και χρόνο (spatiotemporal patterns) μπορούν να εντοπιστούν σε κάθε κανάλι ξεχωριστά. Η επίδραση του περιορισμού εξαρτάται από το βάθος του δικτύου στο οποίο αναφερόμαστε. Στο πρώτο συνελκτικό μπλοκ, τα κανάλια είναι RGB, με αποτέλεσμα ένα depthwise φίλτρο να είναι ικανό να εντοπίσει ακμές στον χώρο ή αλλαγές στον χρόνο σε κάθε ξεχωριστό κανάλι. Στην περίπτωση του πρώτου μπλοκ, η μόνη περίπτωση που μπορεί να εκφραστεί στην περίπτωση της πλήρους 3D συνέλιξης και όχι της μεθόδου που χρησιμοποιείται είναι ενός φίλτρου που αποκρίνεται διαφορετικά σε κόκκινη ακμή από ότι σε μπλε ακμή ίδιου χρώματος. Αυτή η χρωματική διάκριση δεν αποτελεί αντικείμενο του lip reading, καθώς τα στοιχεία που αναζητώνται (η θέση των χειλιών, η γεωμετρία του ανοίγματος και του κλεισίματός τους και η κίνησή τους) εμφανίζονται ως διαφορές φωτεινότητας και σχήματος που εμφανίζονται σε κάθε κανάλι.

Ο περιορισμός που προκαλείται λόγω αυτού του inductive bias ενισχύεται στα επόμενα μπλοκ συνέλιξης, όπου τα κανάλια δεν είναι πλέον κανάλια χρώματος αλλά feature maps. Σε αντίθεση με τα τυπικά 3D φίλτρα, τα οποία μπορούν να εντοπίσουν σε ένα βήμα την ενεργοποίηση δύο διαφορετικών καναλιών, η μέθοδος αυτή δεν μπορεί να κάνει τη μίξη των καναλιών να εξαρτάται από το χωρικό και χρονικό παρακείμενο εντός ενός block. Έτσι, χάνεται εκφραστικότητα του μοντέλου σε κάθε ξεχωριστή στρώση, η οποία ως έναν βαθμό περιορίζεται λόγω της ύπαρξης και του τελευταίου συνελκτικού μπλοκ, το οποίο μπορεί να εκφράσει κάποια πολυκαναλικά μοτίβα που δεν ήταν δυνατόν να εκφραστούν στην προηγούμενη στρώση. Δεδομένου του μεγέθους των dataset για το πρόβλημα αυτό, ο συμβιβασμός αυτός φαίνεται να αξίζει, καθώς η χαμένη εκφραστικότητα αναπληρώνεται ως ένα σημείο με μεγαλύτερο βάθος, ενώ ταυτόχρονα η βελτίωση στην αποδοτικότητα της εκπαίδευσης είναι πολύ μεγάλη. Να σημειωθεί ότι η σύγκριση πλήρους και διαχωρισμένης 3D συνέλιξης θα μπορούσε να αποτελεί αντικείμενο της μελέτης αφαίρεσης (όπως παρουσιάζεται στην ενότητα 6.3.1), αλλά κρίθηκε βασική σχεδιαστική επιλογή και η σύγκριση αυτή θεωρείται ως ένα πιθανό μελλοντικό επόμενο βήμα.

Τα τρία συνελκτικά μπλοκ αυξάνουν τον αριθμό των καναλιών (από 3 σε 32, 64 και τέλος 128), ενώ κάθε ένα από αυτά έχει χωρικό stride 2, άρα η χωρική ανάλυση μειώνεται κατά 8 φορές. Αντιθέτως, το χρονικό stride είναι 1, έτσι ώστε να μη μειώνεται σε καμία περίπτωση ο αριθμός των frames. Η διατήρηση του αριθμού των frames κάθε βίντεο δεν οφείλεται αποκλειστικά στο βήμα αυτό, αλλά και στο temporal padding με τιμή 1 που εφαρμόζεται: για αριθμό frames εισόδου T_{in} , μήκος padding p , μέγεθος kernel k και stride s , έχουμε αριθμό frames στην έξοδο του συνελκτικού block $T_{out} = \lfloor ((T_{in} + 2 \cdot p - k)/s) \rfloor + 1$ και τελικά με τις επιλογές που έχουν γίνει $T_{out} = \lfloor ((T_{in} + 2 \cdot 1 - 3)/1) \rfloor + 1 = T_{in}$. Χωρίς το padding, κάθε συνελκτικό block μειώνει την αλληλουχία frames κατά 2, κάτι που θα ήταν καταστροφικό για τα labels για κάθε frame που έχουν δημιουργηθεί προηγουμένως. Το kernel με μέγεθος 3, ωστόσο, επιτρέπει στο μοντέλο να μάθει χρονικές εξαρτήσεις προσθέτοντας 2 frames στο receptive field του μοντέλου για κάθε στρώση, δημιουργώντας στην έξοδο του τελευταίου layer ένα receptive field από 7 frames, ικανό να περιγράψει την κίνηση των χειλιών και την παραγωγή των φωνημάτων, όπως και τη μετάβαση μεταξύ τους.

Μετά τα 3 συνελκτικά μπλοκ, χρησιμοποιείται pooling μέσω AdaptiveAvgPool3d((None, 3, 3)), περιορίζοντας τις χωρικές διαστάσεις σε έναν σταθερό πίνακα 3×3 και διατηρώντας τη χρονική διάσταση σταθερή. Η επιλογή αυτή γίνεται ώστε το μοντέλο να είναι ανεξάρτητο από το μέγεθος του αρχικού βίντεο που εισάγεται σε αυτό. Έτσι, η αρχιτεκτονική μπορεί να εφαρμοστεί για διάφορα μεγέθη crop. Τελικά, τα παραγόμενα διανύσματα σε διάσταση $128 \times 3 \times 3 = 1152$ αποτελούν είσοδο σε έναν γραμμικό projector προς την κρυφή διάσταση h (hidden dimension), η οποία έχει την προεπιλεγμένη τιμή 256, μειώνοντας τη διάσταση των δεδομένων προτού εισαχθούν στον sequence encoder. Ακολουθεί η εφαρμογή Layer Normalization, ReLU activation function και Dropout, βελτιώνοντας την κανονικοποίηση του μοντέλου. Οι διαστάσεις των δεδομένων είναι πλέον (B, T, h)

Positional Encoding Λόγω της πιθανής επιλογής χρήσης transformer αντί για Bi-LSTM στη βαθμίδα του sequence encoding (όπως φαίνεται και στο πείραμα αφαίρεσης στην ενότητα 6.3.1, απαιτείται η χρήση positional encoder, ώστε να υπάρχει πληροφορία της σειράς των feature vectors που παράγονται από το 3D CNN frontend. Χρησιμοποιείται τυπική ημιτονοειδής κωδικοποίηση της θέσης των feature vectors, όπως παρουσιάζεται στην ενότητα 3.2. Η κωδικοποίηση αυτή, αν και δε χρειάζεται στην περίπτωση χρήσης Bi-LSTM sequence encoder, μια και τα LSTM από τη φύση τους διατηρούν πληροφορία

για την αλληλουχία των tokens, διατηρείται και στην περίπτωση επιλογής Bi-LSTM (η οποία είναι η προ-επιλογή, είναι αυτή που παρουσιάζεται στο σχήμα 9 και που πετυχαίνει καλύτερα αποτελέσματα στη μελέτη αφαίρεσης 6.3.1) για συνοχή της αρχιτεκτονικής και ώστε ο encoder να μπορεί να αλλάξει χωρίς να πρέπει να μεταβληθεί το υπόλοιπο pipeline.

Sequence Encoder Για την επίτευξη του στόχου του lip reading, είναι σημαντικό να προσαρτηθεί στην τελική απόφαση του μοντέλου μεγαλύτερο παρακαίμενο (context), συγκεκριμένα στη διάσταση του χρόνου. Το μοντέλο, έχοντας πρόσβαση σε περισσότερη πληροφορία για το παρελθόν και το μέλλον της ακολουθίας των φωνημάτων, μπορεί να μάθει να εξάγει συμπεράσματα για ένα φώνημα όχι μόνο από τα frames της γειτονιάς στην οποία εκφέρεται, αλλά και από αυτά που προηγήθηκαν ή έπονται. Είναι ευχής έργον το μοντέλο να μάθει εξαρτήσεις φωνημάτων από το παρακαίμενο, ιδιαίτερα σε περιπτώσεις όπου το λεξιλόγιο στο οποίο εκπαιδεύεται το μοντέλο είναι περιορισμένο. Ακόμα και σε μη περιορισμένες περιπτώσεις, ωστόσο, ένα μοντέλο δύναται να μάθει γενικές εξαρτήσεις κάποιας γλώσσας (π.χ. ότι στην αγγλική σε παρακαίμενο με τη λέξη “dog”, οι λέξεις “bark” ή “park” είναι πιο πιθανές από τη λέξη “mark” και άρα τα φωνήματα /b/ ή /p/ πρέπει να προβλεφθούν με μεγαλύτερο βάρος από το /m/, παρά το γεγονός ότι οι λέξεις έχουν την ίδια εικόνα στα χείλη) και με βάση αυτές να βελτιώσει τις προβλέψεις του, ειδικά σε περιπτώσεις σύγχυσης σε κάποια κλάση viseme.

Για τον λόγο αυτόν χρησιμοποιείται στο μοντέλο ο Sequence Encoder, δηλαδή ο κωδικοποιητής αλληλουχίας, δουλειά του οποίου είναι να συμπύκνει την πληροφορία του παρακειμένου και οποιουδήποτε δεδομένου token και με βάση αυτά να δημιουργήσει ένα νέο embedding το οποίο αξιοποιεί και τα δύο. Κατά τη διάρκεια της εργασίας δοκιμάστηκαν δύο τύποι sequence encoders (όπως και η εκδοχή με την πλήρη παράλειψή του) στη μελέτη αφαίρεσης (βλ. ενότητα 6.3.1): ο ένας αξιοποιούσε την αρχιτεκτονική των BiLSTMs (bi-directional long-short term memory) και ο άλλος απαρτιζόταν από transformers. Τελικά η εκδοχή βασισμένη στα BiLSTMs πετυχαίνει καλύτερα αποτελέσματα και άρα είναι αυτή που παρουσιάζεται στο σχήμα 9. Ωστόσο, για πληρότητα, στις παρακάτω παραγράφους παρουσιάζονται και συγκρίνονται αμφοτέρους οι μέθοδοι.

Η εκδοχή με BiLSTM χρησιμοποιεί 2 στρώσεις της συγκεκριμένης αρχιτεκτονικής, οι οποίες επιτρέπουν στην αναπαράσταση του κάθε frame να επηρεάζεται τόσο από παρελθοντικό όσο και από μελλοντικό παρακαίμενο, και παράγει έξοδο με διάσταση $2 \cdot h$, διπλασιάζει δηλαδή την κρυφή διάσταση. Στην περίπτωση του transformer χρησιμοποιείται multi-head self-attention με προεπιλεγμένη τιμή 4 heads και 2 layers, ενώ η διάσταση εξόδου παραμένει σταθερή και ίση με h . Για να μπορούν να συγκριθούν οι δύο εκδοχές, ακολουθούνται και οι 2 από layer normalization και dropout πριν την είσοδο των δεδομένων στην κεφαλή ταξινόμησης.

Όπως αναφέρεται και εξηγείται κατά τον σχολιασμό των αποτελεσμάτων της μελέτης αφαίρεσης 6.3.1, τα 2 μοντέλα διαφέρουν και στο inductive bias με το οποίο συνδέονται. Συγκεκριμένα, το BiLSTM εξετάζει την αλληλουχία βήμα με βήμα, με αποτέλεσμα η αναπαράσταση του frame t να χτίζεται αναδρομικά από την πληροφορία που περιέχεται στο frame $t - 1$ (ή, αντίστοιχα, στο backwards pass από το $t + 1$). Έτσι, το μοντέλο υποθέτει εξ' αρχής μία χρονική συσχέτιση, ειδικά των κοντινών frames. Αντιθέτως, ο μηχανισμός του self-attention χωρίς το sinusoidal encoding θα αντιμετώπιζε την αλληλουχία των frames ως ένα χαώδες σύνολο. Ακόμα και όταν χρησιμοποιείται το positional encoding, ο transformer πρέπει να μάθει να χρησιμοποιεί το παραπάνω σήμα ως πληροφορία αλληλουχίας των frames. Έτσι, παρά της δυνατότητας να δίνει βάρος σε οποιοδήποτε άλλο frame, ανεξαρτήτως χρονικής απόστασης, ο transformer μαθαίνει πιο δύσκολα να εστιάζει στην πληροφορία γειτονικών frames, κάτι που από τη φύση του το BiLSTM, το οποίο δίνει βάρος στο πρόσφατο context, δε χρειάζεται να μάθει. Βέβαια το πλεονέκτημα του transformer έγκειται ακριβώς εκεί: μπορεί να αναπτύξει πιο εύκολα μακροπρόθεσμες εξαρτήσεις, οι οποίες ειδικά σε περιπτώσεις ομιλίας σε μη περιορισμένο περιβάλλον είναι κρίσιμες για την ορθή πρόβλεψη των φωνημάτων και τελικά των λέξεων που εκφέρονται.

Λόγω των επαναλαμβανόμενων πυλών (recurrent gates) που χρησιμοποιούνται για τον υπολογισμό του hidden state του BiLSTM, η μακροχρόνια πληροφορία αναπόφευκτα συμπίεζεται και τελικά παραγράφεται, με αποτέλεσμα η επίδραση ενός πολύ μακρινού frame να είναι τελικά μικρή. Αντιθέτως, η αρχιτεκτονική του self-attention συνδέει κάθε frame με οποιοδήποτε άλλο frame σε κάθε στρώση, διευ-

κολύνοντας την αλληλεξάρτηση μεταξύ μακρινών χρονικά frames. Η διαφοροποίηση αυτή έχει να κάνει λιγότερο με την κίνηση των χειλιών, για της οποίας το υποδοκτικό πεδίο (receptive field) φροντίζει το Conv3d frontend που χρησιμοποιεί παράθυρο 7 frames για την τελική πληροφορία που εξάγει, όσο για πιο μακροχρόνιες δυναμικές της ομιλίας σαν τον ρυθμό και το γενικό παρακείμενο της ομιλίας.

Σε περίπτωση που τα βίντεο ενός batch έχουν αρχικά διαφορετικό μήκος και άρα τα μικρότερα από αυτά έχουν υποστεί padding, χρησιμοποιούνται για τις δύο εκδοχές του μοντέλου διαφορετικές μέθοδοι για να μην επιτρέπεται στα padded frames να επηρεάζουν την εκπαίδευση. Για το BiLSTM χρησιμοποιούνται τα `pack_padded_sequence` και `pad_packed_sequence`, τα οποία αφαιρούν τα padded frames από τη διαδικασία της αναδρομής. Το μοντέλο που χρησιμοποιεί transformer χρησιμοποιεί μία μάσκα `src_key_padding_mask` η οποία μηδενίζει το βάρος του attention από και προς padded frames.

Όσον αφορά τον αριθμό παραμέτρων για κάθε μοντέλο, το BiLSTM αποτελείται από περίπου 2.63 εκατομμύρια παραμέτρους, ενώ ο transformer από 1.58 εκατομμύρια, σχεδόν 1.66 φορές λιγότερες. Αυτό οφείλεται κυρίως στο γεγονός ότι στην έξοδο της πρώτης στρώσης του BiLSTM τα hidden states του προς τα μπροστά και του προς τα πίσω passes συνενώνονται, δημιουργώντας τελικά για τη 2η στρώση είσοδο διάστασης $2 \cdot h$ και αυξάνοντας το κόστος της. Οι παράμετροι του transformer παραμένουν ανάλογες με την αρχική κρυφή διάσταση h , καθώς δεν υπάρχει μεταβολή ανάμεσα στη διάσταση της εισόδου και της εξόδου τους.

Τέλος, να σημειωθεί ότι σε κάθε περίπτωση εφαρμόζεται gradient-norm clipping, το οποίο αποτελεί αναγκαία προσθήκη για την αποφυγή των explosive gradients ειδικά για την περίπτωση του BiLSTM, τα οποία οφείλονται στον πολλαπλασιασμό των recurrent gradients σε διάφορα βήματα του χρόνου. Από την άλλη, λόγω της αρχικής αστάθειας που παρουσιάζουν οι transformers ειδικά κατά τον υπολογισμό logits (τα αρχικά αποτελέσματα του attention είναι εσωτερικά γινόμενα τυχαίων προβολών query και key, με αποτέλεσμα οι προβλέψεις να είναι ιδιαίτερα θορυβώδεις πριν οι προβολές να έχουν μάθει κάτι ιδιαίτερο), χρησιμοποιείται linear warmup του ρυθμού μάθησης, κρατώντας τον χαμηλό όσο παράγονται μη αξιόπιστα gradients που ίσως οδηγούσαν το μοντέλο σε αστάθεια. Οι δύο αυτές προσαρμογές, αν και αντιτίθενται σε διαφορετικά προβλήματα των δύο μοντέλων, χρησιμοποιούνται και πάλι σε κάθε περίπτωση, ώστε η αρχιτεκτονική των μοντέλων να παραμένει σταθερή.

Κεφαλή Ταξινόμησης - Classification Head Για να παραχθούν οι τελικές προβλέψεις logits για κάθε frame, χρησιμοποιείται μία γραμμική στρώση η οποία προβάλλει την έξοδο του sequence encoder (με διάσταση $2h$ όταν επιλέγεται το BiLSTM και h όταν χρησιμοποιείται ο transformer) στη διάσταση $v + 1$, όπου v είναι η διάσταση του λεξιλογίου που χρησιμοποιείται (ο αριθμός των φωνημάτων που περιλαμβάνονται στη μελέτη ή στο συγκεκριμένο dataset). Η μία διάσταση παραπάνω οφείλεται στην ύπαρξη του κενού/blank συμβόλου, που αντιπροσωπεύει τη σιγή. Και σε αυτό το στάδιο δεν υπάρχει υποδειγματοληψία του χρόνου, ώστε οι προβλέψεις να έχουν το ίδιο μήκος με αυτό της πραγματικής αλληλουχίας φωνημάτων και να έχει νόημα ο υπολογισμός του όρου cross entropy.

Συνάρτηση Κόστους - VisemeAwareFrameLoss Για την εκπαίδευση του μοντέλου χρησιμοποιείται ένας προσαρμοσμένος στόχος μάθησης με τίτλο VisemeAwareFrameLoss. Η συνάρτηση αυτή συνδυάζει δύο όρους, έναν όρο cross-entropy στο επίπεδο των frames και έναν όρο Auxiliary CTC Loss. Για τεχνικές πληροφορίες περί των δύο αυτών όρων της αντικειμενικής συνάρτησης, ανατρέξτε στην ενότητα 3.2.

Για κάθε έγκυρο frame, υπολογίζεται ο όρος της cross-entropy ανάμεσα στην προβλεπόμενη κατανομή q και την ομαλή κατανομή target p , με την εξομάλυνση που παρουσιάστηκε παραπάνω. Στον όρο αυτόν προστίθεται μία περαιτέρω ποινή με στόχο τα frames τα οποία έχουν κατηγοριοποιηθεί ως frames σιγής. Συγκεκριμένα, για frame με target t και πρόβλεψη blank token $P(blank)$, ο όρος υπολογίζεται ως

$$penalty = insertion_penalty \cdot 1[t = blank] \cdot (1 - P(blank))$$

όπου $insertion_penalty$ είναι παράμετρος που ορίζει τη μέγιστη τιμή του προστιθέμενου όρου με προεπιλεγμένη τιμή 0.5. Παρατηρώντας τον παραπάνω τύπο, συμπεραίνουμε ότι παίρνει τιμή 0 όταν το label

του frame δεν αντιστοιχεί στη σιγή ή όταν αντιστοιχεί στη σιγή και το μοντέλο προβλέπει με απόλυτη βεβαιότητα το blank token. Σε περίπτωση που το blank token είναι το σωστό, όσο η πρόβλεψη του μοντέλου για το blank token γίνεται με λιγότερη αυτοπεποίθηση, τόσο αυξάνεται και ο όρος ποινής (γραμμικά), με μέγιστη τιμή το $insertion_{penalty}$. Στόχος του όρου αυτού είναι να τιμωρούνται σε μεγαλύτερο βαθμό τα “false positives”, δηλαδή η πρόβλεψη φωνημάτων σε frames στα οποία δεν υπάρχει κάποιο φώνημα. Ο συμμετρικός όρος, όρος δηλαδή που θα τιμωρούσε τα “false negatives”, τις προβλέψεις της σιγής σε περίπτωση που στο frame αντιστοιχίζεται κάποιο φώνημα, δε συμπεριλαμβάνεται, καθώς κατά τις δοκιμές βρέθηκε ότι δεν επηρεάζει αισθητά το αποτέλεσμα.

Η ποινή προστίθεται στην τιμή που υπολογίστηκε από το cross-entropy και το άθροισμα αυτό πολλαπλασιάζεται με το confidence score της πρόβλεψης όπως παρουσιάστηκε προηγουμένως. Τέλος, υπολογίζεται ο μέσος όρος του παραπάνω για όλα τα έγκυρα frames, παράγοντας τον όρο $frame_loss$ του batch. Πέραν του όρου αυτού, υπολογίζεται και η τυπική συνάρτηση κόστους CTC, η οποία ενισχύει το σήμα της σωστής αλληλουχίας φωνημάτων και είναι ανεξάρτητη από την οριοθέτηση των φωνημάτων σε επίπεδο frames. Ο όρος CTC ctc_loss πολλαπλασιάζεται με τη σταθερά ctc_weight με τυπική τιμή 0.3 και προστίθεται στον όρο $frame_loss$ υπολογίζοντας την τελική τιμή της συνάρτησης κόστους:

$$total_loss = frame_loss + ctc_weight \cdot ctc_loss$$

Στόχος του συνδυασμού των δύο συναρτήσεων κόστους είναι να δίνεται στο μοντέλο αυστηρή χρονική επίβλεψη (supervision), ειδικά όταν η πρόβλεψη του target γίνεται με αυτοπεποίθηση, ενώ ταυτόχρονα να υπάρχει το δεύτερο σήμα που δεν τιμωρεί υπερβολικά τις διαφωνίες στην οριοθέτηση αλλά εστιάζει στην επίτευξη της σωστής αλληλουχίας κατά την πρόβλεψη.

Άλλες λεπτομέρειες για την εκπαίδευση Όσον αφορά την εκπαίδευση του μοντέλου, χρησιμοποιήθηκε AdamW optimizer (με weight decay χρησιμοποιώντας τυπική τιμή 10^{-4} , με γραμμικό warmup του ρυθμού μάθησης (τυπικά για 5 εποχές) μέχρι τη μέγιστη τιμή ($3 \cdot 10^{-4}$). Χρησιμοποιείται επίσης ReduceLROnPlateau με scheduling που βασίζεται στο validation token error rate (βλ. ενότητα 6.2). Εφαρμόζεται gradient clipping στο 1.0, ενώ χρησιμοποιείται και μηχανισμός early stopping της εκπαίδευσης, αν το validation token error rate δε βελτιωθεί για τουλάχιστον 10^{-4} για έναν αριθμό εποχών (τυπικά 12). Για την αξιολόγηση στο test set, χρησιμοποιείται το μοντέλο με το χαμηλότερο validation TER, το οποίο δεν είναι αναγκαστικά αυτό της τελευταίας εποχής.

5.3 Βήματα Post-Processing

Όπως παρουσιάστηκε το μοντέλο μέχρι τώρα, είναι ικανό μόνο να προβλέψει φωνήματα από το βουβό βίντεο. Στη συγκεκριμένη υποενότητα, περιγράφονται οι τεχνικές post-processing που εφαρμόστηκαν ώστε η αλληλουχία φωνημάτων να μετατραπεί σε λέξεις, βήμα το οποίο οδηγεί στην επίτευξη του πρωταρχικού στόχου του lip reading.

5.3.1 Αλγοριθμική Πρόβλεψη Λέξεων

Σε εφαρμογές σε περιορισμένο περιβάλλον, όπου το λεξιλόγιο και, προαιρετικά, η γραμματική των φράσεων είναι γνωστά, είναι δυνατόν η πρόβλεψη των λέξεων από την αλληλουχία φωνημάτων να γίνει αλγοριθμικά και χωρίς τη χρήση τεχνητής νοημοσύνης. Για τα παρακάτω, υποθέτουμε (χωρίς βλάβη της γενικότητας και για να γίνει πιο ξεκάθαρη η επεξήγηση της μεθόδου) ότι η ανάλυση γίνεται στο dataset GRID, όπως παρουσιάζεται στην παράγραφο 6.1.


Αρχικά, παράγεται το collapsed sequence φωνημάτων από την αλληλουχία των φωνημάτων που προβλέπεται, ενώνοντας γειτονικά ίδια tokens και απαλείφοντας τα blank tokens, δημιουργώντας μία ομάδα από φωνήματα και τους χρονισμούς τους. Έπειτα, χρησιμοποιείται αλγόριθμος δυναμικού προγραμματισμού ώστε να βρεθεί η τομή των φωνημάτων σε λέξεις και η ανάθεση των προβλεπόμενων λέξεων με το μικρότερο συνολικό κόστος.

Για κάθε υποψήφια λέξη σε κάθε θέση, υπολογίζεται μία τιμή ομοιότητας με την ακολουθία των φωνημάτων που προβλέπεται. Έστω O η πρόβλεψη και T η υποψήφια λέξη. Ορίζεται η βασική απόσταση ως $D(O, T) = \frac{1}{\max(|O|, |T|)} \cdot ED(O, T)$, όπου $ED(O, T)$ είναι η ελάχιστη απόσταση edit της αλληλουχίας φωνημάτων O ώστε να φτάσει στην T . Κάθε φώνημα που πρέπει να αλλαχθεί δεν επηρεάζει με ίδιο τρόπο την $ED(O, T)$. Συγκεκριμένα, όμοια φωνήματα (είτε ακουστικά είτε οπτικά) τιμωρούνται λιγότερο σε σχέση με τελείως διαφορετικά φωνήματα. Το κόστος κάθε αλλαγής, από φώνημα a σε φώνημα b , υπολογίζεται ως εξής:

$$c(a, b) = \begin{cases} 0 & a = b \\ 0.15 & \text{ίδια κλάση viseme και ίδιος τρόπος/τόπος εκφοράς, αλλά διαφορετική φωνοποίηση} \\ 0.35 & \text{ίδια κλάση viseme αλλά όχι μόνο διαφορετική φωνοποίηση} \\ \min(1, \frac{\Delta(a, b)}{4}) & \text{αλλιώς, με διαφορά ιδιοτήτων } \Delta \\ 1 & \text{αν δεν υπάρχει καμία ίδια ιδιότητα} \end{cases}$$

Τότε, το τελικό σκορ ομοιότητας για κάθε υποψήφια λέξη είναι $S(O, T) = D(O, T) - B_{anchor}(O, T) - 0.15B_{rare}(O, T)$, όπου B_{anchor} είναι ένα ισχυρό bonus που δίνεται σε φωνήματα anchor και B_{rare} είναι ένα μικρότερο bonus για σπάνια φωνήματα. Τα φωνήματα anchor είναι φωνήματα που εμφανίζονται μόνο σε μία υποψήφια λέξη κάποιας κατηγορίας. Για παράδειγμα, στις προθέσεις του GRID, το φώνημα /ð/ με ήχο σαν το ελληνικό θήτα εμφανίζεται μόνο στη λέξη with και όχι σε οποιαδήποτε από τις in, by και at. Εάν δεν υπήρχε αυτός ο όρος, μία αλληλουχία φωνημάτων /i/ /ð/ θα οδηγούσε σε πρόβλεψη in και όχι σε πρόβλεψη with, που φαίνεται πιο αληθοφανές, δεδομένου ότι προβλέφθηκε το /ð/ που ανήκει μόνο σε μία λέξη. Με παρόμοιο τρόπο υπολογίζεται και το B_{rare} , αλλά πολλαπλασιάζεται με παράγοντα ανάλογο της σπανιότητας του εκάστοτε φωνήματος.

Με την παραπάνω μέθοδο, είναι δυνατόν να προβλεφθούν και λέξεις εντός του περιορισμένου περιβάλλοντος, πέραν των φωνημάτων. Ο αλγόριθμος αυτός σίγουρα μπορεί να αποτελέσει αντικείμενο βελτίωσης και καλύτερης προσαρμογής στο δεδομένο περιβάλλον στο οποίο γίνεται η κάθε μελέτη, ωστόσο κρίθηκε ότι η τωρινή εκδοχή του είναι αρκετή ώστε να επιδείξει ικανοποιητικά αποτελέσματα. Προφανώς, τα παραπάνω δεν μπορούν να εφαρμοστούν σε μη πεπερασμένο περιβάλλον, στο οποίο τόσο το λεξιλόγιο όσο και η γραμματική είναι σαφώς πιο ποικιλόμορφα, καθώς η λογική ιδιαίτερα του δυναμικού προγραμματισμού καταρρέει όσο αυξάνεται η πολυπλοκότητα των πιθανών λέξεων και της τοποθέτησής τους.



Σχήμα 9: Σχηματική παρουσίαση της προτεινόμενης μεθόδου

6 Αξιολόγηση της Μεθοδολογίας

6.1 Datasets

Για το πρώτο πείραμα, που περιλαμβάνει μία μελέτη αφαίρεσης (ablation study) και μία δοκιμή των αποτελεσμάτων του επιλεγμένου μοντέλου, χρησιμοποιήθηκε το GRID Audio-Visual Speech Corpus [1]. Πρόκειται για ένα από τα πιο ευρέως χρησιμοποιούμενα dataset στον τομέα της αντίληψης ομιλίας. Αποτελείται από εγγραφές ήχου και βίντεο (της περιοχής του προσώπου) για 1000 διαφορετικές φράσεις από 34 ομιλητές (18 αρσενικούς και 16 θηλυκούς), συνολικά 34000 προτάσεις.

Το συγκεκριμένο dataset αποτελεί παράδειγμα ενός περιορισμένου (constrained) περιβάλλοντος μάθησης, διότι οι φράσεις που καταγράφονται παρουσιάζουν μία πολύ συγκεκριμένη μορφή. Αποτελούνται από ένα ρήμα εντολής (bin, lay, place, set), έπειτα ένα χρώμα (blue, green, red, white), μία πρόθεση (at, by, in, with), ένα γράμμα (οποιοδήποτε από τα 26 του αγγλικού αλφαβήτου πέραν του w), ένα ψηφίο (από το 0 έως το 9) και τέλος ένα επίρρημα (again, now, please, soon). Έτσι, το λεξιλόγιο είναι πολύ περιορισμένο σε αντίθεση με ένα in the wild dataset, στο οποίο τόσο η σύνταξη των φράσεων όσο και το ίδιο το λεξιλόγιο παρουσιάζουν σαφώς υψηλότερη ποικιλομορφία.

Για τους σκοπούς της συγκεκριμένης μελέτης, η εκπαίδευση περιορίστηκε αποκλειστικά στα 1000 βίντεο του 1ου ηθοποιού (από το s1.zip). Κάθε .mpg βίντεο έχει μήκος 3 δευτερολέπτων, ρυθμό ανανέωσης frames 25fps, ανάλυση 360x288 pixels και στερεοφωνικό (δικαναλικό) ήχο με ρυθμό δειγματοληψίας 44.1kHz. Η βιντεοληψία γίνεται με τον ομιλητή να κοιτάει ευθεία προς την κάμερα με ουδέτερο παρασκήνιο. Τα βίντεο έχουν τίτλους που αποδίδουν τη φράση που λέγεται σε αυτά (π.χ. η φράση "bin green in t 5 soon" λέγεται στο βίντεο με τίτλο bgit5s.mpg), γεγονός που βοηθάει στην εξαγωγή των πραγματικών φωνημάτων (ground truth). Πέραν των βίντεο, το dataset περιλαμβάνει αρχεία ήχου και ένα αρχείο με ακριβείς χρονισμούς λέξεων για κάθε ομιλητή, τα οποία όμως δε χρησιμοποιούνται.

6.2 Κριτήρια Αξιολόγησης

Για την επακριβή αξιολόγηση της μεθοδολογίας και για τη σύγκριση με το state of the art, αποτελεί κρίσιμο βήμα η ορθή επιλογή και ο ακριβής ορισμός των μετρικών και των κριτηρίων αξιολόγησης. Σε όλα (ή κάποια) από τα παρακάτω πειράματα, η μεθοδολογία αξιολογείται με βάση τα παρακάτω κριτήρια:

- Γράφημα Training Loss vs Epoch: αποδίδει την τιμή της συνάρτησης κόστους στα δεδομένα του training split για κάθε epoch της εκπαίδευσης. Για τον υπολογισμό της αντικειμενικής συνάρτησης, ανατρέξτε στην ενότητα 5.2.
- Γράφημα Validation Loss vs Epoch: το ίδιο με παραπάνω αλλά στο validation split.
- Γράφημα Validation Token Error Rate (TER) vs Epoch: ποσοστό εσφαλμένης πρόβλεψης φωνήματος σε επίπεδο token (δηλαδή, στο collapsed sequence και όχι σε επίπεδο για κάθε frame του video) στο validation split για κάθε εποχή. Υπολογίζεται ως η απόσταση edit Levenshtein διά το μήκος αναφοράς. Για πληροφορίες περί του υπολογισμού της απόστασης Levenshtein ανατρέξτε στην ενότητα 3.3.
- Γράφημα Validation Frame Accuracy vs Epoch: ποσοστό ορθών προβλέψεων φωνήματος σε επίπεδο video frame (πριν το sequence collapse) στο validation split για κάθε εποχή. Άρα, αν το βίντεο αποτελείται από T frames, έχουμε

$$val_frame_acc = \frac{\# \text{ correct predictions}}{T}$$

- Γράφημα Training Frame Accuracy vs Epoch: το ίδιο με παραπάνω αλλά στο training split.
- Area Under Curve (AUC): υπολογίζει την επιφάνεια κάτω από την καμπύλη (συνήθως της ακρίβειας στο validation set vs epoch), δίνοντας μία μετρική τόσο για την τελική ακρίβεια όσο και για την ταχύτητα σύγκλισης και για την αποφυγή ταλαντώσεων.

- Test Token Error Rate (TER): ποσοστό εσφαλμένων προβλέψεων φωνημάτων μετά το sequence collapse στο test set. Όπως παραπάνω, αξιοποιεί την απόσταση Levenshtein της πραγματικής και της προβλεπόμενης αλληλουχίας φωνημάτων.
- Test Frame Accuracy: ποσοστό ακριβών προβλέψεων φωνημάτων σε επίπεδο frame, δηλαδή πριν το sequence collapse.

6.3 Πειράματα

Παρακάτω παρουσιάζονται τα πειράματα με τα οποία δοκιμάστηκε η επίδοση της προτεινόμενης μεθοδολογίας.

6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον

Υποπείραμα 1: Μελέτη Αφαίρεσης Για να απομονωθεί η συνεισφορά κάθε σχεδιαστικής επιλογής του μοντέλου, διεξήχθη μία μελέτη αφαίρεσης (ablation study) με 6 διαφορετικές εκδοχές του μοντέλου. Όλες οι εκδοχές αποτελούνται από ένα 3D CNN backbone, αξιολογήθηκαν στο ίδιο dataset με 32 κλάσεις φωνημάτων, εκπαιδεύτηκαν με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5. Η εκπαίδευση έγινε για μέγιστο αριθμό 40 εποχών με μηχανισμό early stopping με παράγοντα υπομονής 12 epochs στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο παρακάτω πίνακας παρουσιάζει τις 6 διαφορετικές εκδοχές που δοκιμάστηκαν.

Πίνακας 1: Οι εκδοχές του μοντέλου που δοκιμάστηκαν


Εκδοχή	Sequence Encoder	Αντικειμενική Συνάρτηση	Targets του CE
V1	2 επίπεδα BiLSTM	Frame-CE + CTC	Viseme-aware soft targets
V2	2 επίπεδα Transformer	Frame-CE + CTC	Viseme-aware soft targets
V3	Projection head μόνο	Frame-CE + CTC	Viseme-aware soft targets
V4	2 επίπεδα BiLSTM	CTC μόνο	N/A (χωρίς frame-CE)
V5	2 επίπεδα BiLSTM	Frame-CE μόνο	Viseme-aware soft targets
V6	2 επίπεδα BiLSTM	Frame-CE + CTC	Hard (identity) targets

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της μελέτης, πρώτα σε μορφή πίνακα και έπειτα με μερικά χαρακτηριστικά γραφήματα.


Να σημειωθεί ότι οι απόλυτες τιμές των τιμών της αντικειμενικής συνάρτησης στα σχήματα 10, 12 και 13 δεν είναι συγκρίσιμες. Συγκεκριμένα, τα μοντέλα με μόνο έναν από τους 2 όρους (είτε μόνο cross entropy είτε μόνο CTC) έχουν αντικειμενικές συναρτήσεις με μικρότερες τιμές σε απόλυτη τιμή, καθώς ο πολλαπλασιαστικός συντελεστής των δύο όρων παραμένει σταθερός. Τα σχήματα στο 14 ωστόσο, που παρουσιάζουν τη συνεισφορά κάθε όρου της αντικειμενικής συνάρτησης χωριστά, είναι απολύτως συγκρίσιμα. Σημαντικό, επίσης, είναι να παρατηρηθεί ότι το μοντέλο V6 παρουσιάζει τη χαμηλότερη τιμή training και validation loss ανάμεσα στα V1, V2, V3 και V6, χωρίς ωστόσο να πετυχαίνει και τη βέλτιστη επίδοση όσον αφορά το test TER. Αυτό οφείλεται στο ότι η χρήση soft targets στα μοντέλα V1, V2 και V3 μοιράζει την πιθανότητα κάθε φωνήματος σε διάφορες όμοιες (οπτικά ή ακουστικά) κλάσεις παράγοντας ένα target με υψηλότερη εντροπία και άρα οδηγώντας σε υψηλότερες τιμές cross entropy, σε σχέση με το one-hot encoding που χρησιμοποιείται για το μοντέλο V6.

Πίνακας 2: Περίληψη των αποτελεσμάτων της μελέτης αφαίρεσης


Variant	Best Val TER	Test TER	Test Frame Acc.	AUC (Val 1 – TER)	Εποχές μέχρι Val TER < 0.20
V1 — BiLSTM + Full Loss	0.1251	0.1219	0.8474	0.7840	8
V2 — Transformer + Full Loss	0.1551	0.1566	0.8394	0.7176	16
V3 — Projection head μόνο	0.2540	0.2464	0.8122	0.6006	Ποτέ
V4 — BiLSTM + CTC Only	0.1977	0.1869	0.4743	0.6005	33
V5 — BiLSTM + Frame-CE Μόνο	0.1555	0.1419	0.8401	0.7402	16
V6 — BiLSTM + Hard Targets	0.1266	0.1289	0.8456	0.7696	9




Σχήμα 10: Γράφημα τιμών αντικειμενικής συνάρτησης στο training set για κάθε epoch




Σχήμα 11: Γράφημα τιμών frame accuracy στο training set για κάθε epoch




Σχήμα 12: Σύγκριση τιμών loss για training και validation κάθε μοντέλου




Σχήμα 13: Γράφημα τιμών αντικειμενικής συνάρτησης στο validation set για κάθε epoch




Σχήμα 14: Ανάλυση συνεισφοράς των όρων της αντικειμενικής συνάρτησης (CE και CTC)



Σχήμα 15: Γράφημα τιμών frame accuracy στο validation set για κάθε epoch



Σχήμα 16: Γράφημα τιμών TER στο validation set για κάθε epoch



Σχήμα 17: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Από τα παραπάνω εξάγεται το συμπέρασμα ότι το μοντέλο της μεθοδολογίας παρουσιάζει την ισχυρότερη επίδοση τόσο όσον αφορά την τελική απόδοση όσο και την ομαλότητα και αποδοτικότητα της εκπαίδευσης, γεγονότα που αποδεικνύονται από την υπεροχή του V1 στις μετρικές test TER, test frame accuracy και AUC. Στις επόμενες παραγράφους δίνεται μία αναλυτική σύγκριση κάθε εκδοχής με την V1, όπως και τα απαραίτητα σχόλια.

Όπως αποδεικνύει η σύγκριση μεταξύ V1 και V3, η σχεδιαστική επιλογή με το υψηλότερο αντίκρισμα στα αποτελέσματα είναι η παρουσία του χρονικού sequence encoder. Εν απουσία του BiLSTM και αξιοποιώντας μόνο ένα γραμμικό projection head, το μοντέλο V3 πετυχαίνει τελικά test TER 0.2464, υπερδιπλασιάζοντας αυτό του μοντέλου V1. Οι υπόλοιπες μετρικές (val TER, val frame accuracy, AUC)

αποδεικνύουν επίσης την αναγκαιότητα χρήσης sequence encoder. Να σημειωθεί, ωστόσο, ότι μετρικές όπως το test frame accuracy, με τιμή 0.812, αποδεικνύουν ότι το μοντέλο πράγματι είναι ικανό να μάθει. Περιορίζεται, ωστόσο, από την έλλειψη της πληροφορίας παρακειμένου (contextual information), το οποίο είναι βασικό στοιχείο για την κατανόηση των φωνημάτων. Το context που προσφέρει η χρήση 3D CNN backbone δεν είναι τόσο πλούσιο όσο αυτό του συνδυασμού 3D CNN και BiLSTM.

Αντικαθιστώντας τα επίπεδα BiLSTM με Transformer ίδιου βάθους (V2), παρατηρούμε μία σημαντική επιδείνωση των αποτελεσμάτων, της τάξης περίπου του 25%. Η πορεία της εκπαίδευσης δείχνει μία πιο αργή βελτίωση του val TER στο V2 σε σχέση με το V1. Ένα ακόμα στοιχείο που αξίζει να σημειωθεί είναι ότι ο μηχανισμός scheduling του ρυθμού μάθησης ReduceLROnPlateau δε πυροδοτήθηκε κατά την εκπαίδευση του V2, ενώ προκλήθηκε 2 φορές κατά την εκπαίδευση του V1, αποδεικνύοντας ότι η σύγκλιση του V2 δεν έχει ακόμα ολοκληρωθεί κατά την 40η εποχή και ότι θα χρειαζόταν υψηλότερο υπολογιστικό κόστος εκπαίδευσης για να παρουσιάσει το V2 παρόμοια αποτελέσματα με αυτά του V1. Μία από τις κύριες αιτίες για τα αποτελέσματα του V2 είναι το μέγεθος του dataset που χρησιμοποιήθηκε, το οποίο περιλαμβάνει μόλις 700 φράσεις. Οι transformer encoders απαιτούν περισσότερα και πιο ποικιλόμορφα δεδομένα για να μάθουν αποδοτικά μοτίβα attention. Αντιθέτως, το inductive bias των BiLSTM για χρονική εξάρτηση, ειδικά για γειτονικό context, λόγω της recurrent αρχιτεκτονικής τους, βρίσκει εύκολα εφαρμογή στην κίνηση των χειλιών, κατά την οποία γειτονικά frames αλληλεξαρτώνται σε υψηλό βαθμό.


Συγκρίνοντας τα μοντέλα V1 και V4, αναδεικνύεται η σημασία του όρου cross entropy της αντικειμενικής συνάρτησης. Το μοντέλο V4 πετυχαίνει στη μετρική test TER τιμή 0.1869, πάνω από 50% επιδεινωμένη επίδοση σε σχέση με το V1. Η διαφορά των δύο μοντέλων γίνεται ιδιαίτερα προφανής με τη μετρική test frame accuracy, η οποία για το V4 είναι μόλις 0.4743, τιμή που ανταποκρίνεται με την τυχαία ανάθεση labels σε πρόβλημα ταξινόμησης με μία σαφώς επικρατέστερη κλάση, αυτήν του blank token (να μην εκφέρεται στο δεδομένο frame κάποιο φώνημα). Τα αποτελέσματα αυτά είναι αναμενόμενα: το σήμα του gradient, παραγόμενο αποκλειστικά μέσω του όρου CTC, οδηγεί το μοντέλο να μάθει να προβλέπει σωστές αλληλουχίες φωνημάτων αλλά όχι ποιες κινήσεις των χειλιών (και άρα ποια frames του βίντεο) παράγουν το οποιοδήποτε φώνημα. Έτσι, η διαφορά στο test TER δεν είναι τόσο μεγάλη όσο στο test frame accuracy.

Από την άλλη, αφαιρώντας τον όρο CTC και διατηρώντας μόνο τον όρο cross entropy της συνάρτησης κόστους (με το μοντέλο V5), επιτυγχάνεται τελικά test TER με τιμή 0.1419, ελαφρώς χειρότερα από το μοντέλο V1, τιμή που αποτελεί τη 3η καλύτερη στη συγκεκριμένη μετρική. Το σημαντικότερο πρόβλημα που αντιμετωπίζει η εκδοχή V5 είναι η ομαλότητα της εκπαίδευσης. Συγκεκριμένα, η καμπύλη validation TER vs epoch παρουσιάζει εμφανείς ταλαντώσεις και η σύγκλιση είναι πιο αργή σε σχέση με τα μοντέλα V1, V2 και V6. Ταυτόχρονα, το γράφημα val loss vs epoch παρουσιάζει στοιχεία overfitting, καθώς η τιμή αυξάνει μετά την 20η εποχή. Έτσι, εξάγεται το συμπέρασμα ότι ο όρος CTC συμβάλλει στην κανονικοποίηση του μοντέλου, προσθέτοντας τη συνθήκη ότι το τελικό σύνολο προβλέψεων φωνημάτων ανά frame θα πρέπει να καταρρέει σε μία λογική αλληλουχία φωνημάτων. Με αυτόν τον τρόπο βελτιώνεται η γενίκευση αλλά και η απόδοση του μοντέλου.


Τέλος, η διαφορά των μοντέλων V1 και V6 έγκειται στα targets του cross entropy της αντικειμενικής συνάρτησης: ενώ το V1 χρησιμοποιεί soft targets με βάση το πόσο όμοια είναι τα φωνήματα, ακουστικά ή οπτικά, το V6 χρησιμοποιεί τα συνήθη hard targets του cross entropy. Το μοντέλο V6 πετυχαίνει τη 2η καλύτερη τιμή test TER (0.1289), ενώ παρουσιάζει εικόνα εκπαίδευσης πολύ παρόμοια με αυτή του μοντέλου V1. Η ελάχιστη διαφορά των δύο εκδοχών φαίνεται να σημαίνει ότι η χρήση των soft targets παρέχει μικρό αλλά ίσως σταδιακά αυξανόμενο πλεονέκτημα με βάση το μέγεθος και την ποικιλομορφία του dataset. Όσο αυξάνεται η συχνότητα παρόμοιων φωνημάτων, τόσο ο μηχανισμός αυτός θα παρείχε περισσότερη ομαλότητα κατά την εκπαίδευση, προστατεύοντας το μοντέλο από θόρυβο labelling σε αμφίβολες περιπτώσεις. Στο μικρό και περιορισμένο dataset που χρησιμοποιείται στο πείραμα αυτό, είναι πιο εύκολο να "αποστηθίσει" το μοντέλο αλληλουχίες φωνημάτων (άρα λέξεων, π.χ. να μάθει ότι το φώνημα /b/ βρίσκεται πριν το φώνημα /i/ για να δημιουργηθεί η λέξη "bin", και όχι τα οπτικά πανομοιότυπα φωνήματα /p/ ή /m/), σε αντίθεση με ένα ευρύτερο in the wild dataset (στο οποίο κάλλιστα θα μπορούσε να περιέχεται και η λέξη "pin" και άρα να πρέπει να προβλεφθεί το /p/ και όχι το /b/).

Υποπείραμα 2: Δοκιμή του επιλεγμένου μοντέλου σε περιορισμένο περιβάλλον Έχοντας καταλήξει στην τελική και βέλτιστη μορφή του μοντέλου και έχοντας επεξηγήσει τη συνεισφορά κάθε σχεδιαστικής επιλογής στο τελικό αποτέλεσμα, ο πειραματισμός συνεχίζεται με μία δοκιμή σε μεγαλύτερο βάθος στο ίδιο dataset (GRID Audio-Visual Speech Corpus). Συγκεκριμένα, πέραν της πρόβλεψης των φωνημάτων, η ανάλυση προχωρά και σε πρόβλεψη λέξεων με γνώση του περιορισμένου περιβάλλοντος της μελέτης, προσομοιώνοντας έτσι ένα σύστημα με πιο πραγματική εφαρμογή.


Η εκπαίδευση έγινε πάλι με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5, στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο μέγιστος αριθμός εποχών αυξήθηκε σε 60, διατηρώντας τον μηχανισμό early stopping με παράγοντα υπομονής 12 epochs. Παρακάτω παρουσιάζονται τα αποτελέσματα του συγκεκριμένου πειράματος:




Σχήμα 18: Γράφημα τιμών του train loss και του κάθε συντελεστή αυτού για κάθε epoch



Σχήμα 19: Γράφημα τιμών του validation loss για κάθε epoch



Σχήμα 20: Γράφημα τιμών του validation TER για κάθε epoch




Σχήμα 21: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Αρχικά, να σημειωθεί ότι στο σχήμα 18, ο συντελεστής CTC της συνάρτησης κόστους παρουσιάζεται πριν τον πολλαπλασιασμό του με τον κατάλληλο συντελεστή, άρα για κάθε epoch (όπως είναι προφανές από το σχήμα), δεν ισχύει $total_loss = frame_ce_loss + ctc_loss$, αλλά $total_loss = frame_ce_loss + 0.3 \times ctc_loss$.

Παρατηρείται ομαλή εκπαίδευση που τελικά οδηγεί σε βέλτιστη τιμή validation loss 1.027 όπως και βέλτιστη τιμή validation TER 0.1273, με τον μηχανισμό early stopping να πυροδοτείται κατά την εποχή 50. Όπως ήταν και αναμενόμενο, τα αποτελέσματα είναι πολύ παρόμοια με αυτά του μοντέλου V1 της μελέτης αφαίρεσης. Οι μικροδιαφορές οφείλονται σε ελάχιστες διαφοροποιήσεις κατά την εκτέλεση των εκπαιδεύσεων και όχι σε κάποια αρχιτεκτονική παράλειψη.

Στο test set, το μοντέλο πετυχαίνει τιμή $frame_ce_loss = 0.8626$, $ctc_loss = 0.461$, $total_loss = 1.0009$ και $ter = 0.1241$. Παρακάτω παρουσιάζεται ο πίνακας σύγχυσης (confusion matrix) των φωνημάτων που προβλέφθηκαν από το μοντέλο σε σχέση με τα πραγματικά (ground truth).



Σχήμα 22: Πίνακας σύγχυσης (confusion matrix) στο test set

Ο πίνακας σύγχυσης παρουσιάζει ισχυρή προβλεπτική ικανότητα, με την κύρια διαγώνιο (το σύνολο των σωστών προβλέψεων) να κυριαρχεί σε σχέση με τον υπόλοιπο πίνακα. Οι κύριες πηγές προβληματισμού είναι η τελευταία σειρά “<inserted>”, η οποία αποτελείται από περιπτώσεις που ένα φώνημα προβλέφθηκε λανθασμένα στη θέση του blank token και η τελευταία στήλη “<missed>” που περιγράφει το αντίστροφο φαινόμενο, όταν δηλαδή δεν προβλέπεται κάποιο φώνημα που όντως υπάρχει αλλά στη θέση του προβλέπεται το blank token. Συγχύσεις όμοιων οπτικά φωνημάτων (π.χ. /d/ και /t/) υπάρχουν αλλά σε ελάχιστο βαθμό, γεγονός που εξηγείται από την περιορισμένη φύση του dataset: το μοντέλο μαθαίνει ότι το dataset αποτελείται από συγκεκριμένες λέξεις και προσαρμόζεται ανάλογα.

Σε συνέχεια των παραπάνω και εκμεταλλευόμενοι τον περιορισμό των λέξεων που χρησιμοποιούνται στο dataset, αναπτύχθηκε ένα script πρόβλεψης φράσεων από την αλληλουχία φωνημάτων. Το script αυτό έχει πλήρη γνώση τόσο του λεξιλογίου του dataset όσο και της γραμματικής που παρουσιάζουν οι φράσεις (θεωρείται γνωστό, δηλαδή, ότι οι φράσεις είναι της μορφής εντολή, χρώμα, πρόθεση, γράμμα, ψηφίο, επίρρημα, όπως και ποιες είναι οι πιθανές λέξεις για κάθε μία από αυτές της κατηγορίες). Με βάση την προφορά του ηθοποιού, δημιουργείται ένα λεξικό που αντιστοιχίζει αλληλουχίες φωνημάτων σε λέξεις. Ο αλγόριθμος που αναπτύχθηκε περιγράφεται με περισσότερη λεπτομέρεια στην ενότητα (ρεφ).


Η χρήση του παραπάνω script στις προβλέψεις του βέλτιστου μοντέλου πετυχαίνει ορθή πρόβλεψη σε επίπεδο λέξης για 87.1% των λέξεων του test set και ακριβή πρόβλεψη σε επίπεδο πρότασης σε ποσοστό 38%. Το κύριο πρόβλημα είναι η πρόβλεψη στην ομάδα των γραμμάτων: μόλις 46% των γραμμάτων προβλέπονται σωστά. Αυτό οφείλεται τόσο στο μέγεθος της ομάδας αυτής (25 υποψήφιας λέξεις έναντι 4 σε άλλες κατηγορίες), όπως και στο μέγεθος της αλληλουχίας των φωνημάτων που αποτελούν ένα γράμμα (συνήθως είναι λιγότερα και άρα η πρόβλεψη είναι πιο επιρρεπής στον θόρυβο). Η υπόθεση αυτή ενισχύεται από την κατηγορία των προθέσεων, η οποία εμφανίζει το δεύτερο χαμηλότερο ποσοστό ορθής πρόβλεψης με 85.3%. Αντιθέτως, στις ομάδες με μεγαλύτερες λέξεις ή με λέξεις που απαρτίζονται από πιο χαρακτηριστικά φωνήματα, η πρόβλεψη ήταν ιδιαίτερα ακριβής: 98% στις εντολές, 99.3% στα

χρώματα, 95.3% στα ψηφία και 98.7% στα επιρρήματα. Τα ποσοστά αυτά είναι εξαιρετικά και αποδεικνύουν ότι οι προβλέψεις τόσο σε επίπεδο φωνήματος από το μοντέλο όσο και σε επίπεδο λέξης από τον αλγόριθμο είναι ιδιαίτερα ικανές στο περιορισμένο περιβάλλον.


Για να κριθεί ο χρονισμός (timing) της πρόβλεψης και όχι μόνο η ορθότητα του περιεχομένου, χρησιμοποιήθηκε το ffmpeg ώστε να υποτιτλιστούν μερικά από τα video του test set με τις λέξεις που προβλέπονται στον χρόνο που προβλέπονται τα φωνήματα τα οποία παράγουν τις λέξεις. Η διαδικασία αυτή δεν μπορεί να παρουσιαστεί στο πλαίσιο της συγκεκριμένης αναφοράς, παρουσιάζει ωστόσο ιδιαίτερα ακριβή αποτελέσματα, ειδικά, φυσικά, όταν η πρόβλεψη ολόκληρης της φράσης είναι σωστή.

6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον


6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων




Σχήμα 23: Γραφήματα τιμών του βέλτιστου val TER για διάφορες τιμές audio SNR




Σχήμα 24: Γραφήματα τιμών train loss per epoch για διάφορες τιμές audio SNR




Σχήμα 25: Γραφήματα τιμών της audio gate στο validation set per epoch για διάφορες τιμές audio SNR




Σχήμα 26: Γραφήματα τιμών της video gate στο validation set per epoch για διάφορες τιμές audio SNR




Σχήμα 27: Γραφήματα τιμών val TER per epoch για διάφορες τιμές audio SNR




Σχήμα 28: Γραφήματα τιμών val loss per epoch για διάφορες τιμές audio SNR




Σχήμα 29: Γράφημα αριθμού εποχών εκπαίδευσης για διάφορες τιμές audio SNR




Σχήμα 30: Γράφημα τιμών της audio gate στο test set για διάφορες τιμές audio SNR




Σχήμα 31: Γράφημα τιμών της video gate στο test set για διάφορες τιμές audio SNR




Σχήμα 32: Γράφημα τιμών της loss function στο test set για διάφορες τιμές audio SNR




Σχήμα 33: Γράφημα τιμών του TER στο test set για διάφορες τιμές audio SNR




Σχήμα 34: Γράφημα τιμών του βέλτιστου val TER για διάφορες τιμές obstructed video frames




Σχήμα 35: Γραφήματα τιμών train loss per epoch για διάφορες τιμές obstructed video frames




Σχήμα 36: Γραφήματα τιμών της audio gate στο validation set per epoch για διάφορες τιμές obstructed video frames




Σχήμα 37: Γραφήματα τιμών της video gate στο validation set per epoch για διάφορες τιμές obstructed video frames




Σχήμα 38: Γραφήματα τιμών val TER per epoch για διάφορες τιμές obstructed video frames




Σχήμα 39: Γραφήματα τιμών val loss per epoch για διάφορες τιμές obstructed video frames




Σχήμα 40: Γράφημα αριθμού εποχών εκπαίδευσης για διάφορες τιμές obstructed video frames




Σχήμα 41: Γράφημα τιμών της audio gate στο test set για διάφορες τιμές obstructed video frames



Σχήμα 42: Γράφημα τιμών της video gate στο test set για διάφορες obstructed video frames



Σχήμα 43: Γράφημα τιμών της loss function στο test set για διάφορες τιμές obstructed video frames



Σχήμα 44: Γράφημα τιμών του TER στο test set για διάφορες τιμές audio SNR

7 Συμπεράσματα και Μελλοντικές Επεκτάσεις

What have I understood from this project? What can I improve in the future?

8 Αναφορές

- [1] Martin Cooke, Jon Barker, Stuart Cunningham, and Xu Shao. The Grid Audio-Visual Speech Corpus, January 2006.
- [2] Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. volume 2006, pages 369–376, 01 2006.
- [3] Alex Graves and Jürgen Schmidhuber. Framewise phoneme classification with bidirectional lstm and other neural network architectures. *Neural Networks*, 18(5):602–610, 2005. IJCNN 2005.
- [4] Marshall Thomas, Edward Fish, and Richard Bowden. VALLR: Visual ASR Language Model for Lip Reading, 2026.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023.