



ARISTOTLE
UNIVERSITY
OF THESSALONIKI

Department of Electrical
and Computer Engineering

Τμήμα Ηλεκτρολόγων Μηχανικών
και Μηχανικών Υπολογιστών

Thesis - Διπλωματική Εργασία

“Talking Heads”: Phoneme Prediction from Muted Video

“Talking Heads”: Πρόβλεψη Φωνημάτων από Βουβό Βίντεο

Όνομα	Βαπόρης Δημήτριος
A.E.M.	10625
Email	dvaporis@ece.auth.gr
Επιβλέπων Καθηγητής	Ντελόπουλος Αναστάσιος

Καλοκαίρι 2026

Περιεχόμενα

Περιεχόμενα	1
1 Περιλήψεις	2
1.1 Summary in English	2
1.2 Περίληψη στα Ελληνικά	2
2 Εισαγωγή	3
2.1 Ορισμός του Προβλήματος	3
2.2 Διαθέσιμες Μέθοδοι	3
2.3 Περιγραφή της Συγκεκριμένης Εργασίας	3
2.4 Δομή της Συγκεκριμένης Αναφοράς	3
3 Τεχνικό Υπόβαθρο	4
4 State of the Art	5
5 Μεθοδολογία	6
5.1 Δομή του προτεινόμενου μοντέλου	6
5.2 Βήματα Post-Processing	6
5.2.1 Αλγοριθμική Πρόβλεψη Λέξεων	6
6 Αξιολόγηση της Μεθοδολογίας	8
6.1 Datasets	8
6.2 Κριτήρια Αξιολόγησης	8
6.3 Πειράματα	9
6.3.1 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον	16
6.3.2 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων	16
7 Συμπεράσματα και Μελλοντικές Επεκτάσεις	17
8 Αναφορές	18

1 Περιλήψεις

1.1 Summary in English

Summary in English.

1.2 Περίληψη στα Ελληνικά

Περίληψη στα Ελληνικά.

2 Εισαγωγή

2.1 Ορισμός του Προβλήματος

What is the problem this work aims to solve? Why is it important? What may be some applications?

2.2 Διαθέσιμες Μέθοδοι

Briefly describe the methods that have been shown to (partially) solve this problem (or subproblems that may exist). Mention Section 3 (State of the Art) for more info.

2.3 Περιγραφή της Συγκεκριμένης Εργασίας

What did I do for this thesis? How did I attempt to solve the problem? About one page.

2.4 Δομή της Συγκεκριμένης Αναφοράς

Describe the structure of this report in about half a page.

3 Τεχνικό Υπόβαθρο

Describe every necessary background element to understand this work. Tools, Definitions etc. Also define a notation (for the input data, the output data, ...) and stick to it for the rest of the Report.

4 State of the Art

A more detailed description of the state of the art I alluded to in the Introduction chapter.

5 Μεθοδολογία

5.1 Δομή του προτεινόμενου μοντέλου

5.2 Βήματα Post-Processing

Όπως παρουσιάστηκε το μοντέλο μέχρι τώρα, είναι ικανό μόνο να προβλέψει φωνήματα από το βουβό βίντεο. Στη συγκεκριμένη υποενότητα, περιγράφονται οι τεχνικές post-processing που εφαρμόστηκαν ώστε η αλληλουχία φωνημάτων να μετατραπεί σε λέξεις, βήμα το οποίο οδηγεί στην επίτευξη του αρχικού στόχου του lip reading.

5.2.1 Αλγοριθμική Πρόβλεψη Λέξεων

Σε εφαρμογές σε περιορισμένο περιβάλλον, όπου το λεξιλόγιο και, προαιρετικά, η γραμματική των φράσεων είναι γνωστά, είναι δυνατόν η πρόβλεψη των λέξεων από την αλληλουχία φωνημάτων να γίνει αλγοριθμικά και χωρίς τη χρήση τεχνητής νοημοσύνης. Για τα παρακάτω, υποθέτουμε (χωρίς βλάβη της γενικότητας και για να γίνει πιο ξεκάθαρη η επεξήγηση της μεθόδου) ότι η ανάλυση γίνεται στο dataset GRID, όπως παρουσιάζεται στην παράγραφο 6.1.

Αρχικά, παράγεται το collapsed sequence φωνημάτων από την αλληλουχία των φωνημάτων που προβλέπεται, ενώνοντας γειτονικά ίδια tokens και απαλείφοντας τα blank tokens, δημιουργώντας μία ομάδα από φωνήματα και τους χρονισμούς τους. Έπειτα, χρησιμοποιείται αλγόριθμος δυναμικού προγραμματισμού ώστε να βρεθεί η τομή των φωνημάτων σε λέξεις και η ανάθεση των προβλεπόμενων λέξεων με το μικρότερο συνολικό κόστος.

Για κάθε υποψήφια λέξη σε κάθε θέση, υπολογίζεται μία τιμή ομοιότητας με την ακολουθία των φωνημάτων που προβλέπεται. Έστω O η πρόβλεψη και T η υποψήφια λέξη. Ορίζεται η βασική απόσταση ως $D(O, T) = \frac{1}{\max(|O|, |T|)} \cdot ED(O, T)$, όπου $ED(O, T)$ είναι η ελάχιστη απόσταση edit της αλληλουχίας φωνημάτων O ώστε να φτάσει στην T . Κάθε φώνημα που πρέπει να αλλαχθεί δεν επηρεάζει με ίδιο τρόπο την $ED(O, T)$. Συγκεκριμένα, όμοια φωνήματα (είτε ακουστικά είτε οπτικά) τιμωρούνται λιγότερο σε σχέση με τελείως διαφορετικά φωνήματα. Το κόστος κάθε αλλαγής, από φώνημα a σε φώνημα b , υπολογίζεται ως εξής:

$$c(a, b) = \begin{cases} 0 & a = b \\ 0.15 & \text{ίδια κλάση viseme και ίδιος τρόπος/τόπος εκφοράς, αλλά διαφορετική φωνοποίηση} \\ 0.35 & \text{ίδια κλάση viseme αλλά όχι μόνο διαφορετική φωνοποίηση} \\ \min(1, \frac{\Delta(a, b)}{4}) & \text{αλλιώς, με διαφορά ιδιοτήτων } \Delta \\ 1 & \text{αν δεν υπάρχει καμία ίδια ιδιότητα} \end{cases}$$

Τότε, το τελικό σκορ ομοιότητας για κάθε υποψήφια λέξη είναι $S(O, T) = D(O, T) - B_{anchor}(O, T) - 0.15B_{rare}(O, T)$, όπου B_{anchor} είναι ένα ισχυρό bonus που δίνεται σε φωνήματα anchor και B_{rare} είναι ένα μικρότερο bonus για σπάνια φωνήματα. Τα φωνήματα anchor είναι φωνήματα που εμφανίζονται μόνο σε μία υποψήφια λέξη κάποιας κατηγορίας. Για παράδειγμα, στις προθέσεις του GRID, το φώνημα /ð/ με ήχο σαν το ελληνικό θήτα εμφανίζεται μόνο στη λέξη with και όχι σε οποιαδήποτε από τις in, by και at. Εάν δεν υπήρχε αυτός ο όρος, μία αλληλουχία φωνημάτων /i/ /ð/ θα οδηγούσε σε πρόβλεψη in και όχι σε πρόβλεψη with, που φαίνεται πιο αληθοφανές, δεδομένου ότι προβλέφθηκε το /ð/ που ανήκει μόνο σε μία λέξη. Με παρόμοιο τρόπο υπολογίζεται και το B_{rare} , αλλά πολλαπλασιάζεται με παράγοντα ανάλογο της σπανιότητας του εκάστοτε φωνήματος.

Με την παραπάνω μέθοδο, είναι δυνατόν να προβλεφθούν και λέξεις εντός του περιορισμένου περιβάλλοντος, πέραν των φωνημάτων. Ο αλγόριθμος αυτός σίγουρα μπορεί να αποτελέσει αντικείμενο βελτίωσης και καλύτερης προσαρμογής στο δεδομένο περιβάλλον στο οποίο γίνεται η κάθε μελέτη, ωστόσο κρίθηκε ότι η τωρινή εκδοχή του είναι αρκετή ώστε να επιδείξει ικανοποιητικά αποτελέσματα. Προφανώς, τα παραπάνω δεν μπορούν να εφαρμοστούν σε μη πεπερασμένο περιβάλλον, στο οποίο τόσο το λεξιλόγιο όσο και η γραμματική είναι σαφώς πιο ποικιλόμορφα, καθώς η λογική ιδιαίτερα του δυναμικού

προγραμματισμού καταρρέει όσο αυξάνεται η πολυπλοκότητα των πιθανών λέξεων και της τοποθέτησής τους.

6 Αξιολόγηση της Μεθοδολογίας

6.1 Datasets

Για το πρώτο πείραμα, που περιλαμβάνει μία μελέτη αφαίρεσης (ablation study) και μία δοκιμή των αποτελεσμάτων του επιλεγμένου μοντέλου, χρησιμοποιήθηκε το GRID Audio-Visual Speech Corpus [1]. Πρόκειται για ένα από τα πιο ευρέως χρησιμοποιούμενα dataset στον τομέα της αντίληψης ομιλίας. Αποτελείται από εγγραφές ήχου και βίντεο (της περιοχής του προσώπου) για 1000 διαφορετικές φράσεις από 34 ομιλητές (18 αρσενικούς και 16 θηλυκούς), συνολικά 34000 προτάσεις.

Το συγκεκριμένο dataset αποτελεί παράδειγμα ενός περιορισμένου (constrained) περιβάλλοντος μάθησης, διότι οι φράσεις που καταγράφονται παρουσιάζουν μία πολύ συγκεκριμένη μορφή. Αποτελούνται από ένα ρήμα εντολής (bin, lay, place, set), έπειτα ένα χρώμα (blue, green, red, white), μία πρόθεση (at, by, in, with), ένα γράμμα (οποιοδήποτε από τα 26 του αγγλικού αλφαβήτου πέραν του w), ένα ψηφίο (από το 0 έως το 9) και τέλος ένα επίρρημα (again, now, please, soon). Έτσι, το λεξιλόγιο είναι πολύ περιορισμένο σε αντίθεση με ένα in the wild dataset, στο οποίο τόσο η σύνταξη των φράσεων όσο και το ίδιο το λεξιλόγιο παρουσιάζουν σαφώς υψηλότερη ποικιλομορφία.

Για τους σκοπούς της συγκεκριμένης μελέτης, η εκπαίδευση περιορίστηκε αποκλειστικά στα 1000 βίντεο του 1ου ηθοποιού (από το s1.zip). Κάθε .mpg βίντεο έχει μήκος 3 δευτερολέπτων, ρυθμό ανανέωσης frames 25fps, ανάλυση 360x288 pixels και στερεοφωνικό (δικαναλικό) ήχο με ρυθμό δειγματοληψίας 44.1kHz. Η βιντεοληψία γίνεται με τον ομιλητή να κοιτάει ευθεία προς την κάμερα με ουδέτερο παρασκήνιο. Τα βίντεο έχουν τίτλους που αποδίδουν τη φράση που λέγεται σε αυτά (π.χ. η φράση “bin green in t 5 soon” λέγεται στο βίντεο με τίτλο bgit5s.mpg), γεγονός που βοηθάει στην εξαγωγή των πραγματικών φωνημάτων (ground truth). Πέραν των βίντεο, το dataset περιλαμβάνει αρχεία ήχου και ένα αρχείο με ακριβείς χρονισμούς λέξεων για κάθε ομιλητή, τα οποία όμως δε χρησιμοποιούνται.

6.2 Κριτήρια Αξιολόγησης

Για την επακριβή αξιολόγηση της μεθοδολογίας και για τη σύγκριση με το state of the art, αποτελεί κρίσιμο βήμα η ορθή επιλογή και ο ακριβής ορισμός των μετρικών και των κριτηρίων αξιολόγησης. Σε όλα (ή κάποια) από τα παρακάτω πειράματα, η μεθοδολογία αξιολογείται με βάση τα παρακάτω κριτήρια:

- Γράφημα Training Loss vs Epoch: αποδίδει την τιμή της συνάρτησης κόστους στα δεδομένα του training split για κάθε epoch της εκπαίδευσης.
- Γράφημα Validation Loss vs Epoch: το ίδιο με παραπάνω αλλά στο validation split.
- Γράφημα Validation Token Error Rate (TER) vs Epoch: ποσοστό εσφαλμένης πρόβλεψης φωνήματος σε επίπεδο token (δηλαδή, στο collapsed sequence και όχι σε επίπεδο για κάθε frame του video) στο validation split για κάθε εποχή. Υπολογίζεται ως η απόσταση edit Levenshtein διά το μήκος αναφοράς.
- Γράφημα Validation Frame Accuracy vs Epoch: ποσοστό ορθών προβλέψεων φωνήματος σε επίπεδο video frame (πριν το sequence collapse) στο validation split για κάθε εποχή.
- Γράφημα Training Frame Accuracy vs Epoch: το ίδιο με παραπάνω αλλά στο training split.
- Area Under Curve (AUC): υπολογίζει την επιφάνεια κάτω από την καμπύλη (συνήθως της ακρίβειας στο validation set vs epoch), δίνοντας μία μετρική τόσο για την τελική ακρίβεια όσο και για την ταχύτητα σύγκλισης και για την αποφυγή ταλαντώσεων.
- Test Token Error Rate (TER): ποσοστό εσφαλμένων προβλέψεων φωνημάτων μετά το sequence collapse στο test set.
- Test Frame Accuracy: ποσοστό ακριβών προβλέψεων φωνημάτων σε επίπεδο frame, δηλαδή πριν το sequence collapse.

6.3 Πειράματα

Present a series of experiments, showcase and compare the results of each experiment to the state of the art and finally comment on each experiment. The following experiments are subject to change:

Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον

Υποπείραμα 1: Μελέτη Αφαίρεσης Για να απομονωθεί η συνεισφορά κάθε σχεδιαστικής επιλογής του μοντέλου, διεξήχθη μία μελέτη αφαίρεσης (ablation study) με 6 διαφορετικές εκδοχές του μοντέλου. Όλες οι εκδοχές αποτελούνται από ένα 3D CNN backbone, αξιολογήθηκαν στο ίδιο dataset με 32 κλάσεις φωνημάτων, εκπαιδεύτηκαν με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5. Η εκπαίδευση έγινε για μέγιστο αριθμό 40 εποχών με μηχανισμό early stopping με παράγοντα υπομονής 12 epochs στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο παρακάτω πίνακας παρουσιάζει τις 6 διαφορετικές εκδοχές που δοκιμάστηκαν.

Πίνακας 1: Οι εκδοχές του μοντέλου που δοκιμάστηκαν


Εκδοχή	Sequence Encoder	Αντικειμενική Συνάρτηση	Targets του CE
V1	2 επίπεδα BiLSTM	Frame-CE + CTC	Viseme-aware soft targets
V2	2 επίπεδα Transformer	Frame-CE + CTC	Viseme-aware soft targets
V3	Projection head μόνο	Frame-CE + CTC	Viseme-aware soft targets
V4	2 επίπεδα BiLSTM	CTC μόνο	N/A (χωρίς frame-CE)
V5	2 επίπεδα BiLSTM	Frame-CE μόνο	Viseme-aware soft targets
V6	2 επίπεδα BiLSTM	Frame-CE + CTC	Hard (identity) targets

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της μελέτης, πρώτα σε μορφή πίνακα και έπειτα με μερικά χαρακτηριστικά γραφήματα.


Να σημειωθεί ότι οι απόλυτες τιμές των τιμών της αντικειμενικής συνάρτησης στα σχήματα 1, 3 και 4 δεν είναι συγκρίσιμες. Συγκεκριμένα, τα μοντέλα με μόνο έναν από τους 2 όρους (είτε μόνο cross entropy είτε μόνο CTC) έχουν αντικειμενικές συναρτήσεις με μικρότερες τιμές σε απόλυτη τιμή, καθώς ο πολλαπλασιαστικός συντελεστής των δύο όρων παραμένει σταθερός. Τα σχήματα στο 5 ωστόσο, που παρουσιάζουν τη συνεισφορά κάθε όρου της αντικειμενικής συνάρτησης χωριστά, είναι απολύτως συγκρίσιμα. Σημαντικό, επίσης, είναι να παρατηρηθεί ότι το μοντέλο V6 παρουσιάζει τη χαμηλότερη τιμή training και validation loss ανάμεσα στα V1, V2, V3 και V6, χωρίς ωστόσο να πετυχαίνει και τη βέλτιστη επίδοση όσον αφορά το test TER. Αυτό οφείλεται στο ότι η χρήση soft targets στα μοντέλα V1, V2 και V3 μοιράζει την πιθανότητα κάθε φωνήματος σε διάφορες όμοιες (οπτικά ή ακουστικά) κλάσεις παράγοντας ένα target με υψηλότερη εντροπία και άρα οδηγώντας σε υψηλότερες τιμές cross entropy, σε σχέση με το one-hot encoding που χρησιμοποιείται για το μοντέλο V6.

Πίνακας 2: Περίληψη των αποτελεσμάτων της μελέτης αφαίρεσης


Variant	Best Val TER	Test TER	Test Frame Acc.	AUC (Val 1 – TER)	Εποχές μέχρι Val TER < 0.20
V1 — BiLSTM + Full Loss	0.1251	0.1219	0.8474	0.7840	8
V2 — Transformer + Full Loss	0.1551	0.1566	0.8394	0.7176	16
V3 — Projection head μόνο	0.2540	0.2464	0.8122	0.6006	Ποτέ
V4 — BiLSTM + CTC Only	0.1977	0.1869	0.4743	0.6005	33
V5 — BiLSTM + Frame-CE Μόνο	0.1555	0.1419	0.8401	0.7402	16
V6 — BiLSTM + Hard Targets	0.1266	0.1289	0.8456	0.7696	9




Σχήμα 1: Γράφημα τιμών αντικειμενικής συνάρτησης στο training set για κάθε epoch




Σχήμα 2: Γράφημα τιμών frame accuracy στο training set για κάθε epoch




Σχήμα 3: Σύγκριση τιμών loss για training και validation κάθε μοντέλου




Σχήμα 4: Γράφημα τιμών αντικειμενικής συνάρτησης στο validation set για κάθε epoch




Σχήμα 5: Ανάλυση συνεισφοράς των όρων της αντικειμενικής συνάρτησης (CE και CTC)



Σχήμα 6: Γράφημα τιμών frame accuracy στο validation set για κάθε epoch



Σχήμα 7: Γράφημα τιμών TER στο validation set για κάθε epoch



Σχήμα 8: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Από τα παραπάνω εξάγεται το συμπέρασμα ότι το μοντέλο της μεθοδολογίας παρουσιάζει την ισχυρότερη επίδοση τόσο όσον αφορά την τελική απόδοση όσο και την ομαλότητα και αποδοτικότητα της εκπαίδευσης, γεγονότα που αποδεικνύονται από την υπεροχή του V1 στις μετρικές test TER, test frame accuracy και AUC. Στις επόμενες παραγράφους δίνεται μία αναλυτική σύγκριση κάθε εκδοχής με την V1, όπως και τα απαραίτητα σχόλια.

Όπως αποδεικνύει η σύγκριση μεταξύ V1 και V3, η σχεδιαστική επιλογή με το υψηλότερο αντίκρισμα στα αποτελέσματα είναι η παρουσία του χρονικού sequence encoder. Εν απουσία του BiLSTM και αξιοποιώντας μόνο ένα γραμμικό projection head, το μοντέλο V3 πετυχαίνει τελικά test TER 0.2464, υπερδιπλασιάζοντας αυτό του μοντέλου V1. Οι υπόλοιπες μετρικές (val TER, val frame accuracy, AUC) αποδεικνύουν επίσης την αναγκαιότητα χρήσης sequence encoder. Να σημειωθεί, ωστόσο, ότι μετρικές όπως το test frame accuracy, με τιμή 0.812, αποδεικνύουν ότι το μοντέλο πράγματι είναι ικανό να μάθει. Περιορίζεται, ωστόσο, από την έλλειψη της πληροφορίας παρακειμένου (contextual information), το οποίο είναι βασικό στοιχείο για την κατανόηση των φωνημάτων. Το context που προσφέρει η χρήση 3D CNN backbone δεν είναι τόσο πλούσιο όσο αυτό του συνδυασμού 3D CNN και BiLSTM.

Αντικαθιστώντας τα επίπεδα BiLSTM με Transformer ίδιου βάθους (V2), παρατηρούμε μία σημαντική επιδείνωση των αποτελεσμάτων, της τάξης περίπου του 25%. Η πορεία της εκπαίδευσης δείχνει μία πιο αργή βελτίωση του val TER στο V2 σε σχέση με το V1. Ένα ακόμα στοιχείο που αξίζει να σημειωθεί είναι ότι ο μηχανισμός scheduling του ρυθμού μάθησης ReduceLROnPlateau δε πυροδοτήθηκε κατά την εκπαίδευση του V2, ενώ προκλήθηκε 2 φορές κατά την εκπαίδευση του V1, αποδεικνύοντας ότι η σύγκλιση του V2 δεν έχει ακόμα ολοκληρωθεί κατά την 40η εποχή και ότι θα χρειαζόταν υψηλότερο υπολογιστικό κόστος εκπαίδευσης για να παρουσιάσει το V2 παρόμοια αποτελέσματα με αυτά του V1. Μία από τις κύριες αιτίες για τα αποτελέσματα του V2 είναι το μέγεθος του dataset που χρησιμοποιήθηκε, το οποίο περιλαμβάνει μόλις 700 φράσεις. Οι transformer encoders απαιτούν περισσότερα και πιο ποικιλόμορφα δεδομένα για να μάθουν αποδοτικά μοτίβα attention. Αντιθέτως, το inductive bias των BiLSTM

για χρονική εξάρτηση, ειδικά για γειτονικό context, λόγω της recurrent αρχιτεκτονικής τους, βρίσκει εύκολα εφαρμογή στην κίνηση των χειλιών, κατά την οποία γειτονικά frames αλληλεξαρτώνται σε υψηλό βαθμό.


Συγκρίνοντας τα μοντέλα V1 και V4, αναδεικνύεται η σημασία του όρου cross entropy της αντικειμενικής συνάρτησης. Το μοντέλο V4 πετυχαίνει στη μετρική test TER τιμή 0.1869, πάνω από 50% επιδεδειγμένη επίδοση σε σχέση με το V1. Η διαφορά των δύο μοντέλων γίνεται ιδιαίτερα προφανής με τη μετρική test frame accuracy, η οποία για το V4 είναι μόλις 0.4743, τιμή που ανταποκρίνεται με την τυχαία ανάθεση labels σε πρόβλημα ταξινόμησης με μία σαφώς επικρατέστερη κλάση, αυτήν του blank token (να μην εκφέρεται στο δεδομένο frame κάποιο φώνημα). Τα αποτελέσματα αυτά είναι αναμενόμενα: το σήμα του gradient, παραγόμενο αποκλειστικά μέσω του όρου CTC, οδηγεί το μοντέλο να μάθει να προβλέπει σωστές αλληλουχίες φωνημάτων αλλά όχι ποιες κινήσεις των χειλιών (και άρα ποια frames του βίντεο) παράγουν το οποιοδήποτε φώνημα. Έτσι, η διαφορά στο test TER δεν είναι τόσο μεγάλη όσο στο test frame accuracy.

Από την άλλη, αφαιρώντας τον όρο CTC και διατηρώντας μόνο τον όρο cross entropy της συνάρτησης κόστους (με το μοντέλο V5), επιτυγχάνεται τελικά test TER με τιμή 0.1419, ελαφρώς χειρότερα από το μοντέλο V1, τιμή που αποτελεί τη 3η καλύτερη στη συγκεκριμένη μετρική. Το σημαντικότερο πρόβλημα που αντιμετωπίζει η εκδοχή V5 είναι η ομαλότητα της εκπαίδευσης. Συγκεκριμένα, η καμπύλη validation TER vs epoch παρουσιάζει εμφανείς ταλαντώσεις και η σύγκλιση είναι πιο αργή σε σχέση με τα μοντέλα V1, V2 και V6. Ταυτόχρονα, το γράφημα val loss vs epoch παρουσιάζει στοιχεία overfitting, καθώς η τιμή αυξάνει μετά την 20η εποχή. Έτσι, εξάγεται το συμπέρασμα ότι ο όρος CTC συμβάλλει στην κανονικοποίηση του μοντέλου, προσθέτοντας τη συνθήκη ότι το τελικό σύνολο προβλέψεων φωνημάτων ανά frame θα πρέπει να καταρρέει σε μία λογική αλληλουχία φωνημάτων. Με αυτόν τον τρόπο βελτιώνεται η γενίκευση αλλά και η απόδοση του μοντέλου.


Τέλος, η διαφορά των μοντέλων V1 και V6 έγκειται στα targets του cross entropy της αντικειμενικής συνάρτησης: ενώ το V1 χρησιμοποιεί soft targets με βάση το πόσο όμοια είναι τα φωνήματα, ακουστικά ή οπτικά, το V6 χρησιμοποιεί τα συνήθη hard targets του cross entropy. Το μοντέλο V6 πετυχαίνει τη 2η καλύτερη τιμή test TER (0.1289), ενώ παρουσιάζει εικόνα εκπαίδευσης πολύ παρόμοια με αυτή του μοντέλου V1. Η ελάχιστη διαφορά των δύο εκδοχών φαίνεται να σημαίνει ότι η χρήση των soft targets παρέχει μικρό αλλά ίσως σταδιακά αυξανόμενο πλεονέκτημα με βάση το μέγεθος και την ποικιλομορφία του dataset. Όσο αυξάνεται η συχνότητα παρόμοιων φωνημάτων, τόσο ο μηχανισμός αυτός θα παρείχε περισσότερη ομαλότητα κατά την εκπαίδευση, προστατεύοντας το μοντέλο από θόρυβο labelling σε αμφίβολες περιπτώσεις. Στο μικρό και περιορισμένο dataset που χρησιμοποιείται στο πείραμα αυτό, είναι πιο εύκολο να "αποστηθίσει" το μοντέλο αλληλουχίες φωνημάτων (άρα λέξεων, π.χ. να μάθει ότι το φώνημα /b/ βρίσκεται πριν το φώνημα /i/ για να δημιουργηθεί η λέξη "bin", και όχι τα οπτικά πανομοιότυπα φωνήματα /p/ ή /m/), σε αντίθεση με ένα ευρύτερο in the wild dataset (στο οποίο κάλλιστα θα μπορούσε να περιέχεται και η λέξη "rin" και άρα να πρέπει να προβλεφθεί το /p/ και όχι το /b/).

Υποπείραμα 2: Δοκιμή του επιλεγμένου μοντέλου σε περιορισμένο περιβάλλον Έχοντας καταλήξει στην τελική και βέλτιστη μορφή του μοντέλου και έχοντας επεξηγήσει τη συνεισφορά κάθε σχεδιαστικής επιλογής στο τελικό αποτέλεσμα, ο πειραματισμός συνεχίζεται με μία δοκιμή σε μεγαλύτερο βάθος στο ίδιο dataset (GRID Audio-Visual Speech Corpus). Συγκεκριμένα, πέραν της πρόβλεψης των φωνημάτων, η ανάλυση προχωρά και σε πρόβλεψη λέξεων με γνώση του περιορισμένου περιβάλλοντος της μελέτης, προσομοιώνοντας έτσι ένα σύστημα με πιο πραγματική εφαρμογή.


Η εκπαίδευση έγινε πάλι με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5, στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας "Αριστοτέλης". Ο μέγιστος αριθμός εποχών αυξήθηκε σε 60, διατηρώντας τον μηχανισμό early stopping με παράγοντα υπομονής 12 epochs. Παρακάτω παρουσιάζονται τα αποτελέσματα του συγκεκριμένου πειράματος:




Σχήμα 9: Γράφημα τιμών του train loss και του κάθε συντελεστή αυτού για κάθε epoch



Σχήμα 10: Γράφημα τιμών του validation loss για κάθε epoch



Σχήμα 11: Γράφημα τιμών του validation TER για κάθε epoch




Σχήμα 12: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Αρχικά, να σημειωθεί ότι στο σχήμα 9, ο συντελεστής CTC της συνάρτησης κόστους παρουσιάζεται πριν τον πολλαπλασιασμό του με τον κατάλληλο συντελεστή, άρα για κάθε epoch (όπως είναι προφανές από το σχήμα), δεν ισχύει $total_loss = frame_ce_loss + ctc_loss$, αλλά $total_loss = frame_ce_loss + 0.3 \times ctc_loss$.

Παρατηρείται ομαλή εκπαίδευση που τελικά οδηγεί σε βέλτιστη τιμή validation loss 1.027 όπως και βέλτιστη τιμή validation TER 0.1273, με τον μηχανισμό early stopping να πυροδοτείται κατά την εποχή 50. Όπως ήταν και αναμενόμενο, τα αποτελέσματα είναι πολύ παρόμοια με αυτά του μοντέλου V1 της μελέτης αφαίρεσης. Οι μικροδιαφορές οφείλονται σε ελάχιστες διαφοροποιήσεις κατά την εκτέλεση των εκπαιδεύσεων και όχι σε κάποια αρχιτεκτονική παράλειψη.

Στο test set, το μοντέλο πετυχαίνει τιμή $frame_ce_loss = 0.8626$, $ctc_loss = 0.461$, $total_loss = 1.0009$ και $ter = 0.1241$. Παρακάτω παρουσιάζεται ο πίνακας σύγχυσης (confusion matrix) των φωνημάτων που προβλέφθηκαν από το μοντέλο σε σχέση με τα πραγματικά (ground truth).



Σχήμα 13: Πίνακας σύγχυσης (confusion matrix) στο test set

Ο πίνακας σύγχυσης παρουσιάζει ισχυρή προβλεπτική ικανότητα, με την κύρια διαγώνιο (το σύνολο

των σωστών προβλέψεων) να κυριαρχεί σε σχέση με τον υπόλοιπο πίνακα. Οι κύριες πηγές προβληματισμού είναι η τελευταία σειρά “<inserted>”, η οποία αποτελείται από περιπτώσεις που ένα φώνημα προβλέφθηκε λανθασμένα στη θέση του blank token και η τελευταία στήλη “<missed>” που περιγράφει το αντίστροφο φαινόμενο, όταν δηλαδή δεν προβλέπεται κάποιο φώνημα που όντως υπάρχει αλλά στη θέση του προβλέπεται το blank token. Συγχύσεις όμοιων οπτικά φωνημάτων (π.χ. /d/ και /t/) υπάρχουν αλλά σε ελάχιστο βαθμό, γεγονός που εξηγείται από την περιορισμένη φύση του dataset: το μοντέλο μαθαίνει ότι το dataset αποτελείται από συγκεκριμένες λέξεις και προσαρμόζεται ανάλογα.

Σε συνέχεια των παραπάνω και εκμεταλλευόμενοι τον περιορισμό των λέξεων που χρησιμοποιούνται στο dataset, αναπτύχθηκε ένα script πρόβλεψης φράσεων από την αλληλουχία φωνημάτων. Το script αυτό έχει πλήρη γνώση τόσο του λεξιλογίου του dataset όσο και της γραμματικής που παρουσιάζουν οι φράσεις (θεωρείται γνωστό, δηλαδή, ότι οι φράσεις είναι της μορφής εντολή, χρώμα, πρόθεση, γράμμα, ψηφίο, επίρρημα, όπως και ποιες είναι οι πιθανές λέξεις για κάθε μία από αυτές της κατηγορίες). Με βάση την προφορά του ηθοποιού, δημιουργείται ένα λεξικό που αντιστοιχίζει αλληλουχίες φωνημάτων σε λέξεις. Ο αλγόριθμος που αναπτύχθηκε περιγράφεται με περρισσότερη λεπτομέρεια στην ενότητα (ρεφ).

Η χρήση του παραπάνω script στις προβλέψεις του βέλτιστου μοντέλου πετυχαίνει ορθή πρόβλεψη σε επίπεδο λέξης για 87.1% των λέξεων του test set και ακριβή πρόβλεψη σε επίπεδο πρότασης σε ποσοστό 38%. Το κύριο πρόβλημα είναι η πρόβλεψη στην ομάδα των γραμμάτων: μόλις 46% των γραμμάτων προβλέπονται σωστά. Αυτό οφείλεται τόσο στο μέγεθος της ομάδας αυτής (25 υποψήφιες λέξεις έναντι 4 σε άλλες κατηγορίες), όπως και στο μέγεθος της αλληλουχίας των φωνημάτων που αποτελούν ένα γράμμα (συνήθως είναι λιγότερα και άρα η πρόβλεψη είναι πιο επιρρεπής στον θόρυβο). Η υπόθεση αυτή ενισχύεται από την κατηγορία των προθέσεων, η οποία εμφανίζει το δεύτερο χαμηλότερο ποσοστό ορθής πρόβλεψης με 85.3%. Αντιθέτως, στις ομάδες με μεγαλύτερες λέξεις ή με λέξεις που απαρτίζονται από πιο χαρακτηριστικά φωνήματα, η πρόβλεψη ήταν ιδιαίτερα ακριβής: 98% στις εντολές, 99.3% στα χρώματα, 95.3% στα ψηφία και 98.7% στα επιρρήματα. Τα ποσοστά αυτά είναι εξαιρετικά και αποδεικνύουν ότι οι προβλέψεις τόσο σε επίπεδο φωνήματος από το μοντέλο όσο και σε επίπεδο λέξης από τον αλγόριθμο είναι ιδιαίτερα ικανές στο περιορισμένο περιβάλλον.

Για να κριθεί ο χρονισμός (timing) της πρόβλεψης και όχι μόνο η ορθότητα του περιεχομένου, χρησιμοποιήθηκε το ffmpeg ώστε να υποτιτλιστούν μερικά από τα video του test set με τις λέξεις που προβλέπονται στον χρόνο που προβλέπονται τα φωνήματα τα οποία παράγουν τις λέξεις. Η διαδικασία αυτή δεν μπορεί να παρουσιαστεί στο πλαίσιο της συγκεκριμένης αναφοράς, παρουσιάζει ωστόσο ιδιαίτερα ακριβή αποτελέσματα, ειδικά, φυσικά, όταν η πρόβλεψη ολόκληρης της φράσης είναι σωστή.

6.3.1 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον

6.3.2 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων

7 Συμπεράσματα και Μελλοντικές Επεκτάσεις

What have I understood from this project? What can I improve in the future?

8 Αναφορές

- [1] Martin Cooke, Jon Barker, Stuart Cunningham, and Xu Shao. The Grid Audio-Visual Speech Corpus, January 2006.
- [2] Marshall Thomas, Edward Fish, and Richard Bowden. VALLR: Visual ASR Language Model for Lip Reading, 2026.