



ARISTOTLE
UNIVERSITY
OF THESSALONIKI

Department of Electrical
and Computer Engineering

Τμήμα Ηλεκτρολόγων Μηχανικών
και Μηχανικών Υπολογιστών

Thesis - Διπλωματική Εργασία

“Talking Heads”: Phoneme Prediction from Video

“Talking Heads”: Πρόβλεψη Φωνημάτων από Βίντεο

Όνομα	Βαπόρης Δημήτριος
A.E.M.	10625
Email	dvaporis@ece.auth.gr
Επιβλέπων Καθηγητής	Ντελόπουλος Αναστάσιος

Εαρινό Εξάμηνο 2026

Περιεχόμενα

Περιεχόμενα	1
1 Περιλήψεις	2
1.1 Summary in English	2
1.2 Περίληψη στα Ελληνικά	3
2 Εισαγωγή	4
2.1 Ορισμός του Προβλήματος	4
2.2 Διαθέσιμες Μέθοδοι	5
2.3 Περιγραφή της Συγκεκριμένης Εργασίας	5
2.4 Δομή της Συγκεκριμένης Αναφοράς	6
3 Τεχνικό Υπόβαθρο	8
3.1 Φωνήματα και Visemes	8
3.2 Έννοιες Μηχανικής Μάθησης	9
3.3 Άλλες Χρήσιμες Έννοιες	11
4 State of the Art	14
5 Μεθοδολογία	16
5.1 Προεπεξεργασία Δεδομένων	16
5.1.1 Εξαγωγή της περιοχής των χειλιών	16
5.1.2 Εξαγωγή φωνημάτων για κάθε frame	18
5.1.3 Data Augmentation	19
5.1.4 Επιπλέον βήματα κατά τη δοκιμή audiovisual μοντέλου	20
5.2 Δομή του προτεινόμενου μοντέλου	23
5.3 Audiovisual Μοντέλο	29
5.4 Βήματα Post-Processing	36
5.4.1 Αλγοριθμική Πρόβλεψη Λέξεων	36
5.4.2 Πρόβλεψη Φράσεων από Αλληλουχία Φωνημάτων μέσω LLM	37
6 Αξιολόγηση της Μεθοδολογίας	39
6.1 Datasets	39
6.2 Κριτήρια Αξιολόγησης	39
6.3 Πειράματα	40
6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον	40
6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον	48
6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων	48
7 Συμπεράσματα και Μελλοντικές Επεκτάσεις	64
7.1 Συμπεράσματα	64
7.2 Μελλοντικές επεκτάσεις	66
8 Αναφορές	67

1 Περιλήψεις

1.1 Summary in English

This thesis aims to solve the problem of human speech recognition using visual cues, more specifically a video of the speech in question. This is a problem very similar to the classic problem of Automatic Speech Recognition (ASR) and is thereby often called Visual Speech Recognition (VSR) or Audio-Visual Speech Recognition (AVSR), in the cases where both audio as well as video cues are used to predict speech. The field of “lip reading” has grown immensely in the last few years, especially since the advent of Transformers and the ability to train large artificial intelligence models using deep learning. Recent studies tend to divide the problem of VSR into two separate sub-problems; first, the prediction of phonemes (the smallest units containing phonetic information for human speech) and second, the combination of the predicted phonemes so as to predict words and, ultimately, phrases that the original speaker uttered.

During this particular work, more emphasis is placed on solving the first sub-problem, more specifically the problem of phoneme prediction using the video of a speaker. An artificial intelligence model is developed, which takes in as input the video of the speaker, centered around the area of the lips and without auditory information and returns its predicted phonemes per video frame. This model contains a 3D Convolutional Neural Network (CNN) responsible for the extraction of visual features, as well as a BiLSTM architecture as a Sequence Encoder. Moreover, a similar model is implemented which takes in as input both the video of the area of the lips as well as audio cues. This audio-visual model is very similar to the visual model, since it also uses CNNs for the feature extraction process, for both video and audio. A cross-attention mechanism is then applied to these extracted features, followed by a fusion block, which is gated by the reliability of each modality at any given time. Lastly, a BiLSTM architecture is again used as the Sequence Encoder.

The experimental process of this work consists of three separate experiments. During the first, the visual model is benchmarked in a constrained environment, in terms of both the vocabulary spoken by the speaker as well as the syntax they employ. The first sub-experiment is an ablation study, which produces the final proposed method as the model with the best results. The second sub-experiment studies the performance of the proposed method more in-depth, also using an algorithm for word prediction based on the predicted phonemes, which takes advantage of the constraints present in the chosen dataset. The goal of the second experiment is to test the performance of the proposed method in an unconstrained environment, using an “in the wild” dataset. However, since access to a particular popular “in the wild” dataset was not granted, the completion of this experiment was not made possible and the performances of various state of the art models were included for the sake of completeness. The completion of this experiment is mentioned as the most important future expansion of this study. Lastly, the third experiment tested the performance of the proposed audio-visual method, in the same constrained environment, but this time including noise in both modalities. During the first sub-experiment, the results of increasing audio SNR are studied, whereas during the second sub-experiment, the model is tested during conditions where the visual noise is increased.

1.2 Περίληψη στα Ελληνικά

Η συγκεκριμένη εργασία ασχολείται με το πρόβλημα της αναγνώρισης της ανθρώπινης ομιλίας αξιοποιώντας οπτικά μέσα, δηλαδή βίντεο της ομιλίας. Είναι πρόβλημα συγγενικό με το κλασικό πρόβλημα της αυτόματης αναγνώρισης ομιλίας (Automatic Speech Recognition - ASR) και αποκαλείται συχνά Οπτική Αναγνώριση Ομιλίας (Visual Speech Recognition - VSR) ή Οπτικοακουστική Αναγνώριση Ομιλίας (Audio-Visual Speech Recognition - AVSR), σε περίπτωση που χρησιμοποιούνται και ηχητικά στοιχεία, πέραν των οπτικών. Ο τομέας της “αναγνώρισης χειλιών” (lip reading) έχει γνωρίσει τον τελευταίο καιρό σημαντική ανάπτυξη, ιδιαίτερα με την έλευση των Transformers και τη δυνατότητα εκπαίδευσης μοντέλων αξιοποιώντας τη βαθιά μάθηση. Πρόσφατες μελέτες τείνουν να διαχωρίσουν το πρόβλημα της αναγνώρισης της ομιλίας σε 2 υπο-προβλήματα: αφενός την αναγνώριση των φωνημάτων (των ελάχιστων φωνητικών τμημάτων της ανθρώπινης ομιλίας) και αφετέρου τον συνδυασμό των προβλεπόμενων φωνημάτων για την πρόβλεψη λέξεων και, τελικά, φράσεων.

Στα πλαίσια της εργασίας μελετάται η επίλυση του πρώτου υπο-προβλήματος, δηλαδή της πρόβλεψης φωνημάτων από βίντεο ενός ομιλητή. Αναπτύσσεται μοντέλο τεχνητής νοημοσύνης το οποίο δέχεται ως είσοδο βουβό βίντεο της περιοχής των χειλιών και επιστρέφει ως έξοδο τις προβλέψεις του για το ποιο φώνημα εκφέρεται σε κάθε frame του βίντεο. Το μοντέλο αυτό αξιοποιεί ένα 3D συνελικτικό νευρωνικό δίκτυο (CNN) για την εξαγωγή features από το βίντεο και BiLSTM ως Sequence Encoder. Παράλληλα, σχεδιάζεται μοντέλο που δέχεται ως είσοδο τόσο το βίντεο της περιοχής των χειλιών όσο και ηχητικά στοιχεία. Το οπτικο-ακουστικό μοντέλο ακολουθεί λογική παρόμοια με αυτή του οπτικού μοντέλου, αξιοποιώντας CNNs για την εξαγωγή των οπτικών και ακουστικών χαρακτηριστικών. Στα χαρακτηριστικά εξαγόμενα από κάθε modality εφαρμόζεται μηχανισμός cross-attention, ενώ τα αποτελέσματα αυτού συνενώνονται με βάση την αξιοπιστία του κάθε modality για κάθε χρονική στιγμή. Τέλος, εφαρμόζεται και πάλι BiLSTM ως Sequence Encoder.

Η πειραματική διαδικασία της εργασίας αυτής αποτελείται από 3 πειράματα. Κατά το πρώτο πείραμα, δοκιμάζεται η επίδοση του οπτικού μοντέλου σε περιβάλλον περιορισμένο τόσο ως προς το λεξιλόγιο όσο και ως προς το συντακτικό του. Στο πρώτο υπο-πείραμα, πραγματοποιείται μία μελέτη αφαίρεσης, από την οποία προκύπτει η προτεινόμενη μεθοδολογία ως αυτή με τις βέλτιστες επιδόσεις. Στο δεύτερο υπο-πείραμα, μελετάται σε μεγαλύτερο βάθος η επίδοση του προτεινόμενου μοντέλου, αξιοποιώντας και αλγοριθμικό μηχανισμό πρόβλεψης λέξεων από τα φωνήματα. Στόχος του δεύτερου πειράματος είναι η μελέτη της επίδοσης της προτεινόμενης μεθοδολογίας σε περιβάλλον μη περιορισμένο από το λεξιλόγιο και το συντακτικό, δηλαδή σε in the wild συνθήκες. Καθώς δεν κατέστη δυνατή η απόκτηση πρόσβασης σε διαδεδομένο in the wild dataset του χώρου, σημειώθηκαν οι επιδόσεις των state of the art μοντέλων για λόγους πληρότητας και αναφέρθηκε η διεκπεραίωση του συγκεκριμένου πειράματος ως η σημαντικότερη μελλοντική επέκταση. Τέλος, στο 3ο πείραμα μελετήθηκε η επίδοση της προτεινόμενης οπτικο-ακουστικής μεθοδολογίας σε περιβάλλον περιορισμένο αλλά επηρεασμένο από θόρυβο, τόσο ηχητικό όσο και οπτικό. Στο πρώτο υπο-πείραμα μελετάται η επίδραση της αύξησης του SNR του ηχητικού σήματος στην επίδοση του μοντέλου, ενώ στο δεύτερο υπο-πείραμα παρουσιάζονται τα αποτελέσματα της αύξησης του οπτικού θορύβου στις προβλέψεις του μοντέλου.

2 Εισαγωγή

2.1 Ορισμός του Προβλήματος

Η συγκεκριμένη εργασία αντιμετωπίζει το πρόβλημα του “διαβάσματος” των χειλιών (lip reading) ή, αλλιώς, της αναγνώρισης της ομιλίας αξιοποιώντας οπτικά στοιχεία, παραδείγματος χάριν από βίντεο ενός ομιλητή, του οποίου ο ήχος είναι επηρεασμένος από θόρυβο ή απουσιάζει πλήρως. Το πρόβλημα αυτό αποτελεί παραλλαγή του κλασσικού προβλήματος της Αυτόματης Αναγνώρισης Ομιλίας (Automatic Speech Recognition - ASR), στόχος του οποίου είναι η μετατροπή της ομιλούμενης γλώσσας σε γραπτή μορφή, αναλύοντας κατάλληλα την κυματομορφή του ηχητικού σήματος. Για τον λόγο αυτό, συχνά δίνεται στο πρόβλημα που αντιμετωπίζεται στη μελέτη αυτή ο τίτλος “Οπτική Αναγνώριση Ομιλίας” (Visual Speech Recognition - VSR) ή, σε περίπτωση που συνδυάζονται οπτικά αλλά και ακουστικά στοιχεία ως είσοδοι, “Οπτικο-Ακουστική Αναγνώριση Ομιλίας” (Audio-Visual Speech Recognition - AVSR).

Λύση του προβλήματος αποτελεί κατάλληλη μέθοδος η οποία, δεδομένου ενός βίντεο ομιλητή, από το οποίο είτε απουσιάζει (VSR) είτε συνυπάρχει (AVSR) το ηχητικό σήμα, αναγνωρίζει την ομιλία που περιέχεται σε αυτό και την αναπαράγει σε γραπτή μορφή - προβλέπει, δηλαδή, λέξεις και φράσεις που εκφέρει ένας ομιλητής αξιοποιώντας είτε αποκλειστικά οπτικά είτε οπτικοακουστικά στοιχεία. Ιδιαίτερα στην περίπτωση που ο ήχος απουσιάζει πλήρως (VSR), το πρόβλημα αυτό είναι σημαντικά δυσκολότερο από το παραδοσιακό πρόβλημα του ASR, καθώς το σήμα του βίντεο συχνά δεν παρέχει αρκετές φωνολογικές πληροφορίες ώστε η πρόβλεψη λέξης αξιοποιώντας αποκλειστικά αυτό να είναι μονοσήμαντη. Για παράδειγμα, οι αγγλικές λέξεις “bin” και “pin” παρουσιάζουν πανομοιότυπη όψη κατά την εκφορά τους, με αποτέλεσμα η διαφοροποίηση μεταξύ τους χρησιμοποιώντας αποκλειστικά οπτικά στοιχεία να είναι αδύνατη, ενώ η διαφοροποίηση με ακουστικά μέσα είναι μεν δύσκολη αλλά εφικτή. Το πρόβλημα αυτό είναι κεντρικό στον τομέα του VSR και παρουσιάζεται εκτενώς σε επόμενα κεφάλαια. Επίσης, το βίντεο είναι εν γένει μέσο το οποίο αποτελείται από πολλά περισσότερα δεδομένα από αυτά που είναι πραγματικά χρήσιμα για την αναγνώριση της ομιλίας (π.χ. το παρασκήνιο ενός ομιλητή, ή frames στα οποία ο ομιλητής δεν ομιλεί), σε αντίθεση με τον ήχο, στον οποίο, θεωρώντας έλλειψη θορύβου, ολόκληρο το σήμα περιέχει χρήσιμα φωνολογικά χαρακτηριστικά, όσο ο εκφωνητής ομιλεί.

Στην περίπτωση του προβλήματος του AVSR, έγκυρη λύση αποτελεί οποιαδήποτε μέθοδος που “παντρεύει” κατάλληλα την πληροφορία του ηχητικού σήματος με αυτή του βίντεο, ώστε να προβλέπεται ορθά η ομιλία. Σε περιβάλλοντα στα οποία εφαρμόζεται και υπάρχει θόρυβος, αυτό σημαίνει ότι η μέθοδος αναγνωρίζει την αξιοπιστία των δύο modalities και με βάση αυτήν τα συνδυάζει κατάλληλα ώστε να προβλέψει τα λεγόμενα του ομιλητή. Για παράδειγμα, όταν υπάρχουν τεχνικά προβλήματα κατά την καταγραφή του βίντεο (θόλωμα, πάγωμα, ...) ή όταν παρεμβάλλεται εμπόδιο ανάμεσα στην κάμερα και στον ομιλητή, το μοντέλο πρέπει να συμπεραίνει ότι τα χαρακτηριστικά που εξάγονται από το βίντεο είναι μη αξιόπιστα και άρα να βασίζει την πρόβλεψή του κυρίως στο ηχητικό σήμα. Αντίθετα, όταν το ηχητικό σήμα αλλοιώνεται από θόρυβο, λόγω π.χ. βαβούρας μεταξύ των θεατών μίας ομιλίας, ή όταν υπάρχουν τεχνικά προβλήματα κατά την καταγραφή του ήχου, όπως “κόψιμο” του μικροφώνου, το μοντέλο οφείλει να αξιοποιεί τα χαρακτηριστικά του βίντεο σε υψηλότερο βαθμό.

Πιθανές εφαρμογές ενός επιτυχημένου μοντέλου που επιλύει το πρόβλημα του VSR ή του AVSR υπάρχουν σε οποιονδήποτε τομέα της ζωής που είναι αναγκαία η επικοινωνία μεταξύ ανθρώπων. Για παράδειγμα, ένα κατάλληλο σύστημα μπορεί να υποστηρίξει την επικοινωνία ατόμων με πλήρη ή μερική αναπηρία, όπως των κωφών ή των βαρήκων, με τους συνανθρώπους τους, μια και θα μπορούσαν να καταλάβουν την ομιλία δίχως την ανάγκη για νοηματική γλώσσα (την οποία οι περισσότεροι - δυστυχώς - δε γνωρίζουμε). Μία άλλη πιθανή εφαρμογή είναι σε συστήματα Augmented Reality (AR), ώστε να ενισχύσει την κατανόηση της ομιλίας σε καθημερινά περιβάλλοντα, τα οποία συχνά χαρακτηρίζονται από θόρυβο. Σκεφτείτε ένα αμφιθέατρο με φοιτητές που προκαλούν τη συνηθισμένη βαβούρα - το σύστημα θα αξιοποιούσε τόσο τα οπτικά όσο και τα ακουστικά στοιχεία της ομιλίας του καθηγητή ή της καθηγήτριας, επιτρέποντας στους φοιτητές να αντιλαμβάνονται το περιεχόμενο του λόγου του/της. Ακόμη και σε τομείς που ο θόρυβος δεν οφείλεται σε ανθρώπινη ομιλία αλλά μηχανήματα, π.χ. εργοτάξια, μπορεί να αξιοποιηθεί ένα σύστημα AVSR για να ενισχύεται η ικανότητα των ανθρώπων να επικοινωνούν και

άρα να επιταχύνεται και να γίνεται πιο ασφαλές το έργο τους.

2.2 Διαθέσιμες Μέθοδοι

Το VSR ή, όπως αλλιώς ονομάζεται, Automatic Lip Reading, έχει γνωρίσει τα τελευταία χρόνια σημαντική πρόοδο, ξεκινώντας από απλά μοντέλα ταξινόμησης απομονωμένων frames σε φωνήματα ή visemes (βλ. 3.1) και φτάνοντας πλέον σε συστήματα end-to-end που αξιοποιούν τη βαθιά μάθηση (deep learning) και προβλέπουν από το βίντεο απ'ευθείας το περιεχόμενο της ομιλίας. Αρχιτεκτονικές όπως το LipNet [4] και το Watch, Listen, Attend and Spell (WLAS, [7] καθιέρωσαν τη χρήση 3D συνελκτικών νευρωνικών δικτύων (τόσο στους 2 χωρικούς όσο και στον χρονικό άξονα), ακολουθούμενα από decoders βασισμένους είτε στη λογική των recurrent νευρωνικών δικτύων είτε στον μηχανισμό του attention, εκπαιδευόμενων είτε με Connectionist Temporal Classification (βλ. 3.2) είτε με αντικειμενικές συναρτήσεις sequence-to-sequence. Μετέπειτα δουλειές έχουν αξιοποιήσει τους Transformers ως temporal encoders, ενώ άλλες σημαντικές μελέτες έχουν στραφεί προς την προεκπαίδευση οπτικο-ακουστικών μοντέλων σε μεγάλη κλίμακα με self-supervised προβλήματα, όπως το AV-HuBERT [26], το οποίο μαθαίνει κοινές αναπαραστάσεις του ήχου και του βίντεο από unlabelled δεδομένα, ή την αυτόματη δημιουργία labels και την ενίσχυση της επίβλεψης, όπως το Auto-AVSR [19], που χρησιμοποιεί ήδη υπάρχοντα ASR μοντέλα για την επέκταση των labelled δεδομένων.

Πρόσφατα έχει στραφεί η προσοχή στον διαχωρισμό του βασικού προβλήματος του VSR σε δύο υπο-προβλήματα, αφενός την πρόβλεψη των φωνημάτων (βλ. 3.1) και αφετέρου τον συνδυασμό των προβλεπόμενων φωνημάτων για την ανακατασκευή λέξεων και, τελικά, φράσεων. Τέτοιο είναι και το σύστημα που προτείνεται από το VALLR [28], το οποίο πετυχαίνει state-of-the-art επιδόσεις σε πρόβλεψη λέξεων, χρησιμοποιώντας πολύ λιγότερα labelled δεδομένα σε σχέση με τα μοντέλα με τις αμέσως καλύτερες επιδόσεις. Σε αυτήν τη μεθοδολογία βασίζεται σε μεγάλο βαθμό η δουλειά της συγκεκριμένης διπλωματικής. Όπως περιγράφεται και παρακάτω στην ενότητα 2.3, η εργασία αυτή εστιάζει κυρίως στο υπο-πρόβλημα της πρόβλεψης φωνημάτων και όχι τόσο στο δεύτερο υπο-πρόβλημα, αυτό του συνδυασμού των φωνημάτων.

Εκτενέστερη αναφορά στο σχετικό State of the Art για το πρόβλημα του VSR και του AVSR βρίσκεται στο κεφάλαιο 4.

2.3 Περιγραφή της Συγκεκριμένης Εργασίας

Όπως αναφέρθηκε και παραπάνω, η εργασία αυτή εστιάζει σε σημαντικό βαθμό στην επίλυση του πρώτου υποπροβλήματος, την πρόβλεψη, δηλαδή, φωνημάτων είτε αποκλειστικά από το βίντεο, μέσω του visual μοντέλου (βλ. 5.2), είτε μέσω του βίντεο και του ήχου, αξιοποιώντας το audiovisual μοντέλο (βλ. 5.3). Για την επίλυση του 2ου προβλήματος, του συνδυασμού των προβλεπόμενων φωνημάτων ώστε να σχηματιστούν λέξεις και φράσεις, δε δαπανήθηκε ιδιαίτερος χρόνος, καθώς χρησιμοποιήθηκε αποκλειστικά για να παρουσιαστούν τα αποτελέσματα των μοντέλων με μορφή πιο κατανοητή και όχι για να δοκιμαστεί κάποια νέα μέθοδος.

Αναπτύχθηκε, αρχικά, το visual μοντέλο, το οποίο αποτελείται από ένα Front-End συνελκτικού δικτύου τριών διαστάσεων, ακολουθούμενο από BiLSTM Sequence Encoder και μίας γραμμικής στρώσης ταξινόμησης. Το μοντέλο εκπαιδεύεται μέσω αντικειμενικής συνάρτησης που περιλαμβάνει επίβλεψη τόσο σε επίπεδο frame, μέσω ενός όρου cross-entropy, όσο και σε επίπεδο αλληλουχίας φωνημάτων, αξιοποιώντας έναν όρο CTC. Το μοντέλο παρουσιάζεται αναλυτικότερα στην ενότητα 5.2.

Για την εκπαίδευση του μοντέλου αυτού, καθώς χρησιμοποιείται όρος cross-entropy, ήταν αναγκαία η γνώση ποιου φωνήματος εκφωνείται σε κάθε frame του κάθε βίντεο. Αναπτύχθηκε αλγόριθμος εξαγωγής φωνημάτων για κάθε frame, αξιοποιώντας τόσο την πραγματική φράση που εκφωνείται (εφ' όσον είναι γνωστή) όσο και pre-trained μοντέλα που προβλέπουν φωνήματα από τον ήχο του κάθε βίντεο. Έτσι, συνδυάζεται η πληροφορία των αναμενόμενων φωνημάτων από την ground truth φράση και του χρονισμού εκφοράς από την πρόβλεψη του pre-trained μοντέλου. Για μείωση των δεδομένων που εισέρχονται στο μοντέλο, εξήχθη από κάθε βίντεο η περιοχή των χειλιών, χρησιμοποιώντας πάλι pre-trained

μοντέλα. Αναπτύχθηκε μέθοδος δημιουργίας soft targets για τα φωνήματα, με βάση την ομοιότητά τους (οπτική και ακουστική). Εφαρμόστηκε data augmentation στα βίντεο ώστε να αυξηθεί η ευρωστία της εκπαίδευσης. Τα βήματα αυτά εξηγούνται αναλυτικότερα στην ενότητα 5.1. Αναπτύχθηκε αλγόριθμος πρόβλεψης φράσεων από αλληλουχία φωνημάτων, δεδομένων των περιορισμών στο λεξιλόγιο και στο συντακτικό ενός dataset, ο οποίος παρουσιάζεται στην υποενότητα 5.4.

Μετά, αναπτύχθηκε το audiovisual μοντέλο, με λογική παρόμοια με αυτή του visual μοντέλου. Αποτελείται από κατάλληλα συνελκτικά νευρωνικά δίκτυα για την πληροφορία του βίντεο και του ήχου. Έπειτα, εφαρμόζεται μηχανισμός Attention μεταξύ των features εξαγόμενων από το βίντεο και από τον ήχο, ώστε να συνδυάζονται οι πληροφορίες αυτές. Ακολουθεί συνένωση των δύο feature vectors με κατάλληλα gates που επηρεάζονται από την αξιοπιστία του κάθε modality κάθε χρονική στιγμή (πληροφορία που θεωρείται γνωστή, άρα δε χρειάζεται να προβλεφθεί από το μοντέλο). Τέλος, ακολουθεί Sequence Encoder (είτε BiLSTM είτε Transformer) και γραμμικός ταξινομητής. Το μοντέλο και πάλι εκπαιδεύεται χρησιμοποιώντας συνάρτηση με όρους cross-entropy και CTC. Το μοντέλο παρουσιάζεται αναλυτικότερα στην ενότητα 5.3.

Ειδικά για το μοντέλο αυτό, χρησιμοποιούνται μερικά περαιτέρω βήματα Pre-Processing, συγκεκριμένα η πρόβλεψη της αξιοπιστίας του βίντεο και του ήχου για κάθε χρονική στιγμή, η προσθήκη θορύβου σε οποιοδήποτε από τα δύο modalities και ο υπολογισμός των Mel-Spectrograms των ηχητικών σημάτων, τα οποία αποτελούν την είσοδο της πληροφορίας του ήχου στο μοντέλο. Τα βήματα αυτά παρουσιάζονται στην υποενότητα 5.1.4.

Η επίδοση των μοντέλων αυτών δοκιμάστηκε σε μία σειρά 3 πειραμάτων. Το πρώτο πείραμα (βλ. 6.3.1) αποτελείται από 2 υπο-πειράματα, το πρώτο εκ των οποίων αφορά μία μελέτη αφαίρεσης (ablation study) της προτεινόμενης μεθοδολογίας για το visual μοντέλο. Συγκεκριμένα, δοκιμάζονται μοντέλα με διαφορετικό Sequence Encoder (BiLSTM, Transformer ή καθόλου), με διαφορετικές loss functions (μόνο CTC, μόνο cross-entropy ή συνδυασμός των δύο) και με χρήση ή χωρίς των soft targets. Το μοντέλο που αναδεικνύεται βέλτιστο από αυτή τη διαδικασία δοκιμάζεται περαιτέρω στο υπο-πείραμα 2, κατά το οποίο εφαρμόζεται και η πρόβλεψη λέξεων (πέραν των φωνημάτων). Χρησιμοποιείται το GRID dataset (βλ. 6.1), περιβάλλον δηλαδή περιορισμένο ως προς το λεξιλόγιο και το συντακτικό.

Το δεύτερο πείραμα (βλ. 6.3.2) είχε σκοπό τη δοκιμή του προτεινόμενου visual μοντέλου σε in the wild περιβάλλον, με τη χρήση του ευρέως διαδεδομένου στον τομέα LRS2 dataset. Παρά το γεγονός ότι ακολουθήθηκαν τα απαιτούμενα βήματα και η συμπλήρωση αίτησης για απόκτηση πρόσβασης στο συγκεκριμένο dataset, έως τώρα δεν έχει ληφθεί επιβεβαίωση για την άδεια χρήσης και ως εκ τούτου ήταν αδύνατον να ολοκληρωθεί το πείραμα. Συμπεριλήφθηκαν, για λόγους πληρότητας, οι επιδόσεις άλλων state of the art μοντέλων, ενώ αναφέρθηκε η διεξαγωγή του συγκεκριμένου πειράματος ως η βασική μελλοντική επέκταση.

Τέλος, το τρίτο πείραμα (βλ. ??) αφορούσε τη δοκιμή του audiovisual μοντέλου σε περιβάλλον περιορισμένο (χρησιμοποιήθηκε και πάλι το GRID dataset, βλ. 6.1), αλλά υπό καθεστώς ύπαρξης θορύβου τόσο στο βίντεο όσο και στον ήχο. Συγκεκριμένα, στο πρώτο υπο-πείραμα μελετήθηκε η επίδραση της αύξησης του SNR του ηχητικού σήματος στην επίδοση του μοντέλου, ενώ στο δεύτερο υπο-πείραμα παρουσιάστηκαν τα αποτελέσματα της μείωσης της αξιοπιστίας του βίντεο στην ακρίβεια των προβλέψεων, σε επίπεδο φωνημάτων.

2.4 Δομή της Συγκεκριμένης Αναφοράς

Παρακάτω περιγράφεται εν συντομία η δομή της συγκεκριμένης αναφοράς της διπλωματικής εργασίας.

Προηγήθηκαν στην ενότητα 1 οι περιλήψεις της εργασίας στα ελληνικά και στα αγγλικά, ενώ στο συγκεκριμένο κεφάλαιο (2) έγινε μία εισαγωγή, ορίζοντας το πρόβλημα του Lip Reading, παρουσιάζοντας μερικές από τις διαθέσιμες μεθόδους στη βιβλιογραφία και περιγράφοντας σύντομα το αντικείμενο μελέτης της εργασίας.

Ακολουθεί το κεφάλαιο με τίτλο “Τεχνικό Υπόβαθρο” (3), στην οποία εξηγούνται οι έννοιες αναγκαίες για την κατανόηση της εργασίας. Γίνεται, αρχικά, μία αναφορά στα φωνήματα και στα visemes (βλ. 3.1),

η οποία ακολουθείται από μία σύντομη παρουσίαση μερικών από των εννοιών της μηχανικής μάθησης, συγκεκριμένα του Positional Encoding, της συνάρτησης κόστους Cross-Entropy και της συνάρτησης κόστους CTC (βλ. 3.2). Να σημειωθεί ότι οι συναρτήσεις κόστους παρουσιάζονται κυρίως ώστε να αποφευχθεί σύγχυση για τον τρόπο με τον οποίον υπολογίζονται στα πειράματα, ενώ δεν παρουσιάζονται σε αυτήν την ενότητα έννοιες της μηχανικής μάθησης πιο γενικές, όπως τα CNNs, τα BiLSTM, οι Transformers, το Dropout, το Layer Normalization και άλλες, για να μειωθεί η έκταση του κειμένου, καθώς θεωρήθηκαν γνωστές. Τέλος, παρουσιάζονται και 2 ακόμη έννοιες, η απόσταση Levenshtein και τα Mel-Spectrograms (βλ. 3.3), τα οποία χρησιμοποιούνται στην εργασία και δεν ταιριάζουν σε κάποια από τις προαναφερθείσες κατηγορίες.

Έπειτα, ακολουθεί μία εκτενέστερη αναφορά στο State of the Art του προβλήματος του Lip Reading από αυτήν που γίνεται στο συγκεκριμένο κεφάλαιο, στο κεφάλαιο 4 με τίτλο State of the Art.

Το επόμενο κεφάλαιο είναι το μεγαλύτερο σε μέγεθος και έχει τίτλο Μεθοδολογία 5. Παρουσιάζονται αναλυτικά όλα τα βήματα της μεθοδολογίας που εφαρμόζεται και δοκιμάζεται, τόσο για το visual όσο και για το audiovisual μοντέλο, αρχίζοντας από την προεπεξεργασία των δεδομένων (βλ. 5.1). Παρουσιάζεται η αρχιτεκτονική πρώτα του visual μοντέλου (βλ. 5.2) και έπειτα του audiovisual μοντέλου (βλ. 5.3), με κατάλληλο σχολιασμό των σχεδιαστικών επιλογών. Τέλος, γίνεται αναφορά στο post-processing των δεδομένων στην ενότητα 5.4.

Στο κεφάλαιο με τίτλο “Αξιολόγηση της Μεθοδολογίας” (6), παρουσιάζονται αναλυτικά τα διάφορα πειράματα που διεξήχθησαν για τη συγκεκριμένη εργασία, αφού πρώτα παρουσιαστούν τα Datasets (βλ. 6.1) και τα Κριτήρια Αξιολόγησης (βλ. 6.2). Στις υποενότητες 6.3.1, 6.3.2 και 6.3.3 παρουσιάζονται με τη σειρά τα 3 πειράματα που διεξήχθησαν.

Τέλος, στο κεφάλαιο με τίτλο “Συμπεράσματα και Μελλοντικές Επεκτάσεις” (7), παρουσιάζονται τα συμπεράσματα (βλ. 7.1) και οι μελλοντικές επεκτάσεις (βλ. 7.2) που προκύπτουν από την εργασία.

3 Τεχνικό Υπόβαθρο

Στο κεφάλαιο αυτό, θα χτιστεί το τεχνικό υπόβαθρο που χρειάζεται για την κατανόηση της εργασίας. Συμπεριλαμβάνονται λεπτομέρειες τόσο για έννοιες μηχανικής μάθησης όσο και για βασικές ιδέες της γλωσσολογίας.

3.1 Φωνήματα και Visemes

Τα φωνήματα αποτελούν το βασικό αντικείμενο μελέτης της συγκεκριμένης εργασίας. Ένα φώνημα ορίζεται ως ένα σύνολο παρόμοιων ήχων ομιλίας το οποίο γίνεται αντιληπτό από ομιλητές μίας γλώσσας ως ένας βασικός ήχος, πρόκειται δηλαδή για τη μικρότερη πιθανή μονάδα φωνής. Συμβολίζονται συνήθως ως ένας χαρακτήρας εντός δύο forward slash. Για παράδειγμα, το φώνημα /b/ εκπροσωπεί τον ήχο στην αρχή της αγγλικής λέξης bat. Κάθε ομιλούμενη γλώσσα αξιοποιεί τα φωνήματα σε διαφορετικό βαθμό, ενώ ίδια γράμματα ή φθόγγοι μπορεί σε διαφορετικές γλώσσες να προφέρονται τελείως διαφορετικά. Τα προβλήματα αυτά προσπαθεί να λύσει το International Phonetic Alphabet (IPA), το οποίο είναι ένα “αλφάβητο” από φωνήματα βασισμένο κυρίως στους λατινικούς χαρακτήρες και ομοιόμορφο για κάθε γλώσσα. Να σημειωθεί ότι το πλήρες IPA είναι υπερβολικά περίπλοκο για την ανάλυση που ακολουθεί, καθώς αρκετά φωνήματα συναντώνται πολύ σπάνια (ή καθόλου) στην αγγλική γλώσσα που μελετάται καθ’ όλη τη διάρκεια της εργασίας.

Όντας η ελάχιστη μονάδα ομιλίας, τα φωνήματα έχουν αποτελέσει το αντικείμενο ποικίλων γλωσσολογικών μελετών, πολλές από τις οποίες αφορούν το “διάβασμα χειλιών” (lip reading) ή, αλλιώς, την κατανόηση ομιλίας χρησιμοποιώντας αποκλειστικά οπτικά (και όχι ακουστικά) μέσα. Από τις μελέτες αυτές έχει δημιουργηθεί το πρόβλημα των “visemes”, τα οποία αποτελούν το σύνολο ήχων ομιλίας με πανομοιότυπη όψη στα χείλια (ή γενικότερα στο πρόσωπο). Να σημειωθεί ότι τα σύνολα αυτά δεν περιορίζονται σε μοναδικά φωνήματα: για παράδειγμα, οι φράσεις “elephant juice” και “i love you” αποτελούν ένα χιουμοριστικό αλλά έγκυρο παράδειγμα viseme. Στα πλαίσια της συγκεκριμένης μελέτης, στο εξής ως visemes θα αναφέρονται τα φωνήματα κατά την έκφραση των οποίων η όψη του ομιλητή είναι όμοια. Για παράδειγμα, τα φωνήματα /m/, /b/ και /p/ αποτελούν ένα παράδειγμα viseme. Τα visemes προσφέρουν πληροφορία για την τοποθεσία του στόματος στην οποία παράγεται ο ήχος, αλλά όχι για τον τρόπο με τον οποίο παράγεται ο ήχος, το οποίο απαιτεί ακουστικά στοιχεία.

Πέραν της ομαδοποίησης τους μέσω των visemes, τα φωνήματα μπορούν να ομαδοποιηθούν και με βάση 3 ακόμα χαρακτηριστικά: τον τόπο, τον τρόπο εκφοράς τους και το αν είναι έμφωνα ή όχι. Για να παρουσιαστούν με μεγαλύτερη ακρίβεια τα παραπάνω, συμπεριλαμβάνεται το επίσης chart φωνημάτων του IPA. Αγνοώντας τις υπερβολικές λεπτομέρειες στο Σχήμα 1 και εστιάζοντας την προσοχή στον πρώτο πίνακα με τίτλο CONSONANTS (PULMONIC) και στον αμέσως κάτω δεξιά χάρτη με τίτλο VOWELS, μπορούν να εξαχθούν τα παρακάτω συμπεράσματα.

Παρατηρούμε ότι τα σύμφωνα χωρίζονται σε 11 κατηγορίες όσον αφορά τον τόπο εκφοράς τους: τα δειχικά (bilabial, παράγονται χρησιμοποιώντας τα 2 χείλη), τα χειλοδοντικά (labiodental, παράγονται με τη συμμετοχή χειλιών και δοντιών), τα οδοντικά (dental, με τα δόντια), τα φατνιακά (alveolar, παράγονται με τη γλώσσα να ακουμπά ή να πλησιάζει τη φατνιακή ακρολοφία), τα μεταφατνιακά (postalveolar, παράγονται με τη γλώσσα να τοποθετείται πίσω από τη φατνιακή ακρολοφία), τα ανακεκαμμένα (retroflex, παράγονται από την άκρη της γλώσσας όταν κάμπτεται προς τα πίσω προς τον ουρανίσκο), τα ουρανικά (palatals, παράγονται υψώνοντας το κυρίως τμήμα της γλώσσας στον σκληρό ουρανίσκο), τα υπερωικά (velar, όταν το πίσω μέρος της γλώσσας αγγίζει ή πλησιάζει τον μαλακό ουρανίσκο), τα σταφυλικά (uvular, με το πίσω μέρος της γλώσσας να αγγίζει ή να πλησιάζει τη σταφυλή), τα φαρυγγικά (pharyngeal, παράγονται περιορίζοντας τον φάρυγγα) και τέλος τα γλωττιδικά (glottal, χρησιμοποιώντας τη γλωττίδα). Το χαρακτηριστικό αυτό είναι που επηρεάζει κατά κύριο λόγο τα visemes, καθώς ο τρόπος με τον οποίον παράγεται ένα φώνημα και το αν είναι έμφωνο ή όχι πολλές φορές γίνεται κρυφό λόγω της μορφολογίας των χειλιών, που επηρεάζεται προφανώς από τον τόπο εκφοράς του φωνήματος.

Πέραν του τόπου εκφοράς, τα σύμφωνα διαχωρίζονται στον πίνακα με βάση τον τρόπο εκφοράς τους ως εξής: τα έκκροτα/κλειστά σύμφωνα (plosive, παράγονται όταν διακόπτεται τελείως η ροή του αέρα

και απελευθερώνεται ξαφνικά), τα ρινικά (nasal, επιτρέπουν στον αέρα να διαφύγει μέσω της ρινικής κοιλότητας και όχι του στόματος), τα μέσω τρίλιας (trill, παράγονται μέσω γρήγορης δόνησης λόγω της ροής αέρα), τα παλμού/κτύπου (tap/flip, όταν η γλώσσα ακουμπάει στιγμιαία ένα σημείο του στόματος), τα τριβόμενα (fricative, όταν ο αέρας περνάει από στενή δίοδο δημιουργώντας τριβή), τα πλευρικά τριβόμενα (lateral fricative, όπου ο αέρας παράγει τριβή καθώς περνάει από τα πλάγια της γλώσσας), τα προσεγγιστικά (approximant, όπου δύο αρθρωτές πλησιάζουν χωρίς να παράγουν τυρβώδη ροή αέρα ή ολικό κλείσιμο), και τα πλευρικά προσεγγιστικά (lateral approximant, μπλοκάροντας το κέντρο της στοματικής κοιλότητας στην περιοχή του αρθρωτή και επιτρέποντας τη ροή του αέρα από τα πλάγια). Πειραματιζόμενοι με τα παραπάνω μπορούμε να συνειδητοποιήσουμε πώς παράγονται τα φωνήματα που χρησιμοποιούμε, όπως και να αρθρώσουμε φωνήματα που ίσως δεν έχουμε συνηθίσει (π.χ. στα ελληνικά δεν υπάρχει πλευρικό τριβόμενο φώνημα, αλλά σε γλώσσες όπως τα σουαλικά υπάρχει).

Τέλος, ο χαρακτηρισμός έμφωνο ή άφωνο φαίνεται από τη θέση των συμφώνων στο εκάστοτε κελί. Αυτά που είναι τοποθετημένα προς τα δεξιά είναι έμφωνα, ενώ αυτά προς τα αριστερά είναι άφωνα. Τα φωνήεντα, από την άλλη είναι όλα έμφωνα και διαχωρίζονται με βάση το ύψος της γλώσσας (στον κατακόρυφο άξονα), την προώθησή της (στον οριζόντιο άξονα) και το αν τα χείλη είναι στρογγυλεμένα (rounded) ή όχι. Όσον αφορά το ύψος, οι κατηγορίες είναι close, close-mid, open-mid και open, ενώ στον οριζόντιο άξονα οι πιθανές επιλογές είναι front, central και back. Όπου στον χάρτη εμφανίζονται δύο φωνήματα, το δεξιότερο παράγεται με στρογγυλεμένα χείλη.

Με γνώση των παραπάνω και αντίστοιχη προσαρμογή στις ανάγκες της εκάστοτε γλώσσας ή, στην περίπτωση περιορισμένου περιβάλλοντος, στις ιδιαιτερότητες του λεξιλογίου, τα φωνήματα μπορούν να ομαδοποιηθούν με τους παραπάνω κανόνες. Έτσι, σε πλαίσια lip reading, είναι δυνατόν να χτιστούν μέθοδοι εφαρμογής διαφορετικής ποιικής με βάση την ομοιότητα των φωνημάτων (είτε σε επίπεδο visemes είτε σε επίπεδο χαρακτηριστικών, όπως παρουσιάστηκε) ή και μέθοδοι πρόβλεψης λέξεων που να συνυπολογίζουν την ομοιότητα φωνημάτων κατά την αντικατάστασή τους (για περισσότερα βλ. παράγραφο 5.1.2).

3.2 Έννοιες Μηχανικής Μάθησης

Στην ενότητα αυτή ορίζονται οι διάφορες έννοιες της μηχανικής μάθησης και της βαθιάς μάθησης που χρησιμοποιούνται παρακάτω. Ταυτόχρονα, αναπτύσσεται ο συμβολισμός που τηρείται στο υπόλοιπο μέρος της εργασίας.

Positional Encoding Στη βαθιά μάθηση, η σειρά των tokens έχει σημαντική επίδραση στην κατανόηση του συνολικού περιεχομένου. Το κλασικό παράδειγμα “Allen walks dog” και “dog walks Allen” αποδεικνύει τον παραπάνω ισχυρισμό: οι δύο φράσεις έχουν πολύ διαφορετική σημασία, παρά το γεγονός ότι παράγονται από τις ίδιες λέξεις (τα tokens σε αυτήν την περίπτωση). Μοντέλα όπως τα επαναλαμβανόμενα νευρωνικά δίκτυα (RNNs) ή τα μοντέλα μακροπρόθεσμης και βραχυπρόθεσμης μνήμης (long-short term memory, LSTM) διαθέτουν μηχανισμούς που αντιλαμβάνονται και αξιοποιούν τη σειρά των tokens. Αντιθέτως, αρχιτεκτονικές που βασίζονται στους transformers επεξεργάζονται τα tokens εν παραλλήλω και άρα δε διατηρούν πληροφορία για τη σειρά των tokens.

Ο τρόπος με τον οποίον επιλύεται το πρόβλημα αυτό είναι χρησιμοποιώντας Positional Encoding που προσθέτει πληροφορία για την σειρά των tokens στο embedding τους, συγκεκριμένα μέσω Sinusoidal Encoding. Στην εργασία αυτή χρησιμοποιείται το sinusoidal encoding όπως παρουσιάζεται στο [29], που υπολογίζεται ως εξής:

$$PE_{pos,2i} = \sin(pos/n^{2i/d_{model}})$$

$$PE_{pos,2i+1} = \cos(pos/n^{2i/d_{model}})$$

όπου PE είναι η συνάρτηση positional encoding, pos είναι η θέση του token, i είναι η συγκεκριμένη διάσταση, n ένας μεγάλος επιλεγμένος αριθμός (τυπικά 10000) και d_{model} η διάσταση του μοντέλου. Προσθέτοντας (ή σε κάποιες περιπτώσεις συνενώνοντας) τους όρους που παράγονται με αυτόν τον

κανόνα με τα embeddings των tokens, δίνεται στο μοντέλο η έξτρα πληροφορία της τοποθεσίας του κάθε token.

Συνάρτηση Κόστους Cross-Entropy Η συνάρτηση κόστους cross-entropy αποτελεί το τυπικό objective εκπαίδευσης, όταν είναι επιθυμητό ένας ταξινομητής να προσεγγίζει μία στοχευμένη κατανομή. Στη θεωρία πληροφορίας, η cross-entropy μεταξύ δύο κατανομών πιθανότητας p και q , στο ίδιο set γεγονότων, αποτυπώνει τον αριθμό των bits που χρειάζονται για να κατηγοριοποιήσουν ένα γεγονός επιλεγμένο από το set όταν η κωδικοποίηση είναι βέλτιστη για την εκτιμώμενη κατανομή πιθανότητας q και όχι την πραγματική p . Υπολογίζεται από τον τύπο:

$$H(p, q) = - \sum_i p_i \cdot \log(q_i)$$

όπου p_i και q_i είναι οι πιθανότητες που αποδίδονται από τις δύο κατανομές για το i -οστό γεγονός. Σε περίπτωση που η πραγματική κατανομή p έχει τιμή 1 για μία κλάση και τιμή 0 σε οποιαδήποτε άλλη περίπτωση (αντίστοιχα, σε περίπτωση που τα targets σε ένα πρόβλημα ταξινόμησης ακολουθούν τη σύμβαση one-hot encoding), τότε ο τύπος γίνεται $H(p, q) = -\log(q_i)$, δηλαδή η γνωστή αρνητική λογαριθμική πιθανοφάνεια (negative log-likelihood). Στο πρόβλημα του lip reading, για λόγους που γίνονται κατανοητοί παρακάτω, κρίνεται χρήσιμο οι στόχοι να μην είναι απόλυτοι (hard), δηλαδή με πιθανότητα 1 στη σωστή κλάση και 0 αλλού, αλλά εξομαλυσμένοι (soft).

Η πρακτική αυτή, κατά την οποία ένα ποσοστό της μάζας πιθανότητας αναδιανέμεται σε άλλες κλάσεις πέραν της σωστής, ονομάζεται label smoothing (εξομάλυνση ετικετών) και έχει ως στόχο να αποτρέψει την υπερβολική αυτοπεποίθηση του μοντέλου και άρα να βελτιώσει τη γενίκευση αυτού. Στη μελέτη αυτή, όπως φαίνεται στην παράγραφο 5.1.2, η εξομάλυνση αυτή δεν είναι ομοιόμορφη για όλες τις λανθασμένες κλάσεις αλλά βασίζεται στην ομοιότητα που παρουσιάζουν τα φωνήματα, τόσο οπτικά μέσω των visemes όσο και από το τελικό ηχητικό τους αποτέλεσμα (μέσω των τρόπων, τόπων παραγωγής τους και το αν είναι έμφωνα ή όχι).

Η εφαρμογή της cross-entropy loss στη μελέτη αυτή επιφέρει την ανάγκη δημιουργίας ορθών targets για κάθε frame ενός δεδομένου βίντεο. Επομένως, τα δεδομένα πρέπει να προεπεξεργαστούν καταλλήλως ώστε να αντιστοιχισθεί κάθε frame με το φώνημα που εκφέρεται (ή τη σιγή). Πρόκειται για την παλαιότερη και πιο άμεση πρακτική για την εξαγωγή ετικετών της αλληλουχίας, η οποία χρησιμοποιείται από το [13] και επιτρέπει την επιβλεπόμενη μάθηση σε επίπεδο frame.

Συνάρτηση κόστους CTC Για να μην απαιτείται η παραπάνω δημιουργία targets σε επίπεδο frames, εισήχθη από το [12] η συνάρτηση κόστους CTC (Connectionist Temporal Classification). Η συνάρτηση αυτή δεν απαιτεί label για κάθε frame, αλλά απλά μία αλληλουχία φωνημάτων χωρίς segmentation, εκπαιδεύοντας το μοντέλο να αναθέτει υψηλή πιθανότητα στην αλληλουχία αυτή υπό ενός κανόνα “κατάρρευσης” (collapsing rule). Προστίθεται το σύμβολο του κενού και κάθε αλληλουχία σε επίπεδο frame που

- μετά την αφαίρεση των κενών συμβόλων και
- μετά την κατάρρευση διαδοχικών ίδιων συμβόλων σε ένα

οδηγεί στην αρχική αλληλουχία, θεωρείται σωστή. Έτσι, πολλές διαφορετικές αλληλουχίες φωνημάτων τελικά θεωρούνται σωστές, με αποτέλεσμα η ακριβής πρόβλεψη του χρονισμού του κάθε φωνήματος να απαιτεί πολλά περισσότερα δεδομένα (όπως φαίνεται από την επίδοση του V4 στο 6.3.1).

Πιο συγκεκριμένα, έστω μία πιθανή ακολουθία με μήκος T που προβλέπει το μοντέλο $\pi = (\pi_1, \pi_2, \dots, \pi_T)$, που ονομάζεται μονοπάτι (path). Η συνάρτηση κατάρρευσης $B(\pi)$ εκτελεί τη λειτουργία που αναφέρθηκε παραπάνω και υπολογίζει από το αρχικό μονοπάτι το collapsed sequence. Υποθέτοντας ανεξαρτησία μεταξύ των χρονικών βημάτων, η πιθανότητα ενός path δεδομένης της ακολουθίας εισόδου X υπολογίζεται ως $P(\pi|X) = \prod_{t=1}^T y_t^{\pi_t}$, όπου $y_t^{\pi_t}$ είναι η πιθανότητα που έδωσε το δίκτυο για το σύμβολο π_t στο frame t .

Όπως αναφέρθηκε προηγουμένως, η ίδια τελική ακολουθία μπορεί να παραχθεί από πολλά διαφορετικά αρχικά alignments. Άρα, η πιθανότητα της τελικής ακολουθίας Y ορίζεται ως

$$P(Y|X) = \sum_{\pi \in B^{-1}(Y)} P(\pi|X)$$

και η αντικειμενική συνάρτηση υπολογίζεται ως

$$L_{CTC} = -\log(P(Y|X)) = -\log\left(\sum_{\pi \in B^{-1}(Y)} P(\pi|X)\right)$$

Στην πράξη, καθώς το πλήθος των πιθανών paths αυξάνεται εκθετικά με το μήκος της ακολουθίας, δεν είναι εφικτό να απαριθμίσουν όλα από τα παραπάνω μονοπάτια. Αντ’ αυτού, χρησιμοποιείται ο αλγόριθμος Forward-Backward, μία μορφή δυναμικού προγραμματισμού, ο οποίος υπολογίζει την πιθανότητα της επιθυμητής αλληλουχίας σε χρόνο $O(TU)$, όπου T είναι το μήκος της εισόδου και U είναι το μήκος της targeted ακολουθίας. Ο αλγόριθμος αυτός ορίζει forward και backward μεταβλητές που αντιστοιχούν στις πιθανότητες να έχει παραχθεί ένα συγκεκριμένο πρόθεμα ή επίθεμα της ακολουθίας στόχου μέχρι μία χρονική στιγμή. Συνδυάζοντας τις πιθανότητες αυτές υπολογίζεται το συνολικό άθροισμα όλων των έγκυρων αλληλουχιών, χωρίς να εξετάζεται κάθε πιθανό path ξεχωριστά.

Τα πλεονεκτήματα της εκπαίδευσης με την παραπάνω αντικειμενική συνάρτηση είναι η εξάλειψη της απαίτησης ετικετών σε επίπεδο frame, η ικανότητα χρήσης διαφορετικών μηκών εισόδου και εξόδου, η αυτόματη μάθηση της χρονικής ευθυγράμμισης (temporal alignment) των φωνημάτων και ότι επιτρέπει την εκπαίδευση end-to-end. Αποτελεί μειονέκτημα, ωστόσο, η υπόθεση ότι οι προβλέψεις σε διαδοχικά χρονικά βήματα είναι ανεξάρτητες δεδομένης της εισόδου, γεγονός που περιορίζει τη μοντελοποίηση ισχυρών εξαρτήσεων μεταξύ των συμβόλων εξόδου. Άλλα ελαττώματα της χρήσης της συνάρτησης αυτής είναι ότι δεν ενσωματώνεται γλωσσικό μοντέλο κατά την εκπαίδευση, με τη γλωσσική πληροφορία να προστίθεται μόνο κατά την αποκωδικοποίηση, όπως επίσης ότι παρουσιάζονται δυσκολίες κατά την επεξεργασία μεγάλων ακολουθιών ή ακολουθιών με πολλά επαναλαμβανόμενα σύμβολα.

3.3 Άλλες Χρήσιμες Έννοιες

Απόσταση Levenshtein Στη θεωρία πληροφορίας, η απόσταση Levenshtein (ή αλλιώς edit distance) είναι μία μετρική που αφορά την απόσταση δύο αλληλουχιών χαρακτήρων (strings). Αφορά τον ελάχιστο αριθμό αλλαγών μοναδικού χαρακτήρα (αφαιρέσεων, προσθέσεων ή μετατροπών) ώστε ένα string να μετατραπεί σε κάποιο άλλο. Συγκεκριμένα, έστω a και b δύο συμβολοσειρές με μήκη $|a|$ και $|b|$ αντίστοιχα. Η απόσταση Levenshtein των δύο αυτών συμβολοσειρών υπολογίζεται με τον παρακάτω αναδρομικό τύπο ως:

$$lev(a, b) = \begin{cases} |a| & \text{if } |b| = 0 \\ |b| & \text{if } |a| = 0 \\ lev(tail(a), tail(b)) & \text{if } head(a) = head(b) \\ 1 + \min \begin{cases} lev(tail(a), b) \\ lev(a, tail(b)) \\ lev(tail(a), tail(b)) \end{cases} & \text{otherwise} \end{cases}$$

όπου $tail(x)$ μίας συμβολοσειράς x είναι η συμβολοσειρά όλων των χαρακτήρων της x δίχως τον πρώτο και $head(x)$, αντίστοιχα, είναι μόνο ο πρώτος χαρακτήρας της x .

Στην πράξη, για να αποφευχθεί η χρήση του παραπάνω αναδρομικού ορισμού, η οποία αυξάνει το υπολογιστικό κόστος εκθετικά με το μήκος των συμβολοσειρών, χρησιμοποιούνται τεχνικές δυναμικού προγραμματισμού για τον υπολογισμό της απόστασης Levenshtein μεταξύ δύο συμβολοσειρών. Παρακάτω δίνεται ένα παράδειγμα υπολογισμού της απόστασης Levenshtein των συμβολοσειρών “kitten” και “sitting”.

Παρατηρούμε ότι ο ελάχιστος αριθμός αλλαγών σε χαρακτήρες που πρέπει να γίνουν για να ταυτιστούν οι δύο συμβολοσειρές είναι 3, και συγκεκριμένα:

- kitten → sitten (μετατροπή του “k” σε “s”)
- sitten → sittin (μετατροπή του “e” σε “i”)
- sittin → sitting (προσθήκη του “g”)

Η μετατροπή δεν μπορεί να γίνει με λιγότερες κινήσεις και άρα η Levenshtein απόσταση των συμβολοσειρών “kitten” και “sitting” είναι 3.

Mel-Spectrogram Τα Mel-Spectrograms αποτελούν μία από τις πλέον διαδεδομένες αναπαραστάσεις ήχου στην επεξεργασία ομιλίας και στη μηχανική μάθηση, καθώς προσφέρουν μια συμπαγή, χρονικά-συχνοτικά δομημένη περιγραφή ενός ηχητικού σήματος που προσεγγίζει τον τρόπο με τον οποίο το ανθρώπινο αυτί αντιλαμβάνεται τον ήχο. Παράγονται υπολογίζοντας το φάσμα του σήματος μέσω του Μετασχηματισμού Fourier Βραχέος Χρόνου (Short-Time Fourier Transform - STFT), μέσω του οποίου το σήμα χωρίζεται σε επικαλυπτόμενα χρονικά παράθυρα, για το καθένα από τα οποία υπολογίζεται το φάσμα ισχύος, παράγοντας μία δισδιάστατη αναπαράσταση συχνοτήτων και χρόνου. Το κλασικό φασματογράφημα, ωστόσο, απεικονίζει τις συχνότητες σε γραμμική κλίμακα, κάτι που δεν αντιστοιχεί με την ψυχοακουστική αντίληψη του ήχου από τον άνθρωπο, καθώς ο άνθρωπος διακρίνει τις χαμηλότερες συχνότητες με πολύ μεγαλύτερη ευκρίνεια από τις υψηλότερες. Έτσι, μέσω μίας αλληλουχίας τριγωνικών φίλτρων, το φάσμα προβάλλεται σε μία λογαριθμική κλίμακα που συμπιέζει τις υψηλές συχνότητες περισσότερο από τις χαμηλές, προσομοιώνοντας την ανθρώπινη ακοή. Μέσω της διαδικασίας αυτής παράγεται το Mel-Spectrogram ενός ηχητικού σήματος, μειώνοντας σημαντικά τη διάσταση (συνήθως χρησιμοποιούνται 100 μπάντες Mel, ενώ οι αρχικές συνιστώσες του STFT μπορεί να είναι μέχρι και μερικές χιλιάδες) αλλά διατηρώντας σημαντικό μέρος της πληροφορίας που μπορεί να χρησιμοποιηθεί για την ανάκτηση του ήχου (ή, τουλάχιστον, του τμήματος που ακούγεται από τον άνθρωπο).

Στην πράξη εφαρμόζεται συνήθως μετατροπή σε κλίμακα dB, καθώς και η ένταση του ήχου γίνεται αντιληπτή στον άνθρωπο σε λογαριθμική κλίμακα. Η επιλογή αυτή συμβάλλει, επίσης, στη σταθεροποίηση κατά την εκπαίδευση των νευρωνικών δικτύων. Σε γενικές γραμμές, τα Mel-Spectrograms έχουν υιοθετηθεί ευρέως σε εφαρμογές όπως η αναγνώριση ομιλίας (speech recognition) για τους παρακάτω 3 βασικούς λόγους:

- μειώνουν τη διάσταση και αυξάνουν την υπολογιστική αποδοτικότητα σε σχέση με την κυματομορφή του ήχου ή το φασματογράφημα αυτής
- η λογαριθμική κλίμακα ενισχύει τις περιοχές των συχνοτήτων που φέρουν την περισσότερη πληροφορία (όπως τις formants συχνότητες της ανθρώπινης ομιλίας)
- η δισδιάστατή τους δομή επιτρέπει την εφαρμογή μεθόδων μηχανικής μάθησης εμπνευσμένων από την επεξεργασία εικόνας, όπως των συνελκτικών νευρωνικών δικτύων (CNNs)

Παράλληλα, καθώς η μετατροπή από κυματομορφή σε mel-spectrogram είναι ντετερμινιστική συνάρτηση σταθερών υπερπαραμέτρων (ρυθμός δειγματοληψίας, μήκος παραθύρου, βήμα ολίσθησης, αριθμός μπάντων mel), αποτελεί μια αναπαραγώγιμη και εύκολα προ-υπολογίσιμη (cacheable) αναπαράσταση, γεγονός που την καθιστά ιδιαίτερα βολική για χρήση ως είσοδο σε αγωγούς εκπαίδευσης μεγάλης κλίμακας.

THE INTERNATIONAL PHONETIC ALPHABET (revised to 2020)

CONSONANTS (PULMONIC)

©©© 2020 IPA

	Bilabial	Labiodental	Dental	Alveolar	Postalveolar	Retroflex	Palatal	Velar	Uvular	Pharyngeal	Glottal
Plosive	p b		t d			ʈ ɖ	c ɟ	k ɡ	q ɢ		ʔ
Nasal	m	ɱ	n			ɳ	ɲ	ŋ	ɴ		
Trill	ʙ		r						ʀ		
Tap or Flap		ⱱ	ɾ			ɽ					
Fricative	ɸ β	f v	θ ð	s z	ʃ ʒ	ʂ ʐ	ç ʝ	x ɣ	χ ʁ	ħ ʕ	h ɦ
Lateral fricative			ɬ ɮ								
Approximant		ʋ	ɹ			ɻ	j	ɰ			
Lateral approximant			l			ɭ	ʎ	ʟ			

Symbols to the right in a cell are voiced, to the left are voiceless. Shaded areas denote articulations judged impossible.

CONSONANTS (NON-PULMONIC)

Clicks	Voiced implosives	Ejectives
◌ Bilabial	ɓ Bilabial	' Examples:
 Dental	ɗ Dental/alveolar	p' Bilabial
! (Post)alveolar	f Palatal	t' Dental/alveolar
≡ Palatoalveolar	ɡ Velar	k' Velar
 Alveolar lateral	ɠ Uvular	s' Alveolar fricative

OTHER SYMBOLS


Λ Voiceless labial-velar fricative	ʑ ʑ Alveolo-palatal fricatives
W Voiced labial-velar approximant	ɭ Voiced alveolar lateral flap
ʋ Voiced labial-palatal approximant	ɥ Simultaneous ɥ and ʏ
ħ Voiceless epiglottal fricative	
ʕ Voiced epiglottal fricative	Affricates and double articulations
ʡ Epiglottal plosive	can be represented by two symbols
	joined by a tie bar if necessary.

DIACRITICS

^o	Voiceless <u>n̥ d̥</u>	.. ^h	Breathily voiced <u>b̤ a̤</u>	^ɿ	Dental <u>t̪ d̪</u>
^v	Voiced <u>s t</u>	~	Creaky voiced <u>b̰ a̰</u>	^ɹ	Apical <u>t̟ d̟</u>
^h	Aspirated <u>tʰ dʰ</u>		Linguolabial <u>t̼ d̼</u>	^ɻ	Laminal <u>t̻ d̻</u>
^ɔ	More rounded <u>ɔ̞</u>	^w	Labialized <u>tʷ dʷ</u>	~	Nasalized <u>ẽ</u>
^ç	Less rounded <u>ɔ̝</u>	^j	Palatalized <u>tʲ dʲ</u>	ⁿ	Nasal release <u>dⁿ</u>
⁺	Advanced <u>u̟</u>	^Y	Velarized <u>tʏ dʏ</u>	^l	Lateral release <u>d^l</u>
⁻	Retracted <u>e̠</u>	^ʕ	Pharyngealized <u>tˤ dˤ</u>	^ʔ	No audible release <u>dʔ</u>
^{..}	Centralized <u>ë</u>	~	Velarized or pharyngealized	^ɮ	
[×]	Mid-centralized <u>ẽ</u>	^{ɹ̺}	Raised <u>e̝</u> (^{ɹ̺} = voiced alveolar fricative)		
	Syllabic <u>n̩</u>	^ɽ	Lowered <u>e̞</u> (^β = voiced bilabial approximant)		
[^]	Non-syllabic <u>e̯</u>	^{ɹ̺}	Advanced Tongue Root <u>e̘</u>		
[˜]	Rhoticity <u>ə̃ ã</u>	^{ɹ̺}	Retracted Tongue Root <u>e̙</u>		

Some diacritics may be placed above a symbol with a descender, e.g. $\overset{\circ}{\eta}$

VOWELS



Where symbols appear in pairs, the one to the right represents a rounded vowel.

SUPRASEGMENTALS

- | | | |
|---|------------------------------|--------------|
| | Primary stress | |
| | Secondary stress | ˌfəʊnəˈtɪfən |
| ː | Long | eː |
| ˘ | Half-long | e˘ |
| ◌ | Extra-short | ẽ |
| | Minor (foot) group | |
| | Major (intonation) group | |
| . | Syllable break | ˌɪ.ækt |
| ◌ | Linking (absence of a break) | |

TONES AND WORD ACCENTS

LEVEL	CONTOUR
ē or ↗ Extra high	ě or ↗ Rising
é ↗ High	ē ↘ Falling
ē ↗ Mid	ě ↗ High rising
è ↘ Low	ē ↘ Low rising
ē ↘ Extra low	ě ↘ Rising-falling
↓ Downstep	↗ Global rise
↑ Upstep	↘ Global fall

Σχήμα 1: Επίσημο chart φωνημάτων του IPA, έκδοση 2020

4 State of the Art

Παραδοσιακά, το πρόβλημα της αναγνώρισης της ανθρώπινης ομιλίας αξιοποιώντας οπτικά στοιχεία (βίντεο της περιοχής των χειλιών) αντιμετωπιζόταν ως μία δυσκολότερη εκδοχή της ακουστικής ASR (Automatic Speech Recognition). Χωρίς ηχητικά στοιχεία, το γλωσσικό περιεχόμενο πρέπει να αντληθεί χρησιμοποιώντας αποκλειστικά τις κινήσεις των χειλιών και των σαγονιών, με την πληροφορία που αφορά κυρίως τον τρόπο εκφοράς του κάθε φωνήματος να χάνεται. Οι περιορισμοί αυτοί οδήγησαν, αρχικά, σε μελέτες που εστίαζαν στην ταξινόμηση συγκεκριμένων φωνημάτων και visemes από στατικές εικόνες ή μικρά βίντεο σε αντίθεση με τη χρήση ολόκληρων λέξεων ή φράσεων. Προφανώς η αντιμετώπιση αυτή υπέφερε από διάφορους περιορισμούς, κυρίως του μικρού μεγέθους του dataset που χρησιμοποιούταν, το οποίο ήταν ανέκδοτο να περιγράψει πλήρως τη φύση της αλληλουχίας των φωνημάτων στην ανθρώπινη ομιλία. Μερικά παραδείγματα τέτοιων μελετών είναι η [33], στην οποία συνδυάζονται οπτικοακουστικά στοιχεία για να βελτιωθεί η αναγνώριση ομιλίας με ακουστικό θόρυβο, η [32], στην οποία συγκρίνεται η επίδοση νευρωνικού δικτύου και ανθρώπων στην αναγνώριση φωνηέντων από στατικές εικόνες και η [30], στην οποία γίνεται ταξινόμηση σε visemes.

Με την έλευση του deep learning, άρχισαν να αναπτύσσονται end-to-end αρχιτεκτονικές αξιοποιώντας τα 3D CNNs και τα RNNs. Το LipNet [4] αξιοποίησε τη συνέλιξη στις 3 διαστάσεις με bi-directional GRUs και τη CTC loss (βλ. 3.2) ώστε να ταξινομήσει βίντεο της περιοχής του στόματος απευθείας σε αλληλουχίες χαρακτήρων, πετυχαίνοντας υψηλή ακρίβεια στο περιορισμένο GRID dataset, το οποίο χρησιμοποιείται και στα πλαίσια αυτής της διπλωματικής. Λίγο αργότερα, οι Chung et. al δημιούργησαν το Watch, Listen, Attend and Spell [7], ένα μοντέλο sequence-to-sequence με ξεχωριστό encoder για “Watch” (οπτικά στοιχεία, 3D-CNN + LSTM) και “Listen” (ακουστικά στοιχεία, MFCC + LSTM), οι οποίοι τροφοδοτούσαν έναν LSTM decoder βασισμένο στον μηχανισμό του attention. Με τη δουλειά αυτή καθιερώθηκαν τα sentence-level, in-the-wild datasets που χρησιμοποιούνται ακόμη και σήμερα ως benchmarks - τα LRW, LRS2 και LRS3, [1], [8], [7], [9]. Οι δουλειές αυτές απέδειξαν, επίσης, πόσο πιο δύσκολο ήταν πραγματικά το πρόβλημα σε μη περιορισμένο περιβάλλον: ακόμα και μοντέλα με μεγάλη ακρίβεια σε επίπεδο λέξεων στο GRID υπέφεραν σε αυτά τα in the wild datasets.

Μετέπειτα εργασίες εστίασαν στη βελτίωση του temporal encoder και όχι της αντικειμενικής συνάρτησης ή του ορισμού του προβλήματος. Οι Afouras et. al [1] σύγκριναν back-ends βασισμένα σε συνελκτικά νευρωνικά δίκτυα, BiLSTM ή Transformer στο πρόβλημα του lip reading, καταλήγοντας ότι το self-attention πετύχαινε τελικά τις βέλτιστες τιμές ακρίβειας σε επίπεδο λέξης. Έπειτα, σύγκριναν τις επιδόσεις ενός Transformer decoder με CTC και με sequence-to-sequence βάση, τόσο για είσοδο αποκλειστικά οπτική όσο και για οπτικοακουστική. Η περίοδος αυτή καθιέρωσε δύο αρχιτεκτονικές επιλογές οι οποίες έμειναν σταθερές (ως επί το πλείστον) στις περισσότερες μετέπειτα εργασίες, όπως και σε αυτήν: ένα front-end που αξιοποιεί τόσο τη χρονική όσο και τις χωρικές διαστάσεις του βίντεο (3D CNN ή Transformer), διατηρώντας πληροφορία σε επίπεδο frame, και έναν decoder βασισμένο είτε στο CTC είτε στον μηχανισμό του attention.

Πρόσφατες εξελίξεις έχουν αλλάξει τον τρόπο με τον οποίο αξιοποιούνται οι ροές δεδομένων των οπτικών αλλά και των ακουστικών στοιχείων. Το AV-HuBERT [26] συνέχισε τη δουλειά του HuBERT [16] με το masked-prediction objective, μεταφέροντάς το από το ακουστικό στο οπτικοακουστικό πρόβλημα αναγνώρισης ομιλίας. Το προτεινόμενο μοντέλο της εργασίας αυτής μαθαίνει μία κοινή αναπαράσταση των οπτικοακουστικών στοιχείων, χρησιμοποιώντας multimodal clustering και modality dropout, πετυχαίνοντας τελικά βελτιωμένη επίδοση σε σχέση με το τότε state-of-the-art, ακόμα κι αν χρησιμοποιούσε πολύ λιγότερα labelled δεδομένα. Αντιθέτως, το Auto-AVSR [19] επέκτεινε το supervision χρησιμοποιώντας ήδη υπάρχοντα ASR μοντέλα ώστε να παράξει αυτόματα labels για πολλές ώρες οπτικοακουστικού υλικού. Άλλες εργασίες, όπως το Lip2Vec [11], αποτυπώνουν τα features εξαγόμενα από οπτικά στοιχεία σε προεκπαιδευμένους latent χώρους από ακουστικά μοντέλα. Σε κάθε περίπτωση, η συνένωση των οπτικών και των ακουστικών στοιχείων μέσω cross-modal ή cross-attention μηχανισμών αποτελεί πρακτική που εφαρμόζεται σε μεγάλο βαθμό, όπως και στη συγκεκριμένη εργασία, στην περίπτωση του audiovisual μοντέλου που παρουσιάζεται στην ενότητα 5.3.

Για να αντιμετωπιστεί η ασάφεια που προκύπτει στο πρόβλημα του lip reading εξαιτίας των visemes, πρόσφατες μελέτες μεταβάλλουν το τι ακριβώς καλείται να προβλέψει ο visual encoder και όχι πώς να το προβλέψει. Συγκεκριμένα, αντί να αποτυπώνεται ένα βίντεο απ'ευθείας σε αλληλουχία χαρακτήρων ή λέξεων, πολλά συστήματα αξιοποιούν ένα ενδιάμεσο στάδιο πρόβλεψης φωνημάτων, με τη λογική ότι η αλληλουχία φωνημάτων είναι τόσο ένας πιο εύκολος στόχος ως αντικείμενο πρόβλεψης από οπτικά στοιχεία, όσο και ένα ικανοποιητικό ενδιάμεσο στάδιο στο οποίο μπορεί να εφαρμοστεί περαιτέρω γλωσσικό context, ώστε να επιλυθεί η ασάφεια αυτή. Αυτή τη λογική ακολουθεί το VALLR [28], το οποίο αποτελεί πηγή έμπνευσης για μεγάλο τμήμα της συγκεκριμένης εργασίας. Το VALLR χρησιμοποιεί έναν Video Transformer εκπαιδευμένο με CTC ώστε να προβλέπει αλληλουχίες φωνημάτων από το βίντεο της εισόδου, οι οποίες σε ξεχωριστό στάδιο εισέρχονται σε ένα κατάλληλα fine-tuned LLM που παράγει τις προβλεπόμενες λέξεις και τελικά φράσεις, αξιοποιώντας γλωσσικό παρακείμενο σε επίπεδο φράσης στο οποίο δεν μπορεί να έχει πρόσβαση ο visual encoder. Η εκπαίδευση γίνεται σε δύο βήματα, χωρίζοντας το οπτικά αμφίσημο πρόβλημα της αναγνώρισης των φωνημάτων από το πρόβλημα αποκωδικοποίησης των εν λόγω φωνημάτων σε λέξεις (κάτι που με γνώση της γλώσσας που διαθέτει ένα LLM, γίνεται με μεγάλη επιτυχία). Το προτεινόμενο μοντέλο πετυχαίνει state of the art επιδόσεις στα προαναφερθέντα in the wild datasets, χρησιμοποιώντας λιγότερα labelled δεδομένα εκπαίδευσης από άλλα πλήρως supervised μοντέλα ή μοντέλα με self-supervised pre-training, ενώ δεν απαιτεί οπτικοακουστικό pre-training μεγάλης κλίμακας όπως το AV-HuBERT.

Το κεντρικό νόημα της μελέτης του VALLR, ότι δηλαδή η επίβλεψη σε επίπεδο φωνήματος, σε αντίθεση με την πρόβλεψη χαρακτήρων ή λέξεων, επιτρέπει σε μικρούς visual encoders να επιτύχουν υψηλή ακρίβεια στις προβλέψεις τους, αποτελεί την αρχή για τη συγκεκριμένη εργασία. Η εξαγωγή των φωνημάτων σε επίπεδο frame, η αντικειμενική συνάρτηση που περιλαμβάνει γνώση των visemes, η συνένωση των οπτικών και των ακουστικών features με βάση την αξιοπιστία τους, που αναλύονται στα επόμενα κεφάλαια, λειτουργούν ως περαιτέρω εξερεύνηση της αφοσίωσης στα φωνήματα για το πρόβλημα της αναγνώρισης ομιλίας. Έτσι, μελετάται το πώς εξάγονται και ευθυγραμμίζονται τα φωνήματα σε επίπεδο frame, πώς πρέπει να αντιμετωπιστούν οι κλάσεις φωνημάτων που ανήκουν σε visemes και άρα παρουσιάζουν υψηλή σύγχυση και πώς μπορεί να αξιοποιηθεί ένα ακουστικό σήμα (ακόμα και θορυβώδες) σε συνδυασμό με το οπτικό σήμα για τη βελτίωση των προβλέψεων.

5 Μεθοδολογία

Στο κεφάλαιο αυτό παρουσιάζεται αναλυτικά η μεθοδολογία που χρησιμοποιήθηκε κατά τη διεξαγωγή των πειραμάτων. Συμπεριλαμβάνονται επακριβείς πληροφορίες για την προεπεξεργασία των δεδομένων, τη δομή του μοντέλου και για το post-processing που εφαρμόζεται.


5.1 Προεπεξεργασία Δεδομένων

Η προεπεξεργασία των δεδομένων αποτελεί βασικό τμήμα κάθε μελέτης στη Βαθιά Μάθηση. Αποτελεί τη διαδικασία κατά την οποία τα δεδομένα, τα οποία αρχικά βρίσκονται σε μορφή που δεν μπορούν να υποστηρίξουν μάθηση (στην περίπτωση μας, τα αρχικά βίντεο των ομιλητών με τον ήχο και πριν την απόδοση φωνημάτων σε κάθε frame), αποκτούν τη μορφή που τους επιτρέπει να εισαχθούν στο μοντέλο. Αξιοποιώντας τις γνώσεις πάνω στο αντικείμενο, είναι δυνατόν να μειωθεί ο χρόνος εκπαίδευσης μέσω της μείωσης των διαστάσεων των πληροφοριών που εισάγονται στο νευρωνικό δίκτυο και, γενικότερα, να βελτιωθούν τα τελικά αποτελέσματα. Παρακάτω αναλύονται οι εκάστοτε τεχνικές pre-processing που εφαρμόζονται ώστε να λάβουν τα δεδομένα την επιθυμητή μορφή.


5.1.1 Εξαγωγή της περιοχής των χειλιών

Έστω ένα βίντεο ομιλητή $T \times C \times H \times W$ με T τη χρονική διάσταση (τον αριθμό των frames), C τον αριθμό των καναλιών (για RGB βίντεο είναι 3) και H ύψος και W πλάτος σε pixel. Για να περιοριστεί το μέγεθος των δεδομένων και να παραλειφθούν περιττές πληροφορίες του παρασκήνιου αλλά και του προσώπου του ομιλητή, αναπτύχθηκε ένα pre-processing script εντοπισμού της περιοχής των χειλιών. Η περιοχή αυτή είναι που αφορά το αντικείμενο, καθώς εκεί βρίσκεται η πληροφορία των visemes (άλλωστε, για αυτό αποκαλείται lip reading). Χρησιμοποιώντας το διαθέσιμο προεκπαιδευμένο MediaPipe Face Landmarker της Google, εντοπίζονται τα διάφορα “τοπόσημα προσώπου” (facial landmarks) του ομιλητή για κάθε frame του αρχικού βίντεο. Οι δείκτες των τοποσήμων των χειλιών εξαγονται για κάθε frame ξεχωριστά και παράγουν μία νέα εικόνα της περιοχής αυτής (συμπεριλαμβανομένου ενός επιπρόσθετου padding γύρω από τα χείλη για ασφάλεια) με διαστάσεις $H' \times W' \times 3$ και $H' < H, W' < W$.


Από τα εκάστοτε frames παράγεται το νέο βίντεο της περιοχής των χειλιών, το οποίο μετασχηματίζεται by default στην τελική διάσταση $224 \times 224 \times 3 \times T$. Κατά τη διάρκεια των πειραμάτων, βρέθηκε ότι ακόμα λιγότερα pixels είναι ικανά να αποδώσουν το περιεχόμενο των visemes, με αποτέλεσμα πριν την εκπαίδευση να εφαρμόζεται ένας ακόμα μετασχηματισμός στα 96 pixels. Κατά τον εντοπισμό των τοποσήμων χρησιμοποιείται και ένας μηχανισμός fallback, σε περίπτωση που το Face Landmarker αδυνατεί να βρει τους ζητούμενους δείκτες. Συγκεκριμένα, εάν δεν εντοπιστούν για ένα δεδομένο frame τα τοπόσημα, τότε επαναχρησιμοποιούνται αυτά του προηγούμενου frame, ενώ αν δεν υπάρχουν ούτε αυτά εκτιμάται η τοποθεσία των χειλιών ως η κάτω περιοχή του προσώπου (50% του πλάτους και 35% του ύψους, με κατακόρυφο offset 42%). Τα δεδομένα κωδικοποιούνται σε μορφή βίντεο .mp4 διατηρώντας το framerate του αρχικού βίντεο, ενώ παράγονται και μερικά παραδείγματα frames από το βίντεο bbaf2n.mp4 του dataset GRID (βλ. παράγραφο 6.1), τα οποία παρουσιάζονται παρακάτω.




Σχήμα 2: Εξαγωγή χειλιών για το frame 0



Σχήμα 3: Εξαγωγή χειλιών για το frame 24



Σχήμα 4: Εξαγωγή χειλιών για το frame 49



Σχήμα 5: Εξαγωγή χειλιών για το frame 74

5.1.2 Εξαγωγή φωνημάτων για κάθε frame

Για να έχει νόημα η εφαρμογή του όρου cross entropy, είναι απαραίτητο να δημιουργηθούν labels για κάθε frame των βίντεο. Αυτό επιτυγχάνεται με συνδυασμό της γνώσης του περιορισμένου περιβάλλοντος και μεθόδων αναγνώρισης φωνημάτων από ηχητικά σήματα ομιλίας. Να σημειωθεί ότι η παρακάτω διαδικασία μπορεί κάλλιστα να εφαρμοστεί και σε μη πεπερασμένο περιβάλλον, αλλά οι περαιτέρω περιορισμοί που προκύπτουν από τέτοια περιβάλλοντα επιτρέπουν απλοποιήσεις και διορθώσεις σε περίπτωση λανθασμένης προφοράς από τον ομιλητή.

Θεωρώντας γνωστό το φραστικό περιεχόμενο κάθε βίντεο (π.χ. στο GRID dataset γίνεται γνωστή η φράση που εκφέρεται από τον ομιλητή μέσω του τίτλου του αρχείου), μπορεί να μετατραπεί η φράση σε αλληλουχία φωνημάτων μέσω του eSpeak-NG, δίχως ακόμα να υπάρχει ωστόσο γνώση για τον χρονισμό του κάθε φωνήματος. Χρησιμοποιείται ελαφριά κανονικοποίηση στα φωνήματα που εξάγονται ώστε το “αλφάβητο” των τελικών αλληλουχιών να ταυτίζεται με αυτό του μοντέλου wav2vec2, που χρησιμοποιείται για την εξαγωγή φωνημάτων από το ηχητικό περιεχόμενο. Το CTC μοντέλο του wav2vec2 εξάγει πιθανότητες κάθε φωνήματος για κάθε frame και, συγκρίνοντας με την αλληλουχία φωνημάτων που γνωρίζουμε ότι αναμένεται, παράγει μία τελική πρόβλεψη για την αρχή και το τέλος του κάθε φωνήματος. Μέσω αυτών των πληροφοριών, είναι δυνατόν να ολοκληρωθεί το labelling κάθε frame με το αντίστοιχο φώνημα ή το blank token, εφόσον το frame αντιστοιχεί σε χρονική στιγμή εκτός των φωνημάτων. Έτσι, πέραν της εξαγωγής των απαιτούμενων labels, αποφεύγονται τυχόντα προβλήματα από αστοχία κατά την προφορά της κάθε φράσης.

Η επεξεργασία των φωνημάτων δεν ολοκληρώνεται εκεί. Συγκεκριμένα, δημιουργείται ένα viseme grouping (ομαδοποίηση, δηλαδή, των όμοιων οπτικά φωνημάτων) με βάση τα χαρακτηριστικά των φωνημάτων. Για αναλυτικότερες πληροφορίες ως προς την ομαδοποίηση των φωνημάτων, ανατρέξτε στην ενότητα 3.1. Από τα hard targets που υπάρχουν ήδη για κάθε frame των βίντεο, δημιουργούνται soft targets με βάση τις παραπάνω ομάδες. Συγκεκριμένα, το 85% αποδίδεται στο πραγματικό φώνημα, ενώ το υπόλοιπο 15% μοιράζεται στα όμοια φωνήματα του πραγματικού με βάρη που ανταποκρίνονται στην ομοιότητα των φωνημάτων. Για ίδιο viseme, χρησιμοποιείται βάρος 0.95, ενώ για διαφορετικό υπολογίζεται similarity score ως εξής: κάθε φώνημα έχει τον τόπο, τον τρόπο άρθρωσης και το αν είναι έμφωνο ή όχι. Με βάση το πόσα κοινά features άρθρωσης έχουν δύο φωνήματα που δεν ανήκουν στο ίδιο viseme, αποδίδεται μεγαλύτερο βάρος σε αυτά με περισσότερες ομοιότητες και μικρότερο σε αυτά με τις λιγότερες. Έτσι, υπολογίζεται το articulatory_similarity ως εξής: $sim = 1 - \text{diffs}/3$, όπου diffs είναι ο αριθμός διαφορετικών features. Το τελικό similarity matrix χτίζεται με τον ακόλουθο κανόνα:

$$mat[i, j] = \begin{cases} 1 & i = j \\ 0 & \text{είτε το } i \text{ είτε το } j \text{ είναι blank token και } i \neq j \\ 0.95 & \text{ίδια ομάδα viseme} \\ sim(a, b) \cdot 0.4 & \text{σε άλλη περίπτωση} \end{cases}$$

Τελικά τα soft targets χτίζονται με το 85% στο πραγματικό φώνημα και το υπόλοιπο 15% μοιρασμένο στα όμοια φωνήματα σε αναλογία με το similarity score των φωνημάτων, εκτός από την περίπτωση του


blank token, κατά την οποία διατηρούνται τα hard targets. Αυτό συμβαίνει ώστε να ενισχυθεί η ικανότητα του μοντέλου να προβλέπει ακριβώς πότε λέγεται ένα φώνημα και πότε όχι, με αποτέλεσμα οι χρονισμοί των προβλέψεων να είναι ορθοί.

5.1.3 Data Augmentation

Για να εμπλουτιστεί ιδιαίτερα κάποιο περιορισμένο σε μέγεθος dataset, κρίνεται αναγκαίο να εφαρμοστούν μέθοδοι data augmentation, δηλαδή επαύξεσης δεδομένων. Αυτές οι μέθοδοι, εκμεταλλευόμενες τη γνώση μας στο αντικείμενο, παράγουν νέα δεδομένα από τα υπάρχοντα και εμπλουτίζουν τη μάθηση του μοντέλου. Είναι σημαντικό να τονιστεί ότι οι τεχνικές data augmentation που εφαρμόζονται πρέπει να συμβαδίζουν με τους στόχους μάθησης του μοντέλου. Για παράδειγμα, μία πιθανή μέθοδος data augmentation στην περίπτωση που τα δεδομένα βρίσκονται σε μορφή βίντεο είναι η αναστροφή της αλληλουχίας των frames. Ωστόσο, όταν το μοντέλο πρόκειται να μάθει σε κάποιο παρακείμενο στο οποίο έχει σημασία η σωστή χρονική αλληλουχία (όπως για παράδειγμα στο lip reading, όπου οι κινήσεις των χειλιών για την παραγωγή ενός φωνήματος είναι ευαίσθητες στη σωστή χρονική σειρά), δε θα μπορούσε να εφαρμοστεί η παραπάνω μέθοδος.


Οι τεχνικές data augmentation που τελικά εφαρμόζονται, λόγω της ορθότητάς τους για τον τελικό στόχο και λόγω της ταχείας εφαρμογής τους σε πολλαπλά δεδομένα, είναι ο καθρεπτισμός γύρω από τον κατακόρυφο άξονα (horizontal flip), η χρωματική αλλαγή (color jitter) και η αφαίρεση/επικάλυψη (cutout/occlusion). Σε κάθε περίπτωση οι μετασχηματισμοί αυτοί εφαρμόζονται σε ολόκληρο το βίντεο και όχι σε μεμονωμένα frames, ώστε να αποφευχθούν ανεπιθύμητα φαινόμενα αστάθειας. Ο καθρεπτισμός εφαρμόζεται με πιθανότητα $p = 0.5$, ενώ η χρωματική αλλαγή πραγματοποιείται μέσω των παραγόντων της φωτεινότητας (brightness) με συντελεστή από 0.8 έως 1.2, της αντίθεσης (contrast) με παράγοντα 0.8-1.2 και του κορεσμού (saturation) με παράγοντα 0.9-1.1 και με πιθανότητα $p = 0.4$. Τέλος, με τη μέθοδο της επικάλυξης, με πιθανότητα $p = 0.25$ επιλέγεται τυχαία μία ορθογώνια περιοχή (8-20% του ύψους και του πλάτους του frame) και αποκρύπτεται για όλα τα frame του δεδομένου βίντεο, προσομοιώνοντας την ύπαρξη ενός αντικειμένου που εμποδίζει τη θέαση συγκεκριμένης περιοχής. Αυτό έχει ως αποτέλεσμα η εκπαίδευση να γίνεται πιο εύρωστη. Να σημειωθεί ότι η διαδικασία του data augmentation εφαρμόζεται αποκλειστικά στο training split και όχι σε αυτά του validation και του test. Παρακάτω παρουσιάζονται μερικά παραδείγματα των παραπάνω μεθόδων επαύξεσης δεδομένων.

Data Augmentation: Horizontal flip




Σχήμα 6: Παρουσίαση του καθρεπτισμού (horizontal flip) για μερικά frames

Data Augmentation: Brightness / contrast / saturation



Σχήμα 7: Παρουσίαση της αλλαγής χρώματος (color jitter) για μερικά frames

Data Augmentation: Random cutout



Σχήμα 8: Παρουσίαση της αφαίρεσης/επικάλυψης (cutout/occlusion) για μερικά frames

5.1.4 Επιπλέον βήματα κατά τη δοκιμή audiovisual μοντέλου

Κατά τις δοκιμές του πειράματος 3, οι οποίες παρουσιάζονται στην ενότητα 6.3.3, ακολουθούνται μερικά διαφορετικά και μερικά επιπλέον βήματα για την κατάλληλη προεπεξεργασία των δεδομένων, ώστε να ταιριάζουν στις απαιτήσεις του συγκεκριμένου πειράματος. Σε κάθε τμήμα βίντεο και αντίστοιχο τμήμα ήχου προστίθεται θόρυβος, παράγοντας μία θορυβώδη εκδοχή του αρχείου ήχου, μία θορυβώδη εκδοχή του αρχείου βίντεο και δύο πίνακες αξιοπιστίας $r_a(t)$, $r_v(t)$, οι οποίοι είναι ανεξάρτητοι για κάθε modality και καταγράφουν την αξιοπιστία του εκάστοτε modality για κάθε frame (πόσο αναμένεται να επηρεάστηκε η ποιότητα του εκάστοτε modality από τον θόρυβο), λαμβάνοντας μέγιστη τιμή 1 (πλήρως αξιόπιστο frame) και ελάχιστη 0 (καθόλου αξιόπιστο). Έπειτα, από το αρχείο ήχου παράγεται το Mel-Spectrogram που αντιστοιχεί σε αυτό, το οποίο είναι η απαιτούμενη μορφή δεδομένων εισόδου για το modality του ήχου και το προτεινόμενο μοντέλο.

Είναι σημαντικό να τονιστεί ότι η φιλοσοφία του πειράματος 3 απαιτεί την ύπαρξη θορύβου σε κάθε clip, τόσο στον ήχο του όσο και στο αντίστοιχο βίντεο. Η επιλογή αυτή είναι συνειδητή, ώστε να αποφευχθούν περιπτώσεις όπου το audiovisual μοντέλο μαθαίνει ότι ένα από τα δύο modalities παρουσιάζει

στατιστικά μικρότερη επιρροή από τον θόρυβο, αντί να μαθαίνει αξιοποιώντας και τα reliability σήματα $r_a(t)$ και $r_v(t)$. Εξαναγκάζοντας την ύπαρξη θορύβου και στα δύο streams δεδομένων, το μοντέλο μαθαίνει αναγκαστικά να συνδυάζει τα στοιχεία από τα δύο modalities και τελικά προσομοιώνει καλύτερα το περιβάλλον ύπαρξης θορύβου (και στον ήχο, π.χ. από ταυτόχρονη ομιλία άλλων ανθρώπων, και στο βίντεο, π.χ. με μερική ή πλήρη επικάλυψη των χειλιών από εμπόδια ή τεχνικά προβλήματα κατά την καταγραφή του βίντεο). Στη συνέχεια της ενότητας αυτής, παρουσιάζονται αναλυτικότερα τα βήματα προεπεξεργασίας που απαιτούνται.

Προσθήκη θορύβου στο βίντεο Για κάθε βίντεο, ακριβώς μία αλληλουχία frames επηρεάζεται από τον θόρυβο, και όχι διάφορα διάσπαρτα τμήματα. Αυτό αντικατοπτρίζει πραγματικά σενάρια που μπορεί να προκύψουν κατά την καταγραφή (ή τη ζωντανή μετάδοση) βίντεο, όπως τοποθέτηση εμποδίων μπροστά από τα χείλη (π.χ. χεριού ή μικροφώνου) ή τεχνικό πρόβλημα της κάμερας (π.χ. να χαθεί το focus και να εμφανιστεί θόλωση στο βίντεο), τα οποία είναι συνήθως ενιαία και σχετικά μεγάλου μήκους (στη γειτονιά του ενός δευτερολέπτου), αντί να είναι διάσπαρτα και σχετικά μικρού μήκους (πιο κοντά σε μεμονωμένα frames).

Αρχικά, επιλέγεται το span των frames του βίντεο στα οποία θα προστεθεί θόρυβος. Το μήκος του συγκεκριμένου span επιλέγεται ομοιόμορφα στο range $[target_length - jitter, target_length + jitter]$, με τις default τιμές $target_length = 30$ και $jitter = 8$. Σε αρχεία βίντεο στα 25fps, όπως για παράδειγμα αυτά του GRID, αυτό αντιστοιχεί σε θόρυβο στην περιοχή του ενός δευτερολέπτου (συνήθως λίγο παραπάνω από αυτό). Να σημειωθεί ότι, στο υποπείραμα της ενότητας 6.3.3 κατά το οποίο αυξομειώνεται ο αριθμός των επηρεασμένων frames, το μήκος του span δεν είναι τυχαίο αλλά ισούται σε κάθε περίπτωση με τον ακριβή αριθμό $target_length$. Το span τοποθετείται τυχαία και ομοιόμορφα σε κάποια αρχική θέση εντός του clip, προσδίδοντας τυχαιότητα τόσο στην ακριβή θέση του θορύβου όσο και στο πόσο αισθητή είναι η παρουσία του (κρατώντας αυτήν την τιμή κοντά σε μία κεντρική επιθυμητή τιμή) ανάμεσα στα διάφορα clips.

Αφού έχουν επιλεγεί με την παραπάνω μεθοδολογία τα frames τα οποία θα επηρεαστούν από τον θόρυβο, εφαρμόζονται οι εξής μέθοδοι προσθήκης θορύβου, με τυχαίο τρόπο:

- zero (μηδενισμός): οι τιμές των pixels για τα επιλεγμένα frames τίθενται στην τιμή 0, προσομοιώνοντας το σενάριο όπου χάνεται πλήρως η πληροφορία των χειλιών (π.χ. λόγω της εμφάνισης εμποδίου μπροστά από τα χείλη). Για αυτό το mode θορύβου, η τιμή της αξιοπιστίας είναι 0, καθώς δεν υπάρχει οπτική πληροφορία που μπορεί να αξιοποιηθεί.
- freeze (“πάγωμα”): κάθε frame του επιλεγμένου span αντικαθίσταται από το τελευταίο frame πριν από το span (ή, σε περίπτωση που το span ξεκινάει από το 1ο frame του βίντεο, το 1ο του span), προσομοιώνοντας ένα stream βίντεο το οποίο έχει παγώσει. Και πάλι το σκορ αξιοπιστίας για τα frames αυτά τίθεται ίσο με 0, μια και η οπτική πληροφορία που υπάρχει δεν μπορεί να χρησιμοποιηθεί για την εξαγωγή συμπερασμάτων όσον αφορά την έκφανση φωνημάτων.
- blur (θόλωση): κάθε frame του span αντικαθίσταται από το αποτέλεσμα της συνέλιξης αυτού με ένα 25×25 Gaussian kernel (με $\sigma=12$), προσομοιώνοντας την απώλεια focus ή την εμφάνιση motion blur. Στη συγκεκριμένη περίπτωση, καθώς υπάρχει ένα ίχνος οπτικής πληροφορίας για την κίνηση των χειλιών που επιβιώνει, η τιμή της αξιοπιστίας για τα επηρεασμένα frames τίθεται ίση με 0.3 αντί για 0.

Από τη διαδικασία αυτή παράγεται το θορυβώδες βίντεο το οποίο αποτελεί είσοδο για το μοντέλο, όπως και το σήμα αξιοπιστίας $r_v(t)$, $t = 0, 1, \dots, T$, με τιμές 1 για κάθε μη επηρεασμένο frame t και τιμές που ορίζονται από τα παραπάνω για τα frames στα οποία προστίθεται θόρυβος.

Προσθήκη θορύβου στον ήχο Η προσθήκη θορύβου στον ήχο συμβαίνει σε 2 διαφορετικές αλληπαλλήλες στρώσεις, μία στρώση προσθετικού θορύβου που εφαρμόζεται πάντα και μία προαιρετική στρώση ολικού dropout του ηχητικού σήματος.

Αρχικά, εφαρμόζεται ο θόρυβος προσθετικής φύσεως στο ηχητικό σήμα. Υπάρχουν δύο τύποι ηχητικού θορύβου, οι οποίοι επιλέγονται τυχαία για κάθε clip:

- white (λευκός θόρυβος): κλασικός i.i.d (independent identically distributed) γκαουσιανός θόρυβος
- babble (“βαβούρα”): μία πολύ γενική προσέγγιση βαβούρας από πολλαπλούς άλλους ομιλητές. Δημιουργείται παράγοντας λευκό θόρυβο, υπολογίζοντας το άθροισμά του (cumulative sum, προσομοιώνοντας έναν ολοκληρωτή και ενισχύοντας τις χαμηλές συχνότητες) και παίρνοντας την πρώτη διαφορά του. Έτσι, προσδίδεται στον θόρυβο spectral coloring, με αποτέλεσμα να παράγεται θόρυβος με διαφορετικά φασματικά χαρακτηριστικά από τον λευκό, ο οποίος χονδρικά προσομοιώνει την παρουσία πολλών διαφορετικών ομιλητών, χωρίς να χρειάζεται πρόσβαση σε κάποιο αρχείο βαβούρας.

Σε γενικές γραμμές, ο προσθετικός θόρυβος του ήχου θεωρήθηκε συνεχής και όχι διακοπτόμενος. Επιλέγεται τυχαία και ομοιόμορφα μία τιμή signal-to-noise ratio (SNR) σε dB από ένα ορισμένο range (με default τιμή $[-5, 15]$ dB). Στην περίπτωση του υποπειράματος της ενότητας 6.3.3 όπου αυξομειώνεται το SNR, η επιλογή αυτή δεν είναι τυχαία. Ο θόρυβος κανονικοποιείται ώστε να πετυχαίνεται το επιθυμητό SNR:

$$noise_{scaled} = noise \cdot \sqrt{\frac{P_{signal}/10^{SNR_{dB}/10}}{P_{noise}}}$$

όπου P_{signal} και P_{noise} είναι η ισχύς του σήματος και του θορύβου αντίστοιχα. Το τελικό σήμα μετά την προσθήκη του θορύβου επιδέχεται clipping στο σύνολο $[-1, 1]$. Ο μηχανισμός αυτός εγγυάται την ύπαρξη θορύβου (έστω μικρού) σε κάθε audio clip.

Στο δεύτερο επίπεδο, προστίθεται με πιθανότητα *audio_dropout_prob* (με προεπιλεγμένη τιμή 0.3) μία περαιτέρω μορφή θορύβου. Το ηχητικό που αντιστοιχεί σε έναν ακριβής αριθμό frames *audio_dropout_frames* (με default τιμή 15) αντικαθίσταται από το μηδενικό σήμα. Το φαινόμενο αυτό μοιράζεται σε 1 μέχρι *audio_dropout_max_spans* (default τιμή 1, αλλά δίνεται από τον κώδικα ως επιλογή) διαφορετικά spans, προσομοιώνοντας μικρές αποκοπές του ηχητικού σήματος (π.χ. κόψιμο του μικροφώνου).

Όσον αφορά το σήμα αξιοπιστίας του ήχου $r_a(t)$, υπολογίζεται εφαρμόζοντας clipping του επιλεγμένου SNR:

$$r_a = clip\left(\frac{SNR_{dB} - (-5)}{20 - (-5)}, 0, 1\right)$$

όπου οι τιμές -5dB και 20dB επιλέχθηκαν ως τα όρια ενός αξιόπιστου ηχητικού σήματος: οτιδήποτε με SNR κάτω από -5dB θεωρείται πλήρως αναξιόπιστο, αντίθετα οτιδήποτε με SNR πάνω από 20dB θεωρείται πλήρως αξιόπιστο. Για frames στα οποία έχει εφαρμοστεί ολικό dropout του ηχητικού σήματος, η αξιοπιστία παίρνει την τιμή 0.

Υπολογισμός των Mel-Spectrograms Πριν την εκπαίδευση, το ηχητικό σήμα (θορυβώδες ή όχι), το οποίο αντιστοιχεί στους στόχους της εκπαίδευσης και σε κάθε τμήμα βίντεο, μετατρέπεται σε Mel-Spectrogram (βλ. ενότητα 3.3). Καθώς ο υπολογισμός αυτός είναι πλήρως ντετερμινιστική διαδικασία για κάθε ανεξάρτητο αρχείο ήχου, ο επανυπολογισμός του σε κάθε εποχή κρίθηκε επιβαρυντικός για τη διαδικασία της εκπαίδευσης και άρα αποφεύχθηκε μέσω του προ-υπολογισμού και του caching των αποτελεσμάτων.

Έστω μία ηχητική κυματομορφή y η οποία έχει δειγματοληφθεί με sampling rate f_s (με προεπιλεγμένη τιμή τα 16kHz). Το Mel-Spectrogram υπολογίζεται ως εξής:

- υπολογίζεται ο Μετασχηματισμός Fourier Βραχέος Χρόνου (STFT) με διάσταση n_fft (προεπιλεγμένη τιμή 1024) και βήμα *hop_length*, για την τιμή του οποίου γίνεται ειδικός σχολιασμός παρακάτω.

- το φασματογράφημα προβάλλεται σε τριγωνικά φίλτρα της κλίμακας mel, υπ’ αριθμόν n_mels (προεπιλεγμένη τιμή 80), δημιουργώντας ένα Mel-Spectrogram $S \in \mathbb{R}^{n_mels \times T}$.
- εφαρμόζεται λογαριθμική συμπίεση της ισχύος: $S_{dB} = 10 \log_{10}(S / \max(S))$
- εφαρμόζεται αναστροφή ώστε ο χρόνος να γίνει η πρώτη διάσταση (T, n_mels), ώστε να συμφωνεί με την αντίστοιχη μορφή των δεδομένων των βίντεο.
- τέλος, εφαρμόζεται κανονικοποίηση κάθε Spectrogram χρησιμοποιώντας τη δική του μέση τιμή μ και τυπική απόκλιση σ : $(S_{dB} - \mu) / (\sigma + \epsilon)$

Όσον αφορά την τιμή της παραμέτρου hop_length , αυτή επιλέγεται τέτοια ώστε τα frames του Mel-Spectrogram να είναι (σχεδόν) ευθυγραμμισμένα με τα frames του video, με αποτέλεσμα τα δεδομένα της ροής του βίντεο και του ήχου να μπορούν να αναπαρίστανται σε κοινό άξονα χρόνου, χωρίς περαιτέρω επαναδειγματοληψία ή παρεμβολή. Η τιμή αυτή είναι: $hop_length = \text{round}(\frac{f_s}{fps})$, όπου fps είναι το frame rate του βίντεο.


5.2 Δομή του προτεινόμενου μοντέλου

Στην ενότητα αυτή περιγράφεται αναλυτικά η αρχιτεκτονική του προτεινόμενου μοντέλου. Στο σχήμα 9 παρουσιάζεται μία απεικόνιση των βασικών σχεδιαστικών επιλογών του μοντέλου.

Μορφή των δεδομένων εισόδου Όπως παρουσιάστηκε και στην ενότητα 5.1.2, κάθε αντικείμενο του training (κάθε βίντεο) συμπληρώνεται από μία προβλεπόμενη αλληλουχία φωνημάτων σε επίπεδο frame. Για κάθε frame υπάρχει η πρόβλεψη του φωνήματος (κενό αν δεν εκφέρεται φώνημα), ενώ συμπληρωματικά υπάρχει και η συμπυκνωμένη (collapsed) ακολουθία, στην οποία συνεχόμενα επαναλαμβανόμενα φωνήματα και κενά παραλείπονται και η οποία απαιτείται για τον όρο CTC της αντικειμενικής συνάρτησης. Τέλος, συμπεριλαμβάνεται στις γνωστές πληροφορίες και ένα log-probability confidence score για κάθε πρόβλεψη, που έχει παραχθεί κατά τη δημιουργία των προβλεπόμενων αλληλουχιών. Τα log-probabilities περιορίζονται στο σύνολο $[-10, 0]$ και έπειτα μεταφέρονται γραμμικά στο σύνολο $[0.5, 1.5]$, με frames που δεν καλύπτονται από το span κάποιου φωνήματος (κενά frames) να παίρνουν το default βάρος 1. Τα βάρη αυτά επηρεάζουν, έπειτα, τη συνεισφορά του κάθε λάθους σε επίπεδο frame στον όρο cross entropy, ώστε το μοντέλο να τιμωρείται λιγότερο στις περιπτώσεις που η ίδια η πρόβλεψη του target είναι αβέβαιη.

Όσον αφορά τα ίδια τα βίντεο, θεωρούμε ότι σε αυτά έχει εφαρμοστεί η πρόβλεψη χειλιών όπως παρουσιάζεται στην παράγραφο 5.1.1. Θεωρούμε, επίσης, batch size B , αριθμό frames T , αριθμό καναλιών C , ύψος H και πλάτος W σε pixels, με την τελική μορφή των δεδομένων εισόδου, όπως φαίνεται και στο σχήμα 9, να είναι $B \times T \times C \times H \times W$.

Εξαγωγή των Visual Features: Conv3D Frontend Η βασική σχεδιαστική επιλογή του συγκεκριμένου μοντέλου είναι η χρήση 3D συνελκτικού νευρωνικού δικτύου ως το πρώτο στάδιο του μοντέλου και όχι διδιάστατου νευρωνικού εφαρμοσμένου σε κάθε frame του βίντεο χωριστά. Η επιλογή αυτή συμβαίνει συνειδητά λόγω της φύσης του προβλήματος του διαβάσματος των χειλιών, το οποίο είναι τόσο πρόβλημα αναγνώρισης της εμφάνισης των χειλιών όσο είναι και πρόβλημα αναγνώρισης των κινήσεών τους. Η διαφοροποίηση μεταξύ πολλών φωνημάτων δεν έγκειται συχνά στην εικόνα απομονωμένων frames όσο στη σχέση μεταξύ διαδοχικών frames, η οποία φανερώνει, για παράδειγμα, την ταχύτητα με την οποία κλείνουν τα χείλη. Η πληροφορία αυτή, αν δεν μαθαίνεται ήδη από τα αρχικά στάδια του μοντέλου, πρέπει να μαθευτεί αποκλειστικά από το επόμενο στάδιο του μοντέλου (τον sequence encoder), ο οποίος σε αυτήν την περίπτωση έχει πρόσβαση μόνο σε στατική περιγραφή κάθε frame ξεχωριστά. Ωστόσο, σε εκείνο το στάδιο υπάρχει και η μακροπρόθεσμη παρακείμενη πληροφορία (πληροφορία που έχει να κάνει με ποια φωνήματα προηγούνται και ποια έπονται), οπότε κρίθηκε χρήσιμο η πληροφορία της κίνησης των χειλιών σε γειτονικά frames να εξάγεται ήδη από τον feature extractor.



Σχήμα 9: Σχηματική παρουσίαση της προτεινόμενης μεθόδου

Για κάθε ένα από τα 3 blocks συνελκτικού δικτύου 3 διαστάσεων, δεν εφαρμόζεται η τυπική συνέλιξη 3D, αλλά αυτή χωρίζεται σε 2 στάδια: το depthwise stage, κατά το οποίο μία συνέλιξη με kernel $(3, 3, 3)$ εφαρμόζεται ανεξάρτητα σε κάθε κανάλι της εισόδου, και το pointwise stage, που αποτελείται από μία pointwise $(1 \times 1 \times 1)$ συνέλιξη η οποία αναμειγνύει τις προηγούμενες εξόδους. Πρόκειται για μία συνήθη παραγοντοποίηση της συνέλιξης σε 3 διαστάσεις και ονομάζεται depthwise separable convolution (συνέλιξη διαχωρίσιμη ως προς το βάθος). Χρησιμοποιείται λόγω της μείωσης του αριθμού των παραμέτρων που προσφέρει. Συγκεκριμένα, έστω μία τυπική 3D συνέλιξη με πυρήνα $(3, 3, 3)$, η οποία οδηγεί C_{in} κανάλια εισόδου σε C_{out} κανάλια εξόδου. Το δίκτυο αυτό υπολογίζει το κάθε κανάλι εξόδου ως ένα σταθμισμένο άθροισμα όλων των καναλιών εισόδου και όλων των 27 πιθανών “χωροχρονικών” τοποθετήσεων του πυρήνα, χρειάζεται δηλαδή $27 \cdot C_{in} \cdot C_{out}$ παραμέτρους και άλλους τόσους πολλαπλασιασμούς και προσθέσεις. Από την άλλη, κατά το depthwise βήμα του depthwise separable convolution, κάθε κανάλι γίνεται αντικείμενο συνέλιξης με τον δικό του πυρήνα $(3, 3, 3)$ χωρίς να αναμειγνύεται με άλλα κανάλια, χρειάζονται δηλαδή $27 \cdot C_{in}$ παράμετροι. Η μίξη μεταξύ των καναλιών συμβαίνει στο pointwise stage, το οποίο δεν προσφέρει παρακείμενο (context) ούτε στη χρονική ούτε στις χωρικές διαστάσεις και άρα χρειάζεται $C_{in} \cdot C_{out}$ παραμέτρους, ίδιες με την περίπτωση fully connected layer μεταξύ των δύο καναλιών. Τελικά, χρησιμοποιώντας τη μέθοδο της depthwise separable convolution, οι απαιτούμενες παράμετροι και πράξεις μειώνονται από $27 \cdot C_{in} \cdot C_{out}$ σε $27 \cdot C_{in} + C_{in} \cdot C_{out}$, ελαττώνοντας αισθητά το υπολογιστικό κόστος του μοντέλου.

Πιο συγκεκριμένα, για τα 3 συνελκτικά μπλοκ που χρησιμοποιούνται στο μοντέλο, παρατηρούνται οι εξής μειώσεις σε παραμέτρους: για το πρώτο μπλοκ, ενώ με τυπική 3D συνέλιξη θα υπήρχαν $27 \cdot 3 \cdot 32 = 2592$ παράμετροι, ενώ με τη μέθοδο της depthwise separable convolution υπάρχουν $27 \cdot 3 + 3 \cdot 32 = 177$, μείωση δηλαδή κατά πάνω από 93%. Αντίστοιχα, για το δεύτερο μπλοκ η μείωση είναι από $27 \cdot 32 \cdot 64 = 55296$ σε $27 \cdot 32 + 32 \cdot 64 = 2912$, δηλαδή σχεδόν 19 φορές, ενώ στο τρίτο μπλοκ οι παράμετροι ελαττώνονται από $27 \cdot 64 \cdot 128 = 221184$ σε $27 \cdot 64 + 64 \cdot 128 = 9920$, άρα πάνω από 22 φορές λιγότερες. Παρατηρούμε ότι, όσο αυξάνεται το μέγεθος των καναλιών (συγκεκριμένα του καναλιού εξόδου), τόσο μεγαλύτερο γίνεται και το κέρδος χρήσης της μεθόδου αυτής, κάτι που γίνεται προφανές αν συγκριθούν οι όροι $C_{in} \cdot (27 + C_{out})$ και $C_{in} \cdot 27 \cdot C_{out}$: ο συντελεστής του C_{in} στον έναν όρο αυξάνει προσθετικά ενώ στον άλλον πολλαπλασιαστικά με το C_{out} .

Το trade-off της συγκεκριμένης μεθόδου είναι η ενίσχυση του inductive bias (επαγωγική μεροληψία) του μοντέλου: η φύση της depthwise separable convolution υποθέτει ότι τα διάφορα μοτίβα σε χώρο και χρόνο (spatiotemporal patterns) μπορούν να εντοπιστούν σε κάθε κανάλι ξεχωριστά. Η επίδραση του περιορισμού εξαρτάται από το βάθος του δικτύου στο οποίο αναφερόμαστε. Στο πρώτο συνελκτικό μπλοκ, τα κανάλια είναι RGB, με αποτέλεσμα ένα depthwise φίλτρο να είναι ικανό να εντοπίσει ακμές στον χώρο ή αλλαγές στον χρόνο σε κάθε ξεχωριστό κανάλι. Στην περίπτωση του πρώτου μπλοκ, η μόνη περίπτωση που μπορεί να εκφραστεί στην περίπτωση της πλήρους 3D συνέλιξης και όχι της μεθόδου που χρησιμοποιείται είναι ενός φίλτρου που αποκρίνεται διαφορετικά σε κόκκινη ακμή από ότι σε μπλε ακμή ίδιου χρώματος. Αυτή η χρωματική διάκριση δεν αποτελεί αντικείμενο του lip reading, καθώς τα στοιχεία που αναζητώνται (η θέση των χειλιών, η γεωμετρία του ανοίγματος και του κλεισίματός τους και η κίνησή τους) εμφανίζονται ως διαφορές φωτεινότητας και σχήματος που εμφανίζονται σε κάθε κανάλι.

Ο περιορισμός που προκαλείται λόγω αυτού του inductive bias ενισχύεται στα επόμενα μπλοκ συνέλιξης, όπου τα κανάλια δεν είναι πλέον κανάλια χρώματος αλλά feature maps. Σε αντίθεση με τα τυπικά 3D φίλτρα, τα οποία μπορούν να εντοπίσουν σε ένα βήμα την ενεργοποίηση δύο διαφορετικών καναλιών, η μέθοδος αυτή δεν μπορεί να κάνει τη μίξη των καναλιών να εξαρτάται από το χωρικό και χρονικό παρακείμενο εντός ενός block. Έτσι, χάνεται εκφραστικότητα του μοντέλου σε κάθε ξεχωριστή στρώση, η οποία ως έναν βαθμό περιορίζεται λόγω της ύπαρξης και του τελευταίου συνελκτικού μπλοκ, το οποίο μπορεί να εκφράσει κάποια πολυκαναλικά μοτίβα που δεν ήταν δυνατόν να εκφραστούν στην προηγούμενη στρώση. Δεδομένου του μεγέθους των dataset για το πρόβλημα αυτό, ο συμβιβασμός αυτός φαίνεται να αξίζει, καθώς η χαμένη εκφραστικότητα αναπληρώνεται ως ένα σημείο με μεγαλύτερο βάθος, ενώ ταυτόχρονα η βελτίωση στην αποδοτικότητα της εκπαίδευσης είναι πολύ μεγάλη. Να σημειωθεί ότι η σύγκριση πλήρους και διαχωρισμένης 3D συνέλιξης θα μπορούσε να αποτελεί αντικείμενο της μελέτης αφαίρεσης (όπως παρουσιάζεται στην ενότητα 6.3.1), αλλά κρίθηκε βασική σχεδιαστική επιλογή και η

σύγκριση αυτή θεωρείται ως ένα πιθανό μελλοντικό επόμενο βήμα.

Τα τρία συνελκτικά μπλοκ αυξάνουν τον αριθμό των καναλιών (από 3 σε 32, 64 και τέλος 128), ενώ κάθε ένα από αυτά έχει χωρικό stride 2, άρα η χωρική ανάλυση μειώνεται κατά 8 φορές. Αντιθέτως, το χρονικό stride είναι 1, έτσι ώστε να μη μειώνεται σε καμία περίπτωση ο αριθμός των frames. Η διατήρηση του αριθμού των frames κάθε βίντεο δεν οφείλεται αποκλειστικά στο βήμα αυτό, αλλά και στο temporal padding με τιμή 1 που εφαρμόζεται: για αριθμό frames εισόδου T_{in} , μήκος padding p , μέγεθος kernel k και stride s , έχουμε αριθμό frames στην έξοδο του συνελκτικού block $T_{out} = \lfloor ((T_{in} + 2 \cdot p - k)/s) \rfloor + 1$ και τελικά με τις επιλογές που έχουν γίνει $T_{out} = \lfloor ((T_{in} + 2 \cdot 1 - 3)/1) \rfloor + 1 = T_{in}$. Χωρίς το padding, κάθε συνελκτικό block μειώνει την αλληλουχία frames κατά 2, κάτι που θα ήταν καταστροφικό για τα labels για κάθε frame που έχουν δημιουργηθεί προηγουμένως. Το kernel με μέγεθος 3, ωστόσο, επιτρέπει στο μοντέλο να μάθει χρονικές εξαρτήσεις προσθέτοντας 2 frames στο receptive field του μοντέλου για κάθε στρώση, δημιουργώντας στην έξοδο του τελευταίου layer ένα receptive field από 7 frames, ικανό να περιγράψει την κίνηση των χειριών και την παραγωγή των φωνημάτων, όπως και τη μετάβαση μεταξύ τους.

Μετά τα 3 συνελκτικά μπλοκ, χρησιμοποιείται pooling μέσω AdaptiveAvgPool3d((None, 3, 3)), περιορίζοντας τις χωρικές διαστάσεις σε έναν σταθερό πίνακα 3×3 και διατηρώντας τη χρονική διάσταση σταθερή. Η επιλογή αυτή γίνεται ώστε το μοντέλο να είναι ανεξάρτητο από το μέγεθος του αρχικού βίντεο που εισάγεται σε αυτό. Έτσι, η αρχιτεκτονική μπορεί να εφαρμοστεί για διάφορα μεγέθη crop. Τελικά, τα παραγόμενα διανύσματα σε διάσταση $128 \times 3 \times 3 = 1152$ αποτελούν είσοδο σε έναν γραμμικό projector προς την κρυφή διάσταση h (hidden dimension), η οποία έχει την προεπιλεγμένη τιμή 256, μειώνοντας τη διάσταση των δεδομένων προτού εισαχθούν στον sequence encoder. Ακολουθεί η εφαρμογή Layer Normalization, ReLU activation function και Dropout, βελτιώνοντας την κανονικοποίηση του μοντέλου. Οι διαστάσεις των δεδομένων είναι πλέον (B, T, h)

Positional Encoding Λόγω της πιθανής επιλογής χρήσης transformer αντί για Bi-LSTM στη βαθμίδα του sequence encoding (όπως φαίνεται και στο πείραμα αφαίρεσης στην ενότητα 6.3.1, απαιτείται η χρήση positional encoder, ώστε να υπάρχει πληροφορία της σειράς των feature vectors που παράγονται από το 3D CNN frontend. Χρησιμοποιείται τυπική ημιτονοειδής κωδικοποίηση της θέσης των feature vectors, όπως παρουσιάζεται στην ενότητα 3.2. Η κωδικοποίηση αυτή, αν και δε χρειάζεται στην περίπτωση χρήσης Bi-LSTM sequence encoder, μια και τα LSTM από τη φύση τους διατηρούν πληροφορία για την αλληλουχία των tokens, διατηρείται και στην περίπτωση επιλογής Bi-LSTM (η οποία είναι η προεπιλογή, είναι αυτή που παρουσιάζεται στο σχήμα 9 και που πετυχαίνει καλύτερα αποτελέσματα στη μελέτη αφαίρεσης 6.3.1) για συνοχή της αρχιτεκτονικής και ώστε ο encoder να μπορεί να αλλάξει χωρίς να πρέπει να μεταβληθεί το υπόλοιπο pipeline.

Sequence Encoder Για την επίτευξη του στόχου του lip reading, είναι σημαντικό να προσαρτηθεί στην τελική απόφαση του μοντέλου μεγαλύτερο παρακαίμενο (context), συγκεκριμένα στη διάσταση του χρόνου. Το μοντέλο, έχοντας πρόσβαση σε περισσότερη πληροφορία για το παρελθόν και το μέλλον της ακολουθίας των φωνημάτων, μπορεί να μάθει να εξάγει συμπεράσματα για ένα φώνημα όχι μόνο από τα frames της γειτονιάς στην οποία εκφέρεται, αλλά και από αυτά που προηγήθηκαν ή έπονται. Είναι ευχής έργον το μοντέλο να μάθει εξαρτήσεις φωνημάτων από το παρακαίμενο, ιδιαίτερα σε περιπτώσεις όπου το λεξιλόγιο στο οποίο εκπαιδεύεται το μοντέλο είναι περιορισμένο. Ακόμα και σε μη περιορισμένες περιπτώσεις, ωστόσο, ένα μοντέλο δύναται να μάθει γενικές εξαρτήσεις κάποιας γλώσσας (π.χ. ότι στην αγγλική σε παρακαίμενο με τη λέξη “dog”, οι λέξεις “bark” ή “park” είναι πιο πιθανές από τη λέξη “mark” και άρα τα φωνήματα /b/ ή /p/ πρέπει να προβλεφθούν με μεγαλύτερο βάρος από το /m/, παρά το γεγονός ότι οι λέξεις έχουν την ίδια εικόνα στα χείλη) και με βάση αυτές να βελτιώσει τις προβλέψεις του, ειδικά σε περιπτώσεις σύγχυσης σε κάποια κλάση viseme.

Για τον λόγο αυτόν χρησιμοποιείται στο μοντέλο ο Sequence Encoder, δηλαδή ο κωδικοποιητής αλληλουχίας, δουλειά του οποίου είναι να συμπύκνωση την πληροφορία του παρακειμένου και οποιουδήποτε δεδομένου token και με βάση αυτά να δημιουργήσει ένα νέο embedding το οποίο αξιοποιεί και τα δύο. Κατά τη διάρκεια της εργασίας δοκιμάστηκαν δύο τύποι sequence encoders (όπως και η εκδοχή με την

πλήρη παράλειψή του) στη μελέτη αφαίρεσης (βλ. ενότητα 6.3.1): ο ένας αξιοποιούσε την αρχιτεκτονική των BiLSTMs (bi-directional long-short term memory) και ο άλλος απαρτιζόταν από transformers. Τελικά η εκδοχή βασισμένη στα BiLSTMs πετυχαίνει καλύτερα αποτελέσματα και άρα είναι αυτή που παρουσιάζεται στο σχήμα 9. Ωστόσο, για πληρότητα, στις παρακάτω παραγράφους παρουσιάζονται και συγκρίνονται αμφοτέρους οι μέθοδοι.

Η εκδοχή με BiLSTM χρησιμοποιεί 2 στρώσεις της συγκεκριμένης αρχιτεκτονικής, οι οποίες επιτρέπουν στην αναπαράσταση του κάθε frame να επηρεάζεται τόσο από παρελθοντικό όσο και από μελλοντικό παρακείμενο, και παράγει έξοδο με διάσταση $2 \cdot h$, διπλασιάζει δηλαδή την κρυφή διάσταση. Στην περίπτωση του transformer χρησιμοποιείται multi-head self-attention με προεπιλεγμένη τιμή 4 heads και 2 layers, ενώ η διάσταση εξόδου παραμένει σταθερή και ίση με h . Για να μπορούν να συγκριθούν οι δύο εκδοχές, ακολουθούνται και οι 2 από layer normalization και dropout πριν την είσοδο των δεδομένων στην κεφαλή ταξινόμησης.

Όπως αναφέρεται και εξηγείται κατά τον σχολιασμό των αποτελεσμάτων της μελέτης αφαίρεσης 6.3.1, τα 2 μοντέλα διαφέρουν και στο inductive bias με το οποίο συνδέονται. Συγκεκριμένα, το BiLSTM εξετάζει την αλληλουχία βήμα με βήμα, με αποτέλεσμα η αναπαράσταση του frame t να χτίζεται αναδρομικά από την πληροφορία που περιέχεται στο frame $t - 1$ (ή, αντίστοιχα, στο backwards pass από το $t + 1$). Έτσι, το μοντέλο υποθέτει εξ' αρχής μία χρονική συσχέτιση, ειδικά των κοντινών frames. Αντιθέτως, ο μηχανισμός του self-attention χωρίς το sinusoidal encoding θα αντιμετώπιζε την αλληλουχία των frames ως ένα χαώδες σύνολο. Ακόμα και όταν χρησιμοποιείται το positional encoding, ο transformer πρέπει να μάθει να χρησιμοποιεί το παραπάνω σήμα ως πληροφορία αλληλουχίας των frames. Έτσι, παρά της δυνατότητας να δίνει βάρος σε οποιοδήποτε άλλο frame, ανεξαρτήτως χρονικής απόστασης, ο transformer μαθαίνει πιο δύσκολα να εστιάζει στην πληροφορία γειτονικών frames, κάτι που από τη φύση του το BiLSTM, το οποίο δίνει βάρος στο πρόσφατο context, δε χρειάζεται να μάθει. Βέβαια το πλεονέκτημα του transformer έγκειται ακριβώς εκεί: μπορεί να αναπτύξει πιο εύκολα μακροπρόθεσμες εξαρτήσεις, οι οποίες ειδικά σε περιπτώσεις ομιλίας σε μη περιορισμένο περιβάλλον είναι κρίσιμες για την ορθή πρόβλεψη των φωνημάτων και τελικά των λέξεων που εκφέρονται.

Λόγω των επαναλαμβανόμενων πυλών (recurrent gates) που χρησιμοποιούνται για τον υπολογισμό του hidden state του BiLSTM, η μακροχρόνια πληροφορία αναπόφευκτα συμπίεζεται και τελικά παραγράφεται, με αποτέλεσμα η επίδραση ενός πολύ μακρινού frame να είναι τελικά μικρή. Αντιθέτως, η αρχιτεκτονική του self-attention συνδέει κάθε frame με οποιοδήποτε άλλο frame σε κάθε στρώση, διευκολύνοντας την αλληλεξάρτηση μεταξύ μακρινών χρονικά frames. Η διαφοροποίηση αυτή έχει να κάνει λιγότερο με την κίνηση των χειλιών, για της οποίας το υποδεκτικό πεδίο (receptive field) φροντίζει το Conv3d frontend που χρησιμοποιεί παράθυρο 7 frames για την τελική πληροφορία που εξάγει, όσο για πιο μακροχρόνιες δυναμικές της ομιλίας σαν τον ρυθμό και το γενικό παρακείμενο της ομιλίας.

Σε περίπτωση που τα βίντεο ενός batch έχουν αρχικά διαφορετικό μήκος και άρα τα μικρότερα από αυτά έχουν υποστεί padding, χρησιμοποιούνται για τις δύο εκδοχές του μοντέλου διαφορετικές μέθοδοι για να μην επιτρέπεται στα padded frames να επηρεάζουν την εκπαίδευση. Για το BiLSTM χρησιμοποιούνται τα pack_padded_sequence και pad_packed_sequence, τα οποία αφαιρούν τα padded frames από τη διαδικασία της αναδρομής. Το μοντέλο που χρησιμοποιεί transformer χρησιμοποιεί μία μάσκα src_key_padding_mask η οποία μηδενίζει το βάρος του attention από και προς padded frames.

Όσον αφορά τον αριθμό παραμέτρων για κάθε μοντέλο, το BiLSTM αποτελείται από περίπου 2.63 εκατομμύρια παραμέτρους, ενώ ο transformer από 1.58 εκατομμύρια, σχεδόν 1.66 φορές λιγότερες. Αυτό οφείλεται κυρίως στο γεγονός ότι στην έξοδο της πρώτης στρώσης του BiLSTM τα hidden states του προς τα μπροστά και του προς τα πίσω passes συνενώνονται, δημιουργώντας τελικά για τη 2η στρώση είσοδο διάστασης $2 \cdot h$ και αυξάνοντας το κόστος της. Οι παράμετροι του transformer παραμένουν ανάλογες με την αρχική κρυφή διάσταση h , καθώς δεν υπάρχει μεταβολή ανάμεσα στη διάσταση της εισόδου και της εξόδου τους.

Τέλος, να σημειωθεί ότι σε κάθε περίπτωση εφαρμόζεται gradient-norm clipping, το οποίο αποτελεί αναγκασία προσθήκη για την αποφυγή των explosive gradients ειδικά για την περίπτωση του BiLSTM, τα οποία οφείλονται στον πολλαπλασιασμό των recurrent gradients σε διάφορα βήματα του χρόνου. Από την άλλη, λόγω της αρχικής αστάθειας που παρουσιάζουν οι transformers ειδικά κατά τον υπολογισμό

logits (τα αρχικά αποτελέσματα του attention είναι εσωτερικά γινόμενα τυχαίων προβολών query και key, με αποτέλεσμα οι προβλέψεις να είναι ιδιαίτερα θορυβώδεις πριν οι προβολές να έχουν μάθει κάτι ιδιαίτερο), χρησιμοποιείται linear warmup του ρυθμού μάθησης, κρατώντας τον χαμηλό όσο παράγονται μη αξιόπιστα gradients που ίσως οδηγούσαν το μοντέλο σε αστάθεια. Οι δύο αυτές προσαρμογές, αν και αντιτίθενται σε διαφορετικά προβλήματα των δύο μοντέλων, χρησιμοποιούνται και πάλι σε κάθε περίπτωση, ώστε η αρχιτεκτονική των μοντέλων να παραμένει σταθερή.

Κεφαλή Ταξινόμησης - Classification Head Για να παραχθούν οι τελικές προβλέψεις logits για κάθε frame, χρησιμοποιείται μία γραμμική στρώση η οποία προβάλλει την έξοδο του sequence encoder (με διάσταση $2h$ όταν επιλέγεται το BiLSTM και h όταν χρησιμοποιείται ο transformer) στη διάσταση $v + 1$, όπου v είναι η διάσταση του λεξιλογίου που χρησιμοποιείται (ο αριθμός των φωνημάτων που περιλαμβάνονται στη μελέτη ή στο συγκεκριμένο dataset). Η μία διάσταση παραπάνω οφείλεται στην ύπαρξη του κενού/blank συμβόλου, που αντιπροσωπεύει τη σιγή. Και σε αυτό το στάδιο δεν υπάρχει υποδειγματοληψία του χρόνου, ώστε οι προβλέψεις να έχουν το ίδιο μήκος με αυτό της πραγματικής αλληλουχίας φωνημάτων και να έχει νόημα ο υπολογισμός του όρου cross entropy.

Συνάρτηση Κόστους - VisemeAwareFrameLoss Για την εκπαίδευση του μοντέλου χρησιμοποιείται ένας προσαρμοσμένος στόχος μάθησης με τίτλο VisemeAwareFrameLoss. Η συνάρτηση αυτή συνδυάζει δύο όρους, έναν όρο cross-entropy στο επίπεδο των frames και έναν όρο Auxiliary CTC Loss. Για τεχνικές πληροφορίες περί των δύο αυτών όρων της αντικειμενικής συνάρτησης, ανατρέξτε στην ενότητα 3.2.

Για κάθε έγκυρο frame, υπολογίζεται ο όρος της cross-entropy ανάμεσα στην προβλεπόμενη κατανομή q και την ομαλή κατανομή target p , με την εξομάλυνση που παρουσιάστηκε παραπάνω. Στον όρο αυτόν προστίθεται μία περαιτέρω ποινή με στόχο τα frames τα οποία έχουν κατηγοριοποιηθεί ως frames σιγής. Συγκεκριμένα, για frame με target t και πρόβλεψη blank token $P(blank)$, ο όρος υπολογίζεται ως

$$penalty = insertion_penalty \cdot 1[t = blank] \cdot (1 - P(blank))$$

όπου *insertion_penalty* είναι παράμετρος που ορίζει τη μέγιστη τιμή του προστιθέμενου όρου με προεπιλεγμένη τιμή 0.5. Παρατηρώντας τον παραπάνω τύπο, συμπεραίνουμε ότι παίρνει τιμή 0 όταν το label του frame δεν αντιστοιχεί στη σιγή ή όταν αντιστοιχεί στη σιγή και το μοντέλο προβλέπει με απόλυτη βεβαιότητα το blank token. Σε περίπτωση που το blank token είναι το σωστό, όσο η πρόβλεψη του μοντέλου για το blank token γίνεται με λιγότερη αυτοπεποίθηση, τόσο αυξάνεται και ο όρος ποινής (γραμμικά), με μέγιστη τιμή το *insertion_penalty*. Στόχος του όρου αυτού είναι να τιμωρούνται σε μεγαλύτερο βαθμό τα “false positives”, δηλαδή η πρόβλεψη φωνημάτων σε frames στα οποία δεν υπάρχει κάποιο φώνημα. Ο συμμετρικός όρος, όρος δηλαδή που θα τιμωρούσε τα “false negatives”, τις προβλέψεις της σιγής σε περίπτωση που στο frame αντιστοιχίζεται κάποιο φώνημα, δε συμπεριλαμβάνεται, καθώς κατά τις δοκιμές βρέθηκε ότι δεν επηρεάζει αισθητά το αποτέλεσμα.

Η ποινή προστίθεται στην τιμή που υπολογίστηκε από το cross-entropy και το άθροισμα αυτό πολλαπλασιάζεται με το confidence score της πρόβλεψης όπως παρουσιάστηκε προηγουμένως. Τέλος, υπολογίζεται ο μέσος όρος του παραπάνω για όλα τα έγκυρα frames, παράγοντας τον όρο *frame_loss* του batch. Πέραν του όρου αυτού, υπολογίζεται και η τυπική συνάρτηση κόστους CTC, η οποία ενισχύει το σήμα της σωστής αλληλουχίας φωνημάτων και είναι ανεξάρτητη από την οριοθέτηση των φωνημάτων σε επίπεδο frames. Ο όρος CTC *ctc_loss* πολλαπλασιάζεται με τη σταθερά *ctc_weight* με τυπική τιμή 0.3 και προστίθεται στον όρο *frame_loss* υπολογίζοντας την τελική τιμή της συνάρτησης κόστους:

$$total_loss = frame_loss + ctc_weight \cdot ctc_loss$$

Στόχος του συνδυασμού των δύο συναρτήσεων κόστους είναι να δίνεται στο μοντέλο αυστηρή χρονική επίβλεψη (supervision), ειδικά όταν η πρόβλεψη του target γίνεται με αυτοπεποίθηση, ενώ ταυτόχρονα να υπάρχει το δεύτερο σήμα που δεν τιμωρεί υπερβολικά τις διαφωνίες στην οριοθέτηση αλλά

εστιάζει στην επίτευξη της σωστής αλληλουχίας κατά την πρόβλεψη.

Άλλες λεπτομέρειες για την εκπαίδευση Όσον αφορά την εκπαίδευση του μοντέλου, χρησιμοποιήθηκε AdamW optimizer (με weight decay χρησιμοποιώντας τυπική τιμή 10^{-4} , με γραμμικό warmup του ρυθμού μάθησης (τυπικά για 5 εποχές) μέχρι τη μέγιστη τιμή ($3 \cdot 10^{-4}$). Χρησιμοποιείται επίσης ReduceLROnPlateau με scheduling που βασίζεται στο validation token error rate (βλ. ενότητα 6.2). Εφαρμόζεται gradient clipping στο 1.0, ενώ χρησιμοποιείται και μηχανισμός early stopping της εκπαίδευσης, αν το validation token error rate δε βελτιωθεί για τουλάχιστον 10^{-4} για έναν αριθμό εποχών (τυπικά 12). Για την αξιολόγηση στους test set, χρησιμοποιείται το μοντέλο με το χαμηλότερο validation TER, το οποίο δεν είναι αναγκαστικά αυτό της τελευταίας εποχής.

5.3 Audiovisual Μοντέλο

Στην ενότητα αυτή περιγράφεται αναλυτικά η αρχιτεκτονική του προτεινόμενου audiovisual μοντέλου, το οποίο συνδυάζει τόσο το ηχητικό όσο και το σήμα βίντεο για την πρόβλεψη των φωνημάτων και δοκιμάζεται σε συνθήκες όπου υπάρχει θόρυβος και στα δύο modalities. Στα σχήματα 10 και 11, παρουσιάζεται μία απεικόνιση των βασικών σχεδιαστικών επιλογών του μοντέλου.

Το μοντέλο αποτελείται από 5 διαδοχικά στάδια:


1. Τα 2 ανεξάρτητα συνελκτικά frontends, υπεύθυνα για την εξαγωγή των πληροφοριών από το βίντεο και από τον ήχο.
2. Positional Encoding, το οποίο εξυπηρετεί το Cross-Modal Attention που ακολουθεί, όπως και την ύπαρξη της επιλογής του Transformer στο στάδιο του Sequence Encoder.
3. Cross-Modal Attention και στις δύο κατευθύνσεις (audio $\rightarrow$ video και video $\rightarrow$ audio).
4. Συνένωση των αναπαραστάσεων του βίντεο και του ήχου με βάση την αξιοπιστία τους (Reliability-gated fusion)
5. Sequence Encoder με ταξινόμηση σε επίπεδο frame, όπως και δευτερευόντων (auxiliary) ταξινομήσεων με βάση κάθε modality ξεχωριστά

Για κάθε ένα από τα στάδια αυτά, γίνεται ειδική αναφορά παρακάτω.


Δομή των δεδομένων εισόδου Κάθε training instance για το audiovisual μοντέλο αποτελείται από τις εξής χρονικά ευθυγραμμισμένες εισόδους ($t = 1, \dots, T$):

- ένα βίντεο $V \in \mathbb{R}^{T \times C \times H \times W}$, όπου C είναι ο αριθμός των καναλιών (3 για βίντεο RGB), το ύψος και W το πλάτος του κάθε frame σε pixels. Υπενθυμίζεται ότι το βίντεο είναι εστιασμένο στην περιοχή των χειλιών, όπως στην περίπτωση του μοντέλου που αξιοποιεί αποκλειστικά το βίντεο, όμως έχει προστεθεί θόρυβος σύμφωνα με την ενότητα 5.1.4.
- ένα λογαριθμικό Mel-Spectrogram $M \in \mathbb{R}^{T \times n_{mels}}$, που υπολογίζεται από το αρχικό ηχητικό σήμα στο οποίο έχει προστεθεί θόρυβος σύμφωνα με τα περιεχόμενα της ενότητας 5.1.4.
- την πραγματική (ground truth) αλληλουχία φωνημάτων για κάθε frame, με την ίδια μορφή που χρησιμοποιείται στην περίπτωση του βασικού προτεινόμενου μοντέλου.
- τα σκορ αξιοπιστίας $r_v(t) \in [0, 1]$ και $r_a(t) \in [0, 1]$, $t = 1, \dots, T$ του βίντεο και του ήχου αντίστοιχα για κάθε frame. Υπολογίζονται όπως περιγράφεται στην ενότητα 5.1.4. Τα σκορ αυτά θεωρούνται, προς διευκόλυνση του προβλήματος, δεδομένες πληροφορίες και όχι κάτι που πρέπει να υπολογίζεται από το ίδιο το νευρωνικό δίκτυο. Ο τρόπος με τον οποίο χρησιμοποιούνται τα εν λόγω σήματα σχολιάζεται παρακάτω.

Για τα παρακάτω, θεωρείται ότι το batch size είναι ίσο με B και ότι τα κανάλια C είναι πράγματι 3, αντικατοπτρίζοντας τη χρήση RGB βίντεο.



Σχήμα 10: Σχηματική παρουσίαση της προτεινόμενης μεθόδου για το audiovisual model, 1ο σχήμα



Σχήμα 11: Σχηματική παρουσίαση της προτεινόμενης μεθόδου για το audiovisual model, 2ο σχήμα

Εξαγωγή των Visual Features: Conv3D Frontend Το Conv3D Frontend είναι υπεύθυνο για την εξαγωγή των visual features, δηλαδή των χρήσιμων στοιχείων που εμπεριέχονται στο βίντεο. Μετατρέπει τη ροή των δεδομένων του βίντεο από την αρχική διάσταση $V \in \mathbb{R}^{B \times T \times C \times H \times W}$ σε μία αλληλουχία embeddings για κάθε frame της μορφής $F_v \in \mathbb{R}^{B \times T \times d}$, όπου d είναι η τιμή της παραμέτρου *hidden_dim*, με προεπιλεγμένη τιμή 256.

Ως επέκταση της αρχικής προτεινόμενης μεθοδολογίας, η μορφή του Conv3D Frontend είναι πα- νομοιότυπη με αυτήν του αντίστοιχου block του αρχικού visual μοντέλου. Έτσι, συνεχίζει και στην περί- πτωση αυτήν να ισχύει η επιλογή της depthwise 3D συνέλιξης για τη μείωση του υπολογιστικού κόστους, η επιλογή βήματος στον χρονικό άξονα μονίμως 1, ενώ στους χωρικούς άξονες είναι 2 και η γενικότερη μορφή του συνελκτικού δικτύου (με 3 συνελκτικά blocks, αυξάνοντας τον αριθμό των καναλιών από 3 σε 32, μετά σε 64 και τελικά σε 128, ακολουθόμενο από AdaptiveAvgPool3d που κρατά τον χρονικό άξονα αλλά εφαρμόζεται σε περιοχή 3x3 στον χώρο, έπειτα από τον γραμμικό projector, ο οποίος προβάλλει το διάνυσμα feature από την αρχική διάσταση $128 \times 3 \times 3 = 1152$ στη διάσταση $d = \text{hidden_dim}$ και τέλος από στρώσεις LayerNorm, ReLU και dropout).

Τελικά, τα δεδομένα έχουν πλέον τη μορφή $F_v \in \mathbb{R}^{B \times T \times d}$, όπου για κάθε βίντεο του batch το κάθε $F_v(t) \in \mathbb{R}^d, t = 1, \dots, T$ αποτελεί την αναπαράσταση των χαρακτηριστικών του βίντεο για το frame t . Για περισσότερες λεπτομέρειες αναφορικά με τη λειτουργία του μπλοκ αυτού, όπως και τις διάφορες σχεδιαστικές επιλογές που το απαρτίζουν, ανατρέξτε στην ενότητα 5.2.

Εξαγωγή των Audio Features: AudioMel Frontend Το frontend που χρησιμοποιείται για το ηχητικό σήμα είναι ουσιαστικά το ανάλογο του αντίστοιχου μπλοκ για το βίντεο, στις 2 διαστάσεις αντί για τις 3 (μια και τα Mel-Spectrograms είναι διδιάστατα σήματα και όχι τρισδιάστατα, όπως το βίντεο). Το audio frontend προβάλλει το Mel-Spectrogram $M \in \mathbb{R}^{T \times n_{mels}}$ σε μία σειρά από embeddings (features εξαγό- μενα από τον ήχο) $F_a \in \mathbb{R}^{B \times T \times d}$, όπου $d = \text{hidden_dim}$ είναι και πάλι η κρυφή διάσταση. Εντός του block, εκτελούνται τα ακόλουθα βήματα:

1. Το φασματογράφημα επιδέχεται reshaping ώστε να αποτελεί μονοκαναλική εικόνα $(B, 1, T, n_{mels})$, όπου οι χωρικοί άξονες είναι αυτοί του χρόνου και των συχνοτήτων mel. Αυτό επιτρέπει την depthwise separable συνέλιξη που ακολουθεί.
2. Ακολουθούν 3 depthwise separable συνελκτικά block, με φίλτρα 3x3, όπου τα κανάλια αυξάνονται από 1 σε 32, έπειτα σε 64 και τέλος σε 128. Κάθε ένα από αυτά χρησιμοποιεί stride 1 στον χρο- νικό άξονα και 2 στον άξονα των συχνοτήτων mel. Η επιλογή αυτή εξυπηρετεί τη διατήρηση του χρονικού άξονα.
3. Εφαρμόζεται AdaptiveAvgPool2d το οποίο εφαρμόζεται στον άξονα των συχνοτήτων και όχι σε αυτόν του χρόνου, παράγοντας για κάθε frame ένα διάνυσμα χαρακτηριστικών στις 128 διαστάσεις (όσες και τα κανάλια μετά το 3ο συνελκτικό μπλοκ, άρα οι συχνότητες “καταρρέουν”).
4. Τέλος, εφαρμόζεται μία γραμμική στρώση αξιοποιώντας Layer Normalization, ReLU και Dropout, ακριβώς όπως στην περίπτωση του αντίστοιχου συνελκτικού block της πληροφορίας του βίντεο. Η γραμμική στρώση οδηγεί και πάλι στην κρυφή διάσταση $d = \text{hidden_dim}$, όπως και στην περί- πτωση του βίντεο, ώστε τα τελικά σήματα $F_a(t)$ και $F_v(t)$, τα οποία περιέχουν τα per-frame features του ηχητικού σήματος και του βίντεο αντίστοιχα, να έχουν την ίδια διάσταση.

Το συγκεκριμένο block εκτελεί λειτουργία για το φασματογράφημα των συχνοτήτων mel παρόμοια με αυτήν που εκτελεί ένα συνελκτικό δίκτυο ταξινόμησης για μία εικόνα. Συγκεκριμένα, οι πρώτες στρώσεις, οι οποίες λειτουργούν με μικρό δεκτικό πεδίο (receptive field) εντός του επιπέδου χρόνου-συχνοτήτων, μαθαίνουν βασικά τοπικά πρότυπα (patterns) της αναπαράστασης της ομιλίας σε φασματογράφημα (όπως, για παράδειγμα, την τοπική εμφάνιση των διάφορων formants - των βασικών συχνοτήτων κατά την ομιλία - ή τη μεταφορά από έμφωνα σε άφωνα τμήματα της ομιλίας). Οι βαθύτερες στρώσεις συν- δυάζουν τα τοπικά συμπεράσματα των προηγούμενων στρώσεων και εξαγουν μία γενικότερη αναπα- ράσταση του κάθε βήματος χρόνου, η οποία μπορεί να χρησιμοποιηθεί για την τελική πρόβλεψη φωνη- μάτων. Έτσι, οι μετέπειτα στρώσεις ανταποκρίνονται και σε πρότυπα σε μεγάλη περιοχή του φάσματος,

όπως την απεικόνιση των formants που διαχωρίζει τα φωνήεντα, και δεν περιορίζονται σε μόνο τοπικά bins συχνοτήτων, ιδιότητα η οποία είναι βασική για την ορθή πρόβλεψη φωνημάτων.

Επιλέγεται και για αυτό το block η depthwise separable συνέλιξη αντί για την τυπική εκδοχή της. Η 2D συνέλιξη χωρίζεται πρώτα σε ένα depthwise βήμα (ένα φίλτρο 3x3 για κάθε κανάλι, χωρίς μίξη μεταξύ των καναλιών), το οποίο ακολουθείται από ένα pointwise βήμα 1x1 κατά το οποίο αναμειγνύεται η πληροφορία των καναλιών. Ο διαχωρισμός αυτός μειώνει τον αριθμό των παραμέτρων του κάθε συνελκτικού τμήματος (για λόγους πλήρως όμοιους με αυτούς του αντίστοιχου βίντεο block, όπως φαίνεται στην ενότητα 5.2) από $O(k^2 \cdot C_{in} \cdot C_{out})$ σε $O(k^2 \cdot C_{in} + C_{in} \cdot C_{out})$, όπου k είναι το μέγεθος του πυρήνα (εδώ 3) και C_{in}, C_{out} είναι ο αριθμός των καναλιών της εισόδου και της εξόδου αντίστοιχα. Η επιλογή αυτή βοηθά αφενός με τη μείωση των παραμέτρων του μοντέλου που εκπαιδεύεται, ενώ ταυτόχρονα διατηρεί συμμετρική τη μορφή των 2 αρχικών feature extractors, για βίντεο και ήχο. Η επιλογή αυτή καθιστά τους 2 feature extractors όμοια εκφραστικούς, αντί ο ένας από τους δύο να έχει μεγαλύτερη εκφραστική δυνατότητα. Μία ασυμμετρία στην εκφραστική ικανότητα θα μπορούσε να προσφέρει ένα bias στις μετέπειτα στρώσεις του μοντέλου, ώστε να εμπιστεύονται κυρίως το modality που περιγράφεται με υψηλότερη ικανότητα και όχι αναγκαστικά αυτό που περιέχει τη λιγότερο θορυβώδη πληροφορία (και άρα είναι πιο αξιόπιστο).

Καθώς το πρόβλημα είναι sequence labelling και όχι πρόβλημα ταξινόμησης ολόκληρης της φράσης, ο χρονικός άξονας πρέπει να διατηρηθεί και στο ηχητικό σήμα (όπως και σε αυτό του βίντεο). Έτσι, όπως προαναφέρθηκε, επιλέγεται stride 2 στον χώρο των συχνοτήτων και 1 σε αυτό του χρόνου, ώστε να μην υπάρχει κατάρρευση του χρονικού άξονα, ο οποίος έχει ευθυγραμμιστεί για τα 2 modalities και το target phoneme sequence εκ των προτέρων. Αποφεύγεται, με αυτόν τον τρόπο, η ανάγκη χρήσης εργαλείου resampling στον χρόνο, όπως upsampling ή παρεμβολής, πριν τη χρήση των feature vectors F_a και F_v για την εξαγωγή συνολικών συμπερασμάτων με βάση και τα 2 modalities.

Μία ακόμα ενδιαφέρουσα επιλογή είναι η επιλογή να μην κρατηθεί μία μικρή διάσταση συχνοτήτων κατά το pooling (π.χ. να υπάρχει ένας χάρτης χαρακτηριστικών 128x4 για κάθε frame, ο οποίος να προβάλλεται από τη γραμμική στρώση στην κρυφή διάσταση, αντί οι συχνότητες να καταρρέουν τελείως, με τρόπο ανάλογο που γίνεται στην περίπτωση του βίντεο, όπου παραμένει μία περιοχή 3x3 μετά το pooling). Η επιλογή αυτή είναι συνειδητή, καθώς η πληροφορία των δύο σημάτων είναι εν γένει διαφορετική: στο βίντεο, η γενική πληροφορία της θέσης που εντοπίζεται ένα πρότυπο είναι σημαντική για την ομιλία (π.χ. πάνω ή κάτω χείλος), κάνοντας τη διατήρηση μίας μικρής περιοχής χρήσιμη. Αντίθετα, στο Mel-Spectrogram, η πληροφορία κρύβεται στο γενικό σχήμα του συχνοτικού περιεχομένου και όχι στην ακριβή περιοχή που συμβαίνει αυτή η ενεργοποίηση. Έτσι, κρίθηκε εύστοχη απλοποίηση η πλήρης κατάρρευση του άξονα των συχνοτήτων, πριν δοθεί η πληροφορία στη γραμμική στρώση.

Το AudioMel Frontend, όντας αρχιτεκτονικά παρόμοιο με το αντίστοιχο Conv3D Visual Frontend, περιέχει και παρόμοια γραμμική στρώση που παράγει τα τελικά audio features F_a . Η επιλογή αυτή δεν είναι τυχαία, καθώς ακολουθεί cross-attention το οποίο υπολογίζει εσωτερικά γινόμενα και αθροίσματα των $F_v(t)$ και $F_a(t)$. Έτσι, τα δύο αυτά σήματα πρέπει να βρίσκονται στην ίδια διάσταση και να χαρακτηρίζονται από παρόμοια κανονικοποίηση. Η επιλογή της αρχιτεκτονικά όμοιας γραμμικής στρώσης για το ηχητικό σήμα έχει ως αποτέλεσμα τη μη εμφάνιση ασυμμετριών προτού "συναναστραφούν" τα δύο σήματα, άρα οι ασυμμετρίες που εμφανίζονται τελικά μεταξύ των δύο (π.χ. στις πύλες αξιοπιστίας - reliability gates- που περιγράφονται παρακάτω) να οφείλονται αποκλειστικά στην αξιοπιστία του εκάστοτε σήματος και όχι σε προηγούμενη ανεπάρκεια ενός εκ των δύο εξαγωγικών χαρακτηριστικών.

Positional Encoding Προστίθεται στα σήματα F_v και F_a ημιτονοειδές positional encoding (όπως ακριβώς και στην περίπτωση του visual μοντέλου της ενότητας 5.2), το οποίο είναι ίδιο για κάθε modality, πριν την αλληλεπίδραση των δύο. Η επιλογή αυτή είναι αναγκαία για την πλήρη αξιοποίηση της στρώσης Cross-Attention που ακολουθεί (και της επιλογής τελικού transformer encoder), έτσι ώστε να παρέχεται στο μοντέλο πληροφορία περί της χρονικής απόστασης των features του κάθε frame. Χρησιμοποιείται τυπική ημιτονοειδής κωδικοποίηση της θέσης των feature vectors, όπως παρουσιάζεται στην ενότητα 3.2.

Modality Dropout Κατά την εκπαίδευση, εφαρμόζεται ολικό dropout του feature stream αυστηρά ενός εκ των δύο modalities με πιθανότητα ίση με την παράμετρο *modality_dropout* (προεπιλεγμένη τιμή 0.15). Η επιλογή αυτή είναι συχνή σε περιπτώσεις όπου συνδυάζονται δύο διαφορετικά modalities και στοχεύει στην αύξηση της ευρωστίας του μοντέλου. Εξαναγκάζει τον εκάστοτε μηχανισμό συνδυασμού να μπορεί να χειρίζεται περιπτώσεις όπου ένα ολόκληρο modality είναι μη διαθέσιμο ή μη αξιόπιστο σε υψηλό βαθμό.

Cross-modal Attention Η βασική σχεδιαστική επιλογή υπεύθυνη για την ανάμειξη των πληροφοριών των δύο modalities είναι αυτή του Cross-modal Attention που επιβάλλεται για στρώσεις ίσες με *cross_attn_layers* (παράμετρος με προεπιλεγμένη τιμή ίση με 1), πριν το βήμα fusion που συνενώνει τις πληροφορίες πλήρως. Οι είσοδοι στο συγκεκριμένο block είναι οι έξοδοι των Frontends κάθε modality, δηλαδή η αλληλουχία χαρακτηριστικών βίντεο $F_v \in \mathbb{R}^{B \times T \times d}$ και η αντίστοιχη αλληλουχία για τον ήχο $F_a \in \mathbb{R}^{B \times T \times d}$. Ο μηχανισμός της Cross-modal Attention λειτουργεί ως εξής:

1. Πρώτα, εκτελείται Multi-head Attention (MHA) με κατεύθυνση $\text{video} \leftarrow \text{audio}$, όπου δηλαδή τα χαρακτηριστικά του video είναι το query, ενώ τα χαρακτηριστικά του audio είναι το key και το value.

$$\tilde{F}_v = MHA_{v \leftarrow a}(Q = F_v, K = F_a, V = F_a)$$

2. Ακολουθείται Residual Connection και Layer Normalization για τα video features.

$$F'_v = LayerNorm(F_v + \tilde{F}_v)$$

3. Έπεται η αντίστροφη Multi-head Attention με κατεύθυνση $\text{audio} \leftarrow \text{video}$, όπου τα χαρακτηριστικά του audio είναι το query, ενώ τα χαρακτηριστικά του video είναι το key και το value.

$$\tilde{F}_a = MHA_{a \leftarrow v}(Q = F_a, K = F'_v, V = F'_v)$$

4. Τέλος, εφαρμόζεται Residual Connection και Layer Normalization για τα audio features.

$$F'_a = LayerNorm(F_a + \tilde{F}_a)$$

Παρακάτω επεξηγούνται μερικές από τις επιλογές που οδήγησαν στην παραπάνω εικόνα.

Ένα σημαντικό ερώτημα είναι γιατί επιλέγεται ο μηχανισμός του Cross-modal Attention και όχι, π.χ. παρεμβολή των features με σταθερά βάρη. Η απάντηση σε αυτό το ερώτημα έγκειται στην ύπαρξη τυχαίοποιημένου θορύβου, ο οποίος όμως είναι σε συνεχόμενα χρονικά σημεία (π.χ. μία αλληλουχία θολών frames ή ένα σημείο που έχει κοπεί ο ήχος). Χρησιμοποιώντας σταθερά βάρη και υπολογίζοντας τη γραμμική παρεμβολή των δύο εξαγόμενων features, το μοντέλο δε συνυπολογίζει ποια από τις δύο modalities είναι αξιόπιστη για κάθε χρονική στιγμή (και, ακόμα και αν τα βάρη μαθαίνονται, έχει bias προς το γενικά πιο αξιόπιστο modality, αγνοώντας την τοπική πληροφορία). Αντίθετα, ο μηχανισμός attention επιτρέπει σε κάθε frame από κάθε modality να αντλήσει τις απαιτούμενες πληροφορίες από κάθε χρήσιμο frame του άλλου modality (και όχι αποκλειστικά από το ίδιο frame), δίνοντας την ελευθερία στο μοντέλο να αξιοποιήσει περισσότερο τα χρήσιμα και αξιόπιστα frames ώστε να επηρεαστούν κατάλληλα τα features του audio και του video.

Η cross-modal attention πρέπει να γίνεται προς και τις δύο κατευθύνσεις, δηλαδή $\text{audio} \leftarrow \text{video}$ αλλά και $\text{video} \leftarrow \text{audio}$. Ο λόγος είναι ότι, αν μόνο μία από τις δύο κατευθύνσεις ολοκληρωνόταν, τότε θα δημιουργόταν το bias ότι μόνο ένα από τα δύο modalities θα είχε την ευκαιρία να αντλήσει πληροφορία από το άλλο (π.χ. μόνο η απεικόνιση του ήχου θα αξιοποιούσε αυτήν του βίντεο για να επιδιορθώσει λανθασμένα χαρακτηριστικά που οφείλονται στην ύπαρξη θορύβου). Εφ' όσον τα δύο modalities επηρεάζονται από τον θόρυβο με ανεξάρτητο και απρόβλεπτο τρόπο, ο μηχανισμός του cross-modal attention πρέπει να εφαρμοστεί προς και τις δύο κατευθύνσεις, ώστε οποιαδήποτε από τις δύο modalities να

μπορεί να βοηθήσει την άλλη, ανάλογα με το ποια από τις δύο αντιμετωπίζει θόρυβο τη συγκεκριμένη χρονική περίοδο (για παράδειγμα, στα σημεία που εφαρμόζεται το θόλωμα στο βίντεο, οι πληροφορίες εξαγόμενες από τον ήχο μπορούν να βελτιώσουν αυτές που εξάγονται από το θορυβώδες βίντεο).

Τέλος, η χρήση της Residual σύνδεσης εξασφαλίζει ότι, αν η cross-modal πληροφορία δεν είναι χρήσιμη για ένα frame (π.χ. επειδή το άλλο modality είναι επηρεασμένο βαθιά από τον θόρυβο εκείνη τη στιγμή, ενώ από το αρχικό modality έχουν εξαχθεί ισχυρά features), τότε δε θα καταστραφεί πλήρως η unimodal αναπαράσταση από την εφαρμογή attention. Η Layer Normalization σταθεροποιεί τα τελικά features F'_v και F'_a , προτού αυτά εισαχθούν στη fusion gate.

Reliability-gated Fusion Το block του Reliability-gated Fusion είναι αυτό που τελικά συνδυάζει τις πληροφορίες από τις δύο modalities και παράγει ένα ολικό feature sequence, αξιοποιώντας τόσο τις αναπαραστάσεις του ήχου $F'_a(t) \in \mathbb{R}^d$ και του βίντεο $F'_v(t) \in \mathbb{R}^d$ για κάθε frame, όσο και τα σήματα αξιοπιστίας των δύο modalities $r_a(t), r_v(t) \in [0, 1]$, για ήχο και βίντεο αντίστοιχα, στα οποία γίνεται αναφορά στην αρχή της συγκεκριμένης ενότητας.

Ο μηχανισμός του σταδίου αυτού λειτουργεί ως εξής:

1. Παράγεται ένα διάνυσμα εισόδου $g_{in}(t)$ για κάθε frame t ως αποτέλεσμα της παρακάτω συνένωσης (concatenation)

$$g_{in}(t) = [F'_v(t) || F'_a(t) || |F'_v(t) - F'_a(t)| || r_v(t) || r_a(t)] \in \mathbb{R}^{3d+2}$$

2. Το διάνυσμα αυτό γίνεται η είσοδος σε ένα μικρό δίκτυο MLP (LayerNorm $\rightarrow$ Linear $\rightarrow$ ReLU $\rightarrow$ Dropout $\rightarrow$ Linear), παράγοντας δύο logits, τα οποία κανονικοποιούνται με συνάρτηση softmax στην τελική τους μορφή $(g_v(t), g_a(t))$ με $g_v(t) + g_a(t) = 1$.

3. Υπολογίζεται η συνδυασμένη αναπαράσταση $F_{fused}(t)$ για κάθε frame t ως:

$$F_{fused}(t) = g_v(t) \cdot F'_v(t) + g_a(t) \cdot F'_a(t)$$

Παράγεται, τελικά, η ακολουθία των συνδυασμένων αναπαραστάσεων $F_{fused} \in \mathbb{R}^{B \times T \times d}$. Η λογική της χρήσης της απόλυτης διαφοράς $|F'_v(t) - F'_a(t)|$ έγκειται στο ότι δίνεται στο μοντέλο ένα σήμα που εκφράζει εγγενώς την ασυμφωνία των δύο modalities (η διαφορά αυτή παίρνει μεγάλες τιμές όταν τα δύο modalities περιέχουν διαφορετικό φωνητικό περιεχόμενο, και άρα κάποιος από τα δύο έχει πιθανότητα επηρεαστεί από τον θόρυβο). Χρησιμοποιείται, δηλαδή, ως ένα περαιτέρω σήμα ώστε, σε περίπτωση ύπαρξης θορύβου που επηρεάζει μία από τις δύο modalities σημαντικά, να μπορεί το μοντέλο να αναγνωρίσει αυτήν τη συμπεριφορά και να αξιοποιήσει περισσότερο το modality που έχει επηρεαστεί λιγότερο από τον θόρυβο. Σε ένα τελικό σύστημα, έτοιμο να χρησιμοποιηθεί με in the wild θορυβώδη δεδομένα, προφανώς τα σήματα αξιοπιστίας $r_a(t)$ και $r_v(t)$ δε θα ήταν δεδομένα, αλλά θα έπρεπε να υπολογίζονται σε πραγματικό χρόνο από το μοντέλο. Ωστόσο, για απλοποίηση του προβλήματος και κυρίως ως proof of concept, επιλέχθηκε τα σήματα αυτά να είναι διαθέσιμα στο μοντέλο (υπολογισμένα όπως αναγράφεται στην ενότητα 5.1.4) και όχι να πρέπει να υπολογίζονται από το μοντέλο.

Sequence Encoder Ο Sequence Encoder του μοντέλου αυτού δέχεται ως είσοδο τη συνδυασμένη αναπαράσταση $F_{fused} \in \mathbb{R}^{B \times T \times d}$ και έχει μορφή πλήρως πανομοιότυπη με αυτήν που χρησιμοποιείται στο visual μοντέλο και παρουσιάζεται στην ενότητα 5.2. Δίνεται και πάλι η επιλογή χρήσης είτε BiLSTM (που είναι και η προεπιλεγμένη εκδοχή), με διάσταση εξόδου $2d$, είτε Transformer με διάσταση εξόδου d . Η έξοδος του Sequence Encoder κανονικοποιείται με χρήση LayerNorm, περνά από Dropout και προβάλλεται μέσω μίας τελευταίας γραμμικής στρώσης σε $V + 1$ logits ανά frame (όπου V είναι το μήκος του λεξιλογίου και το $+1$ οφείλεται στην ύπαρξη του blank token του CTC).

Κεφαλές Auxiliary CTC Παρέχεται η προαιρετική επιλογή (στην προεπιλογή ενεργοποιημένη) χρήσης auxiliary κεφαλών CTC, κατά την οποία προστίθενται δύο γραμμικές στρώσεις classifiers στις αναπαραστάσεις βίντεο και ήχου πριν τον συνδυασμό τους $F'_v(t)$ και $F'_a(t)$. Κάθε μία από αυτές παράγει τα $V + 1$ logits ανά frame, τα οποία χρησιμοποιούνται κατά τον υπολογισμό της loss function (βλ. παρακάτω) και αγνοούνται στο βήμα του inference. Ο σκοπός της χρήσης των παραπάνω κεφαλών (της παραγωγής, δηλαδή, των auxiliary CTC όρων για βίντεο και ήχο) είναι προληπτικός, ώστε να περιοριστεί το πρόβλημα των vanishing gradients. Ένα modality το οποίο συστηματικά λαμβάνει μικρότερο βάρος (επειδή παρουσιάζει, γενικά, στην κατανομή περισσότερο θόρυβο) μπορεί να λάμβανε σήμα vanishing gradients και άρα να μην προάγεται η εκμάθηση των αναπαραστάσεων του συγκεκριμένου modality. Τότε, το μοντέλο θα έκλινε όλο και περισσότερο σε unimodal μοντέλο και δε θα υπήρχε η δυνατότητα να αξιοποιηθούν τα στοιχεία του γενικά πιο θορυβώδους modality, όταν αυτά είναι αξιόπιστα.

Εκτέλεση με μοναδικό modality Παρέχεται η δυνατότητα εκπαίδευσης μοντέλου που αξιοποιεί μονάχα ένα από τα δύο modalities (είτε μόνο το βίντεο είτε μόνο τον ήχο). Στην περίπτωση αυτή προσπερνώνται τα blocks του cross-attention και του fusion και οι αναπαραστάσεις που παράγονται από το επιλεγμένο modality εισέρχονται απ'ευθείας στον sequence encoder. Έτσι, δίνεται η ευκαιρία στο μοντέλο ήχου-βίντεο να συγκριθεί με τα αντίστοιχα μοντέλα που αξιοποιούν ένα μόνο modality, όπως ακριβώς γίνεται στο πείραμα που παρουσιάζεται στην ενότητα 6.3.3.

Συνάρτηση Κόστους Η αντικειμενική συνάρτηση για το συγκεκριμένο μοντέλο είναι όμοια με την αντίστοιχη του visual μοντέλου που παρουσιάστηκε στην ενότητα 5.2, απαρτίζεται δηλαδή από τον όρο cross-entropy και τον όρο CTC, ενώ σε αυτούς προστίθενται και οι εκάστοτε όροι auxiliary CTC του βίντεο aux_v και του ήχου aux_a (ή ενός εκ των δύο, σε περίπτωση που επιλεγθεί η εκτέλεση με μοναδικό modality), πολλαπλασιασμένοι με τη σταθερά aux_ctc_weight , με προεπιλεγμένη τιμή 0.1. Οι όροι αυτοί υπολογίζονται ακριβώς όπως ο όρος ctc_loss , χρησιμοποιώντας ωστόσο τα logits που παράγονται από τις κεφαλές auxiliary CTC και όχι τα logits της εξόδου μετά τον Sequence Encoder. Τελικά, η τιμή της συνάρτησης κόστους δίνεται ως:

$$total_loss = frame_loss + ctc_weight \cdot ctc_loss + aux_ctc_weight \cdot (aux_v + aux_a)$$

5.4 Βήματα Post-Processing

Όπως παρουσιάστηκε το μοντέλο μέχρι τώρα, είναι ικανό μόνο να προβλέψει φωνήματα από το βουβό βίντεο. Στη συγκεκριμένη υποενότητα, περιγράφονται οι τεχνικές post-processing που εφαρμόστηκαν ώστε η αλληλουχία φωνημάτων να μετατραπεί σε λέξεις, βήμα το οποίο οδηγεί στην επίτευξη του πρωταρχικού στόχου του lip reading.

5.4.1 Αλγοριθμική Πρόβλεψη Λέξεων

Σε εφαρμογές σε περιορισμένο περιβάλλον, όπου το λεξιλόγιο και, προαιρετικά, η γραμματική των φράσεων είναι γνωστά, είναι δυνατόν η πρόβλεψη των λέξεων από την αλληλουχία φωνημάτων να γίνει αλγοριθμικά και χωρίς τη χρήση τεχνητής νοημοσύνης. Για τα παρακάτω, υποθέτουμε (χωρίς βλάβη της γενικότητας και για να γίνει πιο ξεκάθαρη η επεξήγηση της μεθόδου) ότι η ανάλυση γίνεται στο dataset GRID, όπως παρουσιάζεται στην παράγραφο 6.1.

Αρχικά, παράγεται το collapsed sequence φωνημάτων από την αλληλουχία των φωνημάτων που προβλέπεται, ενώνοντας γειτονικά ίδια tokens και απαλείφοντας τα blank tokens, δημιουργώντας μία ομάδα από φωνήματα και τους χρονισμούς τους. Έπειτα, χρησιμοποιείται αλγόριθμος δυναμικού προγραμματισμού ώστε να βρεθεί η τομή των φωνημάτων σε λέξεις και η ανάθεση των προβλεπόμενων λέξεων με το μικρότερο συνολικό κόστος.

Για κάθε υποψήφια λέξη σε κάθε θέση, υπολογίζεται μία τιμή ομοιότητας με την ακολουθία των φωνημάτων που προβλέπεται. Έστω O η πρόβλεψη και T η υποψήφια λέξη. Ορίζεται η βασική απόσταση ως $D(O, T) = \frac{1}{\max(|O|, |T|)} \cdot ED(O, T)$, όπου $ED(O, T)$ είναι η ελάχιστη απόσταση edit της αλληλουχίας

φωνημάτων O ώστε να φτάσει στην T . Κάθε φώνημα που πρέπει να αλλαχθεί δεν επηρεάζει με ίδιο τρόπο την $ED(O, T)$. Συγκεκριμένα, όμοια φωνήματα (είτε ακουστικά είτε οπτικά) τιμωρούνται λιγότερο σε σχέση με τελείως διαφορετικά φωνήματα. Το κόστος κάθε αλλαγής, από φώνημα a σε φώνημα b , υπολογίζεται ως εξής:

$$c(a, b) = \begin{cases} 0 & a = b \\ 0.15 & \text{ίδια κλάση viseme και ίδιος τρόπος/τόπος εκφοράς, αλλά διαφορετική φωνοποίηση} \\ 0.35 & \text{ίδια κλάση viseme αλλά όχι μόνο διαφορετική φωνοποίηση} \\ \min(1, \frac{\Delta(a,b)}{4}) & \text{αλλιώς, με διαφορά ιδιοτήτων } \Delta \\ 1 & \text{αν δεν υπάρχει καμία ίδια ιδιότητα} \end{cases}$$

Τότε, το τελικό σκορ ομοιότητας για κάθε υποψήφια λέξη είναι $S(O, T) = D(O, T) - B_{anchor}(O, T) - 0.15B_{rare}(O, T)$, όπου B_{anchor} είναι ένα ισχυρό bonus που δίνεται σε φωνήματα anchor και B_{rare} είναι ένα μικρότερο bonus για σπάνια φωνήματα. Τα φωνήματα anchor είναι φωνήματα που εμφανίζονται μόνο σε μία υποψήφια λέξη κάποιας κατηγορίας. Για παράδειγμα, στις προθέσεις του GRID, το φώνημα /ð/ με ήχο σαν το ελληνικό θήτα εμφανίζεται μόνο στη λέξη with και όχι σε οποιαδήποτε από τις in, by και at. Εάν δεν υπήρχε αυτός ο όρος, μία αλληλουχία φωνημάτων /i/ /ð/ θα οδηγούσε σε πρόβλεψη in και όχι σε πρόβλεψη with, που φαίνεται πιο αληθοφανές, δεδομένου ότι προβλέφθηκε το /ð/ που ανήκει μόνο σε μία λέξη. Με παρόμοιο τρόπο υπολογίζεται και το B_{rare} , αλλά πολλαπλασιάζεται με παράγοντα ανάλογο της σπανιότητας του εκάστοτε φωνήματος.

Με την παραπάνω μέθοδο, είναι δυνατόν να προβλεφθούν και λέξεις εντός του περιορισμένου περιβάλλοντος, πέραν των φωνημάτων. Ο αλγόριθμος αυτός σίγουρα μπορεί να αποτελέσει αντικείμενο βελτίωσης και καλύτερης προσαρμογής στο δεδομένο περιβάλλον στο οποίο γίνεται η κάθε μελέτη, ωστόσο κρίθηκε ότι η τωρινή εκδοχή του είναι αρκετή ώστε να επιδείξει ικανοποιητικά αποτελέσματα. Προφανώς, τα παραπάνω δεν μπορούν να εφαρμοστούν σε μη πεπερασμένο περιβάλλον, στο οποίο τόσο το λεξιλόγιο όσο και η γραμματική είναι σαφώς πιο ποικιλόμορφα, καθώς η λογική ιδιαίτερα του δυναμικού προγραμματισμού καταρρέει όσο αυξάνεται η πολυπλοκότητα των πιθανών λέξεων και της τοποθέτησής τους.

5.4.2 Πρόβλεψη Φράσεων από Αλληλουχία Φωνημάτων μέσω LLM

Σε περιπτώσεις μη περιορισμένου περιβάλλοντος (in the wild), η αλγοριθμική πρόβλεψη λέξεων από τα φωνήματα είναι προφανώς αδύνατη, λόγω της ύπαρξης μεγάλου αριθμού υποψήφιων λέξεων (ουσιαστικά όλες της αγγλικής - ή οποιασδήποτε άλλης - γλώσσας). Έτσι, απαιτείται ένας διαφορετικός τρόπος ώστε τα φωνήματα που έχουν προβλεφθεί από το μοντέλο να πάρουν μία γλωσσική μορφή που έχει νόημα (δηλ. λέξεις και τελικά φράσεις). Μία μεθοδολογία επίλυσης του συγκεκριμένου προβλήματος που προτείνεται και στο [28] είναι η ανακατασκευή προτάσεων με χρήση LLM (Large Language Model), fine-tuned για το εν λόγω task.

Συγκεκριμένα, έστω $S = (s_1, \dots, s_M)$ η πραγματική πρόταση (αλληλουχία λέξεων $s_i, i = 1, \dots, M$) που εκφέρεται από μία αλληλουχία φωνημάτων P . Εφαρμόζεται fine-tuning στο LLM χρησιμοποιώντας την παρακάτω Cross-Entropy Loss:

$$L_{CE} = - \sum_{t=1}^M \ln p(s_t | P, s_{1:t-1})$$

όπου $p(s_t | P, s_{1:t-1})$ είναι η πιθανότητα ορθής πρόβλεψης της επόμενης λέξης, με δεδομένο την αλληλουχία φωνημάτων και τις λέξεις που έχουν προβλεφθεί ως προηγούμενες. Στη φάση του inference, ζητείται από το LLM με κατάλληλο prompt να παράξει την προβλεπόμενη πρόταση $\hat{S}$ από την προβλεπόμενη αλληλουχία φωνημάτων $\hat{P}$.

Στα πλαίσια της εργασίας αυτής, καθώς τελικά δεν πραγματοποιήθηκε το πείραμα στο in the wild περιβάλλον, όπως αναφέρεται στην ενότητα 6.3.2, δεν αναπτύχθηκε και δε δοκιμάστηκε η λειτουργία αυτή. Αποτελεί μία από τις βασικές μελλοντικές επεκτάσεις (βλ. 7.2, ώστε να δοκιμαστεί η επίδοση του μοντέλου στο σαφώς δυσκολότερο μη περιορισμένο περιβάλλον και να μπορεί να χρησιμοποιηθεί σε

γενικότερες εφαρμογές, και όχι απλά σε συγκεκριμένες σαν αυτές του GRID.

6 Αξιολόγηση της Μεθοδολογίας

6.1 Datasets

Για το πρώτο και το τρίτο πείραμα, που περιλαμβάνει μία μελέτη αφαίρεσης (ablation study) και μία δοκιμή των αποτελεσμάτων των επιλεγμένων μοντέλων, χρησιμοποιήθηκε το GRID Audio-Visual Speech Corpus [10]. Πρόκειται για ένα από τα πιο ευρέως χρησιμοποιούμενα dataset στον τομέα της αντίληψης ομιλίας. Αποτελείται από εγγραφές ήχου και βίντεο (της περιοχής του προσώπου) για 1000 διαφορετικές φράσεις από 34 ομιλητές (18 αρσενικούς και 16 θηλυκούς), συνολικά 34000 προτάσεις.

Το συγκεκριμένο dataset αποτελεί παράδειγμα ενός περιορισμένου (constrained) περιβάλλοντος μάθησης, διότι οι φράσεις που καταγράφονται παρουσιάζουν μία πολύ συγκεκριμένη μορφή. Αποτελούνται από ένα ρήμα εντολής (bin, lay, place, set), έπειτα ένα χρώμα (blue, green, red, white), μία πρόθεση (at, by, in, with), ένα γράμμα (οποιοδήποτε από τα 26 του αγγλικού αλφαβήτου πέραν του w), ένα ψηφίο (από το 0 έως το 9) και τέλος ένα επίρρημα (again, now, please, soon). Έτσι, το λεξιλόγιο είναι πολύ περιορισμένο σε αντίθεση με ένα in the wild dataset, στο οποίο τόσο η σύνταξη των φράσεων όσο και το ίδιο το λεξιλόγιο παρουσιάζουν σαφώς υψηλότερη ποικιλομορφία.

Για τους σκοπούς της συγκεκριμένης μελέτης, η εκπαίδευση περιορίστηκε αποκλειστικά στα 1000 βίντεο του 1ου ηθοποιού (από το s1.zip). Κάθε .mpg βίντεο έχει μήκος 3 δευτερολέπτων, ρυθμό ανανέωσης frames 25fps, ανάλυση 360x288 pixels και στερεοφωνικό (δικανάλικό) ήχο με ρυθμό δειγματοληψίας 44.1kHz. Η βιντεοληψία γίνεται με τον ομιλητή να κοιτάει ευθεία προς την κάμερα με ουδέτερο παρασκήνιο. Τα βίντεο έχουν τίτλους που αποδίδουν τη φράση που λέγεται σε αυτά (π.χ. η φράση “bin green in t 5 soon” λέγεται στο βίντεο με τίτλο bgit5s.mpg), γεγονός που βοηθάει στην εξαγωγή των πραγματικών φωνημάτων (ground truth). Πέραν των βίντεο, το dataset περιλαμβάνει αρχεία ήχου και ένα αρχείο με ακριβείς χρονισμούς λέξεων για κάθε ομιλητή, τα οποία όμως δε χρησιμοποιούνται.

6.2 Κριτήρια Αξιολόγησης

Για την επακριβή αξιολόγηση της μεθοδολογίας και για τη σύγκριση με το state of the art, αποτελεί κρίσιμο βήμα η ορθή επιλογή και ο ακριβής ορισμός των μετρικών και των κριτηρίων αξιολόγησης. Σε όλα (ή κάποια) από τα παρακάτω πειράματα, η μεθοδολογία αξιολογείται με βάση τα παρακάτω κριτήρια:

- Γράφημα Training Loss vs Epoch: αποδίδει την τιμή της συνάρτησης κόστους στα δεδομένα του training split για κάθε epoch της εκπαίδευσης. Για τον υπολογισμό της αντικειμενικής συνάρτησης, ανατρέξτε στην ενότητα 5.2.
- Γράφημα Validation Loss vs Epoch: το ίδιο με παραπάνω αλλά στο validation split.
- Γράφημα Validation Token Error Rate (TER) vs Epoch: ποσοστό εσφαλμένης πρόβλεψης φωνήματος σε επίπεδο token (δηλαδή, στο collapsed sequence και όχι σε επίπεδο για κάθε frame του video) στο validation split για κάθε εποχή. Υπολογίζεται ως η απόσταση edit Levenshtein διά το μήκος αναφοράς. Για πληροφορίες περί του υπολογισμού της απόστασης Levenshtein ανατρέξτε στην ενότητα 3.3.
- Γράφημα Validation Frame Accuracy vs Epoch: ποσοστό ορθών προβλέψεων φωνήματος σε επίπεδο video frame (πριν το sequence collapse) στο validation split για κάθε εποχή. Άρα, αν το βίντεο αποτελείται από T frames, έχουμε

$$val_frame_acc = \frac{\# \text{ correct predictions}}{T}$$

- Γράφημα Training Frame Accuracy vs Epoch: το ίδιο με παραπάνω αλλά στο training split.
- Area Under Curve (AUC): υπολογίζει την επιφάνεια κάτω από την καμπύλη (συνήθως της ακρίβειας στο validation set vs epoch), δίνοντας μία μετρική τόσο για την τελική ακρίβεια όσο και για την ταχύτητα σύγκλισης και για την αποφυγή ταλαντώσεων.

- Test Token Error Rate (TER): ποσοστό εσφαλμένων προβλέψεων φωνημάτων μετά το sequence collapse στο test set. Όπως παραπάνω, αξιοποιεί την απόσταση Levenshtein της πραγματικής και της προβλεπόμενης αλληλουχίας φωνημάτων.
- Test Frame Accuracy: ποσοστό ακριβών προβλέψεων φωνημάτων σε επίπεδο frame, δηλαδή πριν το sequence collapse.

6.3 Πειράματα

Παρακάτω παρουσιάζονται τα πειράματα με τα οποία δοκιμάστηκε η επίδοση της προτεινόμενης μεθοδολογίας.

6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον

Υποπείραμα 1: Μελέτη Αφαίρεσης Για να απομονωθεί η συνεισφορά κάθε σχεδιαστικής επιλογής του μοντέλου, διεξήχθη μία μελέτη αφαίρεσης (ablation study) με 6 διαφορετικές εκδοχές του μοντέλου. Όλες οι εκδοχές αποτελούνται από ένα 3D CNN backbone, αξιολογήθηκαν στο ίδιο dataset με 32 κλάσεις φωνημάτων, εκπαιδεύτηκαν με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5. Η εκπαίδευση έγινε για μέγιστο αριθμό 40 εποχών με μηχανισμό early stopping με παράγοντα υπομονής 12 epochs στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο παρακάτω πίνακας παρουσιάζει τις 6 διαφορετικές εκδοχές που δοκιμάστηκαν.

Πίνακας 1: Οι εκδοχές του μοντέλου που δοκιμάστηκαν


Εκδοχή	Sequence Encoder	Αντικειμενική Συνάρτηση	Targets του CE
V1	2 επίπεδα BiLSTM	Frame-CE + CTC	Viseme-aware soft targets
V2	2 επίπεδα Transformer	Frame-CE + CTC	Viseme-aware soft targets
V3	Projection head μόνο	Frame-CE + CTC	Viseme-aware soft targets
V4	2 επίπεδα BiLSTM	CTC μόνο	N/A (χωρίς frame-CE)
V5	2 επίπεδα BiLSTM	Frame-CE μόνο	Viseme-aware soft targets
V6	2 επίπεδα BiLSTM	Frame-CE + CTC	Hard (identity) targets

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της μελέτης, πρώτα σε μορφή πίνακα και έπειτα με μερικά χαρακτηριστικά γραφήματα.


Να σημειωθεί ότι οι απόλυτες τιμές των τιμών της αντικειμενικής συνάρτησης στα σχήματα 12, 14 και 15 δεν είναι συγκρίσιμες. Συγκεκριμένα, τα μοντέλα με μόνο έναν από τους 2 όρους (είτε μόνο cross entropy είτε μόνο CTC) έχουν αντικειμενικές συναρτήσεις με μικρότερες τιμές σε απόλυτη τιμή, καθώς ο πολλαπλασιαστικός συντελεστής των δύο όρων παραμένει σταθερός. Τα σχήματα στο 16 ωστόσο, που παρουσιάζουν τη συνεισφορά κάθε όρου της αντικειμενικής συνάρτησης χωριστά, είναι απολύτως συγκρίσιμα. Σημαντικό, επίσης, είναι να παρατηρηθεί ότι το μοντέλο V6 παρουσιάζει τη χαμηλότερη τιμή training και validation loss ανάμεσα στα V1, V2, V3 και V6, χωρίς ωστόσο να πετυχαίνει και τη βέλτιστη επίδοση όσον αφορά το test TER. Αυτό οφείλεται στο ότι η χρήση soft targets στα μοντέλα V1, V2 και V3 μοιράζει την πιθανότητα κάθε φωνήματος σε διάφορες όμοιες (οπτικά ή ακουστικά) κλάσεις παράγοντας ένα target με υψηλότερη εντροπία και άρα οδηγώντας σε υψηλότερες τιμές cross entropy, σε σχέση με το one-hot encoding που χρησιμοποιείται για το μοντέλο V6.

Πίνακας 2: Περίληψη των αποτελεσμάτων της μελέτης αφαίρεσης


Variant	Best Val TER	Test TER	Test Frame Acc.	AUC (Val 1 – TER)	Εποχές μέχρι Val TER < 0.20
V1 — BiLSTM + Full Loss	0.1251	0.1219	0.8474	0.7840	8
V2 — Transformer + Full Loss	0.1551	0.1566	0.8394	0.7176	16
V3 — Projection head μόνο	0.2540	0.2464	0.8122	0.6006	Ποτέ
V4 — BiLSTM + CTC Only	0.1977	0.1869	0.4743	0.6005	33
V5 — BiLSTM + Frame-CE Μόνο	0.1555	0.1419	0.8401	0.7402	16
V6 — BiLSTM + Hard Targets	0.1266	0.1289	0.8456	0.7696	9




Σχήμα 12: Γράφημα τιμών αντικειμενικής συνάρτησης στο training set για κάθε epoch




Σχήμα 13: Γράφημα τιμών frame accuracy στο training set για κάθε epoch




Σχήμα 14: Σύγκριση τιμών loss για training και validation κάθε μοντέλου




Σχήμα 15: Γράφημα τιμών αντικειμενικής συνάρτησης στο validation set για κάθε epoch




Σχήμα 16: Ανάλυση συνεισφοράς των όρων της αντικειμενικής συνάρτησης (CE και CTC)



Σχήμα 17: Γράφημα τιμών frame accuracy στο validation set για κάθε epoch



Σχήμα 18: Γράφημα τιμών TER στο validation set για κάθε epoch



Σχήμα 19: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Από τα παραπάνω εξάγεται το συμπέρασμα ότι το μοντέλο της μεθοδολογίας παρουσιάζει την ισχυρότερη επίδοση τόσο όσον αφορά την τελική απόδοση όσο και την ομαλότητα και αποδοτικότητα της εκπαίδευσης, γεγονότα που αποδεικνύονται από την υπεροχή του V1 στις μετρικές test TER, test frame accuracy και AUC. Στις επόμενες παραγράφους δίνεται μία αναλυτική σύγκριση κάθε εκδοχής με την V1, όπως και τα απαραίτητα σχόλια.

Όπως αποδεικνύει η σύγκριση μεταξύ V1 και V3, η σχεδιαστική επιλογή με το υψηλότερο αντίκρισμα στα αποτελέσματα είναι η παρουσία του χρονικού sequence encoder. Εν απουσία του BiLSTM και αξιοποιώντας μόνο ένα γραμμικό projection head, το μοντέλο V3 πετυχαίνει τελικά test TER 0.2464, υπερδιπλασιάζοντας αυτό του μοντέλου V1. Οι υπόλοιπες μετρικές (val TER, val frame accuracy, AUC)

αποδεικνύουν επίσης την αναγκαιότητα χρήσης sequence encoder. Να σημειωθεί, ωστόσο, ότι μετρικές όπως το test frame accuracy, με τιμή 0.812, αποδεικνύουν ότι το μοντέλο πράγματι είναι ικανό να μάθει. Περιορίζεται, ωστόσο, από την έλλειψη της πληροφορίας παρακειμένου (contextual information), το οποίο είναι βασικό στοιχείο για την κατανόηση των φωνημάτων. Το context που προσφέρει η χρήση 3D CNN backbone δεν είναι τόσο πλούσιο όσο αυτό του συνδυασμού 3D CNN και BiLSTM.

Αντικαθιστώντας τα επίπεδα BiLSTM με Transformer ίδιου βάθους (V2), παρατηρούμε μία σημαντική επιδείνωση των αποτελεσμάτων, της τάξης περίπου του 25%. Η πορεία της εκπαίδευσης δείχνει μία πιο αργή βελτίωση του val TER στο V2 σε σχέση με το V1. Ένα ακόμα στοιχείο που αξίζει να σημειωθεί είναι ότι ο μηχανισμός scheduling του ρυθμού μάθησης ReduceLROnPlateau δε πυροδοτήθηκε κατά την εκπαίδευση του V2, ενώ προκλήθηκε 2 φορές κατά την εκπαίδευση του V1, αποδεικνύοντας ότι η σύγκλιση του V2 δεν έχει ακόμα ολοκληρωθεί κατά την 40η εποχή και ότι θα χρειαζόταν υψηλότερο υπολογιστικό κόστος εκπαίδευσης για να παρουσιάσει το V2 παρόμοια αποτελέσματα με αυτά του V1. Μία από τις κύριες αιτίες για τα αποτελέσματα του V2 είναι το μέγεθος του dataset που χρησιμοποιήθηκε, το οποίο περιλαμβάνει μόλις 700 φράσεις. Οι transformer encoders απαιτούν περισσότερα και πιο ποικιλόμορφα δεδομένα για να μάθουν αποδοτικά μοτίβα attention. Αντιθέτως, το inductive bias των BiLSTM για χρονική εξάρτηση, ειδικά για γειτονικό context, λόγω της recurrent αρχιτεκτονικής τους, βρίσκει εύκολα εφαρμογή στην κίνηση των χειλιών, κατά την οποία γειτονικά frames αλληλεξαρτώνται σε υψηλό βαθμό.


Συγκρίνοντας τα μοντέλα V1 και V4, αναδεικνύεται η σημασία του όρου cross entropy της αντικειμενικής συνάρτησης. Το μοντέλο V4 πετυχαίνει στη μετρική test TER τιμή 0.1869, πάνω από 50% επιδεινωμένη επίδοση σε σχέση με το V1. Η διαφορά των δύο μοντέλων γίνεται ιδιαίτερα προφανής με τη μετρική test frame accuracy, η οποία για το V4 είναι μόλις 0.4743, τιμή που ανταποκρίνεται με την τυχαία ανάθεση labels σε πρόβλημα ταξινόμησης με μία σαφώς επικρατέστερη κλάση, αυτήν του blank token (να μην εκφέρεται στο δεδομένο frame κάποιο φώνημα). Τα αποτελέσματα αυτά είναι αναμενόμενα: το σήμα του gradient, παραγόμενο αποκλειστικά μέσω του όρου CTC, οδηγεί το μοντέλο να μάθει να προβλέπει σωστές αλληλουχίες φωνημάτων αλλά όχι ποιες κινήσεις των χειλιών (και άρα ποια frames του βίντεο) παράγουν το οποιοδήποτε φώνημα. Έτσι, η διαφορά στο test TER δεν είναι τόσο μεγάλη όσο στο test frame accuracy.

Από την άλλη, αφαιρώντας τον όρο CTC και διατηρώντας μόνο τον όρο cross entropy της συνάρτησης κόστους (με το μοντέλο V5), επιτυγχάνεται τελικά test TER με τιμή 0.1419, ελαφρώς χειρότερα από το μοντέλο V1, τιμή που αποτελεί τη 3η καλύτερη στη συγκεκριμένη μετρική. Το σημαντικότερο πρόβλημα που αντιμετωπίζει η εκδοχή V5 είναι η ομαλότητα της εκπαίδευσης. Συγκεκριμένα, η καμπύλη validation TER vs epoch παρουσιάζει εμφανείς ταλαντώσεις και η σύγκλιση είναι πιο αργή σε σχέση με τα μοντέλα V1, V2 και V6. Ταυτόχρονα, το γράφημα val loss vs epoch παρουσιάζει στοιχεία overfitting, καθώς η τιμή αυξάνει μετά την 20η εποχή. Έτσι, εξάγεται το συμπέρασμα ότι ο όρος CTC συμβάλλει στην κανονικοποίηση του μοντέλου, προσθέτοντας τη συνθήκη ότι το τελικό σύνολο προβλέψεων φωνημάτων ανά frame θα πρέπει να καταρρέει σε μία λογική αλληλουχία φωνημάτων. Με αυτόν τον τρόπο βελτιώνεται η γενίκευση αλλά και η απόδοση του μοντέλου.


Τέλος, η διαφορά των μοντέλων V1 και V6 έγκειται στα targets του cross entropy της αντικειμενικής συνάρτησης: ενώ το V1 χρησιμοποιεί soft targets με βάση το πόσο όμοια είναι τα φωνήματα, ακουστικά ή οπτικά, το V6 χρησιμοποιεί τα συνήθη hard targets του cross entropy. Το μοντέλο V6 πετυχαίνει τη 2η καλύτερη τιμή test TER (0.1289), ενώ παρουσιάζει εικόνα εκπαίδευσης πολύ παρόμοια με αυτή του μοντέλου V1. Η ελάχιστη διαφορά των δύο εκδοχών φαίνεται να σημαίνει ότι η χρήση των soft targets παρέχει μικρό αλλά ίσως σταδιακά αυξανόμενο πλεονέκτημα με βάση το μέγεθος και την ποικιλομορφία του dataset. Όσο αυξάνεται η συχνότητα παρόμοιων φωνημάτων, τόσο ο μηχανισμός αυτός θα παρείχε περισσότερη ομαλότητα κατά την εκπαίδευση, προστατεύοντας το μοντέλο από θόρυβο labelling σε αμφίβολες περιπτώσεις. Στο μικρό και περιορισμένο dataset που χρησιμοποιείται στο πείραμα αυτό, είναι πιο εύκολο να “αποστηθίσει” το μοντέλο αλληλουχίες φωνημάτων (άρα λέξεων, π.χ. να μάθει ότι το φώνημα /b/ βρίσκεται πριν το φώνημα /i/ για να δημιουργηθεί η λέξη “bin”, και όχι τα οπτικά πανομοιότυπα φωνήματα /p/ ή /m/), σε αντίθεση με ένα ευρύτερο in the wild dataset (στο οποίο κάλλιστα θα μπορούσε να περιέχεται και η λέξη “pin” και άρα να πρέπει να προβλεφθεί το /p/ και όχι το /b/).

Υποπείραμα 2: Δοκιμή του επιλεγμένου μοντέλου σε περιορισμένο περιβάλλον Έχοντας καταλήξει στην τελική και βέλτιστη μορφή του μοντέλου και έχοντας επεξηγήσει τη συνεισφορά κάθε σχεδιαστικής επιλογής στο τελικό αποτέλεσμα, ο πειραματισμός συνεχίζεται με μία δοκιμή σε μεγαλύτερο βάθος στο ίδιο dataset (GRID Audio-Visual Speech Corpus). Συγκεκριμένα, πέραν της πρόβλεψης των φωνημάτων, η ανάλυση προχωρά και σε πρόβλεψη λέξεων με γνώση του περιορισμένου περιβάλλοντος της μελέτης, προσομοιώνοντας έτσι ένα σύστημα με πιο πραγματική εφαρμογή.


Η εκπαίδευση έγινε πάλι με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή 3×10^{-4} και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5, στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο μέγιστος αριθμός εποχών αυξήθηκε σε 60, διατηρώντας τον μηχανισμό early stopping με παράγοντα υπομονής 12 epochs. Παρακάτω παρουσιάζονται τα αποτελέσματα του συγκεκριμένου πειράματος:




Σχήμα 20: Γράφημα τιμών του train loss και του κάθε συντελεστή αυτού για κάθε epoch



Σχήμα 21: Γράφημα τιμών του validation loss για κάθε epoch



Σχήμα 22: Γράφημα τιμών του validation TER για κάθε epoch




Σχήμα 23: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Αρχικά, να σημειωθεί ότι στο σχήμα 20, ο συντελεστής CTC της συνάρτησης κόστους παρουσιάζεται πριν τον πολλαπλασιασμό του με τον κατάλληλο συντελεστή, άρα για κάθε epoch (όπως είναι προφανές από το σχήμα), δεν ισχύει $total_loss = frame_ce_loss + ctc_loss$, αλλά $total_loss = frame_ce_loss + 0.3 \times ctc_loss$.

Παρατηρείται ομαλή εκπαίδευση που τελικά οδηγεί σε βέλτιστη τιμή validation loss 1.027 όπως και βέλτιστη τιμή validation TER 0.1273, με τον μηχανισμό early stopping να πυροδοτείται κατά την εποχή 50. Όπως ήταν και αναμενόμενο, τα αποτελέσματα είναι πολύ παρόμοια με αυτά του μοντέλου V1 της μελέτης αφαίρεσης. Οι μικροδιαφορές οφείλονται σε ελάχιστες διαφοροποιήσεις κατά την εκτέλεση των εκπαιδεύσεων και όχι σε κάποια αρχιτεκτονική παράλειψη.

Στο test set, το μοντέλο πετυχαίνει τιμή $frame_ce_loss = 0.8626$, $ctc_loss = 0.461$, $total_loss = 1.0009$ και $ter = 0.1241$. Παρακάτω παρουσιάζεται ο πίνακας σύγχυσης (confusion matrix) των φωνημάτων που προβλέφθηκαν από το μοντέλο σε σχέση με τα πραγματικά (ground truth).



Σχήμα 24: Πίνακας σύγχυσης (confusion matrix) στο test set

Ο πίνακας σύγχυσης παρουσιάζει ισχυρή προβλεπτική ικανότητα, με την κύρια διαγώνιο (το σύνολο των σωστών προβλέψεων) να κυριαρχεί σε σχέση με τον υπόλοιπο πίνακα. Οι κύριες πηγές προβληματισμού είναι η τελευταία σειρά “<inserted>”, η οποία αποτελείται από περιπτώσεις που ένα φώνημα προβλέφθηκε λανθασμένα στη θέση του blank token και η τελευταία στήλη “<missed>” που περιγράφει το αντίστροφο φαινόμενο, όταν δηλαδή δεν προβλέπεται κάποιο φώνημα που όντως υπάρχει αλλά στη θέση του προβλέπεται το blank token. Συγχύσεις όμοιων οπτικά φωνημάτων (π.χ. /d/ και /t/) υπάρχουν αλλά σε ελάχιστο βαθμό, γεγονός που εξηγείται από την περιορισμένη φύση του dataset: το μοντέλο μαθαίνει ότι το dataset αποτελείται από συγκεκριμένες λέξεις και προσαρμόζεται ανάλογα.

Σε συνέχεια των παραπάνω και εκμεταλλευόμενοι τον περιορισμό των λέξεων που χρησιμοποιούνται στο dataset, αναπτύχθηκε ένα script πρόβλεψης φράσεων από την αλληλουχία φωνημάτων. Το script αυτό έχει πλήρη γνώση τόσο του λεξιλογίου του dataset όσο και της γραμματικής που παρουσιάζουν οι φράσεις (θεωρείται γνωστό, δηλαδή, ότι οι φράσεις είναι της μορφής εντολή, χρώμα, πρόθεση, γράμμα, ψηφίο, επίρρημα, όπως και ποιες είναι οι πιθανές λέξεις για κάθε μία από αυτές της κατηγορίες). Με βάση την προφορά του ηθοποιού, δημιουργείται ένα λεξικό που αντιστοιχίζει αλληλουχίες φωνημάτων σε λέξεις. Ο αλγόριθμος που αναπτύχθηκε περιγράφεται με περισσότερη λεπτομέρεια στην ενότητα (ρεφ).

Η χρήση του παραπάνω script στις προβλέψεις του βέλτιστου μοντέλου πετυχαίνει ορθή πρόβλεψη σε επίπεδο λέξης για 87.1% των λέξεων του test set και ακριβή πρόβλεψη σε επίπεδο πρότασης σε ποσοστό 38%. Το κύριο πρόβλημα είναι η πρόβλεψη στην ομάδα των γραμμάτων: μόλις 46% των γραμμάτων προβλέπονται σωστά. Αυτό οφείλεται τόσο στο μέγεθος της ομάδας αυτής (25 υποψήφιας λέξεις έναντι 4 σε άλλες κατηγορίες), όπως και στο μέγεθος της αλληλουχίας των φωνημάτων που αποτελούν ένα γράμμα (συνήθως είναι λιγότερα και άρα η πρόβλεψη είναι πιο επιρρεπής στον θόρυβο). Η υπόθεση αυτή ενισχύεται από την κατηγορία των προθέσεων, η οποία εμφανίζει το δεύτερο χαμηλότερο ποσοστό ορθής πρόβλεψης με 85.3%. Αντιθέτως, στις ομάδες με μεγαλύτερες λέξεις ή με λέξεις που απαρτίζονται από πιο χαρακτηριστικά φωνήματα, η πρόβλεψη ήταν ιδιαίτερα ακριβής: 98% στις εντολές, 99.3% στα

χρώματα, 95.3% στα ψηφία και 98.7% στα επιρρήματα. Τα ποσοστά αυτά είναι εξαιρετικά και αποδεικνύουν ότι οι προβλέψεις τόσο σε επίπεδο φωνήματος από το μοντέλο όσο και σε επίπεδο λέξης από τον αλγόριθμο είναι ιδιαίτερα ικανές στο περιορισμένο περιβάλλον.

Για να κριθεί ο χρονισμός (timing) της πρόβλεψης και όχι μόνο η ορθότητα του περιεχομένου, χρησιμοποιήθηκε το ffmpeg ώστε να υποτιτλιστούν μερικά από τα video του test set με τις λέξεις που προβλέπονται στον χρόνο που προβλέπονται τα φωνήματα τα οποία παράγουν τις λέξεις. Η διαδικασία αυτή δεν μπορεί να παρουσιαστεί στο πλαίσιο της συγκεκριμένης αναφοράς, παρουσιάζει ωστόσο ιδιαίτερα ακριβή αποτελέσματα, ειδικά, φυσικά, όταν η πρόβλεψη ολόκληρης της φράσης είναι σωστή.

6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον

Στο συγκεκριμένο πείραμα, στόχος είναι η δοκιμή του μοντέλου σε συνθήκες μη περιορισμένου περιβάλλοντος (in the wild). Το πρόβλημα αυτό είναι σαφώς πιο δύσκολο, διότι τόσο το ίδιο το λεξιλόγιο που χρησιμοποιείται (θεωρητικά, ολόκληρη η αγγλική γλώσσα) όσο και η ποικιλομορφία του συντακτικού που χρησιμοποιείται (όχι αυστηρό όπως στο GRID) καθιστούν την πρόβλεψη λέξεων μονάχα από το βίντεο προβληματική. Στα πλαίσια των δοκιμών αυτών, θα γινόταν χρήση των ευρέως διαδεδομένων datasets LRS2 και LRS3 (βλ. [1], [8], [7], [9]). Ωστόσο, λόγω δυσκολιών απόκτησης πρόσβασης στο συγκεκριμένο dataset, ήταν αδύνατη η σύγκριση του μοντέλου με τα state-of-the-art μοντέλα. Το πείραμα αυτό είναι η βασική μελλοντική επέκταση, όπως αναφέρεται και στην ενότητα 7.2.

Για λόγους πληρότητας, παρουσιάζονται στους πίνακες 3 και 4 οι επιδόσεις διάφορων μοντέλων του state-of-the-art, όπως παρουσιάζονται στο [28]. Τα μοντέλα είναι χωρισμένα με βάση τον τρόπο εκπαίδευσής τους, ενώ αναφέρονται και οι ώρες labeled και unlabeled δεδομένων που αξιοποιούνται, όπως και το word error rate (WER ως ποσοστό) που επιτυγχάνουν.

6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων

Στο συγκεκριμένο πείραμα δοκιμάζεται η μεθοδολογία του audiovisual μοντέλου που παρουσιάζεται 5.3, χρησιμοποιώντας δηλαδή ως είσοδο στο μοντέλο όχι μόνο το βουβό βίντεο, αλλά και το τμήμα του ήχου που αντιστοιχεί σε αυτό (ακριβέστερα, το παραγόμενο Mel-Spectrogram). Για τον σκοπό αυτό, χρησιμοποιούνται τόσο κατά την εκπαίδευση με το training set όσο και κατά τη δοκιμή με τα validation και testing sets δεδομένα στα οποία έχει προστεθεί θόρυβος με τους τρόπους που παρουσιάστηκαν παραπάνω, στην ενότητα 5.1.4.

Υποπείραμα 1: Αύξηση του SNR του ήχου Κατά το 1ο υποπείραμα, μελετάται η επίδραση της μείωσης του ηχητικού θορύβου στην ικανότητα του audiovisual μοντέλου να προβλέπει τα σωστά φωνήματα, ενώ συγκρίνεται και με το μοντέλο το οποίο χρησιμοποιεί αποκλειστικά το ηχητικό σήμα για την πρόβλεψη. Το αναμενόμενο αποτέλεσμα είναι ότι, με την αύξηση του SNR, το ηχητικό σήμα γίνεται όλο και πιο αξιόπιστο, με αποτέλεσμα το μοντέλο να “εμπιστεύεται” τον ήχο περισσότερο και να προβλέπει με βάση αυτό το σήμα με μεγαλύτερη ακρίβεια. Παράλληλα, αναμένουμε ότι το μοντέλο που χρησιμοποιεί και τα δύο modalities θα έχει βελτιωμένη επίδοση σε σχέση με το αντίστοιχο που χρησιμοποιεί αποκλειστικά τον ήχο. Για τη συγκεκριμένη δοκιμή, τα frames των βίντεο που επιλέγονται για να τους προστεθεί θόρυβος (με τη μορφή του μηδενισμού, του παγώματος ή του θολώματος) είναι κατά μέσο όρο 30 (από τα συνολικά 75 του κάθε βίντεο του GRID), με jitter ± 8 frames. Ο θόρυβος που προστίθεται στον ήχο χαρακτηρίζεται από SNR στις τιμές -5, 0, 5, 10 και 15, ενώ χρησιμοποιείται και dropout του ηχητικού σήματος με πιθανότητα 30% και μήκος 15 frames (για κάθε διαφορετική φράση, μέχρι 1 φορά μπορεί να γίνει dropout).

Κατά την εκπαίδευση όλων των μοντέλων, χρησιμοποιήθηκε Adam optimizer με ρυθμό μάθησης $3e-4$, weight decay με τιμή $1e-4$ και gradient clipping με τιμή 1. Χρησιμοποιήθηκε scheduling του ρυθμού μάθησης με γραμμικό warmup για τις πρώτες 5 εποχές, μείωση του ρυθμού μάθησης μετά από 6 εποχές χωρίς βελτίωση κατά παράγοντα 0.5, με ελάχιστη τιμή το $1e-6$. Χρησιμοποιείται early stopping με κριτήριο τη μετρική val TER (validation Token Error Rate) και τιμή υπομονής 12 εποχές, batch size 4, με μέγιστο

Πίνακας 3: Σύγκριση επιδόσεων state-of-the-art μοντέλων στο dataset LRS3


Method	Unlabeled (hrs)	Labeled (hrs)	WER (%)
<i>Fully supervised models with publicly available data</i>			
ASR distillation [3]	–	590	68.8
Conv-Seq2Seq [34]	–	855	60.1
Discriminative [31]	–	590	57.8
Hyb. + Conformer [22]	–	590	43.3
VTP [23]	–	698	40.6
<i>Trained on large-scale non-publicly available datasets</i>			
Deep-AV-SR [2]	–	1,519	58.9
Large-scale AV-SR [27]	–	3,886	55.1
RNN-T [21]	–	31,000	33.6
VTP [23]	–	2,676	30.7
ViT-3D [25]	–	90,000	17.0
LP [6]	–	1,000,000	12.5
<i>Self-supervised pre-training + Supervised fine-tuning on LRS3</i>			
LiRA [20]	433	30	71.9
ASR distillation [3]	334	590	59.8
LiteVSR [17]	639	59	45.7
ES3 [35]	433	30	43.5
AV-HuBERT Large [26]	1,759	30	32.5
Lip2Vec [11]	1,759	30	31.2
Sub-Word [23]	2,676	2,676	30.7
SynthVSR [18]	3,652	438	27.9
Whisper [24]	1,759	30	25.5
Auto-AVSR [19]	1,759	433	25.0
LLaMA-AVSR [5]	–	1,756	24.0
RAVEEn [14]	1,759	433	23.1
USR [15]	1,326	433	21.5
<i>Supervised finetuning only on LRS3</i>			
VALLR [28]	–	30	18.7

αριθμό εποχών να είναι 100. Τέλος, κατά την εκπαίδευση, χρησιμοποιείται παράγοντας modality dropout 0.15 (με πιθανότητα 0.15 αφαιρείται πλήρως ένα από τα δύο modalities, βλ. ενότητα 5.3) για να αυξηθεί η ευρωστία του μοντέλου. Μέσω των παρακάτω διαγραμμάτων, αποτυπώνονται τα αποτελέσματα του συγκεκριμένου υποπειράματος.

Όπως φαίνεται στο σχήμα 25, η μετρική val TER (Token Error Rate στο validation set) βελτιώνεται τόσο για το audiovisual μοντέλο, όσο και για το audio unimodal μοντέλο με την αύξηση του SNR του ηχητικού σήματος (με εξαίρεση μία μικρή αύξηση του TER για 15dB έναντι των 10dB στην περίπτωση του audiovisual μοντέλου). Το φαινόμενο αυτό είναι αναμενόμενο και φαίνεται να επιβεβαιώνει την ικανότητα του μοντέλου να αξιοποιήσει περισσότερο την πληροφορία του ήχου, όσο αυτή γίνεται πιο αξιόπιστη. Ταυτόχρονα, τα μοντέλα που αξιοποιούν και τα δύο modalities (βίντεο και ήχο) υπερσχύουν σε κάθε περίπτωση από τα αντίστοιχα που αξιοποιούν μονάχα το ηχητικό σήμα. Αυτό (σε συνδυασμό με το σχήμα 36 παρακάτω) αποδεικνύει πως σε περιβάλλοντα όπου υπάρχει θόρυβος και στο βίντεο και στον ήχο, είναι προτιμότερο να λαμβάνονται υπόψιν και οι 2 μορφές δεδομένων ώστε να αναγνωρίζονται με υψηλότερο ποσοστό επιτυχίας τα φωνήματα και τελικά η ανθρώπινη ομιλία.


Πίνακας 4: Σύγκριση επιδόσεων state-of-the-art μοντέλων στο dataset LRS2

Method	Unlabeled (hrs)	Labeled (hrs)	WER (%)
<i>Fully supervised models with publicly available data</i>			
Auto-AVSR [19]	–	818	27.9
Auto-AVSR [19]	–	3,448	14.6
<i>Self-supervised pre-training + Supervised finetuning on LRS2 for AVSR</i>			
LiRA [20]	1,759	433	38.8
ES3 [35]	1,759	223	26.7
Sub-Word [23]	2,676	2,676	22.6
RAVEN [14]	1,759	223	17.9
USR [15]	1,759	223	15.4
<i>Supervised finetuning only on LRS2</i>			
VALLR [28]	–	28	20.8




Σχήμα 25: Γραφήματα τιμών του βέλτιστου val TER για διάφορες τιμές audio SNR

Στο σχήμα 26, παρουσιάζονται οι καμπύλες εκπαίδευσης (train loss) των μοντέλων για διάφορες τιμές SNR του ηχητικού σήματος. Να σημειωθεί ότι οι τιμές της αντικειμενικής συνάρτησης των audiovisual και των αντίστοιχων audio μοντέλων δεν είναι απολύτως συγκρίσιμες, καθώς η αντικειμενική συνάρτηση του audiovisual μοντέλου περιλαμβάνει έναν περαιτέρω auxiliary CTC όρο, συγκεκριμένα αυτόν του βίντεο. Γενικά, φαίνεται σε όλα τα μοντέλα να επιτυγχάνεται σταθερή σύγκλιση, με την τιμή του SNR να μην επηρεάζει την εικόνα των καμπυλών. Με την αύξηση του SNR, φαίνεται να βελτιώνεται ελάχιστα η τελική τιμή της αντικειμενικής συνάρτησης στο training set.




Σχήμα 26: Γραφήματα τιμών train loss per epoch για διάφορες τιμές audio SNR

Τα σχήματα 27 και 28 δείχνουν τις μέσες τιμές της audio gate και της video gate, αντίστοιχα, για κάθε εποχή της εκπαίδευσης. Προφανώς, στην περίπτωση των audio μοντέλων, οι τιμές αυτές είναι 1 και 0 αντίστοιχα για κάθε εποχή, καθώς δε χρησιμοποιείται εξ' ορισμού το βίντεο. Παρουσιάζει ιδιαίτερο ενδιαφέρον, ωστόσο, η μελέτη των αποτελεσμάτων για το audiovisual μοντέλο. Σε γενικές γραμμές, αναμένουμε το μοντέλο να μαθαίνει να εμπιστεύεται τον ήχο όλο και περισσότερο, όσο το SNR αυξάνεται, επομένως το audio gate να αυξάνει με το SNR και αντίθετα το video gate να μειώνεται. Πράγματι, η τελική εικόνα φαίνεται να επιβεβαιώνει αυτό το φαινόμενο. Παρατηρούμε ότι, για τιμή SNR -5dB, όπου δηλαδή ο θόρυβος υπερिशύει του πραγματικού σήματος, η τιμή της audio gate είναι σταθερά μικρότερη από αυτήν της video gate, δηλαδή ότι το μοντέλο, ορθά, βασίζει τις αποφάσεις του κυρίως στο βίντεο και όχι τόσο στον ήχο. Για SNR 0dB, η τιμή της audio gate φαίνεται να ταλαντεύεται γύρω από το 0.5, υποδεικνύοντας ότι το μοντέλο εμπιστεύεται το ηχητικό σήμα και το βίντεο με όμοιο βάρος. Ήδη, δηλαδή, από το σημείο που ο πραγματικός ήχος και ο θόρυβος έχουν ίδια ενέργεια, το ηχητικό σήμα γίνεται εξίσου αξιόπιστο με το βίντεο από το οποίο έχουν αλλαχθεί λιγότερα από τα μισά frames του. Αυτό αποδεικνύει ότι, σε γενικές γραμμές, με τη βοήθεια του ηχητικού σήματος εξάγονται πιο εύκολα συμπεράσματα για τα φωνήματα και τελικά για την ομιλία, πράγμα αναμενόμενο από όσα έχουν ήδη συζητηθεί. Για τις υπόλοιπες τιμές του SNR, το μοντέλο ορθά εμπιστεύεται όλο και περισσότερο το ηχητικό σήμα εις βάρος του βίντεο για να εξάγει την τελική ταξινόμηση, με τιμή audio gate π.χ. για τα 15dB να ξεπερνάει στο τέλος της εκπαίδευσης το 0.6. Τα αποτελέσματα αυτά φαίνεται να επιβεβαιώνουν την ικανότητα του μοντέλου να προσαρμοστεί στις συνθήκες στις οποίες εφαρμόζεται και να αξιοποιεί την εκάστοτε modality που μπορεί πράγματι να οδηγήσει στη σωστή ταξινόμηση, παρουσιάζοντας μία γενική προτίμηση για το ηχητικό σήμα, κάτι που είναι λογικό, μια και ο ήχος μπορεί απόλυτα να χαρακτηρίσει ένα φώνημα, ενώ το βίντεο όχι.




Σχήμα 27: Γραφήματα τιμών της audio gate στο validation set per epoch για διάφορες τιμές audio SNR




Σχήμα 28: Γραφήματα τιμών της video gate στο validation set per epoch για διάφορες τιμές audio SNR

Τα σχήματα 29 και 30 δείχνουν την πορεία της μετρικής val TER και της loss function στο validation set για τις εποχές της εκπαίδευσης, για τις διάφορες τιμές του SNR. Να σημειωθεί ότι και σε αυτήν την περίπτωση οι τιμές της αντικειμενικής συνάρτησης των audiovisual μοντέλων και των audio μοντέλων δεν είναι απολύτως συγκρίσιμες, για τον ίδιο λόγο που αναφέρθηκε παραπάνω. Όσον αφορά τη μετρική val TER, παρατηρούμε σύγκλιση για όλα τα μοντέλα, με χαμηλότερη τελική τιμή για το audiovisual μοντέλο εις βάρος του αντίστοιχου audio μοντέλου σε κάθε περίπτωση, όπως ήταν και αναμενόμενο. Τόσο η ταχύτητα και η ομαλότητα της σύγκλισης όσο και η τελική τιμή του val TER φαίνεται να βελτιώνονται με την αύξηση του SNR του ηχητικού σήματος. Τα διαγράμματα των τιμών της αντικειμενικής συνάρτησης στο validation set παρουσιάζουν όμοια εικόνα με τα αντίστοιχα στο training set του σχήματος 26, με καθολική ομαλή σύγκλιση. Η τελική τιμή της validation loss φαίνεται να βελτιώνεται όσο αυξάνεται το SNR, τόσο στο audiovisual όσο και στο audio μοντέλο.




Σχήμα 29: Γραφήματα τιμών val TER per epoch για διάφορες τιμές audio SNR




Σχήμα 30: Γραφήματα τιμών val loss per epoch για διάφορες τιμές audio SNR

Το σχήμα 31 δείχνει τις εποχές πριν πυροδοτηθεί ο μηχανισμός early stopping για το audiovisual και το audio μοντέλο ως συνάρτηση του SNR του ήχου που χρησιμοποιείται κατά την εκπαίδευση. Η γενική τάση φαίνεται να είναι το audiovisual μοντέλο να απαιτεί περισσότερες εποχές εκπαίδευσης μέχρι τη σύγκλιση, κάτι που πιθανότατα εξηγείται από την ύπαρξη και των δύο modalities. Σε αντίθεση με το audio μοντέλο, το audiovisual μοντέλο χρησιμοποιεί και οπτικά και ακουστικά στοιχεία για την εξαγωγή των τελικών του αποφάσεων, με αποτέλεσμα να δαπανεί περισσότερες εποχές ώστε να αντιληφθεί σε ποια σημεία πρέπει να εμπιστευτεί το βίντεο και σε ποια τον ήχο. Παράλληλα, μαθαίνει να συνδυάζει τα συμπεράσματα του ενός modality με αυτά του άλλου, κάτι που το audio μοντέλο δε χρειάζεται να κάνει. Η τάση αυτή δε συνεχίζεται όταν το SNR του ήχου είναι 15dB. Σε εκείνο το σημείο, το μοντέλο αξιοποιεί σημαντικά περισσότερο τον ήχο (όπως φαίνεται στο σχήμα 27), βασιζόμενο στο βίντεο μόνο όταν αυτό είναι απαραίτητο (π.χ. στα σημεία με πλήρες audio dropout). Πρόκειται, δηλαδή, για το σημείο που το audiovisual μοντέλο μπορεί βέλτιστα να συνδυάσει τις πληροφορίες των δύο modalities και να συγκλίνει ταχύτερα σε σχέση με το αντίστοιχο audio μοντέλο.




Σχήμα 31: Γράφημα αριθμού εποχών εκπαίδευσης για διάφορες τιμές audio SNR

Τα διαγράμματα 32 και 33 δείχνουν τις μέσες τιμές της audio gate και της video gate αντίστοιχα στο test set. Φυσικά, στην περίπτωση του audio μοντέλου, οι τιμές αυτές είναι 1 και 0 αντίστοιχα ανεξαρτήτως SNR σε dB, όπως και πριν. Το αναμενόμενο είναι το audiovisual μοντέλο να εμπιστεύεται τον ήχο περισσότερο όσο αυξάνεται το SNR και στο test set, πράγμα που συμβαίνει, κοιτώντας τα συγκεκριμένα γραφήματα. Η τιμή της audio gate παρουσιάζει σταθερή άνοδο, ενώ αντίθετα η τιμή της video gate συνεχή πτώση. Για τιμή SNR -5dB, όπου δηλαδή ο θόρυβος είναι ισχυρότερος από το πραγματικό σήμα, η τιμή της audio gate είναι κάτω από 0.5, που σημαίνει ότι το μοντέλο έχει μάθει να εξάγει συμπεράσματα κυρίως βασισμένο στο βίντεο και όχι στον ήχο για αυτήν την τιμή θορύβου. Αντιθέτως, στην τιμή 15dB, όπου πλέον ο θόρυβος είναι πολύ ασθενέστερος από το πραγματικό σήμα, η τιμή της audio gate πλησιάζει το 0.7, κάτι που δείχνει ότι το μοντέλο αναγνωρίζει την αξιοπιστία του modality του ήχου και προσαρμόζεται ανάλογα.




Σχήμα 32: Γράφημα τιμών της audio gate στο test set για διάφορες τιμές audio SNR




Σχήμα 33: Γράφημα τιμών της video gate στο test set για διάφορες τιμές audio SNR

Τέλος, τα διαγράμματα 34 και 35 φανερώουν την τελική επίδοση στο test set με τη μετρική test TER και την τιμή της αντικειμενικής συνάρτησης, για διάφορες τιμές του SNR του ηχητικού σήματος. Και πάλι, να σημειωθεί ότι οι τιμές της αντικειμενικής συνάρτησης μεταξύ του audiovisual και του αντίστοιχου audio μοντέλου δεν είναι απολύτως συγκρίσιμες, λόγω του περαιτέρω όρου auxiliary CTC. Παρατηρούμε ότι, σε κάθε περίπτωση, η αύξηση του SNR επιφέρει βελτίωση των αποτελεσμάτων, όπως ήταν και αναμενόμενο. Όσο αυξάνεται το SNR, τόσο πιο αξιόπιστο γίνεται το σήμα του ήχου, το οποίο, ακόμα και μόνο του, μπορεί να χρησιμοποιηθεί ικανοποιητικά για την πρόβλεψη φωνημάτων. Η τάση αυτή παρουσιάζεται και στις τιμές της αντικειμενικής συνάρτησης αλλά και στη μετρική test TER. Επίσης, όπως είναι αναμενόμενο, η επίδραση της αύξησης του SNR είναι μεγαλύτερη στην περίπτωση του audio μοντέλου, από ότι σε αυτήν του audiovisual μοντέλου. Αυτό οφείλεται, προφανώς, στο γεγονός ότι το μοντέλο με αποκλειστική πρόσβαση στον ήχο αντιμετωπίζει μεγαλύτερη δυσκολία στην πρόβλεψη φωνημάτων για χαμηλά SNR σε σχέση με το audiovisual μοντέλο, το οποίο διαθέτει πρόσβαση και στο modality του βίντεο (ακόμα κι αν αυτό είναι θορυβώδες, μπορεί να αξιοποιηθεί). Έτσι, η μείωση του test TER στην περίπτωση του audio μοντέλου είναι από 0.24 περίπου για -5db στο 0.16 για 15dB, ενώ για το audiovisual μοντέλο είναι από 0.18 στο 0.15 περίπου.



Σχήμα 34: Γράφημα τιμών της loss function στο test set για διάφορες τιμές audio SNR




Σχήμα 35: Γράφημα τιμών του TER στο test set για διάφορες τιμές audio SNR

Υποπείραμα 2: Αύξηση των επηρεασμένων frames του βίντεο Ως συμμετρικό του προηγούμενου υποπείραματος, στο 2ο υποπείραμα μελετάται η επίδραση της αύξησης των επηρεασμένων frames του βίντεο από τον θόρυβο (με τη μορφή μηδενισμού, παγώματος ή θολώματος) στην επίδοση του audiovisual μοντέλου, ενώ συγκρίνεται και με την επίδοση του μοντέλου που χρησιμοποιεί αποκλειστικά το θορυβώδες βίντεο για να προβλέψει τα φωνήματα. Το αναμενόμενο αποτέλεσμα είναι ότι όσο περισσότερα frames του βίντεο επηρεάζονται από θόρυβο, τόσο πιο αναξιόπιστο γίνεται το modality του βίντεο και άρα τόσο λιγότερο το “εμπιστεύεται” το μοντέλο και τόσο χειρότερες είναι οι ταξινομήσεις του σε φωνήματα. Ταυτόχρονα, το μοντέλο που χρησιμοποιεί αποκλειστικά το βίντεο για τις προβλέψεις φωνημάτων αναμένεται να πετυχαίνει χειρότερα αποτελέσματα σε σχέση με το audiovisual μοντέλο, λόγω της εκμετάλλευσης του ηχητικού σήματος. Κατά το πείραμα αυτό, η τιμή του SNR του ήχου είναι σταθερά 15 και το ηχητικό dropout παραμένει με πιθανότητα 30% και μήκος 15 frames, ενώ η τιμή των video frames που επηρεάζονται είναι 10, 15, 20, 25 και 30 (αυτή τη φορά, η τιμή είναι σταθερή και δεν υπάρχει jitter).

Κατά την εκπαίδευση όλων των μοντέλων, πάλι χρησιμοποιήθηκε Adam optimizer με ρυθμό μάθησης $3e-4$, weight decay με τιμή $1e-4$ και gradient clipping με τιμή 1. Επιλέχθηκε scheduling του ρυθμού μάθησης με γραμμικό warmup για τις πρώτες 5 εποχές, μείωση του ρυθμού μάθησης μετά από 6 εποχές χωρίς βελτίωση κατά παράγοντα 0.5, με ελάχιστη τιμή το $1e-6$. Χρησιμοποιήθηκε early stopping με κριτήριο τη μετρική val TER (validation Token Error Rate) και τιμή υπομονής 12 εποχές, batch size 4, με μέγιστο αριθμό εποχών να είναι 100. Τέλος, κατά την εκπαίδευση, χρησιμοποιείται παράγοντας modality dropout 0.15 (με πιθανότητα 0.15 αφαιρείται πλήρως ένα από τα δύο modalities) για να αυξηθεί η ευρωστία του μοντέλου. Τα παρακάτω διαγράμματα περιλαμβάνουν τα αποτελέσματα του πειράματος.


Το σχήμα 36 δείχνει την τάση της μετρικής val TER (τη βέλτιστη τιμή της) για το audiovisual και το video μοντέλο σε συνάρτηση με τον αριθμό frames του βίντεο στα οποία έχει εφαρμοστεί θόρυβος (με τους τρόπους που αναφέρονται παραπάνω). Η αναμενόμενη εικόνα είναι η επίδοση των μοντέλων να μειώνεται όσο αυξάνονται τα επηρεασμένα frames του βίντεο, μια και το modality αυτό θα γίνεται όλο και πιο αναξιόπιστο. Επιπροσθέτως, αναμένουμε η επίδραση αυτή να είναι μεγαλύτερη για την περίπτωση του video μοντέλου, καθώς χρησιμοποιεί μονάχα το βίντεο και όχι ηχητικά στοιχεία για τις αποφάσεις του. Πράγματι, η εικόνα του σχήματος αυτού αναπαράγει τα αναμενόμενα αποτελέσματα. Η βέλτιστη τιμή της μετρικής val TER για το video μοντέλο παίρνει τιμή περίπου 0.2 για 10 επηρεασμένα frames και σταθερά ανεβαίνει, ξεπερνώντας την τιμή 0.35 για 30 επηρεασμένα frames του βίντεο. Η κατάσταση αυτή είναι αναμενόμενη, αν αναλογιστούμε ότι τα κλιπ αποτελούνται από 75 frames συνολικά, κάνοντας τα 30 από τα 75 ένα ποσοστό 40% των εικονιζόμενων frames να έχουν επηρεαστεί. Από την άλλη, για το audiovisual μοντέλο παρατηρείται μία ελαφριά αύξηση της μετρικής όσο αυξάνει ο αριθμός των επηρεα-

σμένων frames, από την τιμή 0.11 για 10 frames μέχρι την τιμή 0.145 για 25 frames, με μία μείωση όταν ο αριθμός των frames αυξάνεται στα 30, περίπου στην τιμή 0.13. Όπως ήταν αναμενόμενο, η επίδραση του φαινομένου υπό μελέτη είναι μικρότερη για το audiovisual μοντέλο, το οποίο σταθερά επικρατεί έναντι του visual μοντέλου. Αυτό οφείλεται, προφανώς, στην εκμετάλλευση του ηχητικού σήματος, το οποίο στις συγκεκριμένες δοκιμές είναι αρκετά ακριβές (15dB SNR, με περιπτώσεις ολικού dropout).




Σχήμα 36: Γράφημα τιμών του βέλτιστου val TER για διάφορες τιμές obstructed video frames

Το σχήμα 37 δείχνει την πορεία της αντικειμενικής συνάρτησης στο training set του audiovisual και του video μοντέλου για τις διάφορες τιμές θορυβωδών frames του βίντεο που χρησιμοποιήθηκαν. Να σημειωθεί και πάλι ότι οι τιμές της αντικειμενικής συνάρτησης του audiovisual μοντέλου και του αντίστοιχου visual μοντέλου δεν είναι απολύτως συγκρίσιμες, λόγω της έλλειψης του auxiliary CTC όρου του audio stream στην περίπτωση του μοντέλου video. Παρατηρείται σε κάθε περίπτωση ομαλή σύγκλιση, με τη βέλτιστη τελική τιμή της αντικειμενικής συνάρτησης να δείχνει να αυξάνει, όσο αυξάνονται και τα επηρεασμένα frames. Μάλιστα, για υψηλές τιμές επηρεασμένων frames, όπου το μοντέλο του βίντεο αναμένουμε να δυσκολεύεται δεδομένων των θορυβωδών συνθηκών, η τιμή της αντικειμενικής συνάρτησης του audiovisual μοντέλου φαίνεται να είναι χαμηλότερη από αυτήν του video μοντέλου, παρά της εγγενούς ανισορροπίας τους. Αυτό αποδεικνύει τη βελτίωση που παρέχει η αξιοποίηση του περαιτέρω modality. Παρά το γεγονός ότι και ο ήχος χαρακτηρίζεται από θόρυβο, το μοντέλο μαθαίνει πολύ πιο εύκολα την αναγνώριση φωνημάτων αξιοποιώντας δύο modalities έναντι ενός.




Σχήμα 37: Γραφήματα τιμών train loss per epoch για διάφορες τιμές obstructed video frames

Τα σχήματα 38 και 39 δείχνουν τις μέσες τιμές της audio gate και της video gate, αντίστοιχα, για κάθε εποχή της εκπαίδευσης. Προφανώς, στην περίπτωση των video μοντέλων, οι τιμές αυτές είναι 0 και 1 αντίστοιχα για κάθε εποχή, καθώς δε χρησιμοποιείται εξ' ορισμού το ηχητικό σήμα. Για το audiovisual μοντέλο, αναμένουμε η μέση τιμή της audio gate να αυξάνει και, αντίστοιχα, αυτή της video gate να μειώνεται, όσο αυξάνεται ο αριθμός των frames που χαρακτηρίζονται από θόρυβο, καθώς το σήμα του βίντεο γίνεται πιο αναξιόπιστο για την πρόβλεψη φωνημάτων και άρα το μοντέλο βασίζει τις αποφάσεις του όλο και περισσότερο στο ηχητικό σήμα. Πράγματι, αυτή φαίνεται να είναι η εικόνα, μια και για τιμή επηρεασμένων frames 10 η μέση τιμή της audio gate ταλαντεύεται λίγο πάνω από το 0.5 και η αντίστοιχη της video gate λίγο κάτω από αυτήν την τιμή (το μοντέλο φαίνεται να εμπιστεύεται εξίσου τα δύο modalities), ενώ για τιμή 30 frames η μέση τιμή της audio gate ξεπερνάει το 0.6. Η διαφορά αυτή δε φαίνεται ιδιαίτερα μεγάλη, υποδεικνύοντας ότι το audiovisual μοντέλο μπορεί να εξαγάγει χρήσιμα συμπεράσματα από το modality του βίντεο, ακόμα και όταν αυτό είναι μεταλλαγμένο σε σημαντικό βαθμό.




Σχήμα 38: Γραφήματα τιμών της audio gate στο validation set per epoch για διάφορες τιμές obstructed video frames




Σχήμα 39: Γραφήματα τιμών της video gate στο validation set per epoch για διάφορες τιμές obstructed video frames

Τα σχήματα 40 και 41 δείχνουν την πορεία της μετρικής val TER και της τιμής της αντικειμενικής συνάρτησης στο validation set για τα epochs της εκπαίδευσης, με τις διάφορες τιμές αριθμού θορυβωδών frames που μελετήθηκαν. Πάλι οι τιμές της αντικειμενικής συνάρτησης του audiovisual και του αντίστοιχου video μοντέλου δεν είναι απολύτως συγκρίσιμες, για τον ίδιο λόγο που αναφέρθηκε παραπάνω. Στα συγκεκριμένα διαγράμματα, αναμενόμενη εικόνα είναι σύγκλιση, με την αύξηση των επηρεασμένων frames να επιφέρει και επιδείνωση των εκάστοτε μετρικών. Πράγματι, το σχήμα 40 έχει αυτήν την εικόνα, με το video μοντέλο πάντα να πετυχαίνει χειρότερη επίδοση από το αντίστοιχο audiovisual μοντέλο, όπως είναι και λογικό. Οι επιδόσεις και των δύο στη συγκεκριμένη μετρική φαίνεται να είναι χειρότερες, όσο αυξάνεται ο αριθμός των επηρεασμένων frames, με την επίδραση αυτή να είναι μεγαλύτερη για το video μοντέλο, κάτι που ήταν αναμενόμενο. Η εικόνα του σχήματος 40 φανερώνει στοιχεία overfitting για την περίπτωση του video μοντέλου, καθώς η σύγκλιση δεν είναι ομαλή και διακόπτεται από μία περίοδο αύξησης, σε κάθε περίπτωση. Να σημειωθεί ότι η συμπεριφορά αυτή μπορούσε να αποφευχθεί, χρησιμοποιώντας ως κριτήριο του early stopping το val loss και όχι το val TER. Αντιθέτως, η εικόνα του audiovisual μοντέλου δείχνει σταθερή σύγκλιση, σε τιμή η οποία μάλιστα είναι καλύτερη από την αντίστοιχη του video μοντέλου, ακόμα κι αν οι δύο αντικειμενικές συναρτήσεις παρουσιάζουν ανισορροπία. Η εκπαίδευση του audiovisual μοντέλου είναι, γενικά, πιο ευσταθής και πιο επιτυχής, αναδεικνύοντας πόσο διευκολύνεται η επίτευξη του στόχου της αναγνώρισης φωνημάτων αξιοποιώντας και στοιχεία από το ηχητικό σήμα.




Σχήμα 40: Γραφήματα τιμών val TER per epoch για διάφορες τιμές obstructed video frames



Σχήμα 41: Γραφήματα τιμών val loss per epoch για διάφορες τιμές obstructed video frames


Το σχήμα 31 δείχνει τον αριθμό εποχών εκπαίδευσης του audiovisual και του video μοντέλου μέχρι να πυροδοτηθεί ο μηχανισμός του early stopping, για τις διάφορες τιμές αριθμού επηρεασμένων από τον θόρυβο frames του video. Παρατηρούμε ότι, σε γενικές γραμμές, οι εποχές εκπαίδευσης του video μοντέλου τείνουν να γίνονται περισσότερες όσο αυξάνεται ο αριθμός των obstructed frames, ενώ του audiovisual μοντέλου ελαττώνονται. Η τάση αυτή δεν είναι απόλυτη και παρουσιάζει αρκετές εξαιρέσεις (για 20 frames, οι εποχές εκπαίδευσης του video model είναι περισσότερες από ότι για 25 ή 30, ενώ για 30 frames το audiovisual μοντέλο απαιτεί τις περισσότερες εποχές εκπαίδευσης σε σχέση με οποιαδήποτε άλλη περίπτωση). Το φαινόμενο αυτό οφείλεται στην ποιότητα των δεδομένων: ειδικά για το video μοντέλο, το οποίο δεν έχει πρόσβαση σε ηχητικά στοιχεία, η ποιότητα των video συσχετίζεται άμεσα με την ποιότητα και την ταχύτητα της εκπαίδευσης. Εάν τα δεδομένα είναι ιδιαίτερα θορυβώδη, το μοντέλο μπορεί να πασχίζει περισσότερο ώστε να καταλήξει σε πιθανές προβλέψεις, βασιζόμενο στα φωνήματα που έχει προβλέψει γύρω από τη θορυβώδη περιοχή του βίντεο και χτίζοντας γνώση του λεξιλογίου (ή, γενικότερα, της γλώσσας) του dataset. Έτσι, μέχρι να φτάσει στο σημείο που μπορεί να κάνει (σχετικά) ρεαλιστικές προβλέψεις για τη θορυβώδη περιοχή, απαιτείται περισσότερος χρόνος εκπαίδευσης και

άρα περισσότερες εποχές. Αντίθετα, το audiovisual μοντέλο έχει τη δυνατότητα να βασιστεί όλο και περισσότερο στον ήχο, όσο το βίντεο γίνεται πιο θορυβώδες. Επομένως, αντί να περιπλέκει τη μάθησή του με περίπλοκες συσχετίσεις μεταξύ ήχου και βίντεο, μαθαίνει (ορθά) να εμπιστεύεται περισσότερο τον ήχο και ως δεύτερη επιλογή το βίντεο και μειώνει (σε γενικές γραμμές) τις απαιτούμενες εποχές για την εκπαίδευσή του.




Σχήμα 42: Γράφημα αριθμού εποχών εκπαίδευσης για διάφορες τιμές obstructed video frames

Τα σχήματα 43 και 44 δείχνουν τις μέσες τιμές των audio και video gates αντίστοιχα στο test set για το audiovisual και το video μοντέλο, για τις τιμές obstructed frames που δοκιμάστηκαν. Προφανώς οι τιμές αυτές είναι 0 και 1 αντίστοιχα στην περίπτωση του video μοντέλου. Για το audiovisual μοντέλο, είναι αναμενόμενο να αυξάνεται η τιμή της audio gate και αντίστοιχα να μειώνεται αυτή της video gate όσο αυξάνεται ο αριθμός των obstructed frames, καθώς το μοντέλο μαθαίνει να εμπιστεύεται το πιο αξιόπιστο σήμα, το οποίο στη συγκεκριμένη περίπτωση είναι ο ήχος. Πράγματι, αυτή είναι η εικόνα που παρουσιάζουν τα συγκεκριμένα διαγράμματα, με διαρκή αύξηση της μέσης τιμής της audio gate και αντίστοιχη μείωση της μέσης τιμής της video gate, όσο αυξάνεται ο αριθμός των επηρεασμένων από τον θόρυβο frames. Το μοντέλο μαθαίνει να δίνει όλο και περισσότερη έμφαση στα συμπεράσματα που εξάγει από τον ήχο και να χρησιμοποιεί συμπληρωματικά το βίντεο, όσο το βίντεο γίνεται πιο θορυβώδες και άρα πιο αναξιόπιστο.




Σχήμα 43: Γράφημα τιμών της audio gate στο test set για διάφορες τιμές obstructed video frames




Σχήμα 44: Γράφημα τιμών της video gate στο test set για διάφορες obstructed video frames

Τέλος, τα σχήματα 45 και 46 απεικονίζουν τις τιμές της αντικειμενικής συνάρτησης στο test set και της μετρικής test TER, για το audiovisual και video μοντέλο, στις συνθήκες που δοκιμάστηκαν. Από τα παραπάνω, αναμενόμενο αποτέλεσμα είναι η επίδοση των μοντέλων να επιδεινώνεται όσο αυξάνεται ο αριθμός των θορυβωδών frames, με το φαινόμενο αυτό να γίνεται πιο αντιληπτό στο video μοντέλο. Αναμένουμε, επίσης, το audiovisual μοντέλο σε κάθε περίπτωση να επιφέρει βελτιωμένα αποτελέσματα σε σχέση με το video μοντέλο, εκμεταλλευόμενο την πρόσβασή του στο ηχητικό σήμα. Η εικόνα αυτή φαίνεται πράγματι να παρουσιάζεται στα αποτελέσματα. Παρά το γεγονός ότι οι αντικειμενικές συναρτήσεις των μοντέλων δεν είναι απολύτως συγκρίσιμες (για τους λόγους που αναφέρθηκαν παραπάνω), η τιμή της αντικειμενικής συνάρτησης του audiovisual μοντέλου είναι σε κάθε περίπτωση μικρότερη από την αντίστοιχη τιμή του video μοντέλου, αποδεικνύοντας τη διαφορά στην ποιότητα της μάθησης που επιτυγχάνουν τα δύο μοντέλα στο θορυβώδες περιβάλλον. Η τιμή της αντικειμενικής συνάρτησης και η μετρική test TER παρουσιάζουν μία γενικά αυξητική τάση και για τα δύο μοντέλα, όσο αυξάνεται ο αριθμός των επηρεασμένων frames, τάση η οποία, όπως ήταν αναμενόμενο, είναι ενισχυμένη για το video μοντέλο. Τα αποτελέσματα αυτά αναδεικνύουν τη διευκόλυνση του προβλήματος που παρέχεται μέσω της πρόσβασης του, έστω και θορυβώδους, ηχητικού σήματος.



Σχήμα 45: Γράφημα τιμών της loss function στο test set για διάφορες τιμές obstructed video frames



Σχήμα 46: Γράφημα τιμών του TER στο test set για διάφορες τιμές audio SNR

7 Συμπεράσματα και Μελλοντικές Επεκτάσεις

7.1 Συμπεράσματα

Από τη συγκεκριμένη διπλωματική εργασία, εξήχθησαν διάφορα συμπεράσματα τα οποία αφορούν τόσο τη φύση του προβλήματος της αναγνώρισης ομιλίας από τα χείλη (lip reading) όσο και τη συγκεκριμένη μεθοδολογία που χρησιμοποιήθηκε και δοκιμάστηκε (τόσο του αρχικού visual μοντέλου, βλ. 5.2, 6.3.1, όσο και του audiovisual μοντέλου, βλ. 5.3, 6.3.3). Τα σημαντικά από αυτά συμπεριλαμβάνονται παρακάτω.

Γενικά, για το πρόβλημα αναγνώρισης φωνημάτων:

- Το πρόβλημα πρόβλεψης φωνημάτων (και, γενικότερα, ανθρώπινης ομιλίας) χρησιμοποιώντας μόνο οπτικά στοιχεία (βουβό βίντεο) είναι αδύνατον να επιλυθεί πλήρως, λόγω της ύπαρξης των visemes, των φωνημάτων δηλαδή που, ενώ είναι διαφορετικά, παρουσιάζουν την ίδια εικόνα στα χείλη κατά την εκφορά τους.
- Για να μειωθεί η επίδραση των visemes στην αναγνώριση των φωνημάτων, είναι σημαντικό να χρησιμοποιείται κατά την πρόβλεψη παράθυρο μεγαλύτερο από τη διάρκεια του ίδιου του φωνήματος, έτσι ώστε το εκάστοτε μοντέλο πρόβλεψης να μπορεί να αξιοποιεί στοιχεία από τη γειτονιά του ίδιου φωνήματος (ποια προηγούνται και ποια έπονται) και, είτε επειδή χτίζει γνώση του λεξιλογίου σε περιορισμένο περιβάλλον, είτε επειδή μαθαίνει τις γενικές τάσεις κάποιας γλώσσας όσον αφορά την αλληλουχία φωνημάτων σε μη περιορισμένο περιβάλλον, να μαντεύει ορθά φωνήματα ακόμα και όταν αυτά ανήκουν σε κάποιο viseme.
- Η κατάτμηση του προβλήματος της αναγνώρισης της ομιλίας πρώτα στην αναγνώριση φωνημάτων και έπειτα στον συνδυασμό των προβλεπόμενων φωνημάτων για τη δημιουργία λέξεων φαίνεται να είναι ουσιώδης, διότι η αναγνώριση ολόκληρης φράσης δίχως το ενδιάμεσο βήμα της πρόβλεψης των φωνημάτων θα ήταν πιθανότατα διαδικασία ιδιαίτερα επιρρεπής στον θόρυβο και στις ιδιομορφίες της προφοράς του κάθε ανθρώπου.

Όσον αφορά τη δομή του προτεινόμενου visual μοντέλου και τα πειραματικά αποτελέσματα που παρουσιάζει:

- Από το πείραμα αφαίρεσης που παρουσιάστηκε στην ενότητα 6.3.1, συμπεραίνουμε ότι απαιτείται ο συνδυασμός του Feature Extractor, ο οποίος στη συγκεκριμένη περίπτωση είναι ένα συνελικτικό δίκτυο, και του Sequence Encoder, ο οποίος είναι υπεύθυνος για τον συνδυασμό των features που εξήχθησαν και την παραγωγή της πληροφορίας από την οποία τελικά γίνεται η πρόβλεψη φωνημάτων. Το μοντέλο δίχως τον Sequence Encoder παρουσίασε τη χειρότερη επίδοση από αυτά που δοκιμάστηκαν.
- Συγκεκριμένα για τον Sequence Encoder, από τη μελέτη αφαίρεσης καταλαβαίνουμε ότι το BiLSTM υπερέχει του Transformer, κάτι το οποίο συμβαίνει πιθανότατα λόγω του μικρού μεγέθους του χρησιμοποιούμενου dataset (GRID) και όχι λόγω κάποιας σχεδιαστικής υπεροχής του μοντέλου με BiLSTM. Όταν τα δεδομένα δεν είναι πολλά, οι transformers τείνουν να υπερπροσαρμόζονται (overfit) στα δεδομένα εκπαίδευσης και τελικά να έχουν χειρότερη επίδοση από άλλες παραδοσιακές αρχιτεκτονικές. Σε περίπτωση δοκιμής σε κάποιο μεγαλύτερο, ειδικά in the wild dataset, η εικασία είναι ότι ο Transformer θα υπερείχε του BiLSTM.
- Όσον αφορά την αντικειμενική συνάρτηση του μοντέλου, συμπεραίνουμε ότι ο συνδυασμός επίβλεψης τόσο σε επίπεδο frame όσο και σε επίπεδο τελικής αλληλουχίας των προβλεπόμενων φωνημάτων υπερέχει της χρήσης οποιασδήποτε από τις δύο μεθόδους ξεχωριστά. Ο όρος CTC της αντικειμενικής συνάρτησης είναι υπεύθυνος για τη πρόβλεψη αλληλουχιών φωνημάτων που έχουν νόημα, ενώ ο όρος cross-entropy προσφέρει σήμα που εκπαιδεύει το μοντέλο στους χρονισμούς εκφοράς του κάθε φωνήματος ξεχωριστά (σημαντικό, αν στόχος είναι η αναπαραγωγή της ομιλίας και όχι αποκλειστικά η πρόβλεψή της).

- Η χρήση soft ή hard targets κατά την εκπαίδευση φαίνεται να παρουσιάζει, τουλάχιστον στο περιορισμένο περιβάλλον, τη μικρότερη επίδραση στο τελικό αποτέλεσμα. Η επίδραση της επιλογής soft targets έναντι hard targets ίσως αυξάνεται με το μέγεθος και την ποικιλομορφία του dataset, καθώς σε περιορισμένο περιβάλλον είναι πιο εύκολο να “αποστηθιστούν” συγκεκριμένες αλληλουχίες φωνημάτων, μια και αυτές που προκύπτουν χρησιμοποιώντας οπτικά παρόμοια φωνήματα είναι τελικά άκυρες.
- Η χρήση της depthwise separable συνέλιξης έναντι της παραδοσιακής εκδοχής της παρέχει σημαντική μείωση στις εκπαιδευόμενες παραμέτρους του μοντέλου, αυξάνοντας την ταχύτητα εκπαίδευσης και μειώνοντας το υπολογιστικό κόστος.
- Το μοντέλο που αναδεικνύεται βέλτιστο από τη μελέτη αφαίρεσης (αυτό που τελικά προτείνεται στην ενότητα 5.2) παρουσιάζει ευχάριστα αποτελέσματα στην πρόβλεψη των φωνημάτων, εικόνα που γίνεται ιδιαίτερα εμφανής μέσω του πίνακα σύγχυσης. Η πρόβλεψη των εκάστοτε λέξεων στο περιορισμένο περιβάλλον από τα προβλεπόμενα φωνήματα φαίνεται επίσης να είναι ιδιαίτερα επιτυχής, με μοναδική εξαίρεση την κατηγορία των γραμμάτων στο GRID. Η αδυναμία αυτή οφείλεται στον αριθμό των υποψήφιων γραμμάτων, ο οποίος είναι πολύ μεγαλύτερος από τους αντίστοιχους αριθμούς για τις άλλες κατηγορίες, αλλά και στο μέγεθος των γραμμάτων σε φωνήματα. Καθώς κατά την εκφορά των περισσότερων γραμμάτων χρησιμοποιούνται περίπου 2 φωνήματα, η διαδικασία πρόβλεψης είναι ιδιαίτερα ευάλωτη στον θόρυβο που προκύπτει από τη λανθασμένη πρόβλεψη ενός από αυτά. Ο προβλεπόμενος χρονισμός του κάθε φωνήματος (και τελικά κάθε λέξης της φράσης) φαίνεται να είναι ιδιαίτερα ακριβής.

Όσον αφορά τη δομή του προτεινόμενου audiovisual μοντέλου και τα πειραματικά αποτελέσματα που παρουσιάζει:

- Η ύπαρξη του ηχητικού σήματος, όπως ήταν αναμενόμενο, βοηθά σε πολύ σημαντικό βαθμό την πρόβλεψη των φωνημάτων και τελικά της ομιλίας, ακόμα και όταν το σήμα αυτό είναι θορυβώδες. Το ηχητικό σήμα προσφέρει τη λύση στο πρόβλημα των visemes, διότι τα visemes ακούγονται διαφορετικά, ακόμα και αν παράγονται τοποθετώντας τα χείλη με παρόμοιο τρόπο.
- Η χρήση των Mel-Spectrograms και όχι του ίδιου του ηχητικού σήματος ως είσοδο στο audio stream του μοντέλου εξυπηρετεί τη διατήρηση της γενικής ιδέας του visual μοντέλου, συγκεκριμένα τη χρήση συνελκτικού νευρωνικού δικτύου για την εξαγωγή των features. Επιπροσθέτως, συμβάλλει στη μείωση του όγκου των δεδομένων που τελικά εισέρχονται στο μοντέλο.
- Σε περιπτώσεις ύπαρξης θορύβου στο ηχητικό σήμα αλλά και στο βίντεο, είναι σημαντικό για ένα μοντέλο που αξιοποιεί τα δύο αυτά σήματα να μάθει τότε πρέπει να σέβεται την πρόβλεψη που εξάγεται από το ένα modality έναντι του άλλου. Επίσης, πρέπει να μάθει να συνδυάζει τις πληροφορίες των δύο modalities ώστε να εξαγάγει ένα κοινό συμπέρασμα για τα φωνητικά χαρακτηριστικά της εκάστοτε χρονικής στιγμής.
- Το πείραμα 3 της ενότητας 6.3.3 αποδεικνύει την ικανότητα του μοντέλου να εμπιστεύεται ένα modality όλο και λιγότερο, όσο αυτό γίνεται λιγότερο αξιόπιστο (και το βίντεο, αλλά και τον ήχο). Αποδεικνύεται, επίσης, η ανώτερη ποιότητα της πρόβλεψης όταν συνυπάρχουν τα δύο modalities έναντι της αξιοποίησης μονάχα ενός εκ των δύο. Η ποιότητα της πρόβλεψης, όπως είναι αναμενόμενο, μειώνεται όσο μειώνεται η αξιοπιστία οποιουδήποτε από τα δύο modalities.
- Το audiovisual μοντέλο φαίνεται να εμφανίζει μία ελαφριά προτίμηση για τα features που προέρχονται από το ηχητικό σήμα, κρίνοντας από τις τιμές της audio gate και τις αντίστοιχες της video gate. Ακόμα και όταν ο θόρυβος είναι συνεχής για το ηχητικό σήμα αλλά πολύ σύντομος για το βίντεο, το μοντέλο εμπιστεύεται ελάχιστα περισσότερο τον ήχο. Αυτό οφείλεται πιθανότατα στο γεγονός ότι η επίλυση του προβλήματος πρόβλεψης φωνημάτων είναι πολύ πιο εύκολη αξιοποιώντας την ομιλία σε σχέση με το βίντεο της ομιλίας.

7.2 ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ

Παρακάτω γίνεται αναφορά σε πιθανές μελλοντικές επεκτάσεις της συγκεκριμένης εργασίας.

- Όπως αναφέρθηκε και στο πείραμα 2 που παρουσιάστηκε στην ενότητα 6.3.2, η βασική μελλοντική επέκταση της εργασίας αυτής είναι η δοκιμή της προτεινόμενης μεθοδολογίας σε περιβάλλον το οποίο είναι μη περιορισμένο (in the wild). Το πείραμα αυτό κρίνεται ιδιαίτερα σημαντικό, τόσο επειδή ανταποκρίνεται σε πραγματικές συνθήκες στις οποίες μπορεί να εφαρμοστεί η αναγνώριση της ανθρώπινης ομιλίας (προφανώς η αναγνώριση σε in the wild περιβάλλον είναι πολύ πιο δύσκολο πρόβλημα και ταυτόχρονα πολύ πιο χρήσιμη εφαρμογή από την αναγνώριση σε περιορισμένο περιβάλλον με μικρό λεξιλόγιο), αλλά και επειδή πρόκειται για το benchmark test των μοντέλων του state-of-the-art. Είναι σημαντικό να μελετηθεί κατά πόσο μειώνεται η επίδοση των προβλέψεων φωνημάτων του μοντέλου στο in the wild dataset σε σχέση με το περιορισμένο dataset και ποιες τεχνικές μπορούν να εφαρμοστούν για τη μείωση του φαινομένου αυτού (π.χ. διαφορετικές μορφές data augmentation που εστιάζουν σε σπάνιες αλληλουχίες φωνημάτων στις οποίες δυσκολεύεται το μοντέλο). Κρίνεται, επίσης, ενδιαφέρουσα η μελέτη για το αν ο Transformer όντως ανταπεξέρχεται καλύτερα ως Sequence Encoder στο μεγαλύτερο και πιο ποικιλόμορφο dataset της in the wild περίπτωσης σε σχέση με το BiLSTM.
- Για την επίτευξη των στόχων του πειράματος αυτού, απαιτείται και η ανάπτυξη μεθόδου πρόβλεψης λέξεων και, τελικά, φράσεων με δεδομένο την ύπαρξη σε μη περιορισμένο περιβάλλον. Όπως παρουσιάζεται στην ενότητα 5.4.2, μπορεί να δοκιμαστεί LLM με κατάλληλο fine-tuning ώστε να προβλέπει μία πιθανή φράση από την αλληλουχία των προβλεπόμενων φωνημάτων. Προφανώς, λόγω του τεράστιου αριθμού των ποσοτήτων, η αλγοριθμική πρόβλεψη δεν μπορεί να εφαρμοστεί στην περίπτωση του in the wild περιβάλλοντος.
- Όσον αφορά την εφαρμογή της πρόβλεψης της ομιλίας, μία σημαντική μελλοντική επέκταση είναι η αναγνώριση λέξεων σε πραγματικό χρόνο. Με την υπάρχουσα εκδοχή, το μοντέλο απαιτεί τη ροή των ήδη καταγεγραμμένων δεδομένων (είτε αποκλειστικά βίντεο είτε βίντεο και ήχου). Σε εφαρμογές Augmented Reality, κατά τις οποίες η πρόβλεψη των λέξεων εφαρμόζεται σε πραγματικό χρόνο ώστε να βοηθήσει είτε άτομα με ειδικές ανάγκες (π.χ. προβλήματα ακοής) είτε σε περιπτώσεις ύπαρξης θορύβου ο οποίος καθιστά την ομιλία μη κατανοητή (π.χ. θορυβώδες αμφιθέατρο), τα δεδομένα εισέρχονται στο μοντέλο την ίδια στιγμή που παράγονται. Έτσι, κρίνεται ενδιαφέρουσα μελλοντική επέκταση η κατάλληλη τροποποίηση του μοντέλου ώστε να δέχεται σε πραγματικό χρόνο τα δεδομένα και να αποφασίζει για τις λέξεις που εκφέρονται.
- Μία ακόμη πιθανή γενίκευση είναι η υποστήριξη διαφόρων γλωσσών και όχι μόνο της αγγλικής. Προφανώς το πρόβλημα αυτό είναι πολύ πιο δύσκολο, καθώς προϋποθέτει το μοντέλο να μπορεί να αντιληφθεί τη γλώσσα που ομιλείται ανά πάσα στιγμή, είτε αποκλειστικά από το βίντεο είτε αξιοποιώντας θορυβώδη ήχο και βίντεο. Ακόμη, θα ήταν αναγκαία η απόκτηση ενός πολύ γενικευμένου dataset που περιλαμβάνει βίντεο από ομιλίες διαφόρων γλωσσών του κόσμου, αυξάνοντας το υπολογιστικό κόστος σημαντικά.

8 Αναφορές

- [1] T. Afouras, J. S. Chung, A. Senior, O. Vinyals, and A. Zisserman. Deep audio-visual speech recognition. In *arXiv:1809.02108*, 2018.
- [2] Triantafyllos Afouras, Joon Son Chung, Andrew Senior, Oriol Vinyals, and Andrew Zisserman. Deep audio-visual speech recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12):8717–8727, December 2022.
- [3] Triantafyllos Afouras, Joon Son Chung, and Andrew Zisserman. Asr is all you need: cross-modal distillation for lip reading, 2020.
- [4] Yannis M. Assael, Brendan Shillingford, Shimon Whiteson, and Nando de Freitas. Lipnet: End-to-end sentence-level lipreading, 2016.
- [5] Umberto Cappellazzo, Minsu Kim, Honglie Chen, Pingchuan Ma, Stavros Petridis, Daniele Falavigna, Alessio Brutti, and Maja Pantic. Large language models are strong audio-visual speech recognition learners, 2025.
- [6] Oscar Chang, Hank Liao, Dmitriy Serdyuk, Ankit Shah, and Olivier Siohan. Conformers are all you need for visual speech recognition, 2023.
- [7] J. S. Chung, A. Senior, O. Vinyals, and A. Zisserman. Lip reading sentences in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [8] J. S. Chung and A. Zisserman. Lip reading in the wild. In *Asian Conference on Computer Vision*, 2016.
- [9] J. S. Chung and A. Zisserman. Lip reading in profile. In *British Machine Vision Conference*, 2017.
- [10] Martin Cooke, Jon Barker, Stuart Cunningham, and Xu Shao. The Grid Audio-Visual Speech Corpus, January 2006.
- [11] Yasser Abdelaziz Dahou Djilali, Sanath Narayan, Haithem Boussaid, Ebtessam Almazrouei, and Merouane Debbah. Lip2vec: Efficient and robust visual speech recognition via latent-to-latent visual to audio representation mapping, 2023.
- [12] Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks. volume 2006, pages 369–376, 01 2006.
- [13] Alex Graves and Jürgen Schmidhuber. Framework phoneme classification with bidirectional lstm and other neural network architectures. *Neural Networks*, 18(5):602–610, 2005. IJCNN 2005.
- [14] Alexandros Haliassos, Pingchuan Ma, Rodrigo Mira, Stavros Petridis, and Maja Pantic. Jointly learning visual and auditory speech representations from raw data, 2023.
- [15] Alexandros Haliassos, Rodrigo Mira, Honglie Chen, Zoe Landgraf, Stavros Petridis, and Maja Pantic. Unified speech recognition: A single model for auditory, visual, and audiovisual inputs, 2024.
- [16] Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhota, Ruslan Salakhutdinov, and Abdelrahman Mohamed. Hubert: Self-supervised speech representation learning by masked prediction of hidden units, 2021.
- [17] Hendrik Laux, Emil Mededovic, Ahmed Hallawa, Lukas Martin, Arne Peine, and Anke Schmeink. Litevsr: Efficient visual speech recognition by learning from speech representations of unlabeled data, 2023.

- [18] Xubo Liu, Egor Lakomkin, Konstantinos Vougioukas, Pingchuan Ma, Honglie Chen, Ruiming Xie, Morrie Doulaty, Niko Moritz, Jáchym Kolář, Stavros Petridis, Maja Pantic, and Christian Fuegen. Synthvsr: Scaling up visual speech recognition with synthetic supervision, 2023.
- [19] Pingchuan Ma, Alexandros Haliassos, Adriana Fernandez-Lopez, Honglie Chen, Stavros Petridis, and Maja Pantic. Auto-avsr: Audio-visual speech recognition with automatic labels. In *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, page 1–5. IEEE, 2023.
- [20] Pingchuan Ma, Rodrigo Mira, Stavros Petridis, Björn W. Schuller, and Maja Pantic. Lira: Learning visual speech representations from audio through self-supervision, 2021.
- [21] Takaki Makino, Hank Liao, Yannis Assael, Brendan Shillingford, Basilio Garcia, Otavio Braga, and Olivier Siohan. Recurrent neural network transducer for audio-visual speech recognition, 2019.
- [22] Stavros Petridis, Themis Stafylakis, Pingchuan Ma, Feipeng Cai, Georgios Tzimiropoulos, and Maja Pantic. End-to-end audiovisual speech recognition, 2018.
- [23] K R Prajwal, Triantafyllos Afouras, and Andrew Zisserman. Sub-word level lip reading with visual attention, 2021.
- [24] K R Prajwal, Triantafyllos Afouras, and Andrew Zisserman. Speech Recognition Models are Strong Lip-readers. In *Interspeech 2024*, pages 2425–2429, 2024.
- [25] Dmitriy Serdyuk, Otavio Braga, and Olivier Siohan. Transformer-based video front-ends for audio-visual speech recognition for single and multi-person video, 2022.
- [26] Bowen Shi, Wei-Ning Hsu, Kushal Lakhotia, and Abdelrahman Mohamed. Learning audio-visual speech representation by masked multimodal cluster prediction, 2022.
- [27] Brendan Shillingford, Yannis Assael, Matthew W. Hoffman, Thomas Paine, Cían Hughes, Utsav Prabhu, Hank Liao, Hasim Sak, Kanishka Rao, Lorraine Bennett, Marie Mulville, Ben Coppin, Ben Laurie, Andrew Senior, and Nando de Freitas. Large-scale visual speech recognition, 2018.
- [28] Marshall Thomas, Edward Fish, and Richard Bowden. VALLR: Visual ASR Language Model for Lip Reading, 2026.
- [29] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023.
- [30] Michiel Visser, Mannes Poel, and Anton Nijholt. *Classifying Visemes for Automatic Lipreading*, volume 1692, pages 349–352. 10 1999.
- [31] Bo Xu, Cheng Lu, Yandong Guo, and Jacob Wang. Discriminative multi-modality speech recognition, 2020.
- [32] Ben P. Yuhass and Jr. Goldstein, Moise H. Comparing human and neural network lip readers. *The Journal of the Acoustical Society of America*, 90(1):598–600, 07 1991.
- [33] Ben P. Yuhass, Moise H. Goldstein, and Terrence J. Sejnowski. Integration of acoustic and visual speech signals using neural networks. *IEEE Communications Magazine*, 27:65–71, 1989.
- [34] Xingxuan Zhang, Feng Cheng, and Wang Shilin. Spatio-temporal fusion based convolutional sequence learning for lip reading. In *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 713–722, 2019.
- [35] Yuanhang Zhang, Shuang Yang, Shiguang Shan, and Xilin Chen. Es3: Evolving self-supervised learning of robust audio-visual speech representations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 27069–27079, June 2024.