



ARISTOTLE  
UNIVERSITY  
OF THESSALONIKI

Department of Electrical  
and Computer Engineering

Τμήμα Ηλεκτρολόγων Μηχανικών  
και Μηχανικών Υπολογιστών

**Thesis - Διπλωματική Εργασία**

**“Talking Heads”: Phoneme Prediction from Muted Video**

**“Talking Heads”: Πρόβλεψη Φωνημάτων από Βουβό Βίντεο**

|                            |                        |
|----------------------------|------------------------|
| <b>Όνομα</b>               | Βαπόρης Δημήτριος      |
| <b>A.E.M.</b>              | 10625                  |
| <b>Email</b>               | dvaporis@ece.auth.gr   |
| <b>Επιβλέπων Καθηγητής</b> | Ντελόπουλος Αναστάσιος |

**Καλοκαίρι 2026**

## Περιεχόμενα

|                                                                                                            |           |
|------------------------------------------------------------------------------------------------------------|-----------|
| <b>Περιεχόμενα</b>                                                                                         | <b>1</b>  |
| <b>1 Περιλήψεις</b>                                                                                        | <b>2</b>  |
| 1.1 Summary in English . . . . .                                                                           | 2         |
| 1.2 Περίληψη στα Ελληνικά . . . . .                                                                        | 2         |
| <b>2 Εισαγωγή</b>                                                                                          | <b>3</b>  |
| 2.1 Ορισμός του Προβλήματος . . . . .                                                                      | 3         |
| 2.2 Διαθέσιμες Μέθοδοι . . . . .                                                                           | 3         |
| 2.3 Περιγραφή της Συγκεκριμένης Εργασίας . . . . .                                                         | 3         |
| 2.4 Δομή της Συγκεκριμένης Αναφοράς . . . . .                                                              | 3         |
| <b>3 Τεχνικό Υπόβαθρο</b>                                                                                  | <b>4</b>  |
| 3.1 Φωνήματα και Visemes . . . . .                                                                         | 4         |
| <b>4 State of the Art</b>                                                                                  | <b>7</b>  |
| <b>5 Μεθοδολογία</b>                                                                                       | <b>8</b>  |
| 5.1 Προεπεξεργασία Δεδομένων . . . . .                                                                     | 8         |
| 5.1.1 Εξαγωγή της περιοχής των χειλιών . . . . .                                                           | 8         |
| 5.1.2 Εξαγωγή φωνημάτων για κάθε frame . . . . .                                                           | 10        |
| 5.1.3 Data Augmentation . . . . .                                                                          | 11        |
| 5.2 Δομή του προτεινόμενου μοντέλου . . . . .                                                              | 12        |
| 5.3 Βήματα Post-Processing . . . . .                                                                       | 12        |
| 5.3.1 Αλγοριθμική Πρόβλεψη Λέξεων . . . . .                                                                | 12        |
| <b>6 Αξιολόγηση της Μεθοδολογίας</b>                                                                       | <b>14</b> |
| 6.1 Datasets . . . . .                                                                                     | 14        |
| 6.2 Κριτήρια Αξιολόγησης . . . . .                                                                         | 14        |
| 6.3 Πειράματα . . . . .                                                                                    | 15        |
| 6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον                            | 15        |
| 6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον . . . . . | 22        |
| 6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων                          | 22        |
| <b>7 Συμπεράσματα και Μελλοντικές Επεκτάσεις</b>                                                           | <b>23</b> |
| <b>8 Αναφορές</b>                                                                                          | <b>24</b> |

# **1 Περιλήψεις**

## **1.1 Summary in English**

Summary in English.

## **1.2 Περίληψη στα Ελληνικά**

Περίληψη στα Ελληνικά.

## **2 Εισαγωγή**

### **2.1 Ορισμός του Προβλήματος**

What is the problem this work aims to solve? Why is it important? What may be some applications?

### **2.2 Διαθέσιμες Μέθοδοι**

Briefly describe the methods that have been shown to (partially) solve this problem (or subproblems that may exist). Mention Section 3 (State of the Art) for more info.

### **2.3 Περιγραφή της Συγκεκριμένης Εργασίας**

What did I do for this thesis? How did I attempt to solve the problem? About one page.

### **2.4 Δομή της Συγκεκριμένης Αναφοράς**

Describe the structure of this report in about half a page.

### 3 Τεχνικό Υπόβαθρο

Στο κεφάλαιο αυτό, θα χτιστεί το τεχνικό υπόβαθρο που χρειάζεται για την κατανόηση της εργασίας. Συμπεριλαμβάνονται λεπτομέρειες τόσο για έννοιες μηχανικής μάθησης όσο και για βασικές ιδέες της γλωσσολογίας.

#### 3.1 Φωνήματα και Visemes

Τα φωνήματα αποτελούν το βασικό αντικείμενο μελέτης της συγκεκριμένης εργασίας. Ένα φώνημα ορίζεται ως ένα σύνολο παρόμοιων ήχων ομιλίας το οποίο γίνεται αντιληπτό από ομιλητές μίας γλώσσας ως ένας βασικός ήχος, πρόκειται δηλαδή για τη μικρότερη πιθανή μονάδα φωνής. Συμβολίζονται συνήθως ως ένας χαρακτήρας εντός δύο forward slash. Για παράδειγμα, το φώνημα /b/ εκπροσωπεί τον ήχο στην αρχή της αγγλικής λέξης bat. Κάθε ομιλούμενη γλώσσα αξιοποιεί τα φωνήματα σε διαφορετικό βαθμό, ενώ ίδια γράμματα ή φθόγγοι μπορεί σε διαφορετικές γλώσσες να προφέρονται τελείως διαφορετικά. Τα προβλήματα αυτά προσπαθεί να λύσει το International Phonetic Alphabet (IPA), το οποίο είναι ένα “αλφάβητο” από φωνήματα βασισμένο κυρίως στους λατινικούς χαρακτήρες και ομοιόμορφο για κάθε γλώσσα. Να σημειωθεί ότι το πλήρες IPA είναι υπερβολικά περίπλοκο για την ανάλυση που ακολουθεί, καθώς αρκετά φωνήματα συναντώνται πολύ σπάνια (ή καθόλου) στην αγγλική γλώσσα που μελετάται καθ’ όλη τη διάρκεια της εργασίας.

Όντας η ελάχιστη μονάδα ομιλίας, τα φωνήματα έχουν αποτελέσει το αντικείμενο ποικίλων γλωσσολογικών μελετών, πολλές από τις οποίες αφορούν το “διάβασμα χειλιών” (lip reading) ή, αλλιώς, την κατανόηση ομιλίας χρησιμοποιώντας αποκλειστικά οπτικά (και όχι ακουστικά) μέσα. Από τις μελέτες αυτές έχει δημιουργηθεί το πρόβλημα των “visemes”, τα οποία αποτελούν το σύνολο ήχων ομιλίας με πανομοιότυπη όψη στα χείλια (ή γενικότερα στο πρόσωπο). Να σημειωθεί ότι τα σύνολα αυτά δεν περιορίζονται σε μοναδικά φωνήματα: για παράδειγμα, οι φράσεις “elephant juice” και “i love you” αποτελούν ένα χιουμοριστικό αλλά έγκυρο παράδειγμα viseme. Στα πλαίσια της συγκεκριμένης μελέτης, στο εξής ως visemes θα αναφέρονται τα φωνήματα κατά την έκφραση των οποίων η όψη του ομιλητή είναι όμοια. Για παράδειγμα, τα φωνήματα /m/, /b/ και /p/ αποτελούν ένα παράδειγμα viseme. Τα visemes προσφέρουν πληροφορία για την τοποθεσία του στόματος στην οποία παράγεται ο ήχος, αλλά όχι για τον τρόπο με τον οποίο παράγεται ο ήχος, το οποίο απαιτεί ακουστικά στοιχεία.

Πέραν της ομαδοποίησης τους μέσω των visemes, τα φωνήματα μπορούν να ομαδοποιηθούν και με βάση 3 ακόμα χαρακτηριστικά: τον τόπο, τον τρόπο εκφοράς τους και το αν είναι έμφωνα ή όχι. Για να παρουσιαστούν με μεγαλύτερη ακρίβεια τα παραπάνω, συμπεριλαμβάνεται το επίσημο chart φωνημάτων του IPA. Αγνοώντας τις υπερβολικές λεπτομέρειες στο Σχήμα ?? και εστιάζοντας την προσοχή στον πρώτο πίνακα με τίτλο CONSONANTS (PULMONIC) και στον αμέσως κάτω δεξιά χάρτη με τίτλο VOWELS, μπορούν να εξαχθούν τα παρακάτω συμπεράσματα.

Παρατηρούμε ότι τα σύμφωνα χωρίζονται σε 11 κατηγορίες όσον αφορά τον τόπο εκφοράς τους: τα δειχικά (bilabial, παράγονται χρησιμοποιώντας τα 2 χείλη), τα χειλοδοντικά (labiodental, παράγονται με τη συμμετοχή χειλιών και δοντιών), τα οδοντικά (dental, με τα δόντια), τα φατνιακά (alveolar, παράγονται με τη γλώσσα να ακουμπά ή να πλησιάζει τη φατνιακή ακρολοφία), τα μεταφατνιακά (postalveolar, παράγονται με τη γλώσσα να τοποθετείται πίσω από τη φατνιακή ακρολοφία), τα ανακεκαμμένα (retroflex, παράγονται από την άκρη της γλώσσας όταν κάμπτεται προς τα πίσω προς τον ουρανίσκο), τα ουρανικά (palatals, παράγονται υψώνοντας το κυρίως τμήμα της γλώσσας στον σκληρό ουρανίσκο), τα υπερωικά (velar, όταν το πίσω μέρος της γλώσσας αγγίζει ή πλησιάζει τον μαλακό ουρανίσκο), τα σταφυλικά (uvular, με το πίσω μέρος της γλώσσας να αγγίζει ή να πλησιάζει τη σταφυλή), τα φαρυγγικά (pharyngeal, παράγονται περιορίζοντας τον φάρυγγα) και τέλος τα γλωττιδικά (glottal, χρησιμοποιώντας τη γλωττίδα). Το χαρακτηριστικό αυτό είναι που επηρεάζει κατά κύριο λόγο τα visemes, καθώς ο τρόπος με τον οποίον παράγεται ένα φώνημα και το αν είναι έμφωνο ή όχι πολλές φορές γίνεται κρυφό λόγω της μορφολογίας των χειλιών, που επηρεάζεται προφανώς από τον τόπο εκφοράς του φωνήματος.

Πέραν του τόπου εκφοράς, τα σύμφωνα διαχωρίζονται στον πίνακα με βάση τον τρόπο εκφοράς τους ως εξής: τα έκκροτα/κλειστά σύμφωνα (plosive, παράγονται όταν διακόπτεται τελείως η ροή του αέρα

και απελευθερώνεται ξαφνικά), τα ρινικά (nasal, επιτρέπουν στον αέρα να διαφύγει μέσω της ρινικής κοιλότητας και όχι του στόματος), τα μέσω τρίλιας (trill, παράγονται μέσω γρήγορης δόνησης λόγω της ροής αέρα), τα παλμού/κτύπου (tap/flip, όταν η γλώσσα ακουμπάει στιγμιαία ένα σημείο του στόματος), τα τριβόμενα (fricative, όταν ο αέρας περνάει από στενή δίοδο δημιουργώντας τριβή), τα πλευρικά τριβόμενα (lateral fricative, όπου ο αέρας παράγει τριβή καθώς περνάει από τα πλάγια της γλώσσας), τα προσεγγιστικά (approximant, όπου δύο αρθρωτές πλησιάζουν χωρίς να παράγουν τυρβώδη ροή αέρα ή ολικό κλείσιμο), και τα πλευρικά προσεγγιστικά (lateral approximant, μπλοκάροντας το κέντρο της στοματικής κοιλότητας στην περιοχή του αρθρωτή και επιτρέποντας τη ροή του αέρα από τα πλάγια). Πειραματιζόμενοι με τα παραπάνω μπορούμε να συνειδητοποιήσουμε πώς παράγονται τα φωνήματα που χρησιμοποιούμε, όπως και να αρθρώσουμε φωνήματα που ίσως δεν έχουμε συνηθίσει (π.χ. στα ελληνικά δεν υπάρχει πλευρικό τριβόμενο φώνημα, αλλά σε γλώσσες όπως τα ουαλικά υπάρχει).

Τέλος, ο χαρακτηρισμός έμφωνο ή άφωνο φαίνεται από τη θέση των συμφώνων στο εκάστοτε κελί. Αυτά που είναι τοποθετημένα προς τα δεξιά είναι έμφωνα, ενώ αυτά προς τα αριστερά είναι άφωνα. Τα φωνήεντα, από την άλλη είναι όλα έμφωνα και διαχωρίζονται με βάση το ύψος της γλώσσας (στον κατακόρυφο άξονα), την προώθησή της (στον οριζόντιο άξονα) και το αν τα χείλη είναι στρογγυλεμένα (rounded) ή όχι. Όσον αφορά το ύψος, οι κατηγορίες είναι close, close-mid, open-mid και open, ενώ στον οριζόντιο άξονα οι πιθανές επιλογές είναι front, central και back. Όπου στον χάρτη εμφανίζονται δύο φωνήματα, το δεξιότερο παράγεται με στρογγυλεμένα χείλη.

Με γνώση των παραπάνων και αντίστοιχη προσαρμογή στις ανάγκες της εκάστοτε γλώσσας ή, στην περίπτωση περιορισμένου περιβάλλοντος, στις ιδιαιτερότητες του λεξιλογίου, τα φωνήματα μπορούν να ομαδοποιηθούν με τους παραπάνω κανόνες. Έτσι, σε πλαίσια lip reading, είναι δυνατόν να χτιστούν μέθοδοι εφαρμογής διαφορετικής ποιικής με βάση την ομοιότητα των φωνημάτων (είτε σε επίπεδο visemes είτε σε επίπεδο χαρακτηριστικών, όπως παρουσιάστηκε) ή και μέθοδοι πρόβλεψης λέξεων που να συνυπολογίζουν την ομοιότητα φωνημάτων κατά την αντικατάστασή τους (για περισσότερα βλ. παράγραφο 5.1.2).

# THE INTERNATIONAL PHONETIC ALPHABET (revised to 2020)

## CONSONANTS (PULMONIC)

© 2020 IPA

|                     | Bilabial | Labiodental | Dental | Alveolar | Postalveolar | Retroflex | Palatal | Velar | Uvular | Pharyngeal | Glottal |
|---------------------|----------|-------------|--------|----------|--------------|-----------|---------|-------|--------|------------|---------|
| Plosive             | p b      |             |        | t d      |              | ʈ ɖ       | c ɟ     | k ɡ   | q ɢ    |            | ʔ       |
| Nasal               | m        | ɱ           |        | n        |              | ɳ         | ɲ       | ŋ     | ɴ      |            |         |
| Trill               | ʙ        |             |        | r        |              |           |         |       | ʀ      |            |         |
| Tap or Flap         |          | ⱱ           |        | ɾ        |              | ɽ         |         |       |        |            |         |
| Fricative           | ɸ β      | f v         | θ ð    | s z      | ʃ ʒ          | ʂ ʐ       | ç ʝ     | x ɣ   | χ ʁ    | ħ ʕ        | h ɦ     |
| Lateral fricative   |          |             |        | ɬ ɮ      |              |           |         |       |        |            |         |
| Approximant         |          | ʋ           |        | ɹ        |              | ɻ         | j       | ɰ     |        |            |         |
| Lateral approximant |          |             |        | l        |              | ɭ         | ʎ       | ʟ     |        |            |         |

Symbols to the right in a cell are voiced, to the left are voiceless. Shaded areas denote articulations judged impossible.

## CONSONANTS (NON-PULMONIC)

| Clicks             | Voiced implosives | Ejectives             |
|--------------------|-------------------|-----------------------|
| ʘ Bilabial         | ɓ Bilabial        | ʼ Examples:           |
| ǀ Dental           | ɗ Dental/alveolar | pʼ Bilabial           |
| ǃ (Post)alveolar   | ɟ Palatal         | tʼ Dental/alveolar    |
| ǂ Palatoalveolar   | ɡ Velar           | kʼ Velar              |
| ǁ Alveolar lateral | ɠ Uvular          | sʼ Alveolar fricative |

## OTHER SYMBOLS

|                                     |                                                                                                         |
|-------------------------------------|---------------------------------------------------------------------------------------------------------|
| ɱ Voiceless labial-velar fricative  | ɕ ʑ Alveolo-palatal fricatives                                                                          |
| ʋ Voiced labial-velar approximant   | ɭ Voiced alveolar lateral flap                                                                          |
| ɥ Voiced labial-palatal approximant | ɥ Simultaneous ʃ and x                                                                                  |
| ħ Voiceless epiglottal fricative    |                                                                                                         |
| ʕ Voiced epiglottal fricative       | Affricates and double articulations can be represented by two symbols joined by a tie bar if necessary. |
| ʡ Epiglottal plosive                |                                                                                                         |


## DIACRITICS

|                                |                                            |                                   |
|--------------------------------|--------------------------------------------|-----------------------------------|
| ◌ <sup>◌</sup> Voiceless       | ◌ <sup>◌</sup> Breathy voiced              | ◌ <sup>◌</sup> Dental             |
| ◌ <sub>◌</sub> Voiced          | ◌ <sub>◌</sub> Creaky voiced               | ◌ <sub>◌</sub> Apical             |
| ◌ <sup>h</sup> Aspirated       | ◌ <sup>̤</sup> Linguolabial                | ◌ <sup>̪</sup> Laminal            |
| ◌ <sup>̙</sup> More rounded    | ◌ <sup>̜</sup> Labialized                  | ◌ <sup>̚</sup> Nasalized          |
| ◌ <sup>̚</sup> Less rounded    | ◌ <sup>̝</sup> Palatalized                 | ◌ <sup>̞</sup> Nasal release      |
| ◌ <sup>̟</sup> Advanced        | ◌ <sup>̠</sup> Velarized                   | ◌ <sup>̡</sup> Lateral release    |
| ◌ <sup>̠</sup> Retracted       | ◌ <sup>̢</sup> Pharyngealized              | ◌ <sup>̣</sup> No audible release |
| ◌ <sup>̣</sup> Centralized     | ◌ <sup>̤</sup> Velarized or pharyngealized |                                   |
| ◌ <sup>̥</sup> Mid-centralized | ◌ <sup>̦</sup> Raised                      |                                   |
| ◌ <sup>̧</sup> Syllabic        | ◌ <sup>̨</sup> Lowered                     |                                   |
| ◌ <sup>̩</sup> Non-syllabic    | ◌ <sup>̪</sup> Advanced Tongue Root        |                                   |
| ◌ <sup>̫</sup> Rhoticity       | ◌ <sup>̬</sup> Retracted Tongue Root       |                                   |

Some diacritics may be placed above a symbol with a descender, e.g. ɲ̩

Typefaces: Doulos SIL (metatext); unipa (symbols)

## VOWELS



Where symbols appear in pairs, the one to the right represents a rounded vowel.

## SUPRASEGMENTALS

|                                 |             |
|---------------------------------|-------------|
| ˈ Primary stress                | ˈfounəˈtʃən |
| ˌ Secondary stress              |             |
| ː Long                          | eː          |
| ˑ Half-long                     | eˑ          |
| ◌̥ Extra-short                  | ɛ̥          |
| ◌̥ Minor (foot) group           |             |
| ◌̥ Major (intonation) group     |             |
| ◌̥ Syllable break               | ˌi.ækt      |
| ◌̥ Linking (absence of a break) |             |

## TONES AND WORD ACCENTS

| LEVEL             | CONTOUR          |
|-------------------|------------------|
| é or ˥ Extra high | ě or ˩ Rising    |
| é High            | ê or ˨ Falling   |
| ē Mid             | ē High rising    |
| è Low             | ē Low rising     |
| è Extra low       | ē Rising-falling |
| ↓ Downstep        | ↗ Global rise    |
| ↑ Upstep          | ↘ Global fall    |

Σχήμα 1: Επίσημο chart φωνημάτων του IPA, έκδοση 2020

## **4 State of the Art**

A more detailed description of the state of the art I alluded to in the Introduction chapter.

## 5 Μεθοδολογία

Στο κεφάλαιο αυτό παρουσιάζεται αναλυτικά η μεθοδολογία που χρησιμοποιήθηκε κατά τη διεξαγωγή των πειραμάτων. Συμπεριλαμβάνονται επακριβείς πληροφορίες για την προεπεξεργασία των δεδομένων, τη δομή του μοντέλου και για το post-processing που εφαρμόζεται.


### 5.1 Προεπεξεργασία Δεδομένων

Η προεπεξεργασία των δεδομένων αποτελεί βασικό τμήμα κάθε μελέτης στη Βαθιά Μάθηση. Αποτελεί τη διαδικασία κατά την οποία τα δεδομένα, τα οποία αρχικά βρίσκονται σε μορφή που δεν μπορούν να υποστηρίξουν μάθηση (στην περίπτωση μας, τα αρχικά βίντεο των ομιλητών με τον ήχο και πριν την απόδοση φωνημάτων σε κάθε frame), αποκτούν τη μορφή που τους επιτρέπει να εισαχθούν στο μοντέλο. Αξιοποιώντας τις γνώσεις πάνω στο αντικείμενο, είναι δυνατόν να μειωθεί ο χρόνος εκπαίδευσης μέσω της μείωσης των διαστάσεων των πληροφοριών που εισάγονται στο νευρωνικό δίκτυο και, γενικότερα, να βελτιωθούν τα τελικά αποτελέσματα. Παρακάτω αναλύονται οι εκάστοτε τεχνικές pre-processing που εφαρμόζονται ώστε να λάβουν τα δεδομένα την επιθυμητή μορφή.


#### 5.1.1 Εξαγωγή της περιοχής των χειλιών

Έστω ένα RGB βίντεο ομιλητή  $H \times W \times 3 \times T$  με  $H$  ύψος και  $W$  πλάτος σε pixel και  $T$  η χρονική διάσταση (ο αριθμός των frames). Για να περιοριστεί το μέγεθος των δεδομένων και να παραλειφθούν περιττές πληροφορίες του παρασκήνιου αλλά και του προσώπου του ομιλητή, αναπτύχθηκε ένα pre-processing script εντοπισμού της περιοχής των χειλιών. Η περιοχή αυτή είναι που αφορά το αντικείμενο, καθώς εκεί βρίσκεται η πληροφορία των visemes (άλλωστε, για αυτό αποκαλείται lip reading). Χρησιμοποιώντας το διαθέσιμο προεκπαιδευμένο MediaPipe Face Landmarker της Google, εντοπίζονται τα διάφορα “τοπόσημα προσώπου” (facial landmarks) του ομιλητή για κάθε frame του αρχικού βίντεο. Οι δείκτες των τοποσήμων των χειλιών εξαγονται για κάθε frame ξεχωριστά και παράγουν μία νέα εικόνα της περιοχής αυτής (συμπεριλαμβανομένου ενός επιπρόσθετου padding γύρω από τα χείλη για ασφάλεια) με διαστάσεις  $H' \times W' \times 3$  και  $H' < H, W' < W$ .


Από τα εκάστοτε frames παράγεται το νέο βίντεο της περιοχής των χειλιών, το οποίο μετασχηματίζεται by default στην τελική διάσταση  $224 \times 224 \times 3 \times T$ . Κατά τη διάρκεια των πειραμάτων, βρέθηκε ότι ακόμα λιγότερα pixels είναι ικανά να αποδόσουν το περιεχόμενο των visemes, με αποτέλεσμα πριν την εκπαίδευση να εφαρμόζεται ένας ακόμα μετασχηματισμός στα 96 pixels. Κατά τον εντοπισμό των τοποσήμων χρησιμοποιείται και ένας μηχανισμός fallback, σε περίπτωση που το Face Landmarker αδυνατεί να βρει τους ζητούμενους δείκτες. Συγκεκριμένα, εάν δεν εντοπιστούν για ένα δεδομένο frame τα τοπόσημα, τότε επαναχρησιμοποιούνται αυτά του προηγούμενου frame, ενώ αν δεν υπάρχουν ούτε αυτά εκτιμάται η τοποθεσία των χειλιών ως η κάτω περιοχή του προσώπου (50% του πλάτους και 35% του ύψους, με κατακόρυφο offset 42%). Τα δεδομένα κωδικοποιούνται σε μορφή βίντεο .mp4 διατηρώντας το framerate του αρχικού βίντεο, ενώ παράγονται και μερικά παραδείγματα frames από το βίντεο bbaf2n.mp4 του dataset GRID (βλ. παράγραφο 6.1), τα οποία παρουσιάζονται παρακάτω.




Σχήμα 2: Εξαγωγή χειλιών για το frame 0



Σχήμα 3: Εξαγωγή χειλιών για το frame 24



Σχήμα 4: Εξαγωγή χειλιών για το frame 49



Σχήμα 5: Εξαγωγή χειλιών για το frame 74

### 5.1.2 Εξαγωγή φωνημάτων για κάθε frame

Για να έχει νόημα η εφαρμογή του όρου cross entropy, είναι απαραίτητο να δημιουργηθούν labels για κάθε frame των βίντεο. Αυτό επιτυγχάνεται με συνδυασμό της γνώσης του περιορισμένου περιβάλλοντος και μεθόδων αναγνώρισης φωνημάτων από ηχητικά σήματα ομιλίας. Να σημειωθεί ότι η παρακάτω διαδικασία μπορεί κάλλιστα να εφαρμοστεί και σε μη πεπερασμένο περιβάλλον, αλλά οι περαιτέρω περιορισμοί που προκύπτουν από τέτοια περιβάλλοντα επιτρέπουν απλοποιήσεις και διορθώσεις σε περίπτωση λανθασμένης προφοράς από τον ομιλητή.

Θεωρώντας γνωστό το φραστικό περιεχόμενο κάθε βίντεο (π.χ. στο GRID dataset γίνεται γνωστή η φράση που εκφέρεται από τον ομιλητή μέσω του τίτλου του αρχείου), μπορεί να μετατραπεί η φράση σε αλληλουχία φωνημάτων μέσω του eSpeak-NG, δίχως ακόμα να υπάρχει ωστόσο γνώση για τον χρονισμό του κάθε φωνήματος. Χρησιμοποιείται ελαφριά κανονικοποίηση στα φωνήματα που εξάγονται ώστε το “αλφάβητο” των τελικών αλληλουχιών να ταυτίζεται με αυτό του μοντέλου wav2vec2, που χρησιμοποιείται για την εξαγωγή φωνημάτων από το ηχητικό περιεχόμενο. Το CTC μοντέλο του wav2vec2 εξάγει πιθανότητες κάθε φωνήματος για κάθε frame και, συγκρίνοντας με την αλληλουχία φωνημάτων που γνωρίζουμε ότι αναμένεται, παράγει μία τελική πρόβλεψη για την αρχή και το τέλος του κάθε φωνήματος. Μέσω αυτών των πληροφοριών, είναι δυνατόν να ολοκληρωθεί το labelling κάθε frame με το αντίστοιχο φώνημα ή το blank token, εφόσον το frame αντιστοιχεί σε χρονική στιγμή εκτός των φωνημάτων. Έτσι, πέραν της εξαγωγής των απαιτούμενων labels, αποφεύγονται τυχόντα προβλήματα από αστοχία κατά την προφορά της κάθε φράσης.

Η επεξεργασία των φωνημάτων δεν ολοκληρώνεται εκεί. Συγκεκριμένα, δημιουργείται ένα viseme grouping (ομαδοποίηση, δηλαδή, των όμοιων οπτικά φωνημάτων) με βάση τα χαρακτηριστικά των φωνημάτων. Για αναλυτικότερες πληροφορίες ως προς την ομαδοποίηση των φωνημάτων, ανατρέξτε στην ενότητα 3.1. Από τα hard targets που υπάρχουν ήδη για κάθε frame των βίντεο, δημιουργούνται soft targets με βάση τις παραπάνω ομάδες. Συγκεκριμένα, το 85% αποδίδεται στο πραγματικό φώνημα, ενώ το υπόλοιπο 15% μοιράζεται στα όμοια φωνήματα του πραγματικού με βάρη που ανταποκρίνονται στην ομοιότητα των φωνημάτων. Για ίδιο viseme, χρησιμοποιείται βάρος 0.95, ενώ για διαφορετικό υπολογίζεται similarity score ως εξής: κάθε φώνημα έχει τον τόπο, τον τρόπο άρθρωσης και το αν είναι έμφωνο ή όχι. Με βάση το πόσα κοινά features άρθρωσης έχουν δύο φωνήματα που δεν ανήκουν στο ίδιο viseme, αποδίδεται μεγαλύτερο βάρος σε αυτά με περισσότερες ομοιότητες και μικρότερο σε αυτά με τις λιγότερες. Έτσι, υπολογίζεται το articulatory\_similarity ως εξής:  $sim = 1 - \text{diffs}/3$ , όπου  $\text{diffs}$  είναι ο αριθμός διαφορετικών features. Το τελικό similarity matrix χτίζεται με τον ακόλουθο κανόνα:

$$mat[i, j] = \begin{cases} 1 & i = j \\ 0 & \text{είτε το } i \text{ είτε το } j \text{ είναι blank token και } i \neq j \\ 0.95 & \text{ίδια ομάδα viseme} \\ sim(a, b) \cdot 0.4 & \text{σε άλλη περίπτωση} \end{cases}$$

Τελικά τα soft targets χτίζονται με το 85% στο πραγματικό φώνημα και το υπόλοιπο 15% μοιρασμένο στα όμοια φωνήματα σε αναλογία με το similarity score των φωνημάτων, εκτός από την περίπτωση του


blank token, κατά την οποία διατηρούνται τα hard targets. Αυτό συμβαίνει ώστε να ενισχυθεί η ικανότητα του μοντέλου να προβλέπει ακριβώς πότε λέγεται ένα φώνημα και πότε όχι, με αποτέλεσμα οι χρονισμοί των προβλέψεων να είναι ορθοί.

### 5.1.3 Data Augmentation

Για να εμπλουτιστεί ιδιαίτερα κάποιο περιορισμένο σε μέγεθος dataset, κρίνεται αναγκαίο να εφαρμοστούν μέθοδοι data augmentation, δηλαδή επαύξεσης δεδομένων. Αυτές οι μέθοδοι, εκμεταλλευόμενες τη γνώση μας στο αντικείμενο, παράγουν νέα δεδομένα από τα υπάρχοντα και εμπλουτίζουν τη μάθηση του μοντέλου. Είναι σημαντικό να τονιστεί ότι οι τεχνικές data augmentation που εφαρμόζονται πρέπει να συμβαδίζουν με τους στόχους μάθησης του μοντέλου. Για παράδειγμα, μία πιθανή μέθοδος data augmentation στην περίπτωση που τα δεδομένα βρίσκονται σε μορφή βίντεο είναι η αναστροφή της αλληλουχίας των frames. Ωστόσο, όταν το μοντέλο πρόκειται να μάθει σε κάποιο παρακείμενο στο οποίο έχει σημασία η σωστή χρονική αλληλουχία (όπως για παράδειγμα στο lip reading, όπου οι κινήσεις των χειλιών για την παραγωγή ενός φωνήματος είναι ευαίσθητες στη σωστή χρονική σειρά), δε θα μπορούσε να εφαρμοστεί η παραπάνω μέθοδος.


Οι τεχνικές data augmentation που τελικά εφαρμόζονται, λόγω της ορθότητάς τους για τον τελικό στόχο και λόγω της ταχείας εφαρμογής τους σε πολλαπλά δεδομένα, είναι ο καθρεπτισμός γύρω από τον κατακόρυφο άξονα (horizontal flip), η χρωματική αλλαγή (color jitter) και η αφαίρεση/επικάλυψη (cutout/occlusion). Σε κάθε περίπτωση οι μετασχηματισμοί αυτοί εφαρμόζονται σε ολόκληρο το βίντεο και όχι σε μεμονωμένα frames, ώστε να αποφευχθούν ανεπιθύμητα φαινόμενα αστάθειας. Ο καθρεπτισμός εφαρμόζεται με πιθανότητα  $p = 0.5$ , ενώ η χρωματική αλλαγή πραγματοποιείται μέσω των παραγόντων της φωτεινότητας (brightness) με συντελεστή από 0.8 έως 1.2, της αντίθεσης (contrast) με παράγοντα 0.8-1.2 και του κορεσμού (saturation) με παράγοντα 0.9-1.1 και με πιθανότητα  $p = 0.4$ . Τέλος, με τη μέθοδο της επικάλυψης, με πιθανότητα  $p = 0.25$  επιλέγεται τυχαία μία ορθογώνια περιοχή (8-20% του ύψους και του πλάτους του frame) και αποκρύπτεται για όλα τα frame του δεδομένου βίντεο, προσομοιώνοντας την ύπαρξη ενός αντικειμένου που εμποδίζει τη θέαση συγκεκριμένης περιοχής. Αυτό έχει ως αποτέλεσμα η εκπαίδευση να γίνεται πιο εύρωστη. Να σημειωθεί ότι η διαδικασία του data augmentation εφαρμόζεται αποκλειστικά στο training split και όχι σε αυτά του validation και του test. Παρακάτω παρουσιάζονται μερικά παραδείγματα των παραπάνω μεθόδων επαύξεσης δεδομένων.

**Data Augmentation: Horizontal flip**




Σχήμα 6: Παρουσίαση του καθρεπτισμού (horizontal flip) για μερικά frames

**Data Augmentation: Brightness / contrast / saturation**



Σχήμα 7: Παρουσίαση της αλλαγής χρώματος (color jitter) για μερικά frames

**Data Augmentation: Random cutout**



Σχήμα 8: Παρουσίαση της αφαίρεσης/επικάλυψης (cutout/occlusion) για μερικά frames

## 5.2 Δομή του προτεινόμενου μοντέλου

## 5.3 Βήματα Post-Processing

Όπως παρουσιάστηκε το μοντέλο μέχρι τώρα, είναι ικανό μόνο να προβλέψει φωνήματα από το βουβό βίντεο. Στη συγκεκριμένη υποενότητα, περιγράφονται οι τεχνικές post-processing που εφαρμόστηκαν ώστε η αλληλουχία φωνημάτων να μετατραπεί σε λέξεις, βήμα το οποίο οδηγεί στην επίτευξη του αρχικού στόχου του lip reading.

### 5.3.1 Αλγοριθμική Πρόβλεψη Λέξεων

Σε εφαρμογές σε περιορισμένο περιβάλλον, όπου το λεξιλόγιο και, προαιρετικά, η γραμματική των φράσεων είναι γνωστά, είναι δυνατόν η πρόβλεψη των λέξεων από την αλληλουχία φωνημάτων να γίνει αλγοριθμικά και χωρίς τη χρήση τεχνητής νοημοσύνης. Για τα παρακάτω, υποθέτουμε (χωρίς βλάβη της

γενικότητας και για να γίνει πιο ξεκάθαρη η επεξήγηση της μεθόδου) ότι η ανάλυση γίνεται στο dataset GRID, όπως παρουσιάζεται στην παράγραφο 6.1.

Αρχικά, παράγεται το collapsed sequence φωνημάτων από την αλληλουχία των φωνημάτων που προβλέπεται, ενώνοντας γειτονικά ίδια tokens και απαλείφοντας τα blank tokens, δημιουργώντας μία ομάδα από φωνήματα και τους χρονισμούς τους. Έπειτα, χρησιμοποιείται αλγόριθμος δυναμικού προγραμματισμού ώστε να βρεθεί η τομή των φωνημάτων σε λέξεις και η ανάθεση των προβλεπόμενων λέξεων με το μικρότερο συνολικό κόστος.

Για κάθε υποψήφια λέξη σε κάθε θέση, υπολογίζεται μία τιμή ομοιότητας με την ακολουθία των φωνημάτων που προβλέπεται. Έστω  $O$  η πρόβλεψη και  $T$  η υποψήφια λέξη. Ορίζεται η βασική απόσταση ως  $D(O, T) = \frac{1}{\max(|O|, |T|)} \cdot ED(O, T)$ , όπου  $ED(O, T)$  είναι η ελάχιστη απόσταση edit της αλληλουχίας φωνημάτων  $O$  ώστε να φτάσει στην  $T$ . Κάθε φώνημα που πρέπει να αλλαχθεί δεν επηρεάζει με ίδιο τρόπο την  $ED(O, T)$ . Συγκεκριμένα, όμοια φωνήματα (είτε ακουστικά είτε οπτικά) τιμωρούνται λιγότερο σε σχέση με τελείως διαφορετικά φωνήματα. Το κόστος κάθε αλλαγής, από φώνημα  $a$  σε φώνημα  $b$ , υπολογίζεται ως εξής:

$$c(a, b) = \begin{cases} 0 & a = b \\ 0.15 & \text{ίδια κλάση viseme και ίδιος τρόπος/τόπος εκφοράς, αλλά διαφορετική φωνοποίηση} \\ 0.35 & \text{ίδια κλάση viseme αλλά όχι μόνο διαφορετική φωνοποίηση} \\ \min(1, \frac{\Delta(a,b)}{4}) & \text{αλλιώς, με διαφορά ιδιοτήτων } \Delta \\ 1 & \text{αν δεν υπάρχει καμία ίδια ιδιότητα} \end{cases}$$

Τότε, το τελικό σκορ ομοιότητας για κάθε υποψήφια λέξη είναι  $S(O, T) = D(O, T) - B_{anchor}(O, T) - 0.15B_{rare}(O, T)$ , όπου  $B_{anchor}$  είναι ένα ισχυρό bonus που δίνεται σε φωνήματα anchor και  $B_{rare}$  είναι ένα μικρότερο bonus για σπάνια φωνήματα. Τα φωνήματα anchor είναι φωνήματα που εμφανίζονται μόνο σε μία υποψήφια λέξη κάποιας κατηγορίας. Για παράδειγμα, στις προθέσεις του GRID, το φώνημα /ð/ με ήχο σαν το ελληνικό θήτα εμφανίζεται μόνο στη λέξη with και όχι σε οποιαδήποτε από τις in, by και at. Εάν δεν υπήρχε αυτός ο όρος, μία αλληλουχία φωνημάτων /i/ /ð/ θα οδηγούσε σε πρόβλεψη in και όχι σε πρόβλεψη with, που φαίνεται πιο αληθοφανές, δεδομένου ότι προβλέφθηκε το /ð/ που ανήκει μόνο σε μία λέξη. Με παρόμοιο τρόπο υπολογίζεται και το  $B_{rare}$ , αλλά πολλαπλασιάζεται με παράγοντα ανάλογο της σπανιότητας του εκάστοτε φωνήματος.

Με την παραπάνω μέθοδο, είναι δυνατόν να προβλεφθούν και λέξεις εντός του περιορισμένου περιβάλλοντος, πέραν των φωνημάτων. Ο αλγόριθμος αυτός σίγουρα μπορεί να αποτελέσει αντικείμενο βελτίωσης και καλύτερης προσαρμογής στο δεδομένο περιβάλλον στο οποίο γίνεται η κάθε μελέτη, ωστόσο κρίθηκε ότι η τωρινή εκδοχή του είναι αρκετή ώστε να επιδείξει ικανοποιητικά αποτελέσματα. Προφανώς, τα παραπάνω δεν μπορούν να εφαρμοστούν σε μη πεπερασμένο περιβάλλον, στο οποίο τόσο το λεξιλόγιο όσο και η γραμματική είναι σαφώς πιο ποικιλόμορφα, καθώς η λογική ιδιαίτερα του δυναμικού προγραμματισμού καταρρέει όσο αυξάνεται η πολυπλοκότητα των πιθανών λέξεων και της τοποθέτησής τους.

## 6 Αξιολόγηση της Μεθοδολογίας

### 6.1 Datasets

Για το πρώτο πείραμα, που περιλαμβάνει μία μελέτη αφαίρεσης (ablation study) και μία δοκιμή των αποτελεσμάτων του επιλεγμένου μοντέλου, χρησιμοποιήθηκε το GRID Audio-Visual Speech Corpus [1]. Πρόκειται για ένα από τα πιο ευρέως χρησιμοποιούμενα dataset στον τομέα της αντίληψης ομιλίας. Αποτελείται από εγγραφές ήχου και βίντεο (της περιοχής του προσώπου) για 1000 διαφορετικές φράσεις από 34 ομιλητές (18 αρσενικούς και 16 θηλυκούς), συνολικά 34000 προτάσεις.

Το συγκεκριμένο dataset αποτελεί παράδειγμα ενός περιορισμένου (constrained) περιβάλλοντος μάθησης, διότι οι φράσεις που καταγράφονται παρουσιάζουν μία πολύ συγκεκριμένη μορφή. Αποτελούνται από ένα ρήμα εντολής (bin, lay, place, set), έπειτα ένα χρώμα (blue, green, red, white), μία πρόθεση (at, by, in, with), ένα γράμμα (οποιοδήποτε από τα 26 του αγγλικού αλφαβήτου πέραν του w), ένα ψηφίο (από το 0 έως το 9) και τέλος ένα επίρρημα (again, now, please, soon). Έτσι, το λεξιλόγιο είναι πολύ περιορισμένο σε αντίθεση με ένα in the wild dataset, στο οποίο τόσο η σύνταξη των φράσεων όσο και το ίδιο το λεξιλόγιο παρουσιάζουν σαφώς υψηλότερη ποικιλομορφία.

Για τους σκοπούς της συγκεκριμένης μελέτης, η εκπαίδευση περιορίστηκε αποκλειστικά στα 1000 βίντεο του 1ου ηθοποιού (από το s1.zip). Κάθε .mpg βίντεο έχει μήκος 3 δευτερολέπτων, ρυθμό ανανέωσης frames 25fps, ανάλυση 360x288 pixels και στερεοφωνικό (δικαναλικό) ήχο με ρυθμό δειγματοληψίας 44.1kHz. Η βιντεοληψία γίνεται με τον ομιλητή να κοιτάει ευθεία προς την κάμερα με ουδέτερο παρασκήνιο. Τα βίντεο έχουν τίτλους που αποδίδουν τη φράση που λέγεται σε αυτά (π.χ. η φράση "bin green in t 5 soon" λέγεται στο βίντεο με τίτλο bgit5s.mpg), γεγονός που βοηθάει στην εξαγωγή των πραγματικών φωνημάτων (ground truth). Πέραν των βίντεο, το dataset περιλαμβάνει αρχεία ήχου και ένα αρχείο με ακριβείς χρονισμούς λέξεων για κάθε ομιλητή, τα οποία όμως δε χρησιμοποιούνται.

### 6.2 Κριτήρια Αξιολόγησης

Για την επακριβή αξιολόγηση της μεθοδολογίας και για τη σύγκριση με το state of the art, αποτελεί κρίσιμο βήμα η ορθή επιλογή και ο ακριβής ορισμός των μετρικών και των κριτηρίων αξιολόγησης. Σε όλα (ή κάποια) από τα παρακάτω πειράματα, η μεθοδολογία αξιολογείται με βάση τα παρακάτω κριτήρια:

- Γράφημα Training Loss vs Epoch: αποδίδει την τιμή της συνάρτησης κόστους στα δεδομένα του training split για κάθε epoch της εκπαίδευσης.
- Γράφημα Validation Loss vs Epoch: το ίδιο με παραπάνω αλλά στο validation split.
- Γράφημα Validation Token Error Rate (TER) vs Epoch: ποσοστό εσφαλμένης πρόβλεψης φωνήματος σε επίπεδο token (δηλαδή, στο collapsed sequence και όχι σε επίπεδο για κάθε frame του video) στο validation split για κάθε εποχή. Υπολογίζεται ως η απόσταση edit Levenshtein διά το μήκος αναφοράς.
- Γράφημα Validation Frame Accuracy vs Epoch: ποσοστό ορθών προβλέψεων φωνήματος σε επίπεδο video frame (πριν το sequence collapse) στο validation split για κάθε εποχή.
- Γράφημα Training Frame Accuracy vs Epoch: το ίδιο με παραπάνω αλλά στο training split.
- Area Under Curve (AUC): υπολογίζει την επιφάνεια κάτω από την καμπύλη (συνήθως της ακρίβειας στο validation set vs epoch), δίνοντας μία μετρική τόσο για την τελική ακρίβεια όσο και για την ταχύτητα σύγκλισης και για την αποφυγή ταλαντώσεων.
- Test Token Error Rate (TER): ποσοστό εσφαλμένων προβλέψεων φωνημάτων μετά το sequence collapse στο test set.
- Test Frame Accuracy: ποσοστό ακριβών προβλέψεων φωνημάτων σε επίπεδο frame, δηλαδή πριν το sequence collapse.

## 6.3 Πειράματα

Present a series of experiments, showcase and compare the results of each experiment to the state of the art and finally comment on each experiment. The following experiments are subject to change:

### 6.3.1 Πείραμα 1: Πρόβλεψη φωνημάτων από βουβό βίντεο σε περιορισμένο περιβάλλον

**Υποπείραμα 1: Μελέτη Αφαίρεσης** Για να απομονωθεί η συνεισφορά κάθε σχεδιαστικής επιλογής του μοντέλου, διεξήχθη μία μελέτη αφαίρεσης (ablation study) με 6 διαφορετικές εκδοχές του μοντέλου. Όλες οι εκδοχές αποτελούνται από ένα 3D CNN backbone, αξιολογήθηκαν στο ίδιο dataset με 32 κλάσεις φωνημάτων, εκπαιδεύτηκαν με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή  $3 \times 10^{-4}$  και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5. Η εκπαίδευση έγινε για μέγιστο αριθμό 40 εποχών με μηχανισμό early stopping με παράγοντα υπομονής 12 epochs στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο παρακάτω πίνακας παρουσιάζει τις 6 διαφορετικές εκδοχές που δοκιμάστηκαν.

Πίνακας 1: Οι εκδοχές του μοντέλου που δοκιμάστηκαν


| Εκδοχή    | Sequence Encoder      | Αντικειμενική Συνάρτηση | Targets του CE            |
|-----------|-----------------------|-------------------------|---------------------------|
| <b>V1</b> | 2 επίπεδα BiLSTM      | Frame-CE + CTC          | Viseme-aware soft targets |
| <b>V2</b> | 2 επίπεδα Transformer | Frame-CE + CTC          | Viseme-aware soft targets |
| <b>V3</b> | Projection head μόνο  | Frame-CE + CTC          | Viseme-aware soft targets |
| <b>V4</b> | 2 επίπεδα BiLSTM      | CTC μόνο                | N/A (χωρίς frame-CE)      |
| <b>V5</b> | 2 επίπεδα BiLSTM      | Frame-CE μόνο           | Viseme-aware soft targets |
| <b>V6</b> | 2 επίπεδα BiLSTM      | Frame-CE + CTC          | Hard (identity) targets   |

Στη συνέχεια παρουσιάζονται τα αποτελέσματα της μελέτης, πρώτα σε μορφή πίνακα και έπειτα με μερικά χαρακτηριστικά γραφήματα.


Να σημειωθεί ότι οι απόλυτες τιμές των τιμών της αντικειμενικής συνάρτησης στα σχήματα 9, 11 και 12 δεν είναι συγκρίσιμες. Συγκεκριμένα, τα μοντέλα με μόνο έναν από τους 2 όρους (είτε μόνο cross entropy είτε μόνο CTC) έχουν αντικειμενικές συναρτήσεις με μικρότερες τιμές σε απόλυτη τιμή, καθώς ο πολλαπλασιαστικός συντελεστής των δύο όρων παραμένει σταθερός. Τα σχήματα στο 13 ωστόσο, που παρουσιάζουν τη συνεισφορά κάθε όρου της αντικειμενικής συνάρτησης χωριστά, είναι απολύτως συγκρίσιμα. Σημαντικό, επίσης, είναι να παρατηρηθεί ότι το μοντέλο V6 παρουσιάζει τη χαμηλότερη τιμή training και validation loss ανάμεσα στα V1, V2, V3 και V6, χωρίς ωστόσο να πετυχαίνει και τη βέλτιστη επίδοση όσον αφορά το test TER. Αυτό οφείλεται στο ότι η χρήση soft targets στα μοντέλα V1, V2 και V3 μοιράζει την πιθανότητα κάθε φωνήματος σε διάφορες όμοιες (οπτικά ή ακουστικά) κλάσεις παράγοντας ένα target με υψηλότερη εντροπία και άρα οδηγώντας σε υψηλότερες τιμές cross entropy, σε σχέση με το one-hot encoding που χρησιμοποιείται για το μοντέλο V6.

Πίνακας 2: Περίληψη των αποτελεσμάτων της μελέτης αφαίρεσης


| Variant                      | Best Val TER  | Test TER      | Test Frame Acc. | AUC (Val 1 – TER) | Εποχές μέχρι Val TER < 0.20 |
|------------------------------|---------------|---------------|-----------------|-------------------|-----------------------------|
| V1 — BiLSTM + Full Loss      | <b>0.1251</b> | <b>0.1219</b> | <b>0.8474</b>   | <b>0.7840</b>     | <b>8</b>                    |
| V2 — Transformer + Full Loss | 0.1551        | 0.1566        | 0.8394          | 0.7176            | 16                          |
| V3 — Projection head μόνο    | 0.2540        | 0.2464        | 0.8122          | 0.6006            | Ποτέ                        |
| V4 — BiLSTM + CTC Only       | 0.1977        | 0.1869        | 0.4743          | 0.6005            | 33                          |
| V5 — BiLSTM + Frame-CE Μόνο  | 0.1555        | 0.1419        | 0.8401          | 0.7402            | 16                          |
| V6 — BiLSTM + Hard Targets   | 0.1266        | 0.1289        | 0.8456          | 0.7696            | 9                           |




Σχήμα 9: Γράφημα τιμών αντικειμενικής συνάρτησης στο training set για κάθε epoch




Σχήμα 10: Γράφημα τιμών frame accuracy στο training set για κάθε epoch




Σχήμα 11: Σύγκριση τιμών loss για training και validation κάθε μοντέλου




Σχήμα 12: Γράφημα τιμών αντικειμενικής συνάρτησης στο validation set για κάθε epoch




Σχήμα 13: Ανάλυση συνεισφοράς των όρων της αντικειμενικής συνάρτησης (CE και CTC)



Σχήμα 14: Γράφημα τιμών frame accuracy στο validation set για κάθε epoch



Σχήμα 15: Γράφημα τιμών TER στο validation set για κάθε epoch



Σχήμα 16: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Από τα παραπάνω εξάγεται το συμπέρασμα ότι το μοντέλο της μεθοδολογίας παρουσιάζει την ισχυρότερη επίδοση τόσο όσον αφορά την τελική απόδοση όσο και την ομαλότητα και αποδοτικότητα της εκπαίδευσης, γεγονότα που αποδεικνύονται από την υπεροχή του V1 στις μετρικές test TER, test frame accuracy και AUC. Στις επόμενες παραγράφους δίνεται μία αναλυτική σύγκριση κάθε εκδοχής με την V1, όπως και τα απαραίτητα σχόλια.

Όπως αποδεικνύει η σύγκριση μεταξύ V1 και V3, η σχεδιαστική επιλογή με το υψηλότερο αντίκρισμα στα αποτελέσματα είναι η παρουσία του χρονικού sequence encoder. Εν απουσία του BiLSTM και αξιοποιώντας μόνο ένα γραμμικό projection head, το μοντέλο V3 πετυχαίνει τελικά test TER 0.2464, υπερδιπλασιάζοντας αυτό του μοντέλου V1. Οι υπόλοιπες μετρικές (val TER, val frame accuracy, AUC) αποδεικνύουν επίσης την αναγκαιότητα χρήσης sequence encoder. Να σημειωθεί, ωστόσο, ότι μετρικές όπως το test frame accuracy, με τιμή 0.812, αποδεικνύουν ότι το μοντέλο πράγματι είναι ικανό να μάθει. Περιορίζεται, ωστόσο, από την έλλειψη της πληροφορίας παρακειμένου (contextual information), το οποίο είναι βασικό στοιχείο για την κατανόηση των φωνημάτων. Το context που προσφέρει η χρήση 3D CNN backbone δεν είναι τόσο πλούσιο όσο αυτό του συνδυασμού 3D CNN και BiLSTM.

Αντικαθιστώντας τα επίπεδα BiLSTM με Transformer ίδιου βάθους (V2), παρατηρούμε μία σημαντική επιδείνωση των αποτελεσμάτων, της τάξης περίπου του 25%. Η πορεία της εκπαίδευσης δείχνει μία πιο αργή βελτίωση του val TER στο V2 σε σχέση με το V1. Ένα ακόμα στοιχείο που αξίζει να σημειωθεί είναι ότι ο μηχανισμός scheduling του ρυθμού μάθησης ReduceLROnPlateau δε πυροδοτήθηκε κατά την εκπαίδευση του V2, ενώ προκλήθηκε 2 φορές κατά την εκπαίδευση του V1, αποδεικνύοντας ότι η σύγκλιση του V2 δεν έχει ακόμα ολοκληρωθεί κατά την 40η εποχή και ότι θα χρειαζόταν υψηλότερο υπολογιστικό κόστος εκπαίδευσης για να παρουσιάσει το V2 παρόμοια αποτελέσματα με αυτά του V1. Μία από τις κύριες αιτίες για τα αποτελέσματα του V2 είναι το μέγεθος του dataset που χρησιμοποιήθηκε, το οποίο περιλαμβάνει μόλις 700 φράσεις. Οι transformer encoders απαιτούν περισσότερα και πιο ποικιλόμορφα δεδομένα για να μάθουν αποδοτικά μοτίβα attention. Αντιθέτως, το inductive bias των BiLSTM

για χρονική εξάρτηση, ειδικά για γειτονικό context, λόγω της recurrent αρχιτεκτονικής τους, βρίσκει εύκολα εφαρμογή στην κίνηση των χειλιών, κατά την οποία γειτονικά frames αλληλεξαρτώνται σε υψηλό βαθμό.


Συγκρίνοντας τα μοντέλα V1 και V4, αναδεικνύεται η σημασία του όρου cross entropy της αντικειμενικής συνάρτησης. Το μοντέλο V4 πετυχαίνει στη μετρική test TER τιμή 0.1869, πάνω από 50% επιδεδειγμένη επίδοση σε σχέση με το V1. Η διαφορά των δύο μοντέλων γίνεται ιδιαίτερα προφανής με τη μετρική test frame accuracy, η οποία για το V4 είναι μόλις 0.4743, τιμή που ανταποκρίνεται με την τυχαία ανάθεση labels σε πρόβλημα ταξινόμησης με μία σαφώς επικρατέστερη κλάση, αυτήν του blank token (να μην εκφέρεται στο δεδομένο frame κάποιο φώνημα). Τα αποτελέσματα αυτά είναι αναμενόμενα: το σήμα του gradient, παραγόμενο αποκλειστικά μέσω του όρου CTC, οδηγεί το μοντέλο να μάθει να προβλέπει σωστές αλληλουχίες φωνημάτων αλλά όχι ποιες κινήσεις των χειλιών (και άρα ποια frames του βίντεο) παράγουν το οποιοδήποτε φώνημα. Έτσι, η διαφορά στο test TER δεν είναι τόσο μεγάλη όσο στο test frame accuracy.

Από την άλλη, αφαιρώντας τον όρο CTC και διατηρώντας μόνο τον όρο cross entropy της συνάρτησης κόστους (με το μοντέλο V5), επιτυγχάνεται τελικά test TER με τιμή 0.1419, ελαφρώς χειρότερα από το μοντέλο V1, τιμή που αποτελεί τη 3η καλύτερη στη συγκεκριμένη μετρική. Το σημαντικότερο πρόβλημα που αντιμετωπίζει η εκδοχή V5 είναι η ομαλότητα της εκπαίδευσης. Συγκεκριμένα, η καμπύλη validation TER vs epoch παρουσιάζει εμφανείς ταλαντώσεις και η σύγκλιση είναι πιο αργή σε σχέση με τα μοντέλα V1, V2 και V6. Ταυτόχρονα, το γράφημα val loss vs epoch παρουσιάζει στοιχεία overfitting, καθώς η τιμή αυξάνει μετά την 20η εποχή. Έτσι, εξάγεται το συμπέρασμα ότι ο όρος CTC συμβάλλει στην κανονικοποίηση του μοντέλου, προσθέτοντας τη συνθήκη ότι το τελικό σύνολο προβλέψεων φωνημάτων ανά frame θα πρέπει να καταρρέει σε μία λογική αλληλουχία φωνημάτων. Με αυτόν τον τρόπο βελτιώνεται η γενίκευση αλλά και η απόδοση του μοντέλου.


Τέλος, η διαφορά των μοντέλων V1 και V6 έγκειται στα targets του cross entropy της αντικειμενικής συνάρτησης: ενώ το V1 χρησιμοποιεί soft targets με βάση το πόσο όμοια είναι τα φωνήματα, ακουστικά ή οπτικά, το V6 χρησιμοποιεί τα συνήθη hard targets του cross entropy. Το μοντέλο V6 πετυχαίνει τη 2η καλύτερη τιμή test TER (0.1289), ενώ παρουσιάζει εικόνα εκπαίδευσης πολύ παρόμοια με αυτή του μοντέλου V1. Η ελάχιστη διαφορά των δύο εκδοχών φαίνεται να σημαίνει ότι η χρήση των soft targets παρέχει μικρό αλλά ίσως σταδιακά αυξανόμενο πλεονέκτημα με βάση το μέγεθος και την ποικιλομορφία του dataset. Όσο αυξάνεται η συχνότητα παρόμοιων φωνημάτων, τόσο ο μηχανισμός αυτός θα παρείχε περισσότερη ομαλότητα κατά την εκπαίδευση, προστατεύοντας το μοντέλο από θόρυβο labelling σε αμφίβολες περιπτώσεις. Στο μικρό και περιορισμένο dataset που χρησιμοποιείται στο πείραμα αυτό, είναι πιο εύκολο να “αποστηθίσει” το μοντέλο αλληλουχίες φωνημάτων (άρα λέξεων, π.χ. να μάθει ότι το φώνημα /b/ βρίσκεται πριν το φώνημα /i/ για να δημιουργηθεί η λέξη “bin”, και όχι τα οπτικά πανομοιότυπα φωνήματα /p/ ή /m/), σε αντίθεση με ένα ευρύτερο in the wild dataset (στο οποίο κάλλιστα θα μπορούσε να περιέχεται και η λέξη “rin” και άρα να πρέπει να προβλεφθεί το /p/ και όχι το /b/).

**Υποπείραμα 2: Δοκιμή του επιλεγμένου μοντέλου σε περιορισμένο περιβάλλον** Έχοντας καταλήξει στην τελική και βέλτιστη μορφή του μοντέλου και έχοντας επεξηγήσει τη συνεισφορά κάθε σχεδιαστικής επιλογής στο τελικό αποτέλεσμα, ο πειραματισμός συνεχίζεται με μία δοκιμή σε μεγαλύτερο βάθος στο ίδιο dataset (GRID Audio-Visual Speech Corpus). Συγκεκριμένα, πέραν της πρόβλεψης των φωνημάτων, η ανάλυση προχωρά και σε πρόβλεψη λέξεων με γνώση του περιορισμένου περιβάλλοντος της μελέτης, προσομοιώνοντας έτσι ένα σύστημα με πιο πραγματική εφαρμογή.


Η εκπαίδευση έγινε πάλι με AdamW optimiser με χρήση γραμμικού learning rate warmup για τις πρώτες 5 εποχές μέχρι την τιμή  $3 \times 10^{-4}$  και scheduling ReduceLROnPlateau με τιμή patience 6 epochs και παράγοντα μείωσης 0.5, στη μονάδα Ampere της Υπερυπολογιστικής Συστοιχίας “Αριστοτέλης”. Ο μέγιστος αριθμός εποχών αυξήθηκε σε 60, διατηρώντας τον μηχανισμό early stopping με παράγοντα υπομονής 12 epochs. Παρακάτω παρουσιάζονται τα αποτελέσματα του συγκεκριμένου πειράματος:




Σχήμα 17: Γράφημα τιμών του train loss και του κάθε συντελεστή αυτού για κάθε epoch



Σχήμα 18: Γράφημα τιμών του validation loss για κάθε epoch



Σχήμα 19: Γράφημα τιμών του validation TER για κάθε epoch




Σχήμα 20: Γράφημα τιμών του ρυθμού μάθησης (learning rate) για κάθε epoch

Αρχικά, να σημειωθεί ότι στο σχήμα 17, ο συντελεστής CTC της συνάρτησης κόστους παρουσιάζεται πριν τον πολλαπλασιασμό του με τον κατάλληλο συντελεστή, άρα για κάθε epoch (όπως είναι προφανές από το σχήμα), δεν ισχύει  $total\_loss = frame\_ce\_loss + ctc\_loss$ , αλλά  $total\_loss = frame\_ce\_loss + 0.3 \times ctc\_loss$ .

Παρατηρείται ομαλή εκπαίδευση που τελικά οδηγεί σε βέλτιστη τιμή validation loss 1.027 όπως και βέλτιστη τιμή validation TER 0.1273, με τον μηχανισμό early stopping να πυροδοτείται κατά την εποχή 50. Όπως ήταν και αναμενόμενο, τα αποτελέσματα είναι πολύ παρόμοια με αυτά του μοντέλου V1 της μελέτης αφαίρεσης. Οι μικροδιαφορές οφείλονται σε ελάχιστες διαφοροποιήσεις κατά την εκτέλεση των εκπαιδεύσεων και όχι σε κάποια αρχιτεκτονική παράλειψη.

Στο test set, το μοντέλο πετυχαίνει τιμή  $frame\_ce\_loss = 0.8626$ ,  $ctc\_loss = 0.461$ ,  $total\_loss = 1.0009$  και  $ter = 0.1241$ . Παρακάτω παρουσιάζεται ο πίνακας σύγχυσης (confusion matrix) των φωνημάτων που προβλέφθηκαν από το μοντέλο σε σχέση με τα πραγματικά (ground truth).



Σχήμα 21: Πίνακας σύγχυσης (confusion matrix) στο test set

Ο πίνακας σύγχυσης παρουσιάζει ισχυρή προβλεπτική ικανότητα, με την κύρια διαγώνιο (το σύνολο

των σωστών προβλέψεων) να κυριαρχεί σε σχέση με τον υπόλοιπο πίνακα. Οι κύριες πηγές προβληματισμού είναι η τελευταία σειρά “<inserted>”, η οποία αποτελείται από περιπτώσεις που ένα φώνημα προβλέφθηκε λανθασμένα στη θέση του blank token και η τελευταία στήλη “<missed>” που περιγράφει το αντίστροφο φαινόμενο, όταν δηλαδή δεν προβλέπεται κάποιο φώνημα που όντως υπάρχει αλλά στη θέση του προβλέπεται το blank token. Συγχύσεις όμοιων οπτικά φωνημάτων (π.χ. /d/ και /t/) υπάρχουν αλλά σε ελάχιστο βαθμό, γεγονός που εξηγείται από την περιορισμένη φύση του dataset: το μοντέλο μαθαίνει ότι το dataset αποτελείται από συγκεκριμένες λέξεις και προσαρμόζεται ανάλογα.

Σε συνέχεια των παραπάνω και εκμεταλλευόμενοι τον περιορισμό των λέξεων που χρησιμοποιούνται στο dataset, αναπτύχθηκε ένα script πρόβλεψης φράσεων από την αλληλουχία φωνημάτων. Το script αυτό έχει πλήρη γνώση τόσο του λεξιλογίου του dataset όσο και της γραμματικής που παρουσιάζουν οι φράσεις (θεωρείται γνωστό, δηλαδή, ότι οι φράσεις είναι της μορφής εντολή, χρώμα, πρόθεση, γράμμα, ψηφίο, επίρρημα, όπως και ποιες είναι οι πιθανές λέξεις για κάθε μία από αυτές της κατηγορίες). Με βάση την προφορά του ηθοποιού, δημιουργείται ένα λεξικό που αντιστοιχίζει αλληλουχίες φωνημάτων σε λέξεις. Ο αλγόριθμος που αναπτύχθηκε περιγράφεται με περρισσότερη λεπτομέρεια στην ενότητα (ρεφ).

Η χρήση του παραπάνω script στις προβλέψεις του βέλτιστου μοντέλου πετυχαίνει ορθή πρόβλεψη σε επίπεδο λέξης για 87.1% των λέξεων του test set και ακριβή πρόβλεψη σε επίπεδο πρότασης σε ποσοστό 38%. Το κύριο πρόβλημα είναι η πρόβλεψη στην ομάδα των γραμμάτων: μόλις 46% των γραμμάτων προβλέπονται σωστά. Αυτό οφείλεται τόσο στο μέγεθος της ομάδας αυτής (25 υποψήφιες λέξεις έναντι 4 σε άλλες κατηγορίες), όπως και στο μέγεθος της αλληλουχίας των φωνημάτων που αποτελούν ένα γράμμα (συνήθως είναι λιγότερα και άρα η πρόβλεψη είναι πιο επιρρεπής στον θόρυβο). Η υπόθεση αυτή ενισχύεται από την κατηγορία των προθέσεων, η οποία εμφανίζει το δεύτερο χαμηλότερο ποσοστό ορθής πρόβλεψης με 85.3%. Αντιθέτως, στις ομάδες με μεγαλύτερες λέξεις ή με λέξεις που απαρτίζονται από πιο χαρακτηριστικά φωνήματα, η πρόβλεψη ήταν ιδιαίτερα ακριβής: 98% στις εντολές, 99.3% στα χρώματα, 95.3% στα ψηφία και 98.7% στα επιρρήματα. Τα ποσοστά αυτά είναι εξαιρετικά και αποδεικνύουν ότι οι προβλέψεις τόσο σε επίπεδο φωνήματος από το μοντέλο όσο και σε επίπεδο λέξης από τον αλγόριθμο είναι ιδιαίτερα ικανές στο περιορισμένο περιβάλλον.

Για να κριθεί ο χρονισμός (timing) της πρόβλεψης και όχι μόνο η ορθότητα του περιεχομένου, χρησιμοποιήθηκε το ffmpeg ώστε να υποτιτλιστούν μερικά από τα video του test set με τις λέξεις που προβλέπονται στον χρόνο που προβλέπονται τα φωνήματα τα οποία παράγουν τις λέξεις. Η διαδικασία αυτή δεν μπορεί να παρουσιαστεί στο πλαίσιο της συγκεκριμένης αναφοράς, παρουσιάζει ωστόσο ιδιαίτερα ακριβή αποτελέσματα, ειδικά, φυσικά, όταν η πρόβλεψη ολόκληρης της φράσης είναι σωστή.

### **6.3.2 Πείραμα 2: Πρόβλεψη φωνημάτων από βουβό βίντεο σε μη περιορισμένο (in the wild) περιβάλλον**

### **6.3.3 Πείραμα 3: Πρόβλεψη φωνημάτων με συνδυασμό οπτικών και ακουστικών στοιχείων**

## **7 Συμπεράσματα και Μελλοντικές Επεκτάσεις**

What have I understood from this project? What can I improve in the future?

## 8 Αναφορές

- [1] Martin Cooke, Jon Barker, Stuart Cunningham, and Xu Shao. The Grid Audio-Visual Speech Corpus, January 2006.
- [2] Marshall Thomas, Edward Fish, and Richard Bowden. VALLR: Visual ASR Language Model for Lip Reading, 2026.